稳定训练

从批量选择到提前停止

第二批验收样章

本批详细核查 12 张训练主题原图，以独立绘图和表格重新组织。接续第一批，解释小批量、动量、Adam、初始化、Dropout 与提前停止。本文件仅包含第二批样章；全书仍在分批修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第二章　让训练稳定下来：批量、优化与正则化 **1**

2.1　样本、批量、更新次数与轮次 1

2.2　小批量 SGD：用部分数据估计梯度 2

2.3　动量：给更新方向加上记忆 3

2.4　RMSprop 与 Adam：按坐标调整更新 4

2.5　手算 Adam 的两步更新 5

2.6　梯度消失：链条越长，乘积可能越小 6

2.7　初始化：打破对称，并控制传播量级 7

2.8　Dropout：训练时加噪声，评估时关掉 8

2.9　提前停止：保存最优记录，再耐心等待 9

2.10　把这些组件放回训练流程 10

2.11　一页速查与自测 11

第二章　让训练稳定下来：批量、优化与正则化

知道怎样计算一次梯度，还不足以完成可靠训练。训练时要决定每步使用多少数据、怎样利用梯度、参数从哪里开始，以及何时停止。本章接着前向与反向传播的基础，把这些选择放回同一条训练流程。

> **先分清三类问题**
>
> **训练算不动**：检查数据、梯度、初始化和学习率。**训练算得慢**：检查批量与优化器。**训练很好，验证不好**：检查数据划分与泄漏，再考虑正则化和停止时刻。不同问题可以同时出现，一个技巧不能替代整套诊断。

2.1　样本、批量、更新次数与轮次

批量大小（Batch Size）是一次计算所用的样本数；一次优化器更新称为一步（Step）。训练轮次（Epoch）通常表示将整个训练集遍历一次。**一个 epoch 通常包含很多步，不能把两者混为同一个计数。**

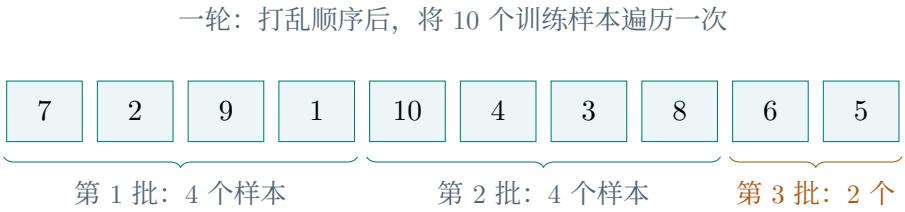


图 2.1：训练集有 10 个样本，批量大小为 4，不丢弃最后一批时，一轮包含 3 个批量。数字是样本编号。

读图：本轮先打乱样本顺序，再依次取出 4、4、2 个样本。若每个批量更新一次参数，完整一轮就更新 3 次。下一轮可重新打乱顺序，避免固定顺序持续影响更新。

设训练样本数为 n，批量大小为 B，在**单份数据遍历、每批更新一次、保留末批**的设置下，每轮更新次数为

$$S = \left\lceil \frac{n}{B} \right\rceil .$$

本例训练 5 轮共更新 $5 \times 3 = 15$ 次，而不是 5 次。若丢弃最后不足一批的数据，则每轮批数变成 $\lfloor n/B \rfloor$，也不再保证每个样本都被遍历。

> **这条计数公式有适用范围**
>
> 梯度累积、分布式采样、重复抽样和无限数据流会改变“批量—更新—轮次”的关系。例如先累积两个批量的梯度再更新一次，就不能再把批数直接当作更新次数。批量大小也没有通用的最佳值，应结合显存、吞吐量和验证效果选择。

2.2 小批量 SGD：用部分数据估计梯度

记单样本损失为 $\ell_i(\theta)$，未加正则化的训练目标为 $J(\theta) = n^{-1}\sum_i \ell_i(\theta)$。全批量梯度下降每步使用所有样本；小批量随机梯度下降（Minibatch Stochastic Gradient Descent, Minibatch SGD）改用一小批样本：

$$\boldsymbol{g}_t = \frac{1}{|\mathcal{B}_t|}\sum_{i\in\mathcal{B}_t}\nabla\ell_i(\theta_t), \qquad \theta_{t+1} = \theta_t - \eta_t\boldsymbol{g}_t. \tag{2.1}$$

$\mathcal{B}_t$ 是当前批次的样本索引集合，$|\mathcal{B}_t|$ 是本批实际大小，$\eta_t > 0$ 为学习率。最后不足一批时，也应按其实际大小求平均。严格说，单样本 SGD 取 $B = 1$；实践中“SGD”也常泛指小批量版本。

2.2.1 一个能手算的梯度估计

设只有一个参数 θ，三个目标值为 $y_1 = 0, y_2 = 2, y_3 = 4$，单样本损失 $\ell_i(\theta) = \frac{1}{2}(\theta - y_i)^2$。固定 $\theta = 0$，可得：

样本目标	单样本梯度 $\theta - y_i$	学习率 0.1 时的下一步参数
0	0	0
2	-2	0.2
4	-4	0.4

全体平均梯度为 -2，全批量一步会得到 $\theta' = 0.2$。若均匀选取一个样本，三个候选梯度的平均同样是 -2；若均匀选两个不同样本，三种候选批量的平均梯度分别是 $-1, -2, -3$，其平均仍是 -2。本例后者的梯度估计方差更小，但一次计算也更贵。

> **平均方向有用，不代表每一步都下降**
>
> 对固定参数均匀抽样，批量平均梯度的期望等于整体梯度。具体一次抽到的梯度可能偏离整体方向，因此小批量损失或整体训练损失都可能短暂上升。每轮不放回随机重排与每步独立抽样的随机过程不同，不能不加条件地套用相同的独立性假设。

记住：比较批量大小时，要同时关注更新次数、处理的样本数与实际耗时，不能只比较 epoch 数。

2.3 动量：给更新方向加上记忆

普通 SGD 只看当前梯度；动量法（Momentum）还保留过去的方向。本书采用以下一种常见约定，初始 $\boldsymbol{v}_0 = 0$：

$$\boldsymbol{v}_t = \beta \boldsymbol{v}_{t-1} + \boldsymbol{g}_t, \qquad \theta_t = \theta_{t-1} - \eta \boldsymbol{v}_t, \quad 0 \le \beta < 1. \tag{2.2}$$

这里 $\boldsymbol{g}_t$ 在更新前的 θ_{t-1} 计算。持续同向的梯度会累积；相互抵消的梯度对历史方向的贡献较弱。另一些资料把当前梯度乘上 $1-\beta$，对应的学习率解释也会变化，比较公式时须先核对约定。

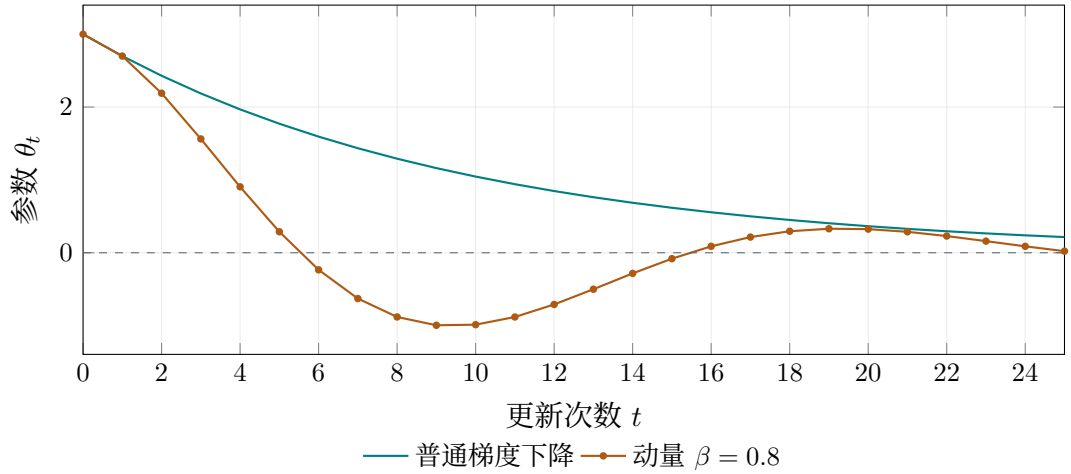


图 2.2： 对 $J(\theta) = \theta^2/2$ 的真实递推轨迹：$\theta_0 = 3$、学习率 0.1、动量初值 0。

读图： 两种方法第一步都到 2.7。第二步，普通梯度下降到 2.43；动量累积值为 $0.8 \times 3 + 2.7 = 5.1$，参数到 2.19。橙线更早接近 0，也越过 0 并振荡；动量可以加快某些方向上的移动，但也可能造成过冲。

> **容易混淆**
>
> 不能把“带动量”理解为一定跳出局部极小值，或一定比普通 SGD 更快。效果取决于目标形状、学习率和动量系数。学习率过大时，带动量的更新仍可能不稳定。图中的比较仅针对给定二次函数与参数设置。

记住： 先明确动量的定义，再调整学习率与 β。梯度历史本身也是优化器状态，不属于网络权重。

2.4 RMSprop 与 Adam：按坐标调整更新

不同参数坐标的梯度量级可能差别很大。RMSprop 用梯度平方的指数滑动平均估计近期量级，再按坐标缩放更新。Adam（Adaptive Moment Estimation，自适应矩估计）同时平滑有符号梯度和梯度平方。

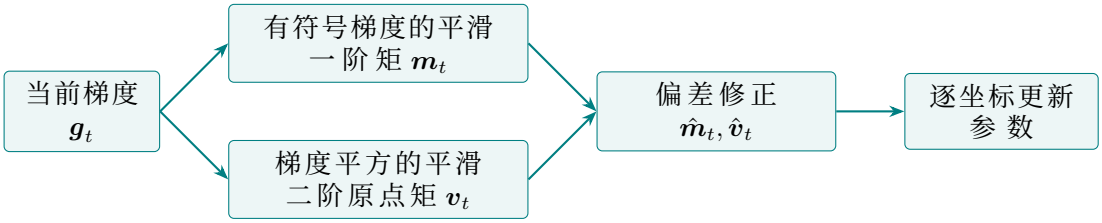


图 2.3: Adam 的两条统计分支。平方和开方均为逐元素运算，二阶原点矩不是中心方差。

读图：上方分支保留方向信息，下方分支反映梯度的平方量级。两者先修正零初始化带来的早期缩小效应，再组合成参数更新。分母通常使近期梯度平方较大的坐标相对少走一些。

对无权重衰减的基本 Adam，令 $\boldsymbol{m}_0 = \boldsymbol{v}_0 = 0$，$t = 1, 2, \ldots$：

$$\boldsymbol{m}_t = \beta_1 \boldsymbol{m}_{t-1} + (1-\beta_1)\boldsymbol{g}_t, \tag{2.3}$$

$$\boldsymbol{v}_t = \beta_2 \boldsymbol{v}_{t-1} + (1-\beta_2)(\boldsymbol{g}_t \odot \boldsymbol{g}_t), \tag{2.4}$$

$$\hat{\boldsymbol{m}}_t = \frac{\boldsymbol{m}_t}{1-\beta_1^t}, \qquad \hat{\boldsymbol{v}}_t = \frac{\boldsymbol{v}_t}{1-\beta_2^t}, \tag{2.5}$$

$$\theta_t = \theta_{t-1} - \eta \, \frac{\hat{\boldsymbol{m}}_t}{\sqrt{\hat{\boldsymbol{v}}_t} + \epsilon}. \tag{2.6}$$

其中 $\beta_1, \beta_2 \in [0, 1)$ 是平滑系数，$\epsilon > 0$ 用于数值稳定；最后一式的除法也逐元素进行。偏差修正补偿指数平均的初始权重和，不表示对任意非平稳梯度过程都获得无偏估计。

> **优化器选择的边界**
>
> SGD、带动量 SGD、RMSprop 与 Adam 都需要选择学习率。Adam 的“自适应”不代表不需要调参，也不保证泛化优于 SGD。AdamW 还改变了权重衰减的处理方式，不能只凭名字把它与基本 Adam 完全等同。

2.5 手算 Adam 的两步更新

用一个参数看清偏差修正与历史记忆。设 $\theta_0 = 1, m_0 = v_0 = 0, \eta = 0.1, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$。为单独检验更新规则，**人为给定**两次输入梯度为 $g_1 = 2$、$g_2 = -1$；不把这组输入当作某项真实实验的测量结果。

2.5.1 第一步：先平均，再修正

$$
\begin{aligned}
m_1 &= 0.1 \times 2 = 0.2, & v_1 &= 0.001 \times 2^2 = 0.004,\\
\hat{m}_1 &= 0.2/(1-0.9) = 2, & \hat{v}_1 &= 0.004/(1-0.999) = 4,\\
\theta_1 &= 1 - 0.1\frac{2}{\sqrt{4}+10^{-8}} \approx 0.900000.
\end{aligned}
$$

若只看未修正的 m_1 和 v_1，数值大小受到零初始化的明显影响。修正后的第一步基本相当于按梯度符号走一个学习率长度，前提是梯度非零且 ϵ 可忽略。

2.5.2 第二步：新梯度已经反向，历史仍然存在

$$
\begin{aligned}
m_2 &= 0.9 \times 0.2 + 0.1 \times (-1) = 0.08,\\
v_2 &= 0.999 \times 0.004 + 0.001 \times (-1)^2 = 0.004996,\\
\hat{m}_2 &= 0.08/(1-0.9^2) \approx 0.421053,\\
\hat{v}_2 &= 0.004996/(1-0.999^2) \approx 2.499250,\\
\theta_2 &= \theta_1 - 0.1\frac{\hat{m}_2}{\sqrt{\hat{v}_2}+10^{-8}} \approx 0.873366.
\end{aligned}
$$

当前梯度 g_2 虽为负，历史平均 m_2 仍为正，因此参数这一步继续减小。Adam 不是每一步都沿当前负梯度方向更新，这也解释了为什么不能仅由当前梯度符号判断实际移动方向。

> **续训时只恢复权重够不够?**
>
> 若要接着同一次优化过程继续训练，通常还需恢复优化器的一阶矩、二阶矩、步数，以及学习率调度等相关状态。只恢复网络权重后重新创建 Adam，会改变后续更新轨迹。若只是做最终预测，则不需要这些优化器状态。

2.6 梯度消失：链条越长，乘积可能越小

反向传播连续应用链式法则。若一条标量计算链上每个局部导数都是 q，长度为 L 时，总导数是 q^L。这给出了梯度消失（Vanishing Gradient）的一个最简单例子。

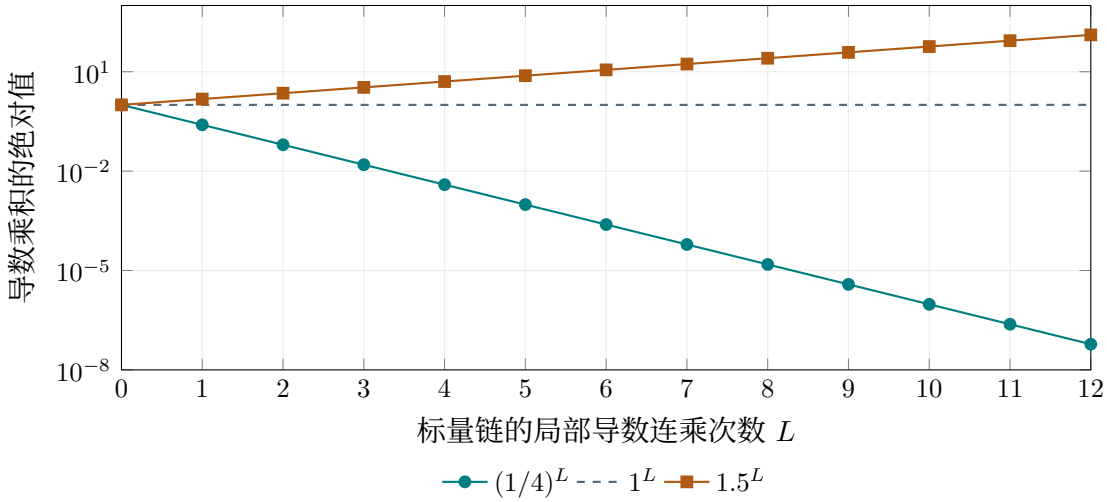


图 2.4: 标量链的导数连乘示例。纵轴为对数刻度；该图不代表任意实际网络的梯度曲线。

读图：当每一项只有 1/4 时，乘 10 次约为 9.54×10^{-7}；乘积很快变小。每项为 1 时量级不变；每项为 1.5 时则越来越大，提示梯度爆炸的另一种可能。纵轴每下降一个十进数量级，数值就缩小 10 倍。

真实网络的反传还包含**权重矩阵、激活导数、不同路径的求和**，不是只把激活导数相乘。图中保留的是链式法则的直觉，不能从 Sigmoid 导数不超过 1/4 直接推出所有深层网络的参数梯度都按 $(1/4)^L$ 衰减。

2.6.1 怎样判断与缓解

早期层的梯度长期极小、参数几乎不变，可能提示梯度消失；但学习率过小、错误的梯度连接或数据问题也会造成训练停滞。应先核对计算与数据，再观察各层梯度量级。合适的激活、初始化和网络连接设计有助于稳定传播；后续架构中的残差连接也与此有关。

> **两个常见误解**
>
> ReLU 正半轴的局部导数为 1，并不保证整个网络梯度稳定；权重连乘仍会影响量级。梯度裁剪通常用来限制过大的梯度，不能把已经消失的梯度恢复出来。

记住：训练不动时，同时检查梯度是否存在、数值是否有限、量级是否合理，以及优化器是否实际执行更新。

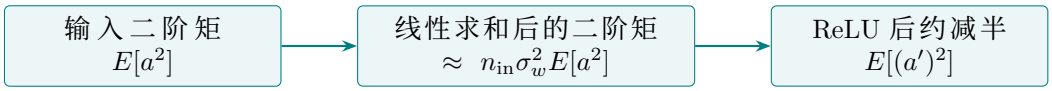
2.7 初始化：打破对称，并控制传播量级

初始化（Initialization）是选择训练的起点，不是预先找到损失的最小值。若一个隐藏层中对称位置的单元采用完全相同的权重，且其它条件保持对称，它们可能得到相同输出和梯度，一直学习重复的特征。因此权重通常随机初始化；偏置常可从 0 开始。

2.7.1 先分清输入数、输出数与分布参数

对 $W \in \mathbb{R}^{n_{\text{out}} \times n_{\text{in}}}$，$n_{\text{in}}$ 是每个单元接收的输入数（fan-in），n_{out} 是本层输出单元数（fan-out），两者都不是网络的层数。下面列出两种常见设置：

方法	单个权重的分布	主要考虑
Xavier 均匀	$U(-a, a),\ a = \sqrt{6/(n_{\text{in}} + n_{\text{out}})}$	增益为 1 时，折中前向与反向量级
He 正态	$N(0, \sigma_w^2),\ \sigma_w^2 = 2/n_{\text{in}}$	用于 ReLU 的常见 fan-in 设置



He 初始化：令 $n_{\text{in}}\sigma_w^2/2 \approx 1$，保持二阶矩的量级

图 2.5: He 初始化的量级直觉：在独立、零均值权重等近似条件下，补偿 ReLU 对二阶矩的缩减。

读图：若 $z = \sum_j w_j a_j$，在相应独立性和均值假设下，$E[z^2] \approx n_{\text{in}}\sigma_w^2 E[a^2]$。若 z 的分布关于 0 对称，ReLU 把二阶矩约减半，于是令 $\sigma_w^2 = 2/n_{\text{in}}$ 可使经过一层后的二阶矩大致保持量级。ReLU 输出均值一般不为 0，所以这里使用二阶矩，而不把它无条件称作中心方差。

例如 $n_{\text{in}} = 100$、$n_{\text{out}} = 50$ 时，Xavier 均匀的界限为 $a = 0.2$；He 正态的**方差**为 0.02，**标准差**约为 0.141421。不能把方差直接当作正态采样接口要求的标准差。

> **容易混淆**
>
> Xavier 可与不同激活的增益配合；He 也有 fan-out 等变体。表中仅列明示条件下的常见形式，不是所有结构的唯一规则。初始化控制起始量级，不能保证整段训练始终稳定。

2.8 Dropout：训练时加噪声，评估时关掉

随机失活（Dropout）是一种正则化方法：训练时随机屏蔽一部分激活，减少网络对特定单元组合的依赖。本节采用常见的反向缩放 Dropout（Inverted Dropout）。记丢弃概率为 $p \in [0,1)$、保留概率为 $q = 1 - p$，则

$$\tilde{\boldsymbol{a}} = \frac{\boldsymbol{m} \odot \boldsymbol{a}}{q}, \qquad m_j \sim \text{Bernoulli}(q). \tag{2.7}$$

普通逐元素 Dropout 对各位置独立采样掩码。屏蔽改变当前计算，不会永久删除参数或改变层的宽度。

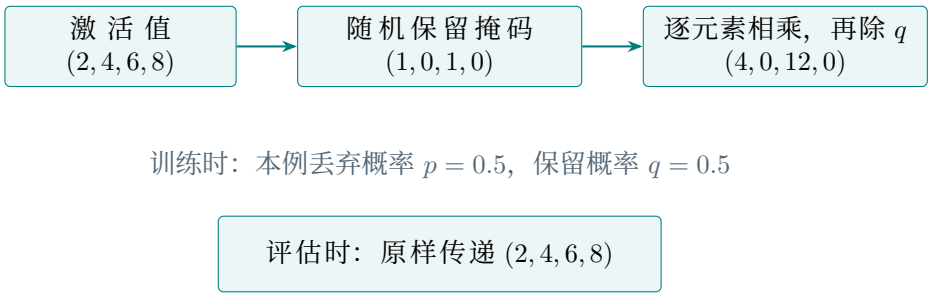


图 2.6: 一个具体掩码的效果。训练时保留值放大 $1/q$ 倍；标准评估时使用恒等映射。

读图：本例保留第 1、3 个激活，屏蔽第 2、4 个，保留值乘 2。这是一次随机采样，不表示每次一定恰好保留一半。评估时不再随机屏蔽，也不再重复做训练时的 $1/q$ 缩放。

对固定输入激活，$E[m_j] = q$，因此

$$E[\tilde{a}_j \mid a_j] = a_j, \qquad \text{Var}(\tilde{a}_j \mid a_j) = \frac{p}{q} a_j^2.$$

缩放保持的是**该激活的条件期望**，不是保证整个非线性网络的输出等于所有随机子网络输出的精确平均。“训练许多共享参数的子网络”是一种理解方式，并非逐个独立训练或枚举所有子网络。

> **容易混淆**
>
> 丢弃概率过高可能导致欠拟合或优化困难；Dropout 也不保证验证效果改善。训练和验证时必须使用正确模式。若验证仍在随机丢弃，指标会额外波动；若在训练时提前关闭，则没有执行预期的正则化。

2.9 提前停止：保存最优记录，再耐心等待

提前停止（Early Stopping）根据验证表现选择训练时长。验证指标可能波动，所以通常不会仅因某一轮上升就立刻停止。应事先规定监控指标、改进阈值、耐心轮数和最大轮数，并保存最佳检查点。

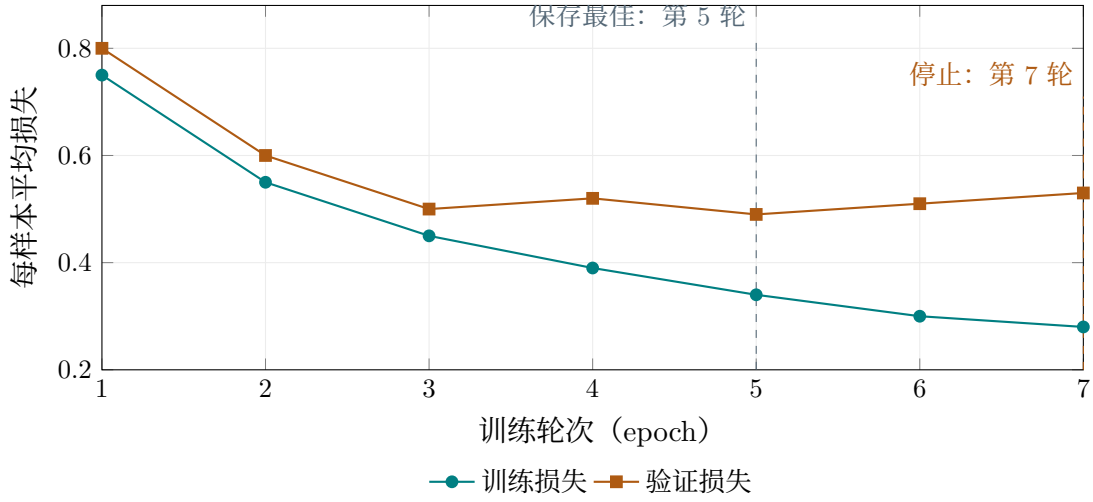


图 2.7: 人为设定的损失序列，用于说明规则：监控验证损失，阈值为 0，patience 为 2。不是实验测量结果。

读图：第 4 轮验证损失从 0.50 升到 0.52，暂记一次未改进；第 5 轮降到 0.49，刷新最佳记录并把等待计数归零。第 6、7 轮连续未改进，到第 7 轮停止，最后恢复第 5 轮的权重。

本例明确采用：验证损失 $V_t < V_{\text{best}} - \delta$ 才算改进；否则计数加 1。连续未改进次数达到 P 就停止。δ 是最小改进量（min-delta），P 是耐心轮数（patience），本例分别为 0 和 2。

轮次	验证损失	最佳轮次	连续未改进数
3	0.50	3	0
4	0.52	3	1
5	0.49	5	0
6	0.51	5	1
7	0.53	5	2：停止

提前停止本身也是模型选择

最佳轮次不是总体泛化风险的已知最优点，而是当前验证规则选出的检查点。patience、阈值和监控指标仍需选择，反复尝试也可能过拟合验证集。最终测试集留到方案确定后评估，不用它决定停止时刻。

2.10 把这些组件放回训练流程

训练和评估不是只差“是否计算梯度”。有些层在不同模式下具有不同计算行为，Dropout就是本章的例子。因此，**切换评估模式**与**关闭梯度记录**应分开理解。

环节	训练阶段	标准验证/预测阶段
使用哪些数据	训练集各小批量	验证集或最终测试集
Dropout	随机掩码与 $1/q$ 缩放	恒等传递
梯度与更新	对训练目标反传，执行优化器更新	通常关闭梯度记录，不更新参数
记录什么	每样本平均训练损失等	固定评估口径下的损失和指标
影响哪些选择	拟合模型参数	验证选方案；测试做最终评估

2.10.1 一轮可执行的检查顺序

1. 开始训练前，只用训练数据拟合预处理，并初始化网络与优化器状态。
2. 每轮打乱训练样本；对每批先清理上一批梯度，再前向、求损失、反传、更新。
3. 一轮结束后，切到评估模式，关闭不需要的梯度记录，遍历验证集。
4. 按**样本数**汇总损失，应用提前停止规则，必要时保存最佳权重。
5. 继续下一轮前切回训练模式；结束后恢复所选检查点，再做最终测试。

若三批分别有 4、4、2 个样本，批内平均损失分别为 0.2、0.4、0.8，全体每样本平均损失应为

$$\frac{4\times 0.2+4\times 0.4+2\times 0.8}{10}=0.4,$$

不能直接把三个批平均再等权平均，得到约 0.467。

训练曲线与验证曲线要有可比口径

启用 Dropout 等噪声或数据增强时，训练阶段的预测本来就更难；正则化项也可能只计入训练目标。因此“验证损失低于训练损失”不必然是错误，二者的差也不能直接全部归因于过拟合。诊断时可在统一评估模式、相同损失定义下额外比较。

2.11 一页速查与自测

遇到的问题	先检查什么
epoch 与 step 对不上	是否保留末批、累积梯度或重复采样。
小批量损失上下波动	抽样噪声、批量大小、学习率；单次上升不等于训练失败。
动量移动过头	学习率与动量系数，不把惯性当作收敛保证。
Adam 续训轨迹变了	是否同时恢复矩估计、步数和调度状态。
早期层几乎不更新	梯度连接、梯度量级、初始化、激活与学习率。
Dropout 评估不稳定	是否关掉标准评估时的随机丢弃。
停止后效果反而差	是否恢复最佳轮次，而不是保留最后一轮。
批量汇总指标不准确	是否按样本数加权，尤其是最后一个小批量。

2.11.1 三个自测问题

1. 有 103 个样本，批量 32，保留末批且每批更新一次。5 轮共更新多少次?
2. Inverted Dropout 的丢弃概率为 0.25。某个激活值 3 被保留时，输出是多少?
3. 验证损失依次为 0.8、0.6、0.61、0.59、0.60、0.62，按本章规则 $\delta = 0, P = 2$，何时停止并恢复哪一轮?

参考答案：（1）$5\lceil 103/32 \rceil = 20$ 次。（2）$3/(1 - 0.25) = 4$。（3）第 6 轮停止，恢复第 4 轮。

2.11.2 进一步查阅

- PyTorch 文档：Adam、初始化、Dropout，用于核对常见公式和模式约定。
- Keras 文档：EarlyStopping，用于核对监控、耐心轮数与恢复最佳权重的配置含义。