机器学习与深度学习：图解速查手册

可信评估

从数据划分到指标选择

第三批阶段样章

本批详细核查 15 张评估主题原图，统一纠正指标定义、数据用途和边界条件。以独立图表替换原插图，给出混淆矩阵、ROC/AUC 和回归的可复算例子。本文件是阶段成果；全书仍在连续修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第三章　可信评估：从数据划分到指标选择 **1**

3.1　训练、验证与测试各自负责什么？ 1

3.2　交叉验证：评估整个拟合流程 2

3.3　混淆矩阵：先声明谁是正类 3

3.4　准确率、查准率与召回率：分母决定问题 4

3.5　F1、平均方式与分类阈值 5

3.6　ROC：让阈值变化起来 6

3.7　AUC：排序能力与并列得分 7

3.8　类别比例变化时，Precision 也会变 8

3.9　回归误差：先看单位与残差 9

3.10　R^2 与平方和：把适用条件写出来 10

3.11　一页速查与自测 11

第三章　可信评估：从数据划分到指标选择

评估不是给模型贴上一个分数，而是回答一个具体问题：模型面对怎样的新数据，完成什么任务，哪些错误最值得关注？本章先划清数据用途，再用同一组计数解释分类指标，最后处理回归误差与决定系数。

> **先定规则，再看结果**
> 在比较模型前确定数据划分、主要指标和比较流程。模型、预处理、分类阈值与停止时刻都属于完整方案的一部分。测试集用于评估已确定方案，不能反复参与这些选择。

3.1　训练、验证与测试各自负责什么？

训练集（Training Set）用于拟合参数；验证集（Validation Set）用于比较候选方案；测试集（Test Set）在方案确定后用于最终评估。三者按**数据用途**区分，不是按程序运行时属于“训练阶段”还是“预测阶段”命名。

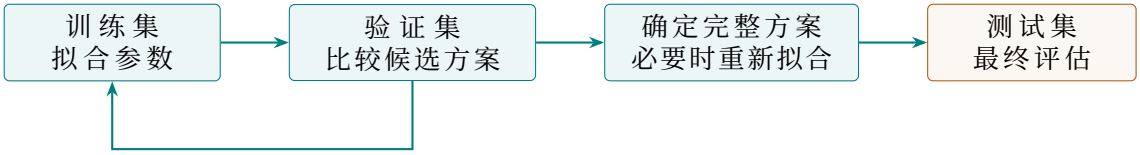


图 3.1：验证形成选择循环，测试不进入这个循环。图中的箭头表示工作流程，不表示将数据混合。

读图：候选模型在训练集上拟合，然后用验证表现调整方案。确定方案后，可以按预定流程使用开发数据重新拟合，再对保留的测试集评估。不能因为测试结果不够好就继续调阈值或换模型，再把同一测试分数作为独立评估。

训练误差在训练集上算，**验证误差**在验证集上算，**测试误差**在测试集上算。分类错误率在相应数据集 D 上定义为

$$\widehat{e}_D = \frac{1}{|D|}\sum_{i\in D}\mathbf{1}[\hat{y}_i \neq y_i].$$

同一公式用于不同数据集时，角色不同。训练错误率低，不等于泛化误差低。

> **独立划分不只是“行号不重叠”**
> 同一设备的多次记录若跨训练与测试，仍可能泄漏设备特征。面向未来预测时，应按时间顺序划分，不能随意打乱未来信息。划分应模拟实际使用条件；随机独立同分布划分只是常见设置之一。

3.2 交叉验证：评估整个拟合流程

K 折交叉验证（K-Fold Cross-Validation）在开发数据内轮流留出一折作验证，其余 $K-1$ 折训练。每折都从头拟合预处理和模型，再汇总各折验证结果。**不从这 K 个模型中简单挑出分数最高的一个作为最终模型。**



图 3.2: 五折示例：每个样本恰作一次折内验证，其余四次用于折内训练。

读图：每一行是一次独立拟合，橙色格仅用于该折验证。把每个候选方案都按相同划分评估，再依据汇总指标选择方案。最后按选定方案用开发数据重新拟合，独立测试集继续留在流程之外。

3.2.1 预处理也必须在折内拟合

标准化的均值与方差、填补缺失值的统计量、特征筛选规则等，都只能从该折的子训练集学习。先在全部数据上做这些步骤，再交叉验证，会让验证信息提前进入训练。把预处理与估计器放在同一拟合流水线中，有助于维持这个边界。

数据情况	常见划分考虑
样本近似独立同分布	普通 K 折或随机留出。
分类且类别不均衡	可分层，让各折类别比例较稳定；少数类数量仍限制折数。
同一对象多次观测	按对象分组，避免同一对象跨训练与验证。
预测未来	按时间向前验证，必要时留间隔防止窗口重叠。

选择折数要权衡样本量和计算开销，不存在“一律 10 折”的规则。重复用同一套交叉验证调参仍可能产生选择偏差；可用独立测试集，或在适当设置下用嵌套交叉验证评估选择流程。

3.3 混淆矩阵：先声明谁是正类

二分类的正类（Positive Class）是需要明确指定的类别，不代表“好”的结果。例如设备故障检测中，可以把“故障”设为正类。混淆矩阵（Confusion Matrix）把真实标签与预测标签交叉计数。

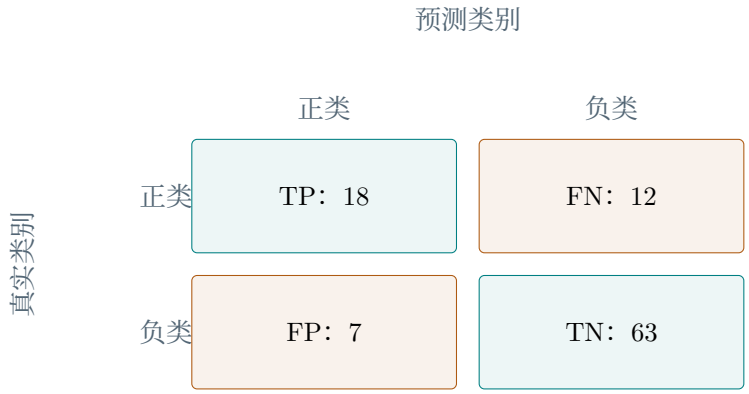


图 3.3： 100 个样本的示例。本书约定行是真实类别、列是预测类别，正类都排在前面。

读图： 30 个真实正类中，18 个被检出，12 个漏检；70 个真实负类中，7 个被误报为正类，63 个正确判为负类。因此预测正类有 25 个，预测负类有 75 个。

计数	英文与中文	本例含义
TP	True Positive，真正例	真实为正，预测也为正：18。
FN	False Negative，假负例	真实为正，预测为负：12。
FP	False Positive，假正例	真实为负，预测为正：7。
TN	True Negative，真负例	真实为负，预测也为负：63。

多分类时可扩展为 $K \times K$ 计数矩阵，主对角线是分类正确的数量。非对角线告诉我们哪些类别互相混淆，比单个准确率提供更多信息。

> **容易混淆**
>
> 不同软件可能按负类在前或其他标签顺序输出矩阵。读取位置之前先核对轴含义和标签顺序。如果只写“左上角是 TP”而没有声明约定，就容易把四种计数认反。

3.4 准确率、查准率与召回率：分母决定问题

准确率（Accuracy）问“全部样本中有多少判对”；查准率（Precision，也称精确率）问“预测为正的样本中有多少真的为正”；召回率（Recall）问“真实正类中有多少被检出”。三者的分母分别是全部样本、预测正类、真实正类。

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \tag{3.1}$$

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}. \tag{3.2}$$

对图 3.3，准确率为 $81/100 = 0.81$，查准率为 $18/25 = 0.72$，召回率为 $18/30 = 0.60$。分类错误率为 $1 - \text{Accuracy} = 0.19$。

3.4.1 把其它常见名称放回同一组计数

在二分类正类口径下，灵敏度（Sensitivity）和真正例率（True Positive Rate, TPR）就是召回率。特异度（Specificity，也称真负例率 TNR）看真实负类中有多少判对；假正例率（False Positive Rate, FPR）看真实负类中有多少被误报：

$$\text{TPR} = \frac{TP}{TP + FN}, \qquad \text{TNR} = \frac{TN}{TN + FP}, \qquad \text{FPR} = \frac{FP}{FP + TN} = 1 - \text{TNR}.$$

本例特异度为 0.90，假正例率为 0.10。**FPR 的分母是真实负类，不是预测正类，因此它不等于** $1 - \text{Precision}$。

> **为什么准确率可能不够？**
> 本例一律预测负类也有 70% 准确率，却检不出任何正类。类别极不均衡时，这种现象更明显。应报告混淆矩阵，并结合漏检和误报的代价选择指标。没有单个指标能在所有任务上替代这项判断。

若某指标公式的分母为 0，其数学定义无法直接使用。软件可能返回 0、缺失值或警告，应记录约定，而不是把这些输出混同于有足够数据支持的测量值。

3.5 F1、平均方式与分类阈值

F1 分数（F1 Score）综合查准率与召回率。在两者定义有效且其和大于 0 时，它是调和平均：

$$F_1 = \frac{2PR}{P+R} = \frac{2TP}{2TP+FP+FN}, \qquad P = \text{Precision},\ R = \text{Recall}.$$

本例为 $36/(36+7+12) = 36/55 \approx 0.655$。这里的 P 不是 Accuracy；本书避免使用含义不清的“精度”替代指标全名。F1 不直接包含 TN，因此也不能代替对真负类表现和错误代价的检查。

3.5.1 多分类汇总必须写明平均方式

可先把每个类别轮流视为正类，求各类 Precision、Recall、F1，再决定怎样汇总。

方式	汇总口径
宏平均（Macro）	各类别的指标等权平均，少数类同样占一份权重。
加权平均（Weighted）	按真实类别样本数加权，各类权重可能差别很大。
微平均（Micro）	先累加各类 TP、FP、FN，再用总计数计算指标。

在覆盖全部类别的**单标签多分类**中，micro-Precision、micro-Recall 和 micro-F1 都等于 Accuracy。宏平均 F1 应当先求各类 F1 再平均，通常不等于把宏平均 Precision 和 Recall 代入 F1 公式。

3.5.2 得分与阈值也是两个对象

若模型输出正类得分 $s(\boldsymbol{x})$，可按 $s \geq \tau$ 判为正类。降低阈值通常会让更多样本判为正类，召回率不会下降，但 Precision 未必单调变化。阈值应在验证流程内选择，然后固定用于测试；不能在测试集上挑最高 F1 再报告为独立测试结果。

> **容易混淆**
>
> F1 对 Precision 和 Recall 给予特定形式的折中，不是通用的业务收益函数。当两种错误的代价差异明显时，应明确代价、约束或使用合适的其它指标，而非仅追求 F1 最大。

3.6 ROC：让阈值变化起来

ROC 曲线（Receiver Operating Characteristic Curve）汇总不同阈值下的分类表现。本书采用常见坐标：**横轴 FPR，纵轴 TPR**，两轴都从 0 到 1。它需要模型输出连续或有序得分，不要求这些得分已是校准概率。

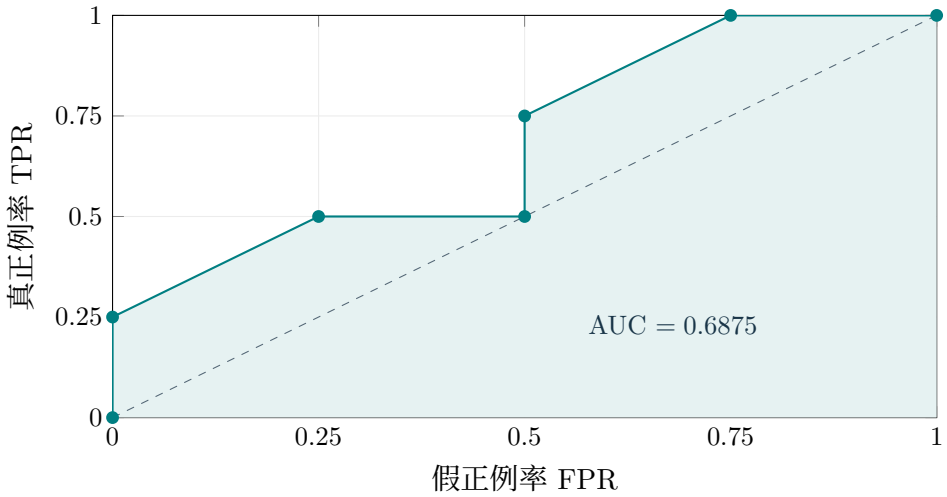


图 3.4: 八个样本的 ROC 示例，得分在下一节给出。并列得分作为一组改变阈值。虚线为对角参考线。

读图：阈值高于全部得分时，没有正类预测，对应 $(0,0)$。逐步降低阈值，会逐组纳入得分相同的样本；阈值低到所有样本都判为正时到达 $(1,1)$。曲线越靠近左上角，表示能在较低假正例率下取得较高真正例率。

每一个曲线点都代表一套阈值选择，不是同一个分类器在固定阈值下同时达到的多种结果。若实际只能接受很低的误报率，应重点看相应区域，而不是只比较整个曲线面积。

> **不要把 Specificity 直接当作本图横坐标**
>
> 有些领域会使用从 1 向 0 排列的特异度横轴，等价展示同一关系。必须同时声明坐标含义和方向，不能把“从 0 到 1 的特异度轴”误画成标准 FPR 轴。计算 ROC 与 AUC 时，评估数据还需包含正、负两类。

3.7 AUC：排序能力与并列得分

ROC 曲线下面积称为 ROC-AUC。对经验二分类得分，一种直观算法是逐对比较正、负样本：

$$\widehat{\mathrm{AUC}} = \frac{\sum_{i\in+}\sum_{j\in-}\left[\mathbf{1}(s_i > s_j) + \frac{1}{2}\mathbf{1}(s_i = s_j)\right]}{n_+ n_-}. \tag{3.3}$$

其中 n_+, n_- 是正、负样本数，s 越大表示越倾向正类。正类得分更高记 1 分，相同记半分，更低记 0 分。

真实类别	模型得分
正类，4 个	0.9, 0.8, 0.5, 0.4
负类，4 个	0.8, 0.6, 0.4, 0.1

四个正类与所有负类逐一比较，分别得到 $4, 3.5, 2, 1.5$ 分，所以 $\widehat{\mathrm{AUC}} = 11/16 = 0.6875$。这也等于图 3.4 按并列分组后作线性连接的梯形面积。若在并列组内部任意排列正负样本再连接，可能得到受排列影响的错误面积。

3.7.1 AUC 告诉了什么，又没告诉什么？

AUC 衡量得分把正类排在负类之前的能力，不直接衡量概率校准，也不指定实际部署阈值。严格递增地变换全部得分不会改变其排序，因而不会改变相应 AUC。一个固定阈值下的准确率却可能改变。

> **核心理解**
>
> AUC 为 0.5 只描述这一排序汇总量，不能断言模型的全部行为与随机猜测相同。AUC 为 1 表示在当前评估样本上正类得分都高于负类，也不是对未来数据的完美保证。报告 AUC 时，应同时说明数据划分与适用任务；多分类还要说明如何组合类别。

3.8 类别比例变化时，Precision 也会变

ROC 使用类内比例 TPR 和 FPR；Precision 还取决于总体中正类有多常见。记正类比例为 π，在类条件表现保持不变的假设下，

$$\text{Precision} = \frac{\pi\,\text{TPR}}{\pi\,\text{TPR} + (1-\pi)\,\text{FPR}}. \tag{3.4}$$

例如保持 TPR $= 0.8$、FPR $= 0.1$：

正类比例	真正例占全部样本比例	Precision
50%	$0.5 \times 0.8 = 0.4$	$0.4/(0.4 + 0.05) \approx 0.889$
1%	$0.01 \times 0.8 = 0.008$	$0.008/(0.008 + 0.099) \approx 0.075$

两种情形的 TPR 与 FPR 相同，预测正类的可靠程度却相差很大。因此，把在均衡抽样数据上得到的 Precision 直接当作实际低发生率场景的 Precision，通常不可靠。若类条件分布也变化，上式中的 TPR 与 FPR 本身还可能改变。

3.8.1 不均衡任务的报告方式

除 Accuracy 外，报告正类支持数、Precision、Recall、阈值和混淆矩阵。Precision–Recall 曲线有助于观察查准与查全的关系；若报告其汇总面积或平均精确率，还要明确计算约定，不能把所有不同定义的“PR 面积”当作同一个数。

> **容易混淆**
>
> “ROC-AUC 对类别比例不敏感”依赖类条件得分分布保持不变，不表示不均衡任务仅看 AUC 就够了，更不表示样本少的正类能得到精确稳定的估计。验证/测试集应代表目标使用情形，并同时考虑统计不确定性。

3.9 回归误差：先看单位与残差

回归任务预测数值。对 n 个样本，记真实目标 y_i、预测 $\hat{y}_i$，残差 $e_i = y_i - \hat{y}_i$。常见指标为

$$\mathrm{MAE} = \frac{1}{n}\sum_i |e_i|, \tag{3.5}$$

$$\mathrm{MSE} = \frac{1}{n}\sum_i e_i^2, \qquad \mathrm{RMSE} = \sqrt{\mathrm{MSE}}. \tag{3.6}$$

MAE 与 RMSE 和目标变量同单位；MSE 的单位是目标单位的平方。平方误差对大残差惩罚更强，但不能因此断言 MAE 完全不受异常值影响。

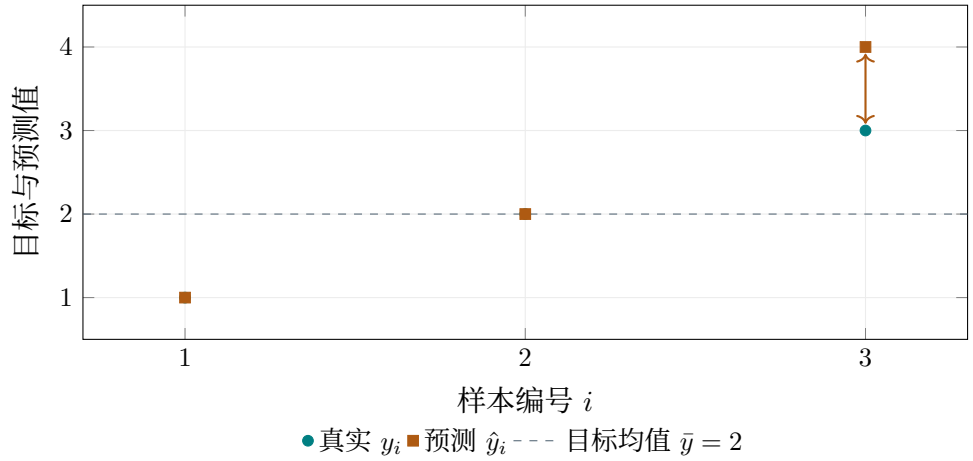


图 3.5: 真实目标为 $(1, 2, 3)$，预测为 $(1, 2, 4)$。箭头标出第 3 个样本的残差大小 1；前两个重合点残差为 0。

读图： 残差向量为 $(0, 0, -1)$，因此 MAE 与 MSE 都为 $1/3$，RMSE 为 $\sqrt{1/3} \approx 0.577$。图中水平线是当前评估目标的均值，不是把模型预测都替换成均值。

> **指标与训练目标可以使用相同公式，但用途不同**
>
> MSE 既可以作为训练目标，也可以作为验证或测试指标。它在测试集上计算时并不会反过来参与训练。比较模型要使用相同数据划分和相同目标尺度；如果训练时变换了目标，需说明评估在哪个尺度上进行。

3.10 R^2 与平方和：把适用条件写出来

决定系数（Coefficient of Determination, R^2）把残差平方和与“始终预测本评估集目标均值”的基准比较。设 $\bar{y} = n^{-1}\sum_i y_i$：

$$\mathrm{TSS} = \sum_i (y_i - \bar{y})^2, \qquad \mathrm{RSS} = \sum_i (y_i - \hat{y}_i)^2, \tag{3.7}$$

$$R^2 = 1 - \frac{\mathrm{RSS}}{\mathrm{TSS}}, \qquad \mathrm{TSS} > 0. \tag{3.8}$$

完美预测的 $R^2 = 1$；与该均值基准同样的平方误差给出 0；比它更差则为负。若评估集目标全相同，TSS 为 0，数学定义的分母失效；软件可能采用约定值，应说明处理方式。当前目标均值只是这个评估统计量的参照，不是允许用测试标签拟合部署模型；实际可部署的均值预测器应从训练数据估计。

目标均为 $(1,2,3)$	预测	RSS	R^2
图中模型	$(1,2,4)$	1	0.5
均值基准	$(2,2,2)$	2	0
较差预测	$(4,4,4)$	14	-6

3.10.1 解释平方和不总等于总平方和减残差平方和

常见定义 $\mathrm{ESS} = \sum_i (\hat{y}_i - \bar{y})^2$。一般展开为

$$\mathrm{TSS} = \mathrm{RSS} + \mathrm{ESS} + 2\sum_i (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}).$$

只有交叉项为 0 时才可直接相加；带截距普通最小二乘的训练集拟合是常见情形。本例预测 $(1,2,4)$ 的 ESS 为 5，交叉项为 -4，所以 $2 = 1 + 5 - 4$，不能把 RSS 和 ESS 无条件相加。

> **容易混淆**
>
> R^2 并非对任意预测都等于相关系数平方。带截距的一元最小二乘训练集拟合、相应方差非 0 时，有 $R^2 = r(x,y)^2$；任意模型或测试集不能照搬。本节图中预测与目标的相关系数平方约为 0.964，实际 R^2 只有 0.5。

3.11 一页速查与自测

要回答的问题	先看什么
模型参数在哪里拟合?	训练集；交叉验证中是每折子训练集。
阈值或超参数在哪里选?	验证流程内；最终测试集保持独立。
预测正类有多少是真的?	Precision：$TP/(TP+FP)$。
真实正类检出了多少?	Recall/TPR：$TP/(TP+FN)$。
真实负类误报了多少?	FPR：$FP/(FP+TN)$。
跨阈值的排序表现怎样?	ROC 与 ROC-AUC；并列正负得分按半对计分。
数值误差有多大?	MAE、RMSE 与残差分布，注意单位。
比目标均值基准好多少?	$R^2 = 1 - \mathrm{RSS}/\mathrm{TSS}$，可能为负。

3.11.1 三个自测问题

1. 若 TP=9、FP=1、FN=6、TN=84，Precision 与 Recall 分别是多少?
2. 两个正类得分为 0.8、0.4，两个负类为 0.8、0.2，AUC 是多少?
3. 若 TSS=10、RSS=15，R^2 是多少? 能否直接认为计算有误?

参考答案：（1）0.9 与 0.6。（2）$(1.5+1)/4 = 0.625$。（3）-0.5；它表示平方误差比该均值基准更大，不必然是计算错误。

3.11.2 进一步查阅

- scikit-learn：数据泄漏与预处理常见问题。
- 指标文档：roc_auc_score、r2_score，核对输入口径与边界约定。