机器学习与深度学习：图解速查手册

数据准备

从原始记录到可用特征

第四批阶段样章

本批详细核查 12 张数据准备原图，统一说明数据表示、处理规则与训练边界。以独立图表替换原插图，给出填补、缩放与采样的可复算例子。本文件是阶段成果；全书仍在连续修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第四章　数据准备：从原始记录到可用特征 **1**

4.1　样本矩阵：行、列与目标 1

4.2　无序类别与独热编码 2

4.3　有序编码保留顺序，不保证间距 3

4.4　缺失值：不知道，不等于零 4

4.5　近邻填补：用观测部分寻找相似记录 5

4.6　缩放：参数来自训练集 6

4.7　特征选择：筛选规则也是模型的一部分 7

4.8　类别不平衡：调整训练，不改写评估对象 8

4.9　SMOTE：在少数类邻居之间插值 9

4.10　把处理步骤放进同一条流水线 10

第四章　数据准备：从原始记录到可用特征

模型接收的是经过整理的输入。列代表什么、缺失怎样表达、尺度如何确定，都会改变模型能学到的关系。本章用小表和可复算的数字解释这些步骤。

> **先划分，再学习处理规则**
> 凡是需要从数据中估计的处理规则，都属于拟合流程的一部分。填补值、缩放参数、类别字典和特征选择规则只在训练数据上学习；验证与测试沿用这些规则。交叉验证时，这个边界要在每一折重新建立。

4.1　样本矩阵：行、列与目标

样本矩阵（Design Matrix）$X \in \mathbb{R}^{n \times d}$ 的每行是一条样本，每列是一个输入特征。x_{ij} 表示第 i 个样本的第 j 个特征。单目标监督学习的标签向量为 $y \in \mathbb{R}^n$；分类时其元素也可以是类别标签。



图 4.1：三个样本、三个数值特征与一个目标的结构示例。数字仅用于说明形状。

读图：第三列只有 0 和 1，仍可能是输入特征。是不是目标取决于任务定义，不能仅凭数据类型或列的位置判断。样本顺序改变时，X 与 y 必须同步改变。

4.1.1　先问预测时能否获得这个特征

预测违约时，申请时的收入可能可用，事后产生的催收记录不能提前作为输入。姓名、设备编号、时间戳不应机械地当作普通连续数值：它们可能用于分组划分、构造合理特征，也可能让模型记住身份或未来信息。

记住：特征不是“表中除标签之外的所有列”；每一列都需要含义、单位和可用时间。

4.2 无序类别与独热编码

无序类别（Nominal Category）只有类别差异，没有自然大小顺序。把红、蓝、绿编码为 0、1、2，并不能说明绿比蓝“大”，也不能说明两者距离为 1。独热编码（One-Hot Encoding）为每个类别建立一个指示列。



图 4.2: 三种颜色映射到三个指示列；这里没有定义颜色间的顺序。

读图：一条非缺失、属于已知类别的记录，在完整独热编码中恰有一列为 1。拟合时记录类别字典和列顺序；预测时必须保持同一顺序。

4.2.1 三个常见边界

训练中未出现的新类别需要预先定义处理方法，例如报错、归入“其他”，或按编码器约定输出全零。若全零同时用作基准类别，应理解其语义可能重合。类别很多时，独热矩阵会很宽；可考虑稀疏存储、合理合并或专门的类别模型。有些树模型原生支持类别特征，应遵循实现接口。

> **独热列与截距可能线性相关**
>
> 完整的 K 个独热列逐行之和为 1，和截距列相关。无约束线性模型常删除一个基准类别列，或采用相应约束；是否删除要结合模型与正则化，不能把“所有模型必须删一列”当成规则。

4.3 有序编码保留顺序，不保证间距

有序类别（Ordinal Category）具有自然顺序，例如低、中、高。编码为 0、1、2 可以表达这种顺序，但不保证“中到高”与“低到中”的实际差异相等。

原特征	可用表示	引入的含义
低、中、高	有序编码 0、1、2	保留顺序；在线性模型中还引入等间距效应。
红、蓝、绿	三个独热列	各类别分别具有指示特征，不强加大小关系。
真实温度	有单位的数值	数值差异有物理意义，需保留测量单位。

例如线性预测 $\hat{y} = b + wx$，低、中、高编码 0、1、2 后，相邻等级的预测差都为 w。这是一项模型假设；若不合理，可以用独热编码分别估计各等级效果。树对有序整数作阈值切分可以保留等级顺序，但任意给无序类别编号会限制它可直接表达的分组。

> **编码值不是比例尺度**
>
> 低 =1、中 =2、高 =3，只说明人为选定了三个数字。不能据此说“高的实际程度是低的三倍”。顺序、差值与倍数是不同层次的信息。

记住：编码方式要与变量含义及模型的使用方式一起选择。

4.4 缺失值：不知道，不等于零

缺失值（Missing Value）表示未获得观测。零可能是有效数值，不能默认用零代替所有缺失。先区分未测量、不适用、采集失败等原因，再选择处理策略。

处理方式	适用考虑与代价
训练均值或中位数	数值特征的简单基线；压缩变异，不能恢复真实缺失值。
训练众数或专门类别	用于类别列；专门类别可以显式保留“未知”的语义。
增加缺失指示列	让模型知道该位置原本缺失；需防止采集流程变化破坏关系。
删除行或列	损失信息，并可能改变样本分布；不能只凭缺失比例小就断言无偏。
利用其他特征预测	如近邻填补；依赖相关结构，仍需验证效果。

训练列为 $[10, \text{缺失}, 20, 30]$ 时，中位数为 20。填补后为 $[10, 20, 20, 30]$；缺失指示列为 $[0, 1, 0, 0]$。新样本的缺失仍用训练得到的 20 填补，不在测试列上重新计算中位数。

> **时间顺序也约束填补**
>
> 预测某时刻的结果时，不能利用当时尚未产生的未来记录反向填补。有些模型可以直接处理缺失值，也需要确认实现的支持范围和训练、预测时的语义一致。

记住：填补后的值是建模用的估计，不是已经找回的真实观测。

4.5 近邻填补：用观测部分寻找相似记录

k 近邻填补（k-NN Imputation）根据已观测特征寻找相似的训练记录，再汇总这些邻居在缺失列上的值。下面只用一个已观测特征 A 计算距离。

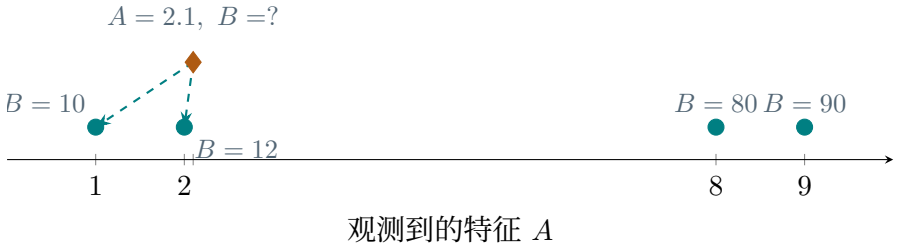


图 4.3: 训练记录为 $(1, 10), (2, 12), (8, 80), (9, 90)$；橙色新记录的 B 缺失。

读图：到 $A = 2.1$ 的距离分别为 1.1、0.1、5.9、6.9。当 $k = 2$ 且等权时，选择前两条记录，填补 $B = (10 + 12)/2 = 11$。全部训练 B 的中位数则为 $(12 + 80)/2 = 46$；两种规则表达不同假设。

4.5.1 距离怎样定义，决定谁是邻居

缺失的 B 本身不能用于寻找邻居。多维特征可依据共同观测的部分定义距离，但共同观测很少时相似度可能不可靠；具体距离和无可用邻居时的回退规则需明确。量纲也会影响距离，例如以元计价的收入可能淹没以年计的年龄。

> **没有固定最优的邻居数**
>
> k、权重、尺度与距离都应通过训练内验证选择。仅从训练数据保存供填补使用的邻居，不能把验证或测试记录加入邻居库。近邻填补可能保留局部结构，也可能传播异常值，不能预先断言优于简单填补。

4.6 缩放：参数来自训练集

Min–Max 缩放使用训练最小值 a 和最大值 b：

$$x' = \frac{x - a}{b - a} \quad (b > a).$$

标准化（Standardization）使用训练均值 μ 与标准差 s：

$$x' = \frac{x - \mu}{s}, \qquad \mu = \frac{1}{n}\sum_i x_i, \quad s = \sqrt{\frac{1}{n}\sum_i (x_i - \mu)^2}.$$

这里明确使用分母 n，与一些统计教材的样本标准差约定不同。

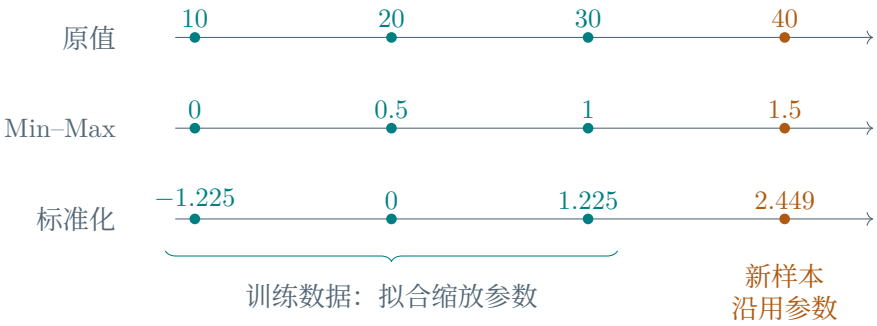


图 4.4: 训练值 10、20、30；新值 40 沿用同一套参数。标准化数字保留三位小数。

读图： 训练均值为 20，标准差为 $\sqrt{200/3} \approx 8.165$。新值 40 经 Min–Max 变为 1.5，经标准化变为约 2.449。训练范围映射到 $[0, 1]$，不意味着所有未来值都在 $[0, 1]$ 内。

> **标准化不会自动变成正态分布**
>
> 减均值、除标准差只改变位置与尺度。它不消除偏态，也不消除异常值。常数列分母为零，需要明确保留、删除或特殊处理规则，不能直接相除。

距离、正则化和梯度更新常受尺度影响；常规按单列阈值切分的树通常不依赖这种缩放。是否缩放仍由模型与特征含义决定。

4.7 特征选择：筛选规则也是模型的一部分

特征选择（Feature Selection）保留原特征的一个子集。它不同于把原特征重新组合成新坐标的特征提取，例如主成分分析。

方法	怎样选择	主要边界
过滤法 Filter	用统计量或单变量分数筛选。	快；单变量分数可能漏掉交互作用。
包装法 Wrapper	对候选子集拟合并验证模型，如前向选择、递归消除。	开销大；反复比较会过拟合验证结果。
嵌入法 Embedded	在训练中形成选择，如 L1 惩罚产生零系数。	依赖模型、尺度及超参数。

先在全部数据上用标签选出“相关性最高”的列，再进行交叉验证，已经泄漏验证标签。每折需要只用子训练集拟合筛选器，再把选定列应用到该折验证集。

4.7.1 不要把经验规则写成定理

高度相关的列可能冗余，也可能各自包含有效信息；低方差的指示特征仍可能识别重要的罕见类别。树的重要性、线性系数大小与预测贡献都受模型和数据影响，不能直接解释为因果作用。

记住：先确定选择流程，再评估整个流程。删列后的泛化表现，比“看起来显著”更接近实际目标。

4.8 类别不平衡：调整训练，不改写评估对象

类别不平衡（Class Imbalance）指类别频率差异较大。多数类、少数类由频率决定，正类、负类由任务定义决定，两组概念不能混用。

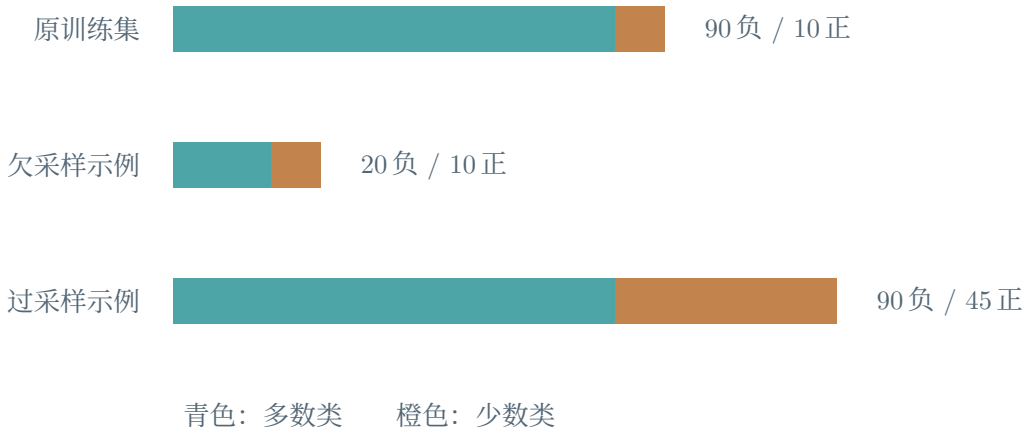


图 4.5： 90 个负类、10 个正类的两个独立采样示例；不要求一定变成 1:1。

读图： 欠采样（Undersampling）从多数类中保留较小子集，会损失部分记录。随机过采样（Random Oversampling）重复抽取少数类，使其在训练中出现更多次；45 条少数类训练记录不代表获得 45 个独立的新对象。

采样只在训练数据内进行；验证与测试保留目标使用场景的分布。交叉验证时也只处理每折子训练集。先重复样本再划分，会使相同对象跨训练与验证。

> **比例变化会影响概率解释**
>
> 采样改变了模型接触的类别先验。输出的概率未必仍是原始人群中的风险概率。阈值选择与概率校准需要在具有目标分布、用途独立的数据上处理。也可以比较类别权重等方案，不必先认定采样一定有益。

4.9 SMOTE：在少数类邻居之间插值

SMOTE 是一种合成过采样方法。基本形式在少数类样本 x_i 与其少数类近邻 x_j 之间生成

$$x_{\text{new}} = x_i + \lambda(x_j - x_i), \qquad 0 \le \lambda \le 1.$$

若 $x_i = (1, 2)$、$x_j = (3, 4)$ 且 $\lambda = 0.25$，则 $x_{\text{new}} = (1.5, 2.5)$。这条新记录位于两点之间，并不证明它在实际世界中一定合理。

需要检查	原因
特征尺度与距离	它们决定选到哪些近邻。
少数类边界与异常值	插值可能穿过多数类区域，或放大噪声。
类别型与离散约束	直接插值可能产生无意义的“半个类别”；需相应方法或表示。
少数类数量	太少时近邻关系不稳，且可能无法满足算法的邻居数要求。
独立验证表现	合成点不是独立采集的额外证据，仍需在目标分布上评估。

记住：随机复制改变记录出现频率；SMOTE 改变训练点的位置。两者都不能替代真实的新数据。

4.10 把处理步骤放进同一条流水线

流水线（Pipeline）把处理步骤按顺序连接，让训练和预测遵循同一套规则。数值列与类别列可以分别处理，再拼接为模型输入。

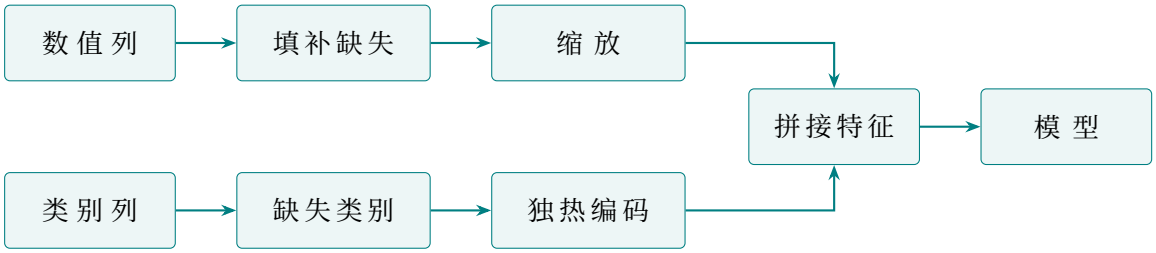


图 4.6: 一个基础表格数据流程；箭头表示数据经过的步骤。可在训练支路添加筛选和采样。

读图：拟合时，在训练集学习各步所需参数并拟合模型。预测时只调用已学规则。数值填补放在缩放之前，是此例的选择；近邻填补等流程还需单独设计距离尺度，不能机械套用。

步骤	训练时学习	验证、测试或上线时使用
填补	中位数、众数或邻居库	固定填补规则
缩放	均值、标准差或极值	固定参数变换
编码	类别字典与列顺序	同一字典及未知类策略
选择	训练内确定的特征子集	同一组列
采样	训练记录的选择、复制或合成	不对待评估记录采样

4.10.1 自测与回看

测试值超出训练最大值，经 Min–Max 得到 1.2，是否一定是程序错误？**不是**。交叉验证前用全部标签筛选列，是否合适？**不合适，筛选应在每折训练内**。复制 10 条少数类到 50 条，是否等于新增 40 个独立对象？**不等于**。

核查依据：scikit-learn 的 Preprocessing、Imputation、Feature selection 与 Common pitfalls 文档，以及 imbalanced-learn 的 Common pitfalls 文档（访问于 2026-10-28）。计算记录见本项目第四批审校文件；图均为本书独立绘制的矢量图。