机器学习与深度学习：图解速查手册

学习与泛化

先把问题定义清楚

第五批阶段样章

本批详细核查 15 张基础概念原图，重写任务、容量、泛化和统计错误。以独立图表替换原插图，复算多项式拟合和偏差—方差分解。本文件是阶段成果；全书仍在连续修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第五章　学习与泛化：先把问题定义清楚 **1**

5.1　从经验到规则，再把规则用于新输入 1

5.2　监督、无监督；分类、回归 2

5.3　决策边界划分预测区域 3

5.4　模型容量与泛化能力分别回答什么？ 4

5.5　参数模型与非参数模型 5

5.6　欠拟合与过拟合：看训练，也看新数据 6

5.7　偏差与方差：固定输入，改变训练集 7

5.8　平方误差怎样分成三部分？ 8

5.9　用现象诊断问题，不背固定曲线 9

5.10　第一类、第二类错误要先声明原假设 10

5.11　简单模型优先，是有条件的选择原则 11

第五章　学习与泛化：先把问题定义清楚

机器学习（Machine Learning）利用数据中的经验改善任务表现。开始建模前，至少要说清楚三件事：完成什么任务、有哪些可用经验、怎样判断表现。“会拟合数据”只是其中一环，最终还要看模型面对合适的新数据是否有用。

> **贯穿全书的四个问题**
>
> 要预测什么？预测时能获得什么？希望在哪种新数据上有效？哪些错误代价更大？模型类型、数据处理、训练目标和评估指标，都需要围绕这些问题选择。

5.1　从经验到规则，再把规则用于新输入

例如根据设备运行记录预测下一天是否故障：任务是故障分类，经验是历史记录与后续故障标签，表现可以用漏报率、误报率或相应成本衡量。只报训练准确率不足以说明这个任务已经做好。

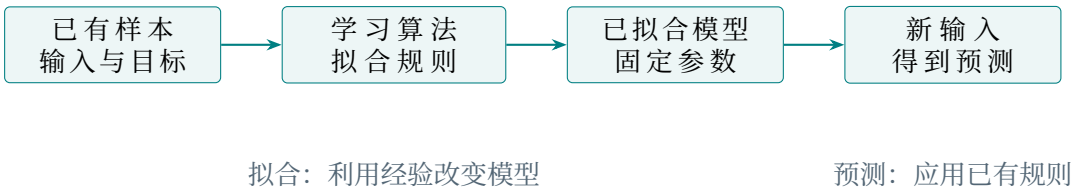


图 5.1：监督学习中的拟合与预测。新输入应满足任务中约定的信息可用性。

读图：学习算法从样本得到一个模型；已拟合模型再把新输入映射为预测。拟合不是逐条记住答案的同义词，预测也不保证每次正确。模型表现是否随更多经验改善，需要用合适的评估流程检验。

5.1.1　预测关系不自动等于因果关系

记录中的某个特征与故障相关，可以帮助预测，但不表示主动改变它一定能减少故障。采集方式、共同原因和选择偏差都可能形成相关性。因果问题需要额外假设或实验设计。

记住：先写下任务、信息与评估规则，再开始选算法。

5.2 监督、无监督；分类、回归

监督学习（Supervised Learning）有用于学习的输入—目标对应关系。无监督学习（Unsupervised Learning）不依赖这种任务标签，常用于寻找结构、压缩或描述分布。

问题	目标形式	例子
分类 Classification	离散类别	是否故障、图像属于哪种动物。
回归 Regression	数值	明日温度、房屋价格。
聚类 Clustering	无给定类别标签，寻找分组	按购买行为探索客户群。
降维 Dimensionality reduction	构造较少的表示坐标	用低维表示压缩或可视化特征。

分类标签即使用数字 0、1、2 表示，仍然是类别。回归值可以是连续测量，也可以是数值计数；关键是预测目标的含义与损失。逻辑回归虽然名为“回归”，常用于分类概率建模。

> **没有标签不代表没有评估**
>
> 聚类结果仍需根据稳定性、结构与实际用途检验，不能只看图上是否分得好看。无监督步骤如果参与后续监督任务，也应服从相应的数据划分与拟合边界。无监督学习并不天然优于或劣于监督学习，两者回答的问题不同。

记住：分类和回归按目标区分；监督和无监督按学习信号区分。

5.3 决策边界划分预测区域

分类器的决策边界（Decision Boundary）是预测类别发生变化的位置。考虑得分 $s = x_1 + x_2 - 4$，采用 $s \geq 0$ 预测 1，否则预测 0；边界是 $x_1 + x_2 = 4$。

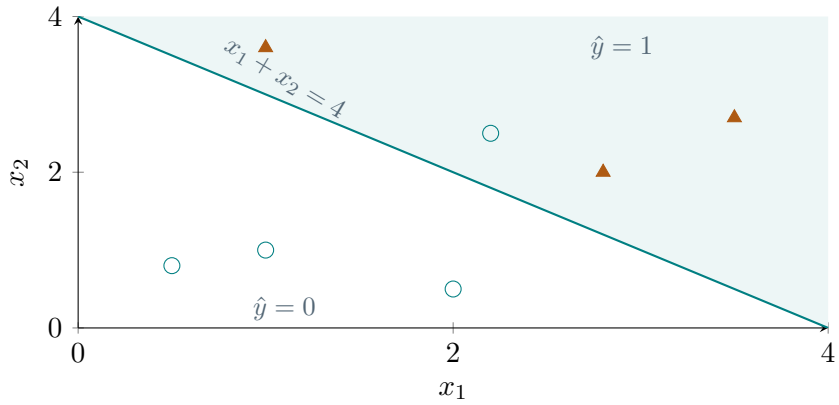


图 5.2: 圆点真实标签为 0，三角真实标签为 1；背景及直线表示模型的预测规则。

读图：直线上方预测 1，下方预测 0。有一个圆点落在上方，因此会被误分。边界说明模型怎样预测，散点说明观测标签，两者不必完全一致。

如果得分先经过 Sigmoid 得到概率 $p = \sigma(s)$，以 $p \geq 0.5$ 分类仍得到同一边界。改变概率阈值会改变边界的位置。非线性特征或模型可以产生弯曲边界，但边界更曲折不直接证明预测更好。

> **类别、得分、概率是不同对象**
>
> 得分可取任意实数；概率应在 $[0, 1]$ 内；类别由决策规则产生。得分经函数变到 $[0, 1]$ 不等于已经证明概率校准良好。

5.4 模型容量与泛化能力分别回答什么？

模型容量（Capacity）描述候选函数集合的表达能力。例如所有常数函数包含在一次多项式中，一次多项式又包含在至多二次多项式中。

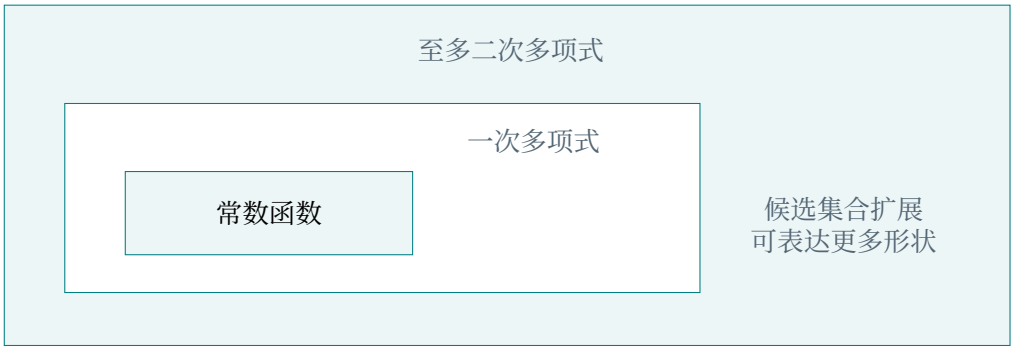


图 5.3: 候选函数集合的包含关系示例。方框面积不表示任何数值容量指标。

读图：外层集合可以表达内层集合的函数，也能表达更多形状。若使用同一训练损失、没有额外限制并找到全局最优，扩大候选集合不会提高最优训练损失。这不保证实际优化一定找到最优，更不保证新数据表现改善。

泛化（Generalization）关注从已见数据学到的规则在目标新数据上的表现。它取决于数据量、任务结构、噪声、模型和训练方式，也受训练与使用分布差异影响。参数多寡可提供一些线索，但不是跨模型通用的容量或泛化度量。

记住：容量问“能够表达什么”；泛化问“学到的规则在目标新数据上表现如何”。

5.5 参数模型与非参数模型

固定输入维度时，参数模型（Parametric Model）用固定有限维参数描述模型族。非参数模型（Nonparametric Model）的复杂度可以随数据量增长；这个名称不表示没有参数。

例子	怎样表示	主要边界
线性回归	d 个系数与一个截距。	固定 d 时，样本增加不会新增系数。
固定结构神经网络	固定数量的权重与偏置。	是参数模型；函数可以高度非线性。
k 近邻预测	保存训练样本并查询邻居。	需要保存的信息通常随训练量增长；k 是超参数。
可增长的树	根据数据形成切分与叶子。	复杂度受深度、叶数等限制；具体约束需声明。

参数是拟合时学习的量，如回归系数；超参数（Hyperparameter）控制模型或训练流程，如近邻数、树深和正则化强度，常通过开发数据内验证选择。

> **不能从名称推出分布假设**
>
> 参数模型不等于“数据必须正态”，非参数模型也不等于“没有任何假设”。距离、平滑性、局部结构等仍是重要假设，必须结合具体模型判断。

5.6 欠拟合与过拟合：看训练，也看新数据

欠拟合（Underfitting）指模型或训练流程未充分学到有用结构。过拟合（Overfitting）指对训练样本中的偶然变化适应过多，影响新数据表现。用同一组九条带固定扰动的样本，比较三种最小二乘多项式拟合。

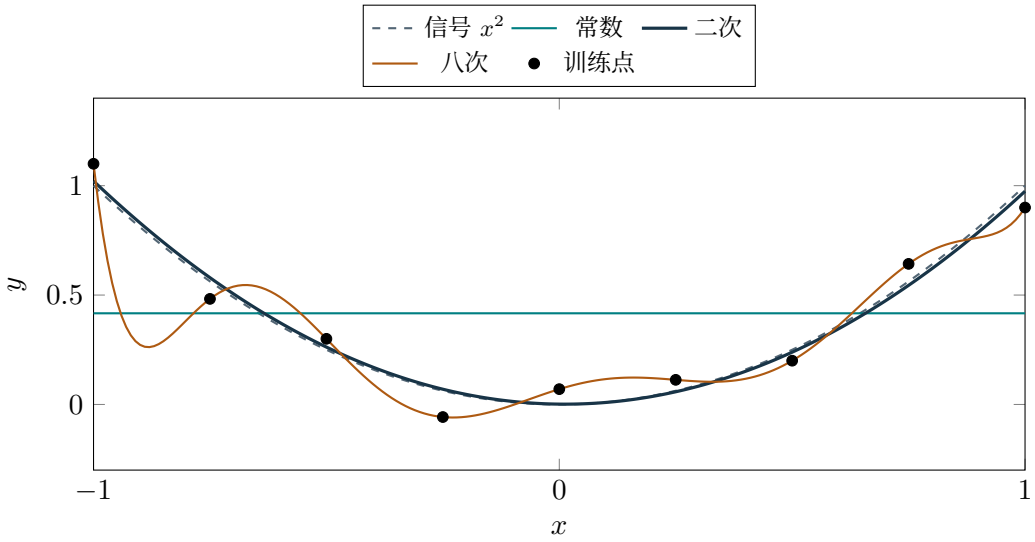


图 5.4: 人工构造的 $y = x^2 + \varepsilon$ 示例。曲线在同一训练集拟合；虚线是已知生成信号。

读图：常数无法描述弯曲趋势；二次函数接近信号；八次函数穿过训练点但产生额外起伏。这些判断在本例有已知信号支撑。真实任务通常不知道信号，需依靠独立验证。

拟合次数	训练 MSE	网格上对真实信号的 MSE
0	0.13933	0.09707
2	0.00639	0.00018
8	$< 10^{-20}$	0.02308

数值保留五位小数；网格误差只比较 201 个等距位置的无噪声信号，不是从真实人群采集的测试分数。

5.7 偏差与方差：固定输入，改变训练集

回归中固定输入 x，令 $f(x) = \mathbb{E}[Y \mid X = x]$。从相同机制重新采集训练集 D 并拟合，得到不同预测 $\hat{f}_D(x)$。期望 $\mathbb{E}_D$ 表示对这些训练集及所考虑的训练随机性取平均。

$$\bar{f}(x) = \mathbb{E}_D[\hat{f}_D(x)], \qquad \mathrm{Bias}(x) = \bar{f}(x) - f(x),$$

$$\mathrm{Var}(x) = \mathbb{E}_D[(\hat{f}_D(x) - \bar{f}(x))^2].$$

偏差描述平均预测偏离条件均值的程度，方差描述不同拟合之间预测的波动。它们都不是单个训练样本的残差。

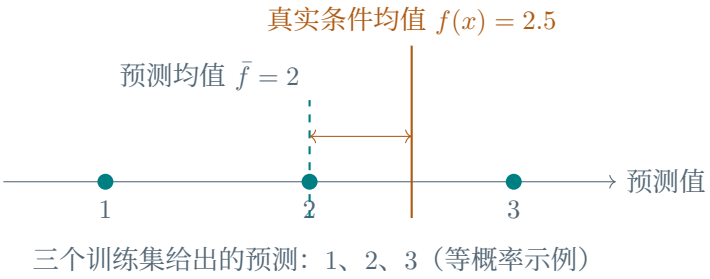


图 5.5: 固定 x 处，三种训练结果等概率出现的离散教学例子。

读图：预测均值为 2,偏差为 $2-2.5 = -0.5$,偏差平方为 0.25。方差为 $[(1-2)^2+0+(3-2)^2]/3 = 2/3$。偏差可以有正负，偏差平方非负。

> **一个数据集的残差不能直接给出这些量**
>
> 真实条件均值通常未知，也没有无限多个独立训练集。重采样实验可以帮助研究稳定性，但不能把其输出自动当作真实偏差和方差。

5.8 平方误差怎样分成三部分?

设新响应 $Y = f(x) + \varepsilon$ 满足 $\mathbb{E}[\varepsilon \mid x] = 0$、$\mathrm{Var}(\varepsilon \mid x) = \sigma^2(x)$，且新响应噪声与训练集独立。固定 x，有

$$\mathbb{E}_{D,Y|x}[(Y - \hat{f}_D(x))^2] = \mathrm{Bias}(x)^2 + \mathrm{Var}(x) + \sigma^2(x).$$

部分	在这个设置下的含义
偏差平方	平均预测与条件均值的差异。
预测方差	不同训练集、训练随机性造成的预测波动。
条件噪声方差	给定现有特征 x，响应仍有的不确定性。

5.8.1 只需看交叉项为什么为零

写成 $Y - \hat{f}_D = \varepsilon + (f - \bar{f}) + (\bar{f} - \hat{f}_D)$。平方展开后，$\mathbb{E}\varepsilon = 0$、$\mathbb{E}_D(\bar{f} - \hat{f}_D) = 0$，以及新噪声与训练集的独立性，使交叉项期望为零；其余三项就是上式。

接着上一页，令新噪声以相同概率取 -0.5 或 0.5，则噪声方差为 0.25。预期平方误差为 $0.25 + 2/3 + 0.25 = 7/6 \approx 1.167$。对三个预测与两个新响应的六种组合直接计算，也得到相同结果。

> **条件与损失不能省略**
>
> 这是固定输入处、独立新响应的平方损失分解，不能原样套到 0–1 错误率。噪声是相对给定特征而言的；增加有效信息可能降低条件不确定性。变量相关本身不等于噪声来源。

5.9 用现象诊断问题，不背固定曲线

经典偏差—方差权衡提供一种解释：放宽模型限制时，偏差可能降低而方差可能增大。但这不是所有算法、数据量和训练方式下的单调定律，验证误差也不保证呈单一 U 形。

观察到的现象	先检查什么
训练与验证都较差	数据/目标是否一致，特征是否有信息，优化是否充分，限制是否过强。
训练好、验证明显差	泄漏与划分是否正确，样本量与代表性，模型约束，选择流程是否过多调试。
训练与验证接近	接近不代表都好；要与简单基线、目标需求比较。
上线表现突然恶化	输入、标签、采集流程或人群是否变化，是否存在时间或群组差异。

正则化、限制树深、早停、更多合适数据等都可能改善泛化。增加复杂度也可能改善欠拟合，但应先排查编码错误、训练未收敛等实现问题。数据量增加并不保证错误标签或分布错位自行消失。

记住：把诊断变成可比较的实验：固定划分、一次改变清楚的因素，再看验证结果。

5.10 第一类、第二类错误要先声明原假设

假设检验中先设原假设 H_0 和备择假设 H_1。第一类错误（Type I Error）是在 H_0 为真时拒绝它；第二类错误（Type II Error）是在 H_0 为假时未拒绝它。

真实情况	拒绝 H_0	未拒绝 H_0
H_0 为真	第一类错误	无此类错误
H_0 为假	无此类错误	第二类错误

若把 H_0 设为“没有故障”，并把拒绝 H_0 作为“检出故障”，第一类错误对应假阳性，第二类错误对应假阴性。这项对应依赖原假设和正类定义，不能跳过声明。第一类错误概率记为 α，第二类错误概率记为 β，检验功效为 $1-\beta$。

> **未拒绝不等于证明为真**
>
> 没有足够证据拒绝 H_0，可能是效应弱或样本不足。p 值也不是“原假设为真的概率”。预测模型的错误率与统计检验的错误概率，需要按各自任务分别定义。

5.11 简单模型优先，是有条件的选择原则

奥卡姆剃刀（Occam's Razor）鼓励在解释能力和证据相近时，避免不必要的复杂性。在实际建模中，可以同时比较验证表现、维护成本、解释要求和运行代价，不能只凭训练集拟合好坏就宣布简单模型总是更优。

5.11.1 没有免费午餐强调假设的重要性

没有免费午餐（No Free Lunch）定理有具体的任务空间、平均方式和损失等条件。在有限输入、所有标签函数等可能的设置下，未观察位置的标签无法仅凭已有标签推断；对所有这些任务平均，并不能获得普遍占优的预测规则。实际任务通常具有结构，模型正是利用这种结构与先验假设工作。

> **两句话可以同时成立**
> 没有一个方法在所有可能任务上普遍最好；某个方法在明确的一类实际任务上可能非常有效。因此应从任务结构提出候选模型，再用适当数据比较，而不是随机选择或放弃比较。

5.11.2 自测与回看

训练误差为零，是否证明泛化良好？**不能**。固定结构神经网络是否一定属于非参数模型？**不是**。偏差是否就是一次预测的残差？**不是**。第二类错误是否是假阳性？**在常见“无病”为原假设的对应中，是假阴性**。

参考：James 等，*An Introduction to Statistical Learning*，第二版，2021，第 2 章；本章数值例子、图和计算文件均为独立构造。