机器学习与深度学习：图解速查手册

建模工具与数学速查

目标、约束与基本计算

第六批阶段样章

本批详细核查 11 张原图，重写建模工具并精简数学附录。以独立图表替换原插图，复算重采样、信息准则、矩阵与概率例子。本文件是阶段成果；全书仍在连续修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第六章　建模工具：目标、约束与不确定性 **1**

6.1　假设空间、损失与风险 1

6.2　常用损失速查 2

6.3　凸性是相对具体变量而言的 3

6.4　梯度为零，不保证已经最小 4

6.5　Bootstrap：从经验分布中有放回重采样 5

6.6　AIC 与 BIC：在可比似然下权衡拟合与复杂度 6

6.7　维数灾难：覆盖空间需要多少格子？ 7

6.8　贝叶斯误差：相对给定信息的最佳错误率 8

附录 A　数学速查：为模型计算服务 **9**

A.1　向量、矩阵与乘法形状 9

A.2　内积、范数、秩与行列式 10

A.3　特征值与奇异值：方向、缩放与降维 11

A.4　导数、梯度与链式法则 12

A.5　条件概率与贝叶斯公式 13

A.6　随机变量、期望、方差与协方差 14

A.7　常用分布与样本统计量 15

第六章　建模工具：目标、约束与不确定性

选定模型后，还需要明确学什么、怎样优化、如何解释不确定性。本章把容易混在一起的概念分开：候选函数集合、训练损失、总体风险、正则化与选择准则。

> **三个层次**
> 假设空间限制可选的函数，目标函数决定拟合时的偏好，优化算法决定如何寻找参数。这三个层次共同影响结果，不能只看某个损失的名称就判断模型是否凸、是否泛化良好。

6.1　假设空间、损失与风险

假设空间（Hypothesis Space）$\mathcal{H}$ 是允许选择的预测函数集合。例如 $\mathcal{H} = \{x \mapsto b + wx : b, w \in \mathbb{R}\}$ 包含所有一元仿射函数。集合中的函数不必都与当前样本拟合良好；训练是在集合内作出选择。

单样本损失 $\ell(\hat{y}, y)$ 衡量一次预测的代价。总体风险和经验风险分别为

$$R(f) = \mathbb{E}_{(X,Y)}[\ell(f(X), Y)], \qquad \widehat{R}_n(f) = \frac{1}{n}\sum_{i=1}^{n} \ell(f(\boldsymbol{x}_i), y_i).$$

前者依赖目标新样本分布，后者在实际数据上求平均。训练集平均较小不保证总体风险较小。

训练目标	含义
经验风险最小化	在 $\mathcal{H}$ 内使 $\widehat{R}_n$ 较小。
带正则化的目标	$J(f) = \widehat{R}_n(f) + \lambda\Omega(f)$，$\lambda \geq 0$。
约束形式	在满足如 $\|w\| \leq c$ 的集合内拟合。

Ω 是对模型的惩罚，不是预测方差的直接测量。λ 控制惩罚强度，需要在开发数据内比较。最终评估指标可以与训练损失不同，例如用交叉熵训练、用召回率评估。

6.2 常用损失速查

以下均先定义单样本损失；对相应数据集取平均，才得到平均损失或错误率。

损失	定义	约定
0–1	$\mathbf{1}[\hat{y} \neq y]$	单标签二类或多类。
平方	$(\hat{y} - y)^2$	对大残差较敏感。
绝对	$\lvert\hat{y} - y\rvert$	在零残差处不可微。
Hinge	$\max(0, 1 - ys)$	$y \in \{-1, 1\}$，s 为实值得分。
二元交叉熵	$-y \log p - (1 - y) \log(1 - p)$	$y \in \{0, 1\}$。
类别交叉熵	$-\log p_y$	p_y 为真实类别概率。

对三个真实值 $[1, 2, 3]$ 和预测 $[1, 1, 5]$，残差为 $[0, -1, 2]$，MAE 为 1，MSE 为 $5/3$。平方与绝对损失表达不同的偏好。交叉熵使用自然对数；正确类别概率从 0.8 降到 0.2 时，损失从约 0.223 升到 1.609。

6.2.1 多标签中的逐位错误与整组错误

有 n 个样本、每样本 K 个二元标签时，汉明损失为

$$L_{\mathrm{H}} = \frac{1}{nK} \sum_{i,k} \mathbf{1}[\hat{y}_{ik} \neq y_{ik}].$$

例如真实标签 $[1, 0, 1]$、预测 $[1, 1, 1]$，汉明损失为 $1/3$，要求整组完全匹配的子集 0–1 损失为 1。

> **零概率的数值处理**
>
> 真实类别概率为 0 时，负对数损失趋于无穷。计算中常直接用 logits 与稳定的 log-sum-exp 实现；不要用错误的代数改写掩盖极端数值。

6.3 凸性是相对具体变量而言的

定义域为凸集，且任意 x, z 及 $\alpha \in [0,1]$ 满足

$$f(\alpha x + (1-\alpha)z) \le \alpha f(x) + (1-\alpha) f(z),$$

则 f 为凸函数（Convex Function）。反向不等式定义凹函数（Concave Function）。不同教材可能使用不同中文旧称，本书统一按上述英文与不等式对应。

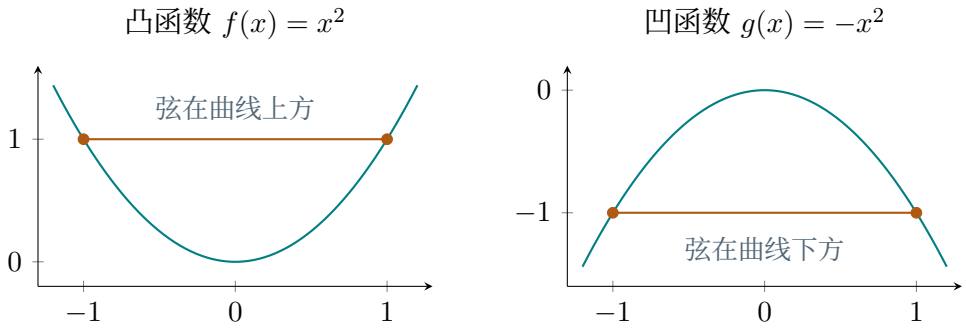


图 6.1: 弦与函数图像的位置关系。线性函数可以同时是凸函数和凹函数。

读图： x^2 的弦不低于曲线；$-x^2$ 的弦不高于曲线。对不同端点和内部权重使用严格不等式，得到严格凸或严格凹。二次可微的一元函数在区间上满足 $f'' \ge 0$ 可判定凸性。

平方损失对预测值 $\hat{y}$ 是凸的，但若 $\hat{y}$ 是参数的非线性函数，训练目标对参数不一定凸。例如 $J(\theta) = (\theta^2 - 1)^2$ 在 $\theta = 0$ 附近非凸。常规线性回归的平方目标对系数凸；一般神经网络的目标则通常非凸。

记住： 判断凸性时，要同时说出函数、变量和定义域。

6.4 梯度为零，不保证已经最小

局部最小值只和附近点比较；全局最小值与整个定义域比较。在内部可微点，局部极小要求梯度为零，但梯度为零只是必要条件之一。

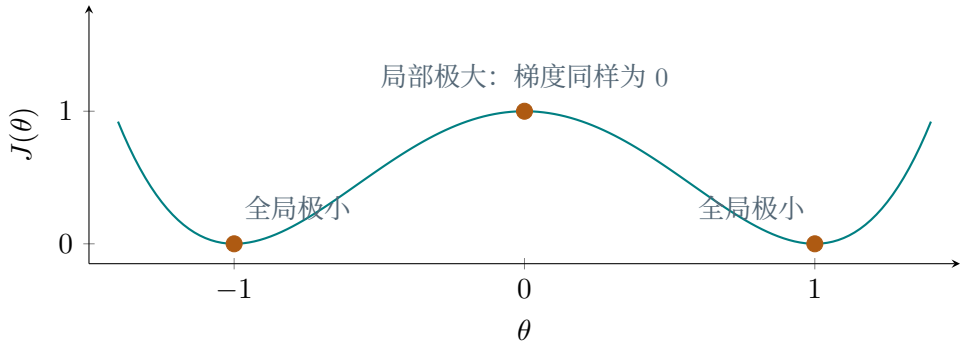


图 6.2： $J(\theta) = (\theta^2 - 1)^2$：导数为 $4\theta(\theta^2 - 1)$。

读图： $\theta = -1, 0, 1$ 处的导数都为 0，但 0 是局部极大值，± 1 是全局极小值。多维非凸函数还可能有鞍点，如 $f(u, v) = u^2 - v^2$ 的原点。

凸函数的任何局部最小值都是全局最小值；严格凸时若最小值存在则唯一。这不表示所有凸函数都能取得最小值，例如 e^x 在实数域内只趋近 0 而不达到。具体算法的收敛还依赖步长、光滑性和其他条件。

> **优化目标与目标分布仍有距离**
>
> 即使找到训练目标的全局最优，也不能单凭这一点证明泛化良好。反之，优化不足也可能造成欠拟合；诊断时应检查数据、模型和优化过程。

6.5 Bootstrap：从经验分布中有放回重采样

自助法（Bootstrap）常从 n 条观测中有放回抽取 n 次，重新计算统计量，用许多次结果近似其抽样变化。重采样的记录可能重复，也可能遗漏。

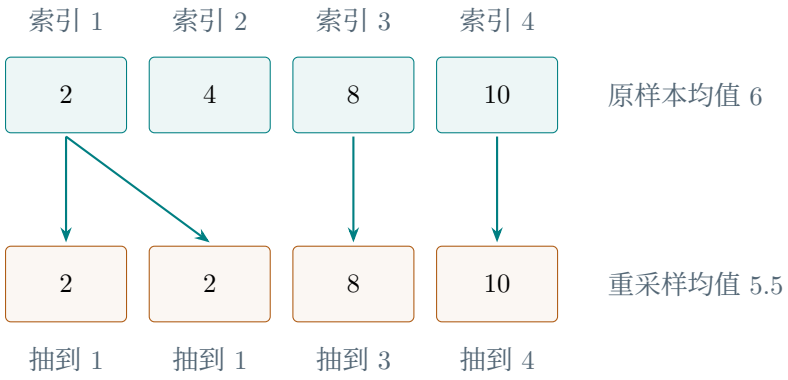


图 6.3： 原样本 $[2, 4, 8, 10]$，一次抽到索引 $[1, 1, 3, 4]$。保持每条记录的所有字段与标签同步。

读图： 这一次均值从 6 变成 5.5；它不是新的独立采集样本。反复重采样可以研究均值等统计量的变动，也可用于 Bagging 训练多个模型。

一条原记录在 n 次抽取中一次都未被抽到的概率为 $(1-1/n)^n$，当 n 很大时趋近 $e^{-1} \approx 0.368$。这解释了袋外记录的来源，不是每次恰好遗漏 36.8% 记录的保证。

> **重采样必须尊重数据结构**
>
> 普通逐行 Bootstrap 依赖近似独立的观测设置。时间序列、同一对象的重复记录等可能需要分块或按组重采样。置信区间方法有不同假设与误差，不能把任意重采样结果自动当成可靠区间。

6.6 AIC 与 BIC：在可比似然下权衡拟合与复杂度

设 $\hat{\ell}$ 为最大化后的**对数似然**，k 为估计参数个数，n 为样本量，常用形式为

$$\mathrm{AIC} = 2k - 2\hat{\ell}, \qquad \mathrm{BIC} = k\log n - 2\hat{\ell}.$$

两者都是在可比候选模型中越小越好。参数个数应按模型完整定义计算；例如高斯回归中，噪声方差若也估计，应计入相应参数数目。

$n = 100$	k	$\hat{\ell}$	AIC	BIC
模型 A	3	-120	246	253.816
模型 B	5	-117	244	257.026

在这个例子中 AIC 选择 B，BIC 选择 A；不同准则有不同目标和推导条件。

6.6.1 比较的前提不能省略

使用同一响应、同一批观测和可比的似然定义。不能直接用不同数据量或任意缩放的损失代替对数似然再比较。AIC 的某些回归专用写法、C_p 或小样本修正形式并非对所有模型通用。

> **不是防止一切过拟合的保证**
>
> BIC 的复杂度项在 $n > e^2$ 时大于 AIC 对应项，但并不自动解决维数灾难、泄漏或分布偏移。这些准则不能代替独立评估，也不是越小的数值就等于越高的分类准确率。

6.7 维数灾难：覆盖空间需要多少格子？

维数灾难（Curse of Dimensionality）描述高维空间中覆盖、距离与统计估计变困难的现象。一个简单例子：每个坐标轴分成 5 份，d 维单位立方体就有 5^d 个小格。

维度 d	1	2	5	10
格子数 5^d	5	25	3125	9765625
1000 样本平均每格	200	40	0.32	0.0001024

即使每格平均一条也不能保证均匀覆盖；这个计数仅帮助理解稀疏性。若希望轴向比例为 r 的邻域覆盖固定概率质量，在独立均匀设置下体积为 r^d，维度增加时会迅速变小。真实数据若集中在低维结构上，实际难度可能不同。

6.7.1 应对方法取决于结构

可以增加有效数据、利用领域约束、做训练内特征选择或降维，并采用合适的正则化。距离方法要特别注意无关列、尺度与表示。支持向量机和树等方法也受数据结构与样本量影响，不能笼统称为“不受维度限制”。

记住：高维不是自动失败；更多特征也不是自动得到更多有效信息。

6.8 贝叶斯误差：相对给定信息的最佳错误率

在 0–1 损失下，知道真实条件概率时，选择概率最大的类别可以最小化条件错误率。二分类记 $\eta(x) = P(Y = 1 \mid X = x)$，则

$$h^*(x) = \mathbf{1}[\eta(x) \geq 0.5], \qquad R^* = \mathbb{E}_X[\min\{\eta(X), 1 - \eta(X)\}].$$

R^* 称为该特征信息与分布下的贝叶斯错误率（Bayes Error Rate）。多分类的条件错误率相应为 $1 - \max_k P(Y = k \mid X = x)$。

输入情形	出现概率	$\eta(x)$	最佳预测	条件错误率
A	0.5	0.9	1	0.1
B	0.5	0.6	1	0.4

总体最佳错误率为 $0.5 \times 0.1 + 0.5 \times 0.4 = 0.25$。这是已知构造分布的计算；真实任务通常不知道精确条件概率，不能直接计算真值。

> **人类表现不是定义中的下界**
>
> 人类可能使用不同特征、不同信息，也可能远未达到最优。人类错误率可以作为有条件的参照，不能自动等同或作为严格估计的贝叶斯误差。增加有效特征可能改变条件分布并降低最佳可达风险。

参考： ISLR 第二版（2021）第 2、5、6 章；Boyd 与 Vandenberghe，*Convex Optimization*（2004），第 3 章。本章例子与图为独立构造，复算见第六批审校记录。

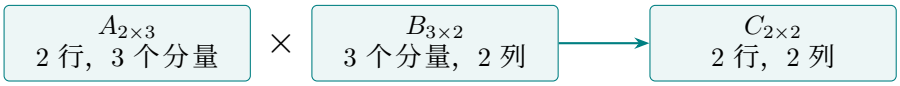
附录 A　数学速查：为模型计算服务

本附录保留理解本书公式最常用的数学工具：形状、内积、矩阵运算、导数、概率与统计量。每个公式都应先确认变量含义与适用条件。无需在开始学习机器学习之前逐页背诵。

> **先检查形状，再检查数值**
> 矩阵相乘看内部维度，梯度应与参数具有相同形状，概率应满足非负与归一化。这三类检查能较早发现许多实现错误。

A.1　向量、矩阵与乘法形状

列向量 $\boldsymbol{x} \in \mathbb{R}^d$ 有 d 个分量；矩阵 $A \in \mathbb{R}^{m\times n}$ 有 m 行 n 列，元素记为 a_{ij}，转置满足 $(A^\top)_{ji} = a_{ij}$。矩阵积 $C = AB$ 的元素为 $c_{ij} = \sum_{k=1}^{n} a_{ik} b_{kj}$。



内部维度相同才能相乘；结果保留外部维度

图 A.1: 例子 $A \in \mathbb{R}^{2\times 3}$、$B \in \mathbb{R}^{3\times 2}$，相乘后为 2×2。

读图：结果每个位置都是左矩阵一行与右矩阵一列的内积。一般 $AB \neq BA$，甚至可能只有一个方向的积有定义。维度合适时，乘法满足结合律。

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \end{bmatrix}, \quad B = \begin{bmatrix} 2 & 1 \\ 1 & 2 \\ 3 & 0 \end{bmatrix}, \quad AB = \begin{bmatrix} 4 & 5 \\ 10 & 2 \end{bmatrix}.$$

例如 $(AB)_{12} = 1\times 1 + 2\times 2 + 0\times 0 = 5$。逐元素乘法 $A \odot B$ 要求相应形状匹配，不是上述矩阵乘法。

记住：批量线性预测常写作 $X\boldsymbol{w} + b\mathbf{1}$：$X$ 为 $n \times d$，$\boldsymbol{w}$ 为 $d \times 1$，结果为 $n \times 1$。

A.2 内积、范数、秩与行列式

内积 $\boldsymbol{x}^\top \boldsymbol{z} = \sum_j x_j z_j$ 衡量方向上的关系。常用范数为

$$\|\boldsymbol{x}\|_1 = \sum_j |x_j|, \quad \|\boldsymbol{x}\|_2 = \sqrt{\sum_j x_j^2}, \quad \|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2}.$$

例如 $(3,-4)$ 的 L1 范数为 7，L2 范数为 5；范数总是非负。矩阵的秩（Rank）是独立列或独立行的最大数目，不等于行数、列数的简单乘积。

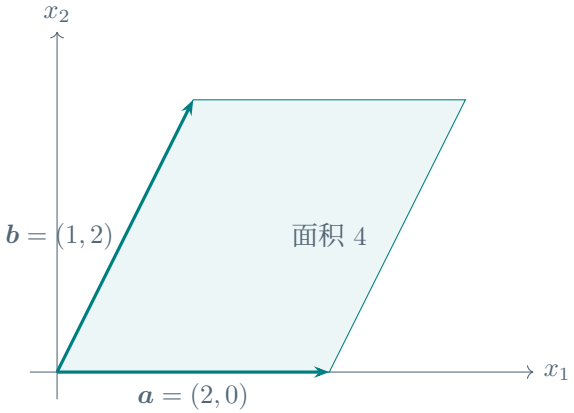


图 A.2: 二维列向量构成的平行四边形，面积为行列式绝对值。

读图： $A = [\boldsymbol{a}\ \boldsymbol{b}] = \left[\begin{smallmatrix} 2 & 1 \\ 0 & 2 \end{smallmatrix}\right]$，$\det A = 2\times 2 - 1\times 0 = 4$，面积为 4。行列式本身有符号，交换两列会变号。

$n \times n$ 方阵的行列式是 n 个特征值的乘积，**不是所有元素的乘积**。$\det A \neq 0$ 等价于方阵可逆。非方阵没有此处定义的行列式。实际求解线性方程常采用稳定分解方法，不必先显式计算 A^{-1}。

A.3 特征值与奇异值：方向、缩放与降维

若非零向量 $\boldsymbol{v}$ 满足 $A\boldsymbol{v}=\lambda\boldsymbol{v}$, 则 λ 是特征值, $\boldsymbol{v}$ 是特征向量。实对称矩阵可写成 $A=Q\Lambda Q^{\top}$, Q 的列为正交单位向量。

工具	用途与条件
正半定	对称矩阵满足 $\boldsymbol{z}^{\top}A\boldsymbol{z}\geq 0$；等价于特征值非负。
奇异值分解 SVD	任意实 $m\times n$ 矩阵可写成 $A=U\Sigma V^{\top}$，奇异值非负。
低秩近似	只保留最大的若干奇异值和相应方向，以压缩矩阵。
PCA 的线性代数	对中心化的数据矩阵作 SVD，或对相应协方差矩阵求特征方向。

例如 $A=\mathrm{diag}(3,1)$ 把两个坐标方向分别缩放为 3 倍、1 倍，奇异值为 3、1。保留第一方向得到 $A_1=\mathrm{diag}(3,0)$，误差 $\|A-A_1\|_F=1$。

> **方向不是自动“有用”的标签信息**
>
> PCA 寻找较大方差方向，不直接使用目标标签，也不保证保留最强预测信号。用于监督流程时，中心化和降维都应在训练内拟合。一般矩阵不一定有实数特征值；SVD 与特征分解不是同一概念。

A.4 导数、梯度与链式法则

一元导数 $f'(x)$ 描述局部变化率；多元标量函数的梯度由各偏导组成：

$$\nabla_{\boldsymbol{w}} J = (\partial J/\partial w_1, \ldots, \partial J/\partial w_d)^\top.$$

在可微条件下，$J(\boldsymbol{w}+\Delta) \approx J(\boldsymbol{w}) + \nabla J(\boldsymbol{w})^\top \Delta$。

函数	导数或梯度
x^p	$p x^{p-1}$（在有定义且可微处）
e^x	e^x
$\log x$	$1/x$，$x>0$
$\sigma(x)=1/(1+e^{-x})$	$\sigma(x)(1-\sigma(x))$
$\frac{1}{2}\lVert\boldsymbol{w}\rVert_2^2$	$\boldsymbol{w}$
$\frac{1}{2n}\lVert X\boldsymbol{w}-\boldsymbol{y}\rVert_2^2$	$\frac{1}{n}X^\top(X\boldsymbol{w}-\boldsymbol{y})$

复合函数 $z=f(g(x))$ 的导数为 $f'(g(x))g'(x)$。多条路径依赖同一变量时，各路径贡献相加，这正是计算图中反向传播的基础。

A.4.1 一个形状与数值检查

$X=\left[\begin{smallmatrix}1&2\\3&4\end{smallmatrix}\right]$、$\boldsymbol{w}=(0.5,-0.25)^\top$、$\boldsymbol{y}=(1,0)^\top$，则残差为 $(-1,0.5)^\top$，$J=0.3125$、$\nabla J=(0.25,0)^\top$。梯度与 $\boldsymbol{w}$ 均为两维列向量。

> **不可微与零梯度**
>
> $|x|$ 在 0 处不可微，可以使用次梯度；ReLU 在 0 处也需实现约定。梯度为 0 不一定是极小值。神经网络反向传播要先正确设置损失与计算依赖。

A.5 条件概率与贝叶斯公式

对事件 A, B，$P(A \cup B) = P(A) + P(B) - P(A \cap B)$。当 $P(B) > 0$ 时，$P(A \mid B) = P(A \cap B)/P(B)$。独立要求 $P(A \cap B) = P(A)P(B)$；互斥事件并不因此独立。

设 $B_1, \ldots, B_K$ 构成互斥且完备的划分，$P(B_k) > 0$，则

$$P(A) = \sum_k P(A \mid B_k)P(B_k), \qquad P(B_j \mid A) = \frac{P(A \mid B_j)P(B_j)}{P(A)}.$$

后一式还要求 $P(A) > 0$。先验 $P(B_j)$、似然 $P(A \mid B_j)$ 与后验 $P(B_j \mid A)$ 的方向不同。

某检测的已知概率	数值
患病先验	$P(D) = 0.01$
患病者检出率	$P(+ \mid D) = 0.90$
未患病者假阳性率	$P(+ \mid \bar{D}) = 0.05$

$$P(D \mid +) = \frac{0.90 \times 0.01}{0.90 \times 0.01 + 0.05 \times 0.99} = \frac{2}{13} \approx 0.154.$$

检出率 90% 并不意味着阳性者有 90% 患病；先验与假阳性共同影响后验。

记住：遇到条件概率，先读清楚竖线两侧，再决定能否交换方向。

A.6 随机变量、期望、方差与协方差

随机变量（Random Variable）把试验结果映射到数值。例如两次抛硬币的正面个数，把四种等可能结果映射到 0、1、2。

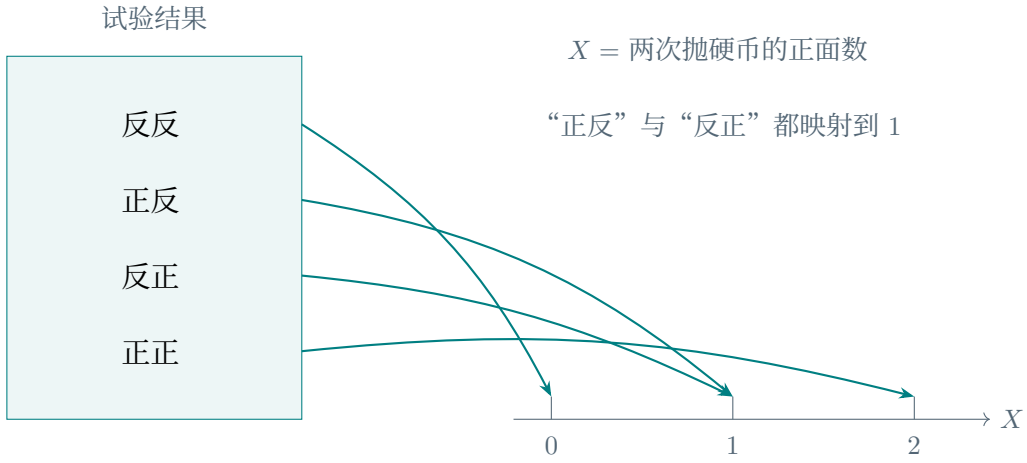


图 A.3: 四种试验结果映射到三个计数值；不同结果可以映射到相同数值。

读图：公平且独立的两次抛掷中，$P(X=0)=1/4$、$P(X=1)=1/2$、$P(X=2)=1/4$，所以 $\mathbb{E}X=1$、$\mathrm{Var}(X)=1/2$。

离散随机变量有 $\mathbb{E}[g(X)]=\sum_x g(x)P(X=x)$；连续情形用密度积分。若相应二阶矩存在，

$$\mathrm{Var}(X)=\mathbb{E}[(X-\mathbb{E}X)^2]=\mathbb{E}[X^2]-(\mathbb{E}X)^2,$$

$$\mathrm{Cov}(X,Y)=\mathbb{E}[(X-\mathbb{E}X)(Y-\mathbb{E}Y)].$$

期望满足线性性，不要求独立；独立且二阶矩有限时协方差为 0，逆命题一般不成立。

> **零相关仍可能有确定依赖**
>
> 令 X 等可能取 $-1,0,1$，$Y=X^2$，则协方差为 0，但 Y 完全由 X 决定。相关系数只反映相应的线性关系，且两变量方差应非零。

A.7 常用分布与样本统计量

概率质量函数直接给离散取值的概率；概率密度需要在区间上积分。密度可以大于 1，例如 $U(0, 0.5)$ 的密度为 2，整个区间概率仍为 1。

分布	质量函数或密度	均值与方差
Bernoulli(p)	$p^x(1-p)^{1-x}$，$x \in \{0,1\}$	p；$p(1-p)$
Binomial(n,p)	$\binom{n}{x}p^x(1-p)^{n-x}$，$x=0,\dots,n$	np；$np(1-p)$
Uniform(a,b)	$1/(b-a)$ 在 $[a,b]$ 内，区间外 0	$(a+b)/2$；$(b-a)^2/12$
Normal(μ,s^2)	$\exp[-(x-\mu)^2/(2s^2)]/(s\sqrt{2\pi})$	μ；s^2

$0 \le p \le 1$，二项 n 为非负整数，均匀分布 $a < b$，正态 $s > 0$。固定 n 次独立同分布 Bernoulli 试验的和才具有上述二项分布。

A.7.1 总体矩与样本估计要区分

对独立同分布观测 $x_1, \dots, x_n$，样本均值为 $\bar{x} = \sum_i x_i/n$。$n > 1$ 时，$s^2 = \sum_i (x_i - \bar{x})^2/(n-1)$ 是总体方差的无偏估计（有限二阶矩）。描述手头数据或某些标准化实现则使用分母 n，应明确约定。对 $[1,2,3]$，均值为 2，分母 n 的方差为 $2/3$，分母 $n-1$ 为 1。

> **大样本结论仍有条件**
>
> 在独立同分布等适当条件下，大数定律说明均值趋近总体期望，中心极限定理描述标准化均值的近似分布。它们不表示任意原始数据都会随着样本增多变成正态。

参考： Deisenroth、Faisal 与 Ong，*Mathematics for Machine Learning*（2020），第 2、4、5、6 章。本附录图与数字例子独立设计；更多计算细节见本项目复核脚本。