机器学习与深度学习：图解速查手册

线性模型与近邻

先建立可靠基线

第七批阶段样章

本批新增详细核查 12 张原图，并处理已核查的回归概念图引用。重写最小二乘、正则化、逻辑回归、多分类和近邻，以独立图表和数字说明。本文件是阶段成果；全书仍在连续修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第七章　线性模型与近邻：先建立可靠基线 **1**

7.1　线性回归与最小二乘 1

7.2　怎样求参数：方程、分解与迭代 2

7.3　多项式回归：改变表示，不增加样本 3

7.4　Ridge：连续收缩系数 4

7.5　Lasso：为什么能够产生零系数? 5

7.6　Elastic Net：同时控制稀疏与收缩 6

7.7　逻辑回归：线性得分对应分类概率 7

7.8　多分类：Softmax 与一对其余 8

7.9　k 近邻：根据局部训练记录预测 9

第七章　线性模型与近邻：先建立可靠基线

线性模型把输入特征组合为一个得分；近邻模型根据相似训练记录预测。二者都适合建立可解释的起点，但依赖不同假设。本章使用统一目标约定比较拟合、正则化和分类扩展。

> **把模型与训练目标配对**
> 连续数值可从平方损失线性回归开始；二分类概率可从逻辑回归开始。特征表示决定“线性”能够表达什么，正则化强度与近邻数则需要训练内验证。

7.1　线性回归与最小二乘

线性回归（Linear Regression）预测 $\hat{y} = b + \boldsymbol{w}^{\top}\boldsymbol{x}$。普通最小二乘（Ordinary Least Squares, OLS）最小化残差平方和，也可以等价地最小化其正比例缩放 $J = \frac{1}{2n}\sum_i (\hat{y}_i - y_i)^2$。

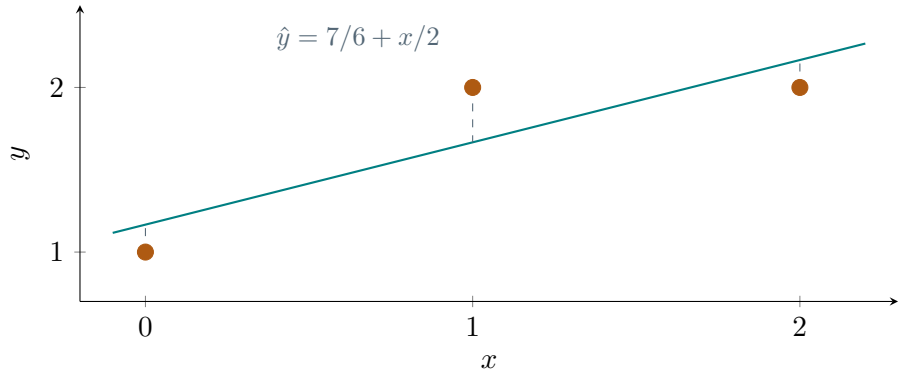


图 7.1： 三个观测 $(0,1),(1,2),(2,2)$ 的最小二乘直线；虚线为竖直残差。

读图： 拟合得到 $w = 1/2$、$b = 7/6$。三个预测为 $7/6, 5/3, 13/6$，按“预测减真实”计的残差为 $1/6, -1/3, 1/6$，平方和为 $1/6$，训练 MSE 为 $1/18$。

7.1.1　线性指的是系数的进入方式

模型可以对 x^2、对数或交互特征作线性组合，仍对系数线性。线性回归本身不要求输入特征服从正态；若要作某些经典置信区间推断，才需额外的误差假设。

记住： 拟合关系不自动具有因果含义；外推到训练范围之外要结合领域结构判断。

7.2 怎样求参数：方程、分解与迭代

将截距作为一列 1 并记增广矩阵为 $\tilde{X}$，系数为 $\boldsymbol{\theta}$。令平方目标梯度为 0，得到正规方程（Normal Equations）

$$\tilde{X}^\top \tilde{X}\boldsymbol{\theta} = \tilde{X}^\top \boldsymbol{y}.$$

只有当列满秩时，才能写 $\hat{\theta} = (\tilde{X}^\top \tilde{X})^{-1}\tilde{X}^\top \boldsymbol{y}$。不满秩时可能有多个最优系数；在样本上的拟合投影仍可确定。

方法	实际考虑
QR 或 SVD 分解	通常比先形成正规方程再显式求逆更适合数值计算；SVD 可处理秩亏。
梯度方法	避免显式矩阵求逆，适合较大或稀疏问题；需考虑尺度、步长和收敛。
闭式表达	有助于理解目标，但不是要求程序照着显式求逆执行。

正规方程不是“大数据时必定首选”或“绝不能用”的二元规则。计算成本与样本数、特征数、稀疏性、条件数及求解器有关。平方目标凸不代表任意步长的梯度下降都能收敛。

> **相关列与数值稳定性**
>
> 重复列或完整独热加截距可能造成秩亏；接近相关的列也可能使系数不稳定。正则化和稳定求解都可以帮助，但用途与假设需要分别理解。

7.3 多项式回归：改变表示，不增加样本

多项式回归（Polynomial Regression）使用 $\phi(x) = (x, x^2, \ldots, x^d)$，预测 $\hat{y} = b + \sum_{j=1}^{d} w_j x^j$。对原输入可非线性，对系数仍线性。

原输入 x	截距列 1	x	x^2
0	1	0	0
1	1	1	1
2	1	2	4

同样三条样本增加了表示列，没有新增独立观测。上一页的目标 $[1, 2, 2]$ 可被 $1 + 1.5x - 0.5x^2$ 精确拟合，但只有三个点不能证明这个二次关系适用于新数据。

7.3.1 次数越高，越要检查数值与泛化

高次幂可能尺度差异很大，并造成病态问题。可结合适当缩放、稳定基函数和正则化。多变量展开还包含交互项，列数可能迅速增加。次数与表示步骤应在训练内选择，不能看完测试结果再决定展开方式。

记住：特征构造扩展了模型可表达的函数；它不是数据增强，也不是免费增加证据。

7.4 Ridge：连续收缩系数

岭回归（Ridge Regression）在本章使用

$$J(\boldsymbol{w}, b) = \frac{1}{2n}\|X\boldsymbol{w} + b\mathbf{1} - \boldsymbol{y}\|_2^2 + \frac{\lambda}{2}\|\boldsymbol{w}\|_2^2, \quad \lambda \geq 0.$$

截距 b 不惩罚。特征已中心化、单独处理截距时，

$$(X^\top X + n\lambda I)\hat{\boldsymbol{w}} = X^\top \boldsymbol{y}.$$

$\lambda > 0$ 时，对全部斜率施加的 L2 惩罚使此系数矩阵正定，即使原矩阵秩亏。

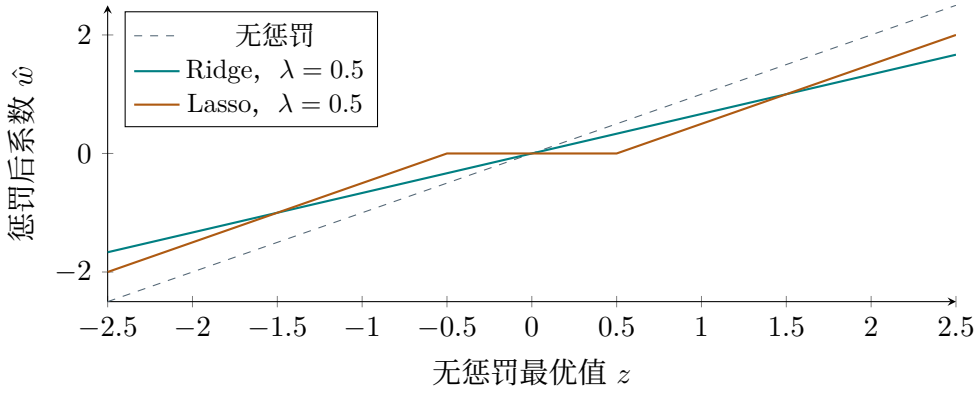


图 7.2: 单系数教学目标 $\frac{1}{2}(w - z)^2$ 上，Ridge 为 $z/(1 + \lambda)$；下页解释 Lasso。

读图： Ridge 通常使系数向 0 收缩，但不能说“绝不等于 0”：当 $z = 0$ 时仍为 0。惩罚强度依赖目标中的 n、$1/2$ 等缩放约定，比较软件参数前需对照完整公式。

尺度会改变同一系数惩罚所代表的限制，数值特征常在训练内标准化。相关特征的单个系数路径可以变化，不能把每个系数都必然单调趋零当作一般定理。

7.5 Lasso：为什么能够产生零系数？

Lasso 使用 $J=\frac{1}{2n}\|X\boldsymbol{w}+b\mathbf{1}-\boldsymbol{y}\|^2+\lambda\|\boldsymbol{w}\|_1$，截距不惩罚。L1 惩罚在 0 处不可微，其几何与次梯度使零系数能够成为最优解。

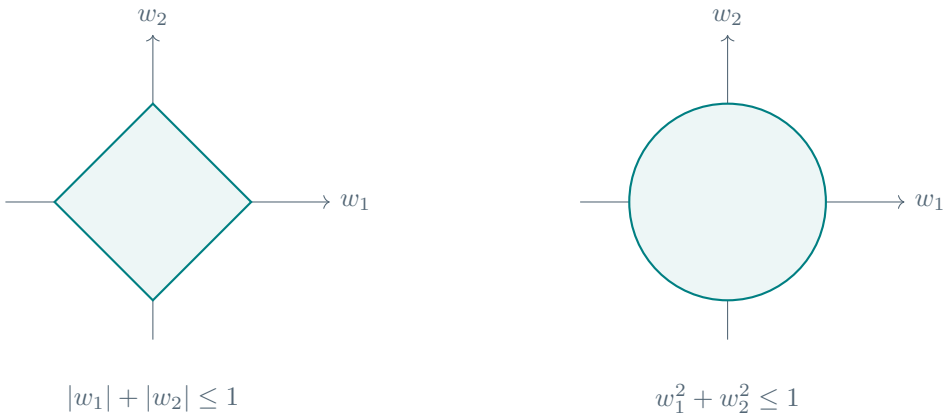


图 7.3: 两个系数的 L1 与平方 L2 约束区域。这里只比较区域形状，未画任意相切等高线。

读图： L1 菱形的角在坐标轴上，一个系数为 0；L2 圆盘边界更平滑。这帮助理解稀疏性，但并不保证每个数据集都选择出真实变量。

对单系数目标 $\frac{1}{2}(w-z)^2+\lambda|w|$，精确解为软阈值

$$\hat{w}=\operatorname{sign}(z)\max(|z|-\lambda,0).$$

当 $z=0.3,\lambda=0.5$，Lasso 系数为 0，Ridge 为 0.2；当 $z=2$ 时，两者分别为 1.5 与 $4/3$。

> **选中不等于因果；未选中不等于永远无用**
> 相关特征可能互相替代，选择结果也可能随样本变化。Lasso 在秩亏等情形下未必有唯一系数解。不能把 L1 也当成保证正规方程可逆的方法。

7.6 Elastic Net：同时控制稀疏与收缩

弹性网络（Elastic Net）结合两种惩罚。本章约定总强度 λ 和混合比例 ρ:

$$J = \frac{1}{2n}\|X\boldsymbol{w} + b\mathbf{1} - \boldsymbol{y}\|^2 + \lambda\rho\|\boldsymbol{w}\|_1 + \frac{\lambda(1-\rho)}{2}\|\boldsymbol{w}\|_2^2, \quad 0 \le \rho \le 1.$$

$\rho = 1$ 得到 Lasso，$\rho = 0$ 得到本章约定的 Ridge。不同软件对 alpha、lambda、l1-ratio 的命名与缩放可能不同，应比较公式。

方法	典型效果	选择时考虑
Ridge	连续收缩，通常保留多数非零系数。	相关列与稳定预测。
Lasso	可以得到零系数。	稀疏表示，选择稳定性。
Elastic Net	结合 L1 与 L2，可同时稀疏与收缩。	相关特征组与两个超参数的权衡。

“特征很多就必须先用 Elastic Net”不是通用规则。应比较基线、特征结构、计算开销和验证表现。若 $\lambda(1-\rho) > 0$，系数目标具有严格的二次惩罚，有助于唯一性；截距仍需按数据与模型定义处理。

记住：正则化表达偏好，不会自动识别哪些特征是真实原因。

7.7 逻辑回归：线性得分对应分类概率

二元逻辑回归（Logistic Regression）令 $p = P(Y = 1 \mid \boldsymbol{x}) = \sigma(s)$，$s = b + \boldsymbol{w}^\top \boldsymbol{x}$，等价于 $\log[p/(1-p)] = s$，即对数几率对特征线性。

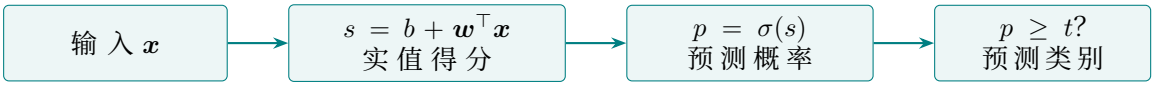


图 7.4: 概率与类别之间还需要决策阈值 t，默认 0.5 只是常见选择。

读图：若 $s = \log 3$，则几率为 3，概率为 $3/4$。阈值 0.5 时预测 1；阈值 0.8 时预测 0。阈值改变决策，不改变已拟合概率函数。

以二元交叉熵拟合时，对单样本得分有 $\partial \ell / \partial s = p - y$。批量参数梯度为 $X^\top(\boldsymbol{p} - \boldsymbol{y})/n$，再加所选正则项。对线性参数的逻辑损失为凸，但无正则且类别完全可分时，有限最优参数可能不存在。

> **线性得分不表示对输入的概率线性**
>
> Sigmoid 后的概率通常随输入非线性变化。普通线性回归直接输出实数，可能超出 $[0, 1]$；逻辑回归为概率建模提供相应结构。概率是否准确反映频率，还需校准与独立评估。

7.8 多分类：Softmax 与一对其余

多项逻辑回归（Multinomial Logistic Regression）为 K 个互斥类别计算得分 s_k，令 $p_k = \exp(s_k)/\sum_j \exp(s_j)$，用类别交叉熵联合拟合。所有得分加同一常数不会改变概率，因此参数识别通常需基准类或其他约束。

方法	怎样训练	输出如何理解
Softmax	一个联合的多分类目标。	类别概率和为 1，面向互斥类别。
一对其余 OvR	每类训练“此类/其余”的二元模型。	独立二元概率不必和为 1；单标签预测需统一比较规则。
多标签	每个标签独立判断是否存在。	允许多个标签同时为真，不应强行 Softmax 归一化。

得分 $[0, \log 2, \log 3]$ 经 Softmax 变为 $[1/6, 1/3, 1/2]$。三个 OvR 二元模型则可能同时输出 $[0.7, 0.6, 0.2]$，它们并非一组已经归一化的互斥概率。有些实现会另外归一化，但须按实现说明解释，不能与联合 Softmax 混为一谈。

记住：先确定标签能否同时出现，再选择输出结构与损失。

7.9 k 近邻：根据局部训练记录预测

k 近邻（k-Nearest Neighbors, KNN）查询最相似的 k 条训练记录。分类可等权投票，回归可平均目标；也可按距离加权，需明确定义零距离的处理。

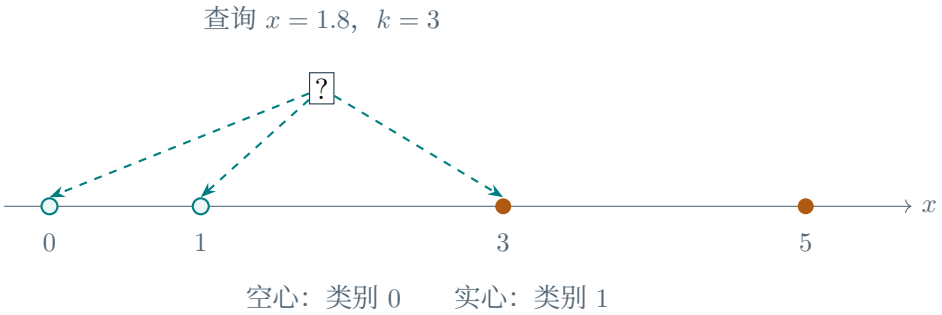


图 7.5: 一维分类例子：训训练位置 0、1 标签为 0，3、5 标签为 1。

读图：查询 1.8 到四点距离为 1.8、0.8、1.2、3.2。三个近邻为 1、3、0，票数 2 比 1，预测 0；若 $k = 1$ 也预测 0，但依据只有最近点。

Minkowski 距离为 $d_p(\boldsymbol{x}, \boldsymbol{z}) = (\sum_j |x_j - z_j|^p)^{1/p}$，$p \geq 1$。$p = 1$ 为曼哈顿，$p = 2$ 为欧氏，$p \to \infty$ 为最大分量差。尺度、相关列和无关特征都会影响“近”的含义，应根据任务设计表示。

> **奇数 k 并不消除所有平票**
>
> 二分类等权投票时奇数可避免两类票数相同；多分类、距离平局或加权规则仍可能平票。KNN 依赖局部相似性假设，也可能受异常点与高维影响。大样本查询成本高，可考虑适合维度与精度需求的索引或近似检索。

参考：ISLR 第二版第 3、4、6 章；scikit-learn Linear Models 与 Nearest Neighbors 文档。本章例子和图独立构造，公式缩放均按正文约定。