机器学习与深度学习：图解速查手册

树、概率模型与集成学习

切分、组合与修正

第八批阶段样章

本批详细核查剩余 10 张在用原图，完成经典算法部分重写。以独立图表和数值例子解释树、朴素贝叶斯、随机森林及两种提升方法。本文件是阶段成果；全书仍在连续修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第八章　树、概率模型与集成学习 **1**

8.1 分类树：按规则进入叶子 1

8.2 回归树：叶子输出常数 2

8.3 树的复杂度与实现边界 3

8.4 朴素贝叶斯：给定类别后作独立近似 4

8.5 概率模型的估计与数值实现 5

8.6 Bagging 与随机森林：让平均更有价值 6

8.7 特征重要性：量的是哪种贡献? 7

8.8 梯度提升：逐步拟合修正方向 8

8.9 AdaBoost：一个完整的二分类权重步骤 9

8.10 投票、Boosting 与 Stacking 怎样选择? 10

第八章　树、概率模型与集成学习

树把输入空间切成若干区域；朴素贝叶斯通过条件分布计算类别后验；集成学习组合多个模型。本章先理解单个预测怎样产生，再解释组合的价值与限制。

> **预测结构决定了检查重点**
>
> 树关注切分与叶子，概率模型关注分布假设和概率方向，集成方法关注模型之间的依赖与组合规则。任何一种训练方法都仍需正确划分、训练内调参和独立评估。

8.1　分类树：按规则进入叶子

决策树（Decision Tree）依次询问特征条件，把输入送到一个叶节点。叶子可给出多数类别或根据训练记录估计的类别比例。下面用八条样本说明一次二元切分。

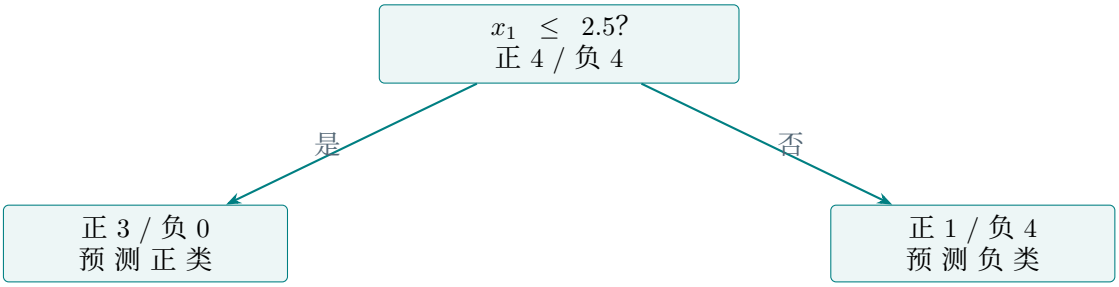


图 8.1：根节点正负各 4 条；左叶 3 条，右叶 5 条。条件按输入特征判断。

读图：真实标签为 $[1,1,1,0,0,0,0,1]$、输入 $x_1 = 0,\dots,7$ 时，阈值 2.5 产生图中计数。右叶仍有一个正样本，所以叶子不一定纯，也不一定全部预测正确。

分类节点的 Gini 不纯度为 $G = 1-\sum_k p_k^2$；熵为 $H = -\sum_k p_k \log_2 p_k$，约定 $0\log 0 = 0$。切分后按子节点样本数加权。此例父 Gini 为 0.5，子节点加权 Gini 为 $\frac{3}{8}\times 0+\frac{5}{8}\times[1-(1/5)^2-(4/5)^2] = 0.2$，下降 0.3。

记住：训练时用标签评价候选切分；预测时沿已确定规则走树，不需要新样本的标签。

8.2 回归树：叶子输出常数

平方损失回归树在区域 R_m 输出训练目标均值 c_m，可写成 $\hat{f}(\boldsymbol{x}) = \sum_m c_m \mathbf{1}[\boldsymbol{x} \in R_m]$。每次尝试特征和阈值，使左右子区域内的残差平方和较小。

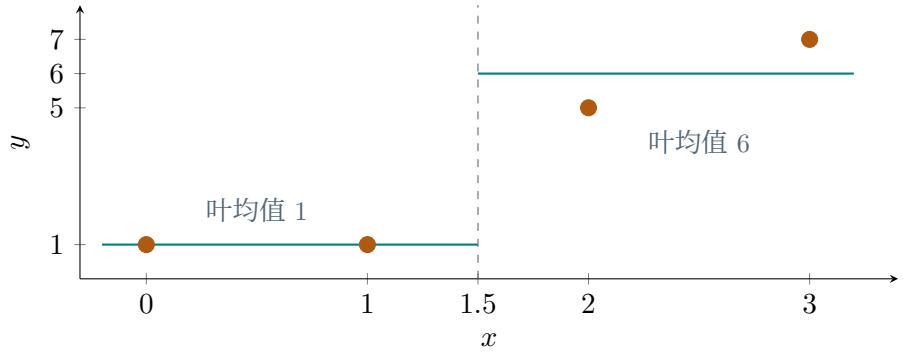


图 8.2: 四条记录 $(0,1),(1,1),(2,5),(3,7)$，在 $x = 1.5$ 切分成两个叶子。

读图：左叶预测 1，右叶预测 6，平方误差和为 0+1+1=2。不切分时输出总体均值 3.5，平方误差和为 27。单次切分降低训练误差，不等于已经证明泛化改善。

叶子均值是在固定区域下平方误差的最优常数；若改为绝对误差，最优常数相应为中位数。常规轴向切分使预测呈分段常数，通常不能像线性趋势那样向训练目标范围之外外推。

> **贪心不等于全局最优树**
>
> 逐节点选择当前最佳切分是局部搜索。它不保证给定深度下找到所有可能树中的最优结构，样本的小变化也可能改变切分。

8.3 树的复杂度与实现边界

树越深、叶子越小，通常越能适应训练样本细节。限制深度、叶子最少样本数、最小增益或作代价复杂度剪枝，都是控制方式。具体参数应在训练内验证，而不是按训练误差一直生长到零。

经典方法	常见选择准则	理解边界
ID3	信息增益	经典形式面向离散分类特征。
C4.5	增益率及相关启发式	用于减轻取值数偏好，非简单任意最大化比值。
CART	分类常用 Gini，回归常用平方误差	二元树；可有不同损失与实现扩展。

原生类别与缺失支持取决于算法和软件版本，不能仅凭“决策树”这个名称假定都支持。常规阈值树一般不需要数值标准化，但无序类别的整数编码仍可能改变可表达的分组。单棵浅树通常容易读；很深的树和大量树的组合则难以完整解释。

记住：树可以表达特征交互；不能笼统说树忽略特征之间的所有关联。

8.4 朴素贝叶斯：给定类别后作独立近似

朴素贝叶斯（Naive Bayes）用类先验 $P(Y=c)$ 及各特征的类条件分布，作近似

$$P(\boldsymbol{x} \mid Y=c) \approx \prod_j P(x_j \mid Y=c), \qquad P(Y=c \mid \boldsymbol{x}) \propto P(Y=c) \prod_j P(x_j \mid Y=c).$$

连续特征应使用相应密度，而非把单点概率写成正数。“朴素”假设是**给定类别后的特征条件独立**，不是要求所有特征无条件独立。

观测 $x_1=1, x_2=0$	类先验	$P(x_1=1 \mid c)$	$P(x_2=0 \mid c)$
类别 1	0.6	0.8	0.5
类别 0	0.4	0.2	0.25

未归一化分数分别为 0.24 与 0.02；归一化得到 $P(Y=1 \mid \boldsymbol{x}) = 12/13 \approx 0.923$。0–1 损失下选择最大后验；错误成本不同则应比较期望成本。

> **不要在后验上再乘一次先验**
>
> 先验已经进入贝叶斯公式。特征强相关时，独立近似可能重复累计证据，分类仍可能有效，但输出概率容易过度自信，需要独立检查。

8.5 概率模型的估计与数值实现

不同朴素贝叶斯版本对输入作不同假设。

版本	常见输入/假设	需要检查
Gaussian NB	类别内数值特征的高斯密度。	方差与分布形态，零方差的稳定处理。
Multinomial NB	词频等非负计数特征。	词典、平滑、非负输入；不是任意有符号数值。
Bernoulli NB	二元是否出现。	出现与未出现都进入相应概率。

对离散计数，平滑可避免训练中未见事件使整项乘积为零。例如有 K 种取值、总计数 N、某取值计数 N_j，加法平滑为 $(N_j+\alpha)/(N+K\alpha)$，$\alpha>0$。实际常用 $\log P(c)+\sum_j \log P(x_j \mid c)$ 计算，再用稳定方式归一化。

8.5.1 MLE、MAP 和后验均值不能混用

MLE 最大化似然，MAP 最大化后验，平方损失下的贝叶斯参数点估计为后验均值。例如硬币 2 次正面、1 次反面，正面概率 θ 的 MLE 为 $2/3$。均匀先验下，后验密度与 $\theta^2(1-\theta)$ 成比例，即 $\mathrm{Beta}(3,2)$ 分布；MAP 为 $2/3$，后验均值为 $3/5$。均匀先验没有让均值也自动等于 MLE。

记住：参数估计的不确定性、模型的预测概率和最终决策规则，是相连但不同的对象。

8.6 Bagging 与随机森林：让平均更有价值

Bagging（Bootstrap Aggregating）在多份有放回重采样数据上拟合模型，再平均或投票。随机森林（Random Forest）进一步在**每个节点的切分**中随机考虑特征子集，常结合 Bootstrap，以减少树之间相似的错误。

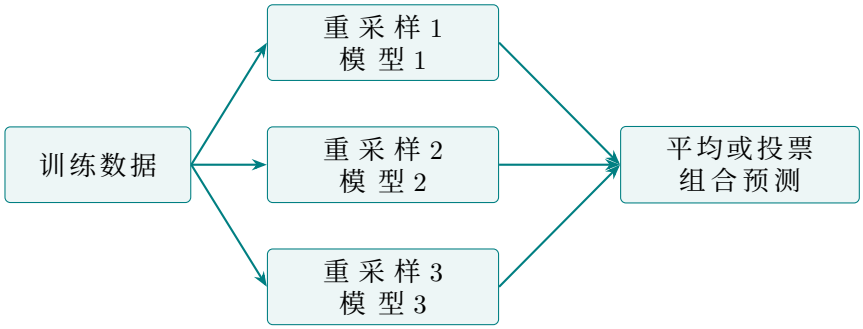


图 8.3: 并列训练与组合示意；仅画三个模型以说明流程。

读图：回归可平均预测。分类可硬投票或平均类别概率后决策，具体要看算法实现。三模型正类概率 0.49、0.49、0.99，硬投票预测 0，但概率均值约 0.657 会预测 1。

若 B 个模型预测方差都为 σ^2、两两相关系数为 ρ，其均值方差为

$$\sigma^2\left[\rho+\frac{1-\rho}{B}\right].$$

$\sigma^2=1,\rho=0.2$ 时，10 模型得 0.28，100 模型得 0.208。这个简化分析说明相关误差不能仅靠无限增加树数消除，不是对所有森林的精确测量公式。

袋外（Out-of-Bag）记录可用于相应评估，但分组、时间约束与数据处理也需保持正确。随机森林能降低单树的高方差风险，仍可能过拟合或遭遇分布变化。

8.7 特征重要性：量的是哪种贡献?

树的不纯度重要性（Mean Decrease in Impurity, MDI）累计某特征参与切分时带来的加权不纯度下降。它反映训练中的使用方式，可能偏向可尝试切分较多的高基数特征。

方法	解释与限制
不纯度重要性	来自训练切分；高基数、相关特征和过拟合可影响排序。
置换重要性	固定已拟合模型，打乱特征后比较评估分数变化；依赖数据、指标与模型。
分组重要性	可把同一原始变量的多个编码列作为一组处理。

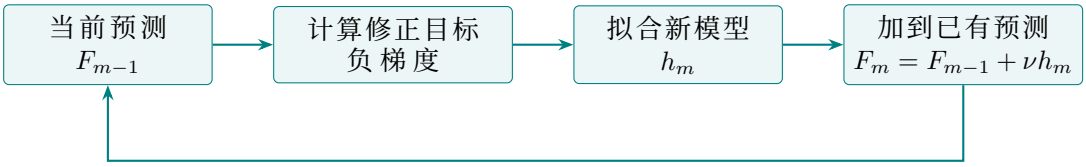
若一个类别变量拆成三个独热列，MDI 分别为 0.10、0.04、0.06，三者求和 0.20 可作为该模型对原变量的汇总，但不自动消除基数偏好。若做分组置换，应对整组使用同一行排列，以保持合法的独热组合；不能随意独立打乱各列。

置换重要性可在开发数据的留出部分计算。若据此反复选择特征或模型，该部分已经参与选择，不能再把其结果当作完全未使用的最终测试。

> **相关特征可能掩盖彼此的重要性**
> 一个特征打乱后，另一个仍提供相似信息，分数下降可能很小。这不等于两者都无信息；高重要性也不证明因果作用。

8.8 梯度提升：逐步拟合修正方向

梯度提升（Gradient Boosting）构建加法模型 $F_m = F_{m-1} + \nu h_m$。新模型拟合当前损失对预测值的负梯度方向；ν 是收缩步长。平方损失时，这个方向恰好是残差 $y_i - F_{m-1}(x_i)$。



下一轮依赖当前组合的预测

图 8.4: 每轮依赖当前预测。一般损失的修正目标不一定是普通数值残差。

读图：目标 $[0, 2, 4]$，初始常数预测为 2。残差 $[-2, 0, 2]$ 若由一个树桩拟合成 $[-2, 1, 1]$，取 $\nu = 0.5$，新预测为 $[1, 2.5, 2.5]$，训练 MSE 从 $8/3$ 下降为 $7/6$。

Boosting 不都通过“给错样本加权”实现；梯度提升也不是只拟合前一棵树的错误，而是针对**当前全部组合**的损失更新。树深、学习率、轮数、采样与正则化共同影响结果。XGBoost、LightGBM 等是相关的树提升实现，细节和默认行为应查具体版本文档。

记住：训练损失下降是一个过程信号；轮数与停止仍应根据合适的验证表现选择。

8.9 AdaBoost：一个完整的二分类权重步骤

经典离散二分类 AdaBoost 使用 $y_i, h_m(x_i) \in \{-1, 1\}$ 及归一化样本权重 $D_m(i)$。

$$e_m = \sum_i D_m(i)\mathbf{1}[h_m(x_i) \neq y_i], \qquad \alpha_m = \frac{1}{2}\log\frac{1-e_m}{e_m},$$

$$D_{m+1}(i) = \frac{D_m(i)\exp[-\alpha_m y_i h_m(x_i)]}{Z_m}, \qquad H(x) = \operatorname{sign}\left(\sum_m \alpha_m h_m(x)\right).$$

Z_m 使权重和为 1；边界、停止与平票需约定。

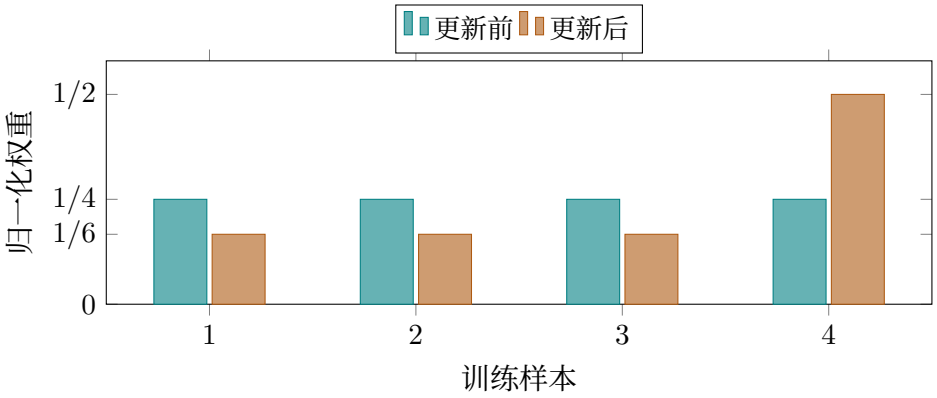


图 8.5: 四个样本初始均为 1/4，仅第 4 个被当前弱模型分错。

读图： $e = 1/4$、$\alpha = \frac{1}{2}\log 3 \approx 0.549$。更新归一化后，错样本权重为 1/2，另外三个各为 1/6；这是相对权重变化，不是重新采集了更多错样本。

若 $e = 0$，应采用相应提前停止/有限数值处理；不能直接除零。若 $e \geq 1/2$，没有上述正权重弱优势，需按算法策略停止或处理，而非机械继续。噪声标签和离群记录可能被反复强调，轮数也需验证。

8.10 投票、Boosting 与 Stacking 怎样选择?

集成不是保证每个模型都正确，而是利用预测之间的差异及组合结构。如果所有模型犯同样的错误，增加数量帮助有限。

方法	模型如何形成	常见检查
Bagging/森林	重采样与随机化后分别拟合。	相关性、叶子限制、袋外/独立验证。
Boosting	根据已有组合逐步添加修正模型。	学习率与轮数、损失、噪声敏感性。
Voting/平均	组合多个已定义的候选模型。	权重、概率与硬标签组合的差别。
Stacking	用基础模型的预测训练一个组合模型。	组合模型需使用折外预测，防止训练预测泄漏。

Stacking 中，基础模型在某样本上的输入给第二层的预测，通常应由未用该样本训练的模型产生。用第一层对自己训练样本的拟合预测直接训练第二层，会让第二层看到过于乐观的输入。最终仍要评估包含预处理、第一层和第二层的完整流程。

8.10.1 自测与回看

森林的树是否必然相互独立? **不是**。梯度提升是否总是修改样本权重? **不是**。贝叶斯后验上是否还要再乘先验? **不需要**。特征重要性是否等于因果作用? **不等于**。

参考： ISLR 第二版第 4、8 章；scikit-learn 的 Decision Trees、Naive Bayes、Ensembles 和 Permutation importance 文档。数字、流程图和权重图均独立构造。