机器学习与深度学习：图解速查手册

间隔、聚类与降维

SVM、K-means 与 PCA

第九批阶段样章

本批详细核查 11 张 to-do 原图，补齐 SVM、聚类和 PCA 基础。以独立图表解释间隔、核相似性、中心更新、轮廓系数及投影方差。本文件是阶段成果；全书仍在连续修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第九章　支持向量机：用间隔约束分类 **1**

9.1　硬间隔与支持向量 1

9.2　软间隔：正确分类也可能付出代价 2

9.3　核函数：在相似性上建立非线性边界 3

第十章　无监督学习：分组与低维表示 **4**

10.1　K-means：分配，再更新中心 4

10.2　选择簇数与轮廓系数 5

10.3　PCA：寻找单位长度的最大方差方向 6

10.4　保留多少主成分：方差与任务一起看 7

10.5　核 PCA 与方法选择的边界 8

第九章　支持向量机：用间隔约束分类

支持向量机（Support Vector Machine, SVM）在分类得分中同时考虑间隔与违例代价。先理解线性情形，再理解核函数如何改变相似性计算。

> **得分不直接等于概率**
> 线性得分 $s = \boldsymbol{w}^\top \boldsymbol{x} + b$ 的符号给出二分类规则。间隔关注样本离决策边界的程度；若需要概率，应另按适当流程估计或校准。

9.1　硬间隔与支持向量

对可线性分开的数据，硬间隔形式最小化 $\frac{1}{2}\|\boldsymbol{w}\|^2$，约束 $y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1$，其中 $y_i \in \{-1, 1\}$。在这个规范化下，两条间隔边界为 $s = \pm 1$，总几何宽度为 $2/\|\boldsymbol{w}\|$。

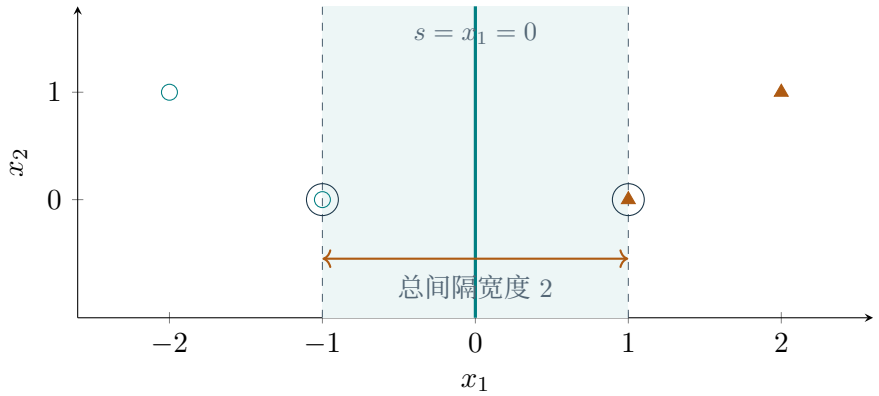


图 9.1： 人工例子 $\boldsymbol{w} = (1, 0)$、$b = 0$，圆形为负类，三角为正类；圈出的点位于间隔边界。

读图： 决策边界 $x_1 = 0$，间隔边界为 $x_1 = \pm 1$，总宽度为 2。在硬间隔解中，贴住间隔约束的点决定边界；对偶中系数 $\alpha_i > 0$ 的训练点称支持向量。

记住： 硬间隔要求可分且对异常记录敏感；不可分时不能机械强制所有约束。

9.2 软间隔：正确分类也可能付出代价

软间隔允许松弛变量 $\xi_i \geq 0$：

$$\min_{\boldsymbol{w},b,\xi} \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_i \xi_i, \qquad y_i s_i \geq 1 - \xi_i, \quad C > 0.$$

最小可行松弛为 $\xi_i = \max(0, 1 - y_i s_i)$，即 Hinge 损失。本式使用损失求和，软件或其他章节若改为平均，参数缩放需相应比较。

正类样本得分 s	最小 ξ	解释
1.2	0	正确且在正侧间隔边界之外。
0.4	0.6	正确，但进入间隔内部。
0	1	在决策边界上，类别取决于平票约定。
-0.4	1.4	落到错误一侧。

$\xi = 0$ 不只表示“恰在间隔边界”；$\xi > 0$ 也不都表示误分类。C 越大，单位违例的惩罚越强，模型通常更努力适应训练约束；这不保证泛化更好。支持向量也可能在间隔内部或被误分，不能仅按“离边界最近”一句话定义全部软间隔情形。

> **尺度会改变几何含义**
> 线性间隔和常见核函数都受输入尺度影响。标准化应在训练内拟合；类别不平衡还可能需要类权重与合适评估，而不是只调整 C。

9.3 核函数：在相似性上建立非线性边界

核函数满足 $K(x,z)=\langle\phi(x),\phi(z)\rangle$，允许在不显式构造全部 ϕ 坐标的情况下计算相应内积。核 SVM 得分可写为 $s(x)=\sum_i \alpha_i y_i K(x_i,x)+b$。常见 RBF 核为

$$K(x,z)=\exp[-\gamma\|x-z\|_2^2], \qquad \gamma>0.$$

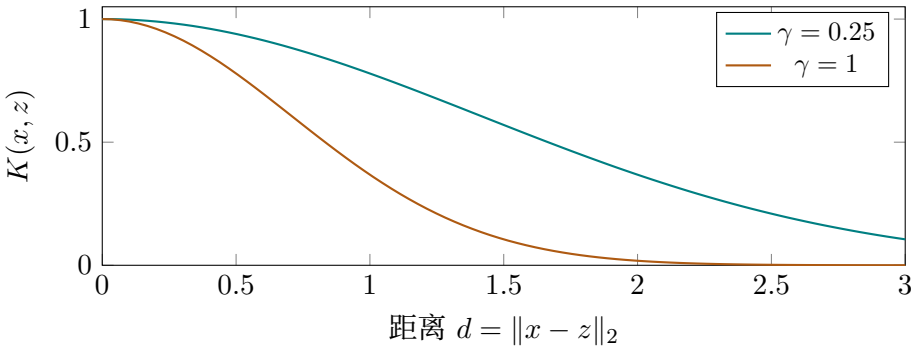


图 9.2: RBF 相似度随距离降低；较大 γ 使影响更局部。

读图：相同点的核值为 1。$x=(0,0)$、$z=(1,1)$、$\gamma=0.5$ 时，核值为 $e^{-1}\approx 0.368$。指数的负号不能省略。核方法也不保证任意数据与标签都能理想泛化。

C 与 γ 通常需要联合验证。核矩阵与求解成本可能随样本数迅速增加，较大任务可比较线性方法、核近似等方案。核相似性、得分和概率各有含义，不能混用。

参考：ISLR 第二版第 9 章；scikit-learn Support Vector Machines 文档。图和数值例子为本书独立构造。

第十章　无监督学习：分组与低维表示

聚类寻找分组，降维寻找较少的表示坐标。没有任务标签时，也要明确距离、结构假设和结果用途。簇编号本身没有类别含义；低维图分得好看也不证明发现了真实类别。

> **先决定什么叫相似，什么值得保留**
> 特征选择和尺度会影响聚类；PCA 保留较大方差方向。这些目标与监督任务的预测准确性不同，需要结合用途评价。

10.1　K-means：分配，再更新中心

K-means 最小化各点到所属中心的平方欧氏距离和：

$$J = \sum_{i} \|\boldsymbol{x}_i - \boldsymbol{\mu}_{c_i}\|_2^2.$$

常用 Lloyd 迭代交替进行最近中心分配与簇内均值更新。

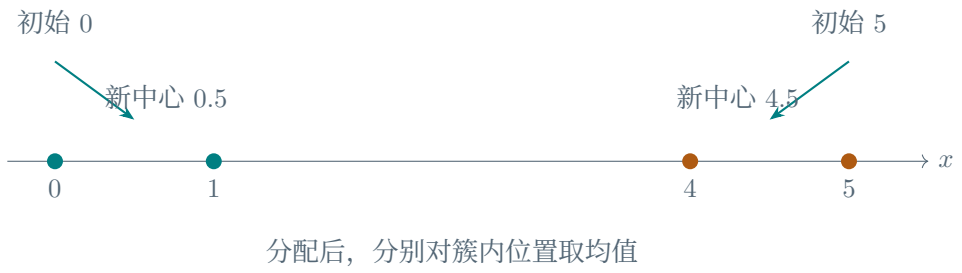


图 10.1：四个一维样本 0、1、4、5，初始中心 0 与 5；一次更新得到 0.5 与 4.5。

读图：初始分组为 $\{0,1\}$、$\{4,5\}$；更新后组内平方和从 2 降到 1。再次分配不变，此例已经稳定。一般迭代不能保证得到全局最优，需考虑初始化和多次运行。

平方距离偏好相应几何中的紧凑分组，异常值可显著移动均值。空簇需要实现约定；混合尺度、非球状结构或密度差异大时，应比较其他方法与表示。K-means++ 改善初始化选择，但不把全局最优变成保证。

10.2 选择簇数与轮廓系数

组内平方和一般随 K 增加而不增，因此不能直接选择其最小值来确定合理簇数。肘部法是观察改进幅度的启发式，未必出现清晰拐点。轮廓系数（Silhouette Coefficient）同时比较簇内和簇间距离。

对样本 i，a_i 是到同簇其他点的平均距离，b_i 是到各其他簇的平均距离的最小值，

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}, \qquad S = \frac{1}{n}\sum_i s_i.$$

常见取值在 $[-1, 1]$，较大表示在该距离定义下更接近本簇、远离最近其他簇。单点簇通常按实现约定取 0；一个簇或每点单独一簇不能按普通定义有效比较。

分组 $\{0,1\},\{4,5\}$	a_i	b_i	s_i
点 0	1	4.5	7/9
点 1	1	3.5	5/7

另外两点对称，总平均为 $47/63 \approx 0.746$。这里用普通一维欧氏距离计算轮廓，不能把 K-means 目标中的平方距离不加说明地代入。

记住：轮廓分数依赖距离和几何，不直接证明分组符合实际用途或真实标签。

10.3 PCA：寻找单位长度的最大方差方向

主成分分析（Principal Component Analysis, PCA）先中心化输入。第一方向最大化投影方差，约束 $\|\boldsymbol{v}\|_2 = 1$；后续方向在与先前方向正交的条件下依次选择。不加长度约束，任意放大系数就能放大方差，问题没有同样意义。

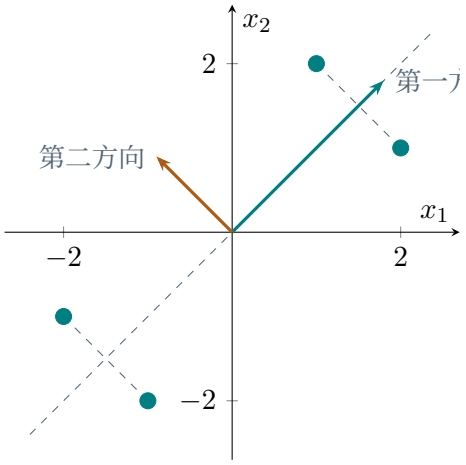


图 10.2： 中心为 0 的四点 $(2,1),(1,2),(-1,-2),(-2,-1)$，第一方向为 $(1,1)/\sqrt{2}$。

读图： 沿第一方向投影后，$(2,1)$ 的坐标为 $3/\sqrt{2}$，重建为 $(1.5,1.5)$。虚线表示丢弃第二方向造成的误差，平方距离为 0.5。第一方向描述输入变化，不直接使用类别标签。

投影坐标为 $Z = X_c V_r$，重建为 $\hat{X} = ZV_r^\top + \mathbf{1}\boldsymbol{\mu}^\top$。中心与方向均在训练内拟合。主成分符号正负可以同时翻转，不改变对应子空间。

10.4 保留多少主成分：方差与任务一起看

采用分母 $n-1$ 的样本协方差时，上页四点的矩阵为

$$S = \begin{bmatrix} 10/3 & 8/3 \\ 8/3 & 10/3 \end{bmatrix},$$

特征值为 6 与 $2/3$，解释方差比例为各特征值除以总和。

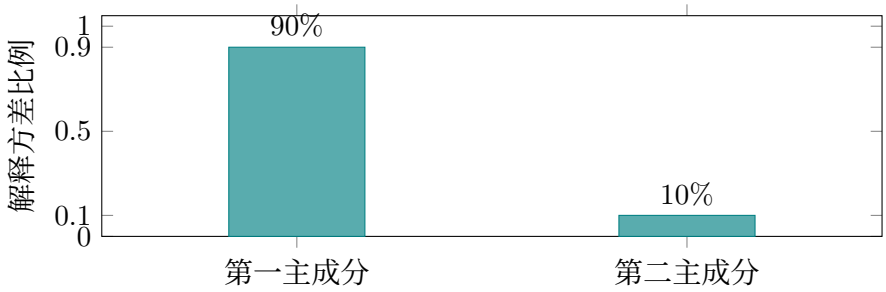


图 10.3：本例第一方向解释 90% 方差，第二方向解释 10%；保留一维后仍有重建误差。

读图：四条记录各损失 0.5 的平方距离，重建误差平方和为 2。若用“至少 90% 方差”规则，本例保留一维；若要求超过 90%，则需两维。

比例阈值是工程选择，不存在普遍正确的 95% 或 99%。较小方差方向也可能包含重要预测信息；应把 PCA 与后续模型一起在训练内验证。PCA 通常中心化，但是否标准化取决于单位和目标；标准化会改变所优化的方差结构。

记住：解释方差比例描述这个表示对输入变动的保留，不等于保留同比例的“所有有用信息”。

10.5 核 PCA 与方法选择的边界

核 PCA（Kernel PCA）在核所对应的特征空间中进行 PCA，可形成非线性表示。训练核矩阵也要在该特征空间中心化，常写为 $K_c = HKH$，$H = I - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$。

方法	主要目标	不能直接推断
K-means	降低簇内平方距离。	得到的簇自动等于真实类别。
线性 PCA	用正交方向保留较大输入方差。	高解释方差就保留最强标签信号。
核 PCA	在核特征空间中寻找主成分。	降维后一定线性可分或可无损重建。

核与超参数决定表示；核空间的方差不能不加区别地解释为原输入单位下的方差。新点的变换要沿用训练中心化规则；一般核表示的原空间逆映射并不自动存在。对初学者，应先建立线性 PCA 与简单聚类基线，再决定是否需要非线性方法。

10.5.1 自测与回看

$\xi = 0$ 是否只表示在 SVM 间隔边界? **不是**。轮廓系数是否直接使用组内平方和? **不是**。PCA 保留 90% 方差是否保证保留 90% 预测能力? **不能**。核 PCA 是否保证任何标签线性可分? **不能**。

参考： ISLR 第二版第 12 章；MML 第 10 章；scikit-learn Clustering 与 Decomposition 文档。图和数字例子独立构造。