卷积网络

共享局部计算

第十批阶段样章

本批核查张量、参数共享、数据增强 3 张相关原图，独立补写 CNN 架构。以新矢量图与算例解释卷积、形状、参数量、池化、残差及完整分类器。本文件是阶段成果；全书仍在连续修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第十章　卷积网络：共享局部计算 **1**

10.1 张量形状：批量、通道与空间 1

10.2 一次卷积怎样得到一个数？ 2

10.3 通道与参数共享：参数数怎样算？ 3

10.4 步幅、填充与输出大小 4

10.5 池化与理论感受野 5

10.6 残差连接：为变换加一条直接路径 6

10.7 归一化层：统计量在哪些轴上计算？ 7

10.8 数据增强：保持任务语义的变化 8

10.9 一个完整小网络：形状与参数对照 9

第十章　卷积网络：共享局部计算

卷积神经网络（Convolutional Neural Network, CNN）把局部连接与参数共享结合起来，适合处理具有网格结构的输入。理解 CNN 时，先跟踪形状、一次局部计算和参数数量，再理解多层组合怎样形成表示。

> **同一个核，在多个位置重复使用**
> 一个卷积核在不同空间位置使用同一组权重。这能减少参数，并表达对局部模式重复出现的偏好；它不保证对所有位置变化完全不敏感。

10.1　张量形状：批量、通道与空间

深度学习程序中的张量（Tensor）通常指多维数组。图像批量常用 NCHW 或 NHWC 布局；字母顺序决定轴的含义，不能只看数组有几维。本章统一用 B, C, H, W 表示批量、通道、高、宽。



NCHW 布局示例：$X \in \mathbb{R}^{8\times3\times32\times32}$

图 10.1: 8 张 32×32 的 RGB 图像，按通道在前布局存储。每个通道不是一条独立样本。

读图：共有 $8 \times 3 \times 32 \times 32 = 24576$ 个数值。卷积通常在每张图像上独立进行，跨输入通道加权求和，不把批量轴当空间轴滑动。

标量、向量、矩阵分别可以作为 0 阶、1 阶、2 阶数组；这里的“阶/轴数”不要与矩阵秩或特征数混用。改变轴顺序需要相应置换，单纯 reshape 通常不能代替布局转换。

记住：每层都记录输入、输出的轴顺序与形状，比仅画一个三维方块更容易检查实现。

10.2 一次卷积怎样得到一个数?

常见深度学习库称为“卷积”的操作实际按不翻转核的互相关（Cross-correlation）实现。单通道、步幅 1、无填充时，$Y_{ij} = b + \sum_{u,v} K_{uv} X_{i+u,j+v}$。数学上的离散卷积常还包含核翻转，读公式时需声明约定。

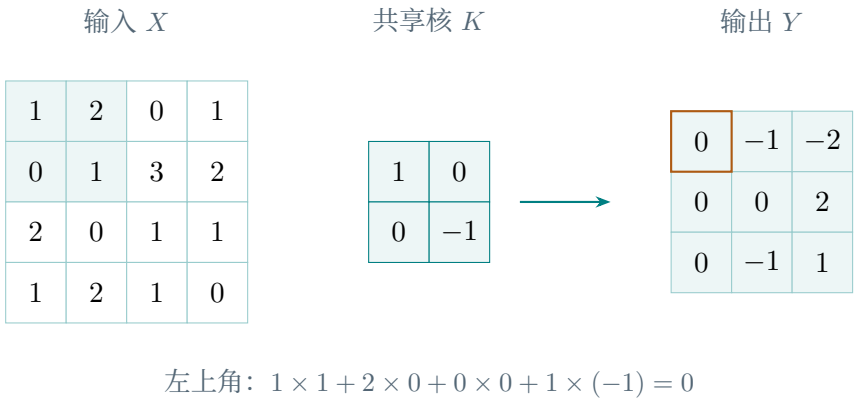


图 10.2: 4×4 输入、2×2 核，偏置 0；每次移动一格，得到 3×3 输出。

读图：核左上位置乘 1、右下位置乘 −1，其余乘 0。在输入左上 2×2 块计算得 0；向右一格得到 $2-3=-1$。输出每个位置都复用同一组四个权重。

核权重通常由损失与反向传播学习，不能一概说每个核固定是边缘检测器。叠加非线性使多层网络能表达更复杂关系；若只叠加线性或仿射层而没有非线性，整体仍是线性或仿射映射。

> **特征图不是原图的复制**
> 输出位置表示某个局部加权计算的结果。空间大小、通道数与原输入可能不同，数值也不必在原像素范围内。

10.3 通道与参数共享：参数数怎样算?

普通非分组二维卷积中，每个输出通道都有覆盖所有输入通道的核:

$$Y_{o,i,j} = b_o + \sum_{c=1}^{C_{\text{in}}} \sum_{u,v} K_{o,c,u,v} X_{c,i+u,j+v}.$$

$k_h \times k_w$ 核、每输出通道一个偏置时，参数数为

$$C_{\text{out}}(C_{\text{in}} k_h k_w + 1).$$

若不使用偏置，去掉最后的 C_{out}；分组卷积要按分组方式另算。

相同 3×3 输出的教学比较	参数数	连接方式
4×4 单通道输入，2×2 卷积	$4 + 1 = 5$	9 个位置共享一个核与偏置。
同样局部窗口，但各位置不共享	$9(4 + 1) = 45$	每位置单独学习。
完全连接到 9 个输出单元	$9(16 + 1) = 153$	每单元连接全部 16 输入。

较大的例子：3 输入通道、16 输出通道、3×3 核，共 $16(27 + 1) = 448$ 个参数。同一层参数数不随批量或图像宽高增加而增加，但计算量和激活内存会增加。

记住：通道汇总、空间滑动和批量独立，是三种不同的轴操作。

10.4 步幅、填充与输出大小

对某一空间轴，输入长度 L、两侧各填充 p、核大小 k、步幅 s、膨胀率 d，常用输出长度为

$$L_{\text{out}} = \left\lfloor \frac{L + 2p - d(k-1) - 1}{s} \right\rfloor + 1.$$

有效核跨度为 $d(k-1)+1$。公式假定参数有效、使用通常的向下取整规则，某些自动 padding 或池化的 ceil 模式需要另按接口约定。

例子	L	k	p	s	d	输出
无填充小例子	4	2	0	1	1	3
保持 32 长度	32	3	1	1	1	32
步幅 2 降采样	7	3	1	2	1	4
膨胀核示例	7	3	0	1	2	3

Padding 在边缘提供约定的额外数值，例如 0；它不是自动补回真实图像信息。Stride 跳过部分位置，Dilation 拉开核采样点间隔；二者对输出大小与感受野的作用不同。

> **“same”不总等于宽高完全不变**
> 一些接口在步幅 1 下维持大小，在步幅大于 1 时按特定规则产生约 L/s 的输出。使用文字模式时，应查接口的填充与非对称边界约定。

10.5 池化与理论感受野

池化（Pooling）按局部窗口汇总数值，常见最大池化和平均池化通常没有可学习权重。它们可减少空间大小，但也可能丢失位置或细节信息。

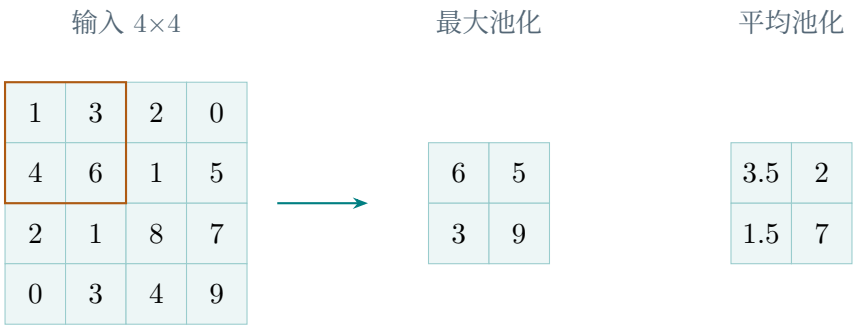


图 10.3: 两个独立的 2×2 池化例子；最大与平均不是要依次串联的两步。

读图： 左上块 $[1,3;4,6]$ 最大值为 6，均值为 3.5。最大池化的反向梯度流向取得最大值的位置；出现相等最大值时需按实现约定处理。

一个输出所能依赖的输入区域称感受野（Receptive Field）。令初始跨度 $r_0 = 1$、相邻位置间距 $j_0 = 1$，则

$$r_l = r_{l-1} + [d_l(k_l - 1)]j_{l-1}, \qquad j_l = j_{l-1}s_l.$$

3 核步幅 1 卷积后，$r = 3, j = 1$；2 核步幅 2 池化后，$r = 4, j = 2$；再接 3 核步幅 1 卷积，$r = 8, j = 2$。这是理论依赖跨度，不表示该区域内每个像素影响完全相同。

记住： 共享卷积常带来平移等变倾向；步幅、填充和边界会影响它，池化也不保证任意平移不变。

10.6 残差连接：为变换加一条直接路径

残差块（Residual Block）把一个变换 $F(x)$ 与输入相加：$y = x + F(x)$。当 $F(x) = 0$ 时，可以直接实现恒等映射；这为深层网络的信息与梯度提供另一条路径。

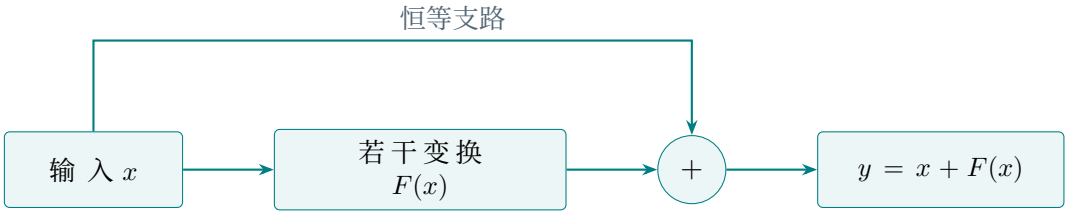


图 10.4: 最简残差结构示意，未规定卷积、归一化和激活的具体顺序。

读图：两条支路的输出形状必须能逐元素相加。若通道数或空间大小变化，可用相应投影/下采样支路 $P(x)$，成为 $y = P(x) + F(x)$。

在形状一致、可微设置中，局部 Jacobian 为 $I + \partial F/\partial x$。这说明直接路径的存在，但不意味着梯度永不消失或训练必定成功。不同 ResNet 变体的归一化与激活位置不同，应按具体结构计算。

> **相加与拼接不同**
>
> 相加要求对应位置具有兼容形状，输出通道数通常不增加。拼接（Concatenation）沿指定轴保留两组特征，会改变该轴长度。不要因为图中都是两条箭头汇合，就把两种操作视作同一个运算。

10.7 归一化层：统计量在哪些轴上计算?

Batch Normalization（BN）训练时按约定轴计算均值与方差，再进行可学习的缩放与平移：

$$\hat{x} = \frac{x - \mu}{\sqrt{v + \epsilon}}, \qquad y = \gamma \hat{x} + \beta.$$

CNN 中常为每个通道在批量和空间位置上汇总。$\epsilon > 0$ 用于数值稳定，γ, β 为可学习参数，统计量不是同一种参数。

层/阶段	常见统计范围	预测时的考虑
BN 训练	同通道的批量与空间位置。	训练批量影响统计，常维护滑动估计。
BN 推理	通常使用保存的滑动统计。	需切换到适当模式，不能默认仍用当前批量。
Layer Normalization	单条记录约定的特征轴。	通常训练/推理都按该条输入计算，无批量滑动统计。

简单两值 $x = [1, 3]$，$\mu = 2, v = 1$，$\gamma = 1, \beta = 0$ 时，输出为 $[-1, 1]/\sqrt{1 + \epsilon}$。方差估计和滑动更新的细节取决于框架，不能把所有实现的分母约定混为一谈。

记住：训练/推理模式与是否记录梯度是不同开关；归一化也不会自动把分布变成正态。

10.8 数据增强：保持任务语义的变化

数据增强（Data Augmentation）在训练中构造合理变换，让模型学习任务所允许的变化。它是建模假设，不是“加入任意噪声都能大幅改善表现”。

操作	必须同时考虑
裁剪、翻转、旋转	是否改变标签？方向识别、数字或医学左右侧任务可能不适合某些变换。
亮度或颜色扰动	是否仍处于真实采集的合理范围？颜色本身可能是目标信号。
检测与分割变换	框、掩码与图像使用同一几何变换。
训练数据派生记录	先按原对象/时间划分，再在训练内增强，避免同源副本跨验证测试。

增强样本通常与原记录相关，不能当作独立新增的真实对象来估计有效样本量。验证与测试使用约定的确定性处理；测试时增强若使用，应作为完整评估方案明确报告。

> **共享权重不保证识别所有位置**
>
> 参数共享使相同局部计算在多处可用；识别完整对象仍依赖训练分布、上下文与后续层。CNN 对旋转、尺度和任意位置变化的鲁棒性不是自动得到的保证。

10.9 一个完整小网络：形状与参数对照

下面是用于说明计算的小型 10 类图像分类器，不代表对任何任务的最佳架构。卷积采用 3 核、步幅 1、填充 1，池化采用 2 核、步幅 2。

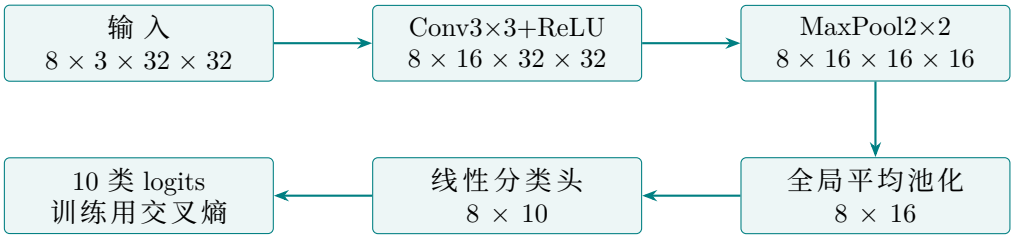


图 10.5: 蛇形箭头按顺序连接，批量轴 8 始终保留；最后输出尚未归一化的 logits。

读图：卷积有 448 个参数；线性头 16 输入、10 输出，含偏置共 170 个参数。ReLU、池化和全局平均池化无可学习参数，本例总计 618 个参数。

全局平均池化（Global Average Pooling）对每通道的空间位置取平均，把 $8 \times 16 \times 16 \times 16$ 变为 8×16，不对批量或通道轴求平均。训练时常把 logits 直接交给包含稳定对数运算的交叉熵接口，避免重复 Softmax。

10.9.1 自测与回看

图像宽高翻倍，卷积参数会自动翻四倍吗？**共享核参数不变，计算与激活内存会增大**。张量 4 轴是否代表四维特征空间的四个特征？**不是，必须看每轴含义**。残差相加是否与通道拼接相同？**不同**。

参考：Goodfellow 等，*Deep Learning*（2016）第 9 章；He 等，*Deep Residual Learning for Image Recognition*（2016）；PyTorch Conv2d、Pooling 与 Normalization 文档。图和例子为独立构造。