机器学习与深度学习：图解速查手册

文本、序列与注意力

从词袋到 Transformer

第十一批阶段样章

本批详细核查 6 张文本表示原图，并独立补写 RNN、门控网络和 Transformer。用新图与算例连接 Token、稀疏/稠密表示、共享状态、注意力与信息遮罩。本文件是阶段成果；全书仍在连续修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第十一章　文本表示：从符号到模型输入 **1**

11.1 Tokenization、词干与停用词 1

11.2 词袋与 TF-IDF：可解释的稀疏基线 2

11.3 嵌入与 Word2Vec：学习稠密向量 3

第十二章　序列与注意力：共享状态与动态汇总 **4**

12.1 RNN：同一组权重逐位置更新状态 4

12.2 LSTM 与 GRU：门控制信息更新 5

12.3 注意力：查询键，再汇总值 6

12.4 因果与填充遮罩：在 Softmax 之前处理 7

12.5 多头注意力：多组投影再拼接 8

12.6 Transformer 块：注意力、前馈与残差 9

12.7 编码器、解码器与下一 Token 目标 10

12.8 比较架构，同时检查时间与内存 11

第十一章　文本表示：从符号到模型输入

文本要先转成模型能处理的表示。词袋、TF-IDF 与嵌入向量保留的信息不同，并非一个必然比另一个更高级。先用简单基线理解任务，再决定是否需要序列与上下文模型。

> **符号编号没有大小距离含义**
>
> Token ID 是查表索引，不表示语义的高低远近。词典、分词规则与模型输入必须一致；需要从当前数据学习的词典和文档频率，应在训练内拟合。

11.1　Tokenization、词干与停用词

Tokenization 把文本切成处理单元（Token），可以是词、子词、字符等。中文不必按空格切分，词干提取也不是所有语言和模型都需要的步骤。

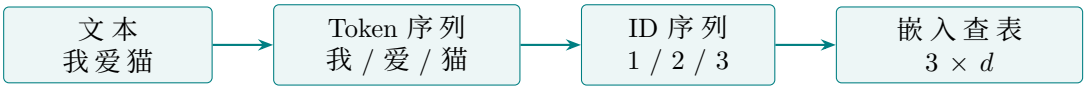


图 11.1： 一个人工分词与词典例子，词典含 PAD=0、我 =1、爱 =2、猫 =3。实际系统可采用不同切分。

读图： 三项 ID 查三行嵌入，得到三条向量。ID 为 3 不表示“猫”是“我”的三倍。验证与上线必须沿用同一词典及未知 Token 处理规则。

处理	作用与限制
词干提取 Stemming	按规则缩减词形，输出未必是语言学词根或完整单词。
词形还原 Lemmatization	试图还原词元，可能依赖词性或语言资源。
停用词 Stop words	某些任务过滤高频功能词；否定、语气等也可能是关键信息，不能默认全删。

记住：“不喜欢”中的“不”可能决定情感标签；文本清洗必须与任务语义一致。

11.2 词袋与 TF-IDF：可解释的稀疏基线

词袋（Bag of Words）把文档表示为词典上的计数或出现指示向量。它忽略词序：“猫追狗”与“狗追猫”在相同分词下可以具有相同词袋，但含义不同。指示值 0/1 不是一个“二元分类器”，只是特征数值。

文档/词典	猫	狗	看	跑
D1：猫看猫	2	0	1	0
D2：狗看	0	1	1	0
D3：猫跑	1	0	0	1
文档频率 df	2	1	2	1

TF-IDF 组合词频与逆文档频率。本例使用原始计数 tf、自然对数和平滑式

$$idf(t) = \log \frac{1+N}{1+df(t)} + 1, \qquad v_{d,t} = tf(t,d)\, idf(t),$$

其中 $N = 3$, df 按出现该词的**文档数**计, 不是总次数。“猫”和“看”的 $idf = 1+\log(4/3) \approx 1.288$, 另外两项为 $1 + \log 2 \approx 1.693$。若再作 L2 归一化，D1 变为 $[2/\sqrt{5}, 0, 1/\sqrt{5}, 0]$。

不同实现有不同 TF、平滑与归一化约定，应报告完整设置。常见词权重降低不代表它没有语义价值，稀有词权重高也不证明它具有预测或因果作用。

记住：词典与 IDF 从训练数据学习，随后固定用于验证、测试和新文档。

11.3 嵌入与 Word2Vec：学习稠密向量

嵌入（Embedding）用矩阵 $E \in \mathbb{R}^{V \times d}$ 为 V 个 Token 存储 d 维向量。长度 T 的 ID 序列查表得到 $T \times d$ 矩阵，批量后常为 $B \times T \times d$。仅嵌入矩阵就有 Vd 个参数；PAD、未知词和是否冻结按实现设计。

Word2Vec 通过局部上下文预测等目标学习词向量，典型形式包括 CBOW 与 Skip-gram。上下文相似可能产生向量相近，但相似性和类比关系是数据与训练的结果，不是对任意词都成立的语义定理。词向量还可能保留语料中的偏差。

表示	同一 Token 在不同句子中	常见考虑
词袋/TF-IDF	对应固定词典列。	简单、稀疏；通常忽略顺序。
静态词嵌入	查同一行向量。	稠密；多义词共享初始表示。
上下文表示	经序列/注意力层后可随上下文变化。	需要位置、遮罩及更复杂训练。

预训练嵌入可冻结后作为特征，也可以随任务微调。预处理应与预训练模型约定一致，不能任意删词、改变 Token 划分后仍假定原模型语义不变。

参考： Manning 等，*Introduction to Information Retrieval*（2008）第 6 章；Mikolov 等（2013）的 Word2Vec 工作；scikit-learn Text feature extraction 文档。本章表格与流程图独立设计。

第十二章　序列与注意力：共享状态与动态汇总

序列模型需要处理位置之间的依赖。RNN 按顺序更新状态，注意力根据当前表示计算位置之间的权重。本章沿着输入形状、计算路径与可见信息，建立 RNN、门控结构和 Transformer 的基本联系。

> **能看到什么，是模型定义的一部分**
> 离线阅读整段文本与根据历史预测未来，允许的信息不同。双向处理、填充遮罩与因果遮罩必须围绕任务设定，不能仅把它们当作程序选项。

12.1　RNN：同一组权重逐位置更新状态

基本循环神经网络（Recurrent Neural Network, RNN）可写为

$$\boldsymbol{h}_t = \tanh(W_x \boldsymbol{x}_t + W_h \boldsymbol{h}_{t-1} + \boldsymbol{b}).$$

若输入维度 d、状态维度 h，则 $W_x \in \mathbb{R}^{h\times d}$、$W_h \in \mathbb{R}^{h\times h}$。同一组参数在所有位置复用，序列加长不自动增加这组参数数量。

三个位置使用同一组权重，不是三个独立模型

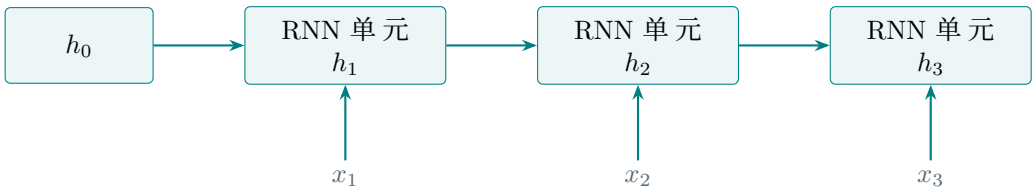


图 12.1： 展开三个位置只是展示计算依赖，横向箭头传递状态。

读图： 标量例子 $h_t = \tanh(x_t + 0.5h_{t-1})$，$h_0 = 0$、输入 $[1, 0, -1]$，得到约 $[0.762, 0.363, -0.674]$。同一个输入值出现在不同历史后，可以产生不同状态。

反向传播通过时间（Backpropagation Through Time, BPTT）沿展开图计算，共享参数在各位置的贡献需要相加。长路径上的 Jacobian 连乘可能导致梯度消失或爆炸；截断 BPTT 限制回传长度，裁剪可帮助控制爆炸，但两者都不是保证学到所有长期依赖。

记住： 双向 RNN 可以利用前后文，因而不能直接用于当时不可获得未来输入的实时预测。

12.2 LSTM 与 GRU：门控制信息更新

长短期记忆网络（Long Short-Term Memory, LSTM）的经典形式用 Sigmoid 门与候选状态控制更新：

$$\boldsymbol{c}_t = \boldsymbol{f}_t \odot \boldsymbol{c}_{t-1} + \boldsymbol{i}_t \odot \widetilde{\boldsymbol{c}}_t, \qquad \boldsymbol{h}_t = \boldsymbol{o}_t \odot \tanh(\boldsymbol{c}_t).$$

遗忘门 f、输入门 i、输出门 o 分别由当前输入和前一状态的仿射变换经 Sigmoid 得到；候选 $\tilde{c}$ 常用 tanh。c 为记忆单元，h 为输出状态，$\odot$ 表示逐元素乘法。

结构	主要区别
基本 RNN	直接由输入与旧状态生成新状态，路径反复经过同类非线性。
LSTM	有 c 与 h 两种状态，门控制旧记忆保留、候选写入与输出。
GRU	通常只有一个状态，用更新门与重置门组合旧状态和候选。

一种 GRU 约定为 $h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \widetilde{h}_t$，候选依赖输入与 $r_t \odot h_{t-1}$。不同文献可对 z 采用互补命名，读实现时要对照公式。LSTM 的 i 与 f 一般独立，不要求两者之和为 1。

标量 LSTM 例子 $c_{t-1} = 2, f = 0.9, i = 0.2, \widetilde{c} = -0.5, o = 0.8$,则 $c_t = 1.7, h_t = 0.8 \tanh 1.7 \approx 0.748$。门控提供更适合保留状态的路径，但并不保证永远记住所有历史。

12.3 注意力：查询键，再汇总值

缩放点积注意力（Scaled Dot-Product Attention）为

$$\mathrm{Attn}(Q,K,V)=\mathrm{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}+M\right)V.$$

Softmax 逐行作用。Q 是查询（Query），K 是键（Key），V 是值（Value），M 指定允许关注的位置；键与值的行数必须对应。

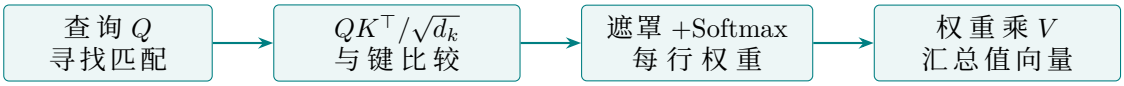


图 12.2: 键参与计算匹配分数，值提供被加权汇总的内容；两者职责不同。

读图：一个查询 $q=\log 3$、$d_k=1$，两个键为 $[0,1]$，得分为 $[0,\log 3]$。权重为 $[1/4,3/4]$；若值为 $(2,0)$ 和 $(0,4)$，输出为 $(0.5,3)$。

若 $Q\in\mathbb{R}^{T_q\times d_k}$、$K\in\mathbb{R}^{T_k\times d_k}$、$V\in\mathbb{R}^{T_k\times d_v}$，权重形状是 $T_q\times T_k$，输出为 $T_q\times d_v$。自注意力（Self-attention）的 Q/K/V 来自同一序列的不同投影，不要求三个矩阵数值相同。交叉注意力可让查询与键/值来自不同序列。

记住：权重随输入变化，是一种计算关系；不能直接把权重大小当作因果解释。

12.4 因果与填充遮罩：在 Softmax 之前处理

因果自注意力只允许位置 i 关注 $j \le i$。常令 $M_{ij} = 0$ 表示允许，$M_{ij} = -\infty$ 表示屏蔽，再计算 Softmax。这使被屏蔽位置的权重为 0，而允许位置重新归一化。

	键 1	键 2	键 3
查询 1	1	0	0
查询 2	1/2	1/2	0
查询 3	1/3	1/3	1/3

右上三角被遮罩；每行允许的权重和为 1

图 12.3: 三个位置的未遮罩得分全为 0 时，加入因果遮罩后得到的注意力权重。

读图：第一行只能看第 1 位置，第二行平均看前两个，第三行平均看三个。先做 Softmax 再简单把未来位置设 0 而不重新归一化，会得到另一种运算。

填充遮罩（Padding Mask）用于排除 PAD 等无效位置，和因果遮罩解决不同问题。损失或序列池化也要排除相应填充位置；不要只屏蔽键就默认所有输出均有效。避免整行都被屏蔽，使 Softmax 没有可用位置；实际布尔遮罩的 True 含义还需对照接口。

> **训练可并行，不表示能偷看未来**
>
> 训练时可以同时计算所有位置，但因果遮罩仍限制每个位置的可见信息。逐步生成则按已有前缀扩展，两种计算方式可以实现同一个信息约束。

12.5 多头注意力：多组投影再拼接

多头注意力(Multi-Head Attention, MHA)并行计算多个注意力头:$\text{head}_i = \text{Attn}(XW_i^Q, XW_i^K, XW_i^V)$，再拼接并乘输出投影 W_O。头之间通常有不同的可学习投影。

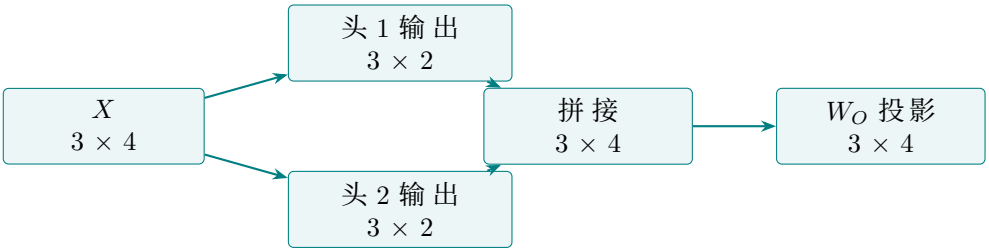


图 12.4: 省略批量轴，长度 3、表示维度 4、两个等宽头的形状例子。

读图：每头的键和值维度为 2，输出各为 3×2，拼接恢复 3×4。拼接不是取平均；W_O 进一步混合不同头的输出。

在常见等宽设置中，d_{model} 能被头数整除。若 Q、K、V 和输出均从 d 维映到 d 维，忽略偏置，四组投影参数共 $4d^2$；这不是整个 Transformer 的参数数，还未包括前馈层、归一化和嵌入。

> **每个头不保证学到一种固定语言功能**
>
> 可以观察到不同注意模式，但不能预先指定“某头一定负责语法、某头一定负责语义”。头的作用依赖任务、数据和训练结果。

12.6 Transformer 块：注意力、前馈与残差

Transformer 把注意力、逐位置前馈层、残差和归一化组合起来。下面选择一种 Pre-LN 示意：$Z = X + \mathrm{MHA}(\mathrm{LN}(X))$，$Y = Z + \mathrm{FFN}(\mathrm{LN}(Z))$。

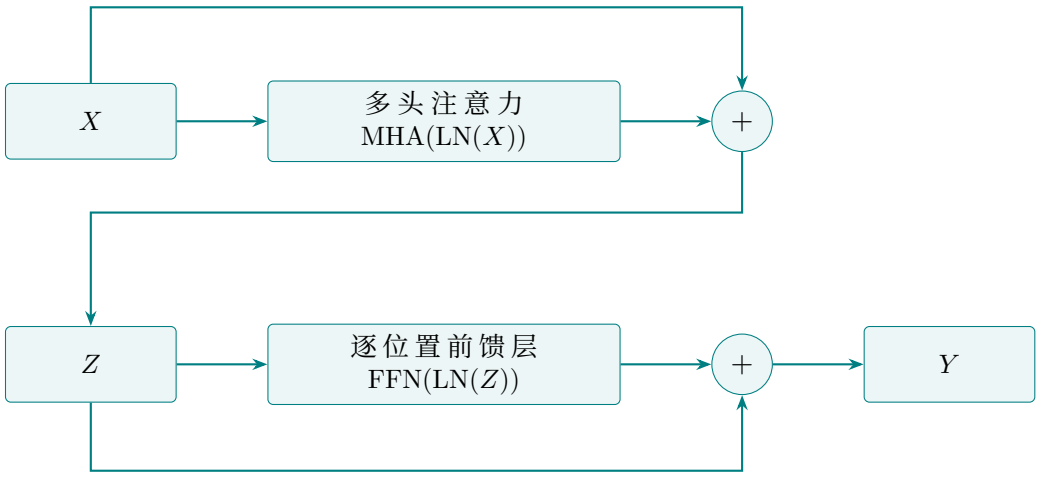


图 12.5: 省略 Dropout 与部分实现细节的 Pre-LN 块；不是所有 Transformer 变体的唯一顺序。

读图：注意力在位置间汇总；FFN 对每个位置分别应用同一组权重，典型为 $d \to d_{\mathrm{ff}} \to d$ 的两次仿射变换与中间非线性。残差支路保持对应形状，LayerNorm 常按每个位置的特征轴计算。

普通自注意力若没有位置或其他次序结构，对位置排列具有等变性。序列模型通常加入位置表示，如可学习位置向量、正弦编码或相对位置机制。它们提供次序信息，不能用“不同 Token 的编号大小”代替。

记住：Transformer 不是只有一个 Softmax：表示、位置、遮罩、注意力、前馈与训练目标共同决定行为。

12.7 编码器、解码器与下一 Token 目标

编码器常对完整输入作双向表示；自回归解码器按前缀预测下一 Token；编码器—解码器结构还用交叉注意力读取源表示。

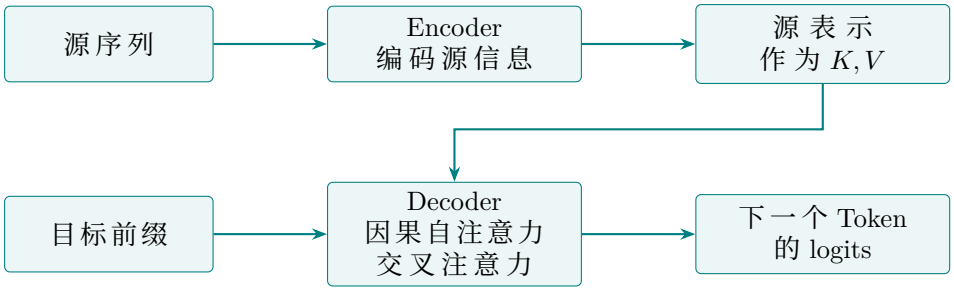


图 12.6: 条件生成示意：目标查询读取源序列的键和值，同时屏蔽目标未来位置。

读图：交叉注意力中的键/值来自编码器源表示，查询来自解码器目标状态。源长度与目标长度可以不同，不能按逐位置一一配对理解。

自回归训练通常将输入和目标错开一个位置：

位置	1	2	3
输入	BOS	我	爱
监督目标	我	爱	猫

位置 3 在训练时只看到 BOS、我、爱，预测猫；不能把猫同时放在该位置输入中让模型直接复制。教师强制（Teacher Forcing）使用真实历史目标作为训练前缀，生成时则使用已生成前缀。

> **预训练目标不同，使用方式也不同**
>
> 掩码 Token 恢复与因果下一 Token 预测有不同可见信息和输出目标。不能仅凭名称把任何编码器模型当作已经训练好的自回归生成器。

12.8 比较架构，同时检查时间与内存

没有架构在所有任务上都最好。局部结构、序列长度、可用数据与部署需求会影响选择。

架构	信息交互	常见考虑
CNN	共享局部窗口，叠层扩大依赖范围。	网格与局部模式；步幅、边界和尺度。
RNN、LSTM、GRU	按顺序更新共享状态。	有序计算与长路径；可逐步维护状态。
Transformer	根据输入计算注意力交互。	位置、遮罩、长序列开销与任务目标。

显式注意力权重的元素数为 $B\,h\,T_q\,T_k$。$B=2, h=4, T_q=T_k=128$ 时，共 131072 个元素；float32 仅这部分占 0.5MiB。长度都变为 256 时，该部分变为 2MiB，即 4 倍。这不是总训练显存；优化实现可能避免完整保存权重矩阵，其他激活和参数仍需计入。

12.8.1 自测与回看

共享参数是否意味着每个位置输出相同？**不意味着**。LSTM 输入门与遗忘门是否必须互补？**不必**。多头输出是否简单取平均？**通常是拼接再投影**。训练并行是否允许看到未来标签？**不允许**。

参考： Goodfellow 等《Deep Learning》第 10 章；Hochreiter 与 Schmidhuber（1997）的 LSTM；Cho 等（2014）的门控结构；Vaswani 等，*Attention Is All You Need*（2017）。图、形状与数值例子独立构造。