机器学习与深度学习：图解速查手册

选择、诊断与聚类补充

搜索、概率与不确定性

第十二批阶段样章

本批逐张核查 10 张原图，以独立图表补写搜索、嵌套验证、曲线、概率、MCC 与区间，并补充 DBSCAN 与层次聚类。本文件为阶段样章，全书仍在修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第四章　选择与诊断：把分数变成可靠判断 **1**

4.1　参数、超参数与搜索预算 1

4.2　嵌套交叉验证：评估选择流程 2

4.3　三种曲线：先读横轴，再谈诊断 3

4.4　概率预测：Brier 与对数损失 4

4.5　校准、排序与阈值分工 5

4.6　MCC：同时使用四种计数 6

4.7　不确定性：区间也有适用条件 7

第五章　聚类补充：密度与层次 **8**

5.1　DBSCAN：通过核心点扩展密度连接 8

5.2　层次聚类：链接方式决定合并距离 9

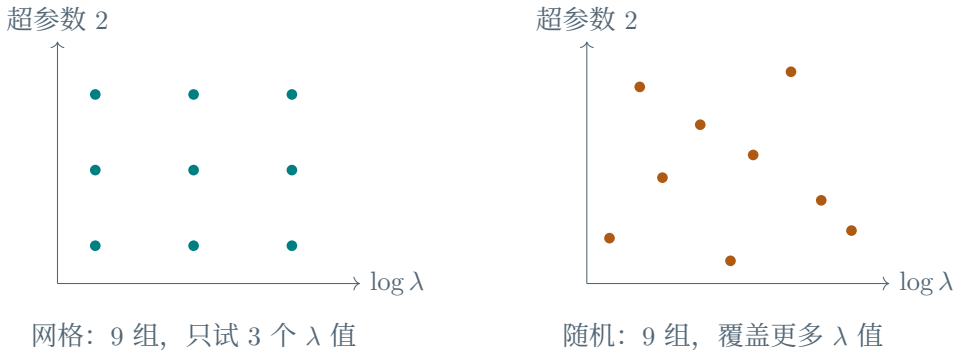
第四章　选择与诊断：把分数变成可靠判断

一个可复用的建模方案包含预处理、模型、超参数、停止规则与决策规则。本章接续可信评估，把搜索、曲线、概率与不确定性放回这个完整流程。

> **分数越好，越需要问清它怎样得到**
> 选择次数、数据用途、指标方向与估计误差共同影响结论。在测试集上反复试出一个好结果，不能替代预先约定的验证流程。

4.1　参数、超参数与搜索预算

参数（Parameter）通常由拟合学习，如回归系数与网络权重；超参数（Hyperparameter）控制模型或学习流程，如正则强度、树深度、学习率。超参数可以由验证搜索自动选择，不能简单理解为“只有人工才设置”。



网格：9 组，只试 3 个 λ 值　　随机：9 组，覆盖更多 λ 值

图 4.1：等预算的独立示意。随机搜索能试更多不同坐标值，但不保证每次更优。

读图：网格搜索枚举指定笛卡尔积；3 个正则强度与 4 个树深度共 12 组，五折评估需 60 次折内拟合，最后全开发集重拟合另计一次。不能按训练分数挑选。

随机搜索从预先指定分布抽样；若正值跨多个数量级，可考虑对数尺度，例如 $\log_{10}\lambda \sim U[-4, 0]$，而非默认在线性区间均匀取值。两者给不同尺度的搜索预算，不存在通用最优搜索分布。

记住：先定指标方向、范围、预算、划分与随机种子。候选失败和实际开销也应记录；搜索只在指定范围内比较。

4.2 嵌套交叉验证：评估选择流程

普通交叉验证可用于选择超参数；同一组折上最优候选的分数，已经受到选择影响。若需要估计整套选择流程的泛化表现，可用嵌套交叉验证（Nested CV）。

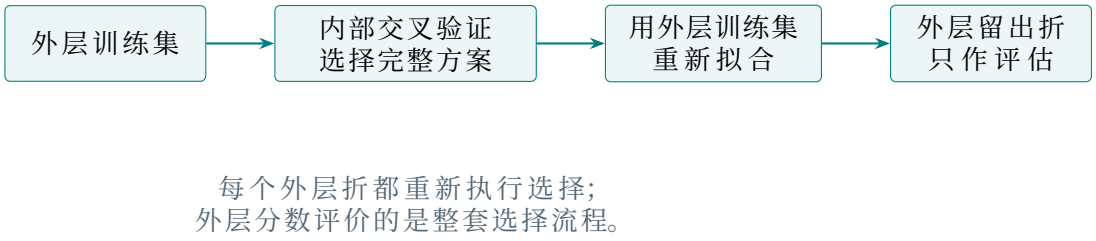


图 4.2: 外层评估、内层选择；预处理始终与模型一起在相应训练部分拟合。

读图：外层留出折不参与内层搜索；在不同外层折上选出的超参数可以不同。汇总外层结果，评价的是“给定新训练样本后执行这套选择流程”的表现。

若外层 5 折、内层 3 折、每次比较 8 组候选，内层拟合共 $5 \times 3 \times 8 = 120$ 次；每个外层选定后重新拟合一次，共 5 次，因此外层评估阶段 125 次。最后在全开发集上再选参并拟合用于部署，属于另外的计算与模型。

> **外层也不能无限反复优化**
>
> 看到外层结果后持续改变特征、候选范围或搜索策略，会再次产生适应性选择。嵌套 CV 不是泄漏或研究者选择的万能修补。独立测试集可作为另一种评估设计；按数据、用途与预算选择，不要求所有项目都同时堆叠两者。

时间序列与分组数据的内外层都需保持相应边界。也不要把五个外层模型中分数最高的一个直接当作“最终最佳模型”。

4.3 三种曲线：先读横轴，再谈诊断

“学习曲线”有时泛指训练过程曲线，阅读时务必先检查横轴。这里区分训练样本量、一个超参数与训练步数三类图。

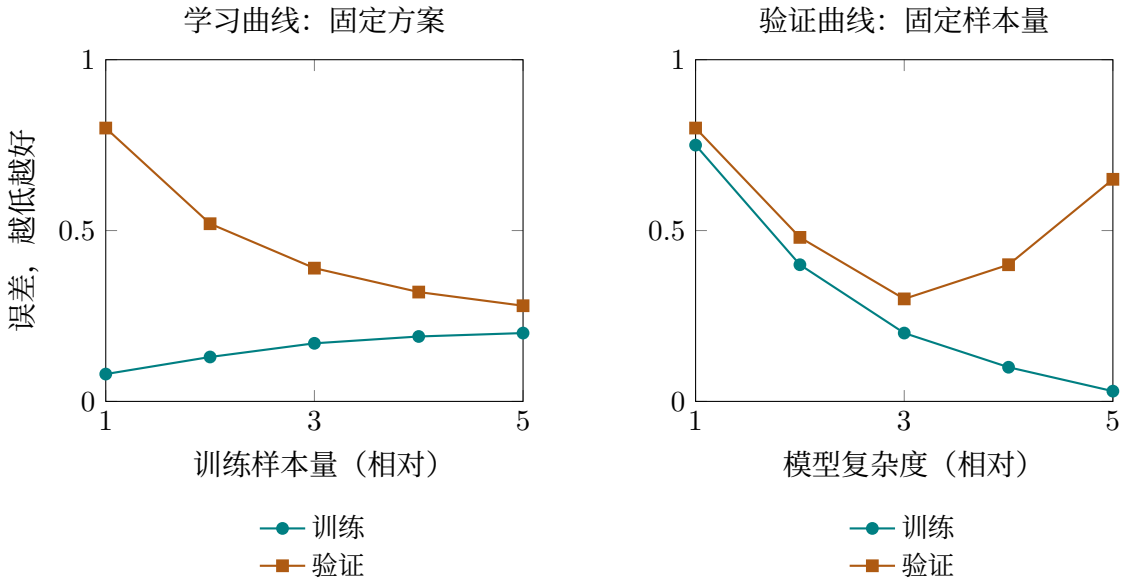


图 4.3: 独立构造的趋势示意，不是实验结果；这类形状并非必然定律。

读图：左图改变训练样本量、固定方案，每个规模重新拟合；右图改变复杂度、固定样本量。纵轴均为误差，越低越好。若换成准确率等得分，方向应对应改变。

横轴	可以帮助判断什么
训练样本量	在固定流程下，增加同分布数据是否仍可能改善验证表现。
超参数	候选范围内的表现与敏感性，不保证所有参数都有简单 U 形关系。
Epoch 或更新步数	优化过程、训练/验证分离和停止时刻；不是样本量变化。

训练与验证都差：先查标签、指标、实现与优化，再考虑容量不足。训练好、验证差：检查泄漏、划分、分布变化、正则与数据量。曲线只提供线索，不能单凭间距唯一诊断原因；验证误差也可能暂时低于训练误差。

4.4 概率预测：Brier 与对数损失

二分类模型给出的 p_i 应对应指定正类，$y_i \in \{0,1\}$。Brier 分数（Brier Score）与二元对数损失都直接评价概率，越小越好：

$$\mathrm{BS} = \frac{1}{n}\sum_i (p_i - y_i)^2, \tag{4.1}$$

$$\mathrm{LogLoss} = -\frac{1}{n}\sum_i [y_i \log p_i + (1-y_i)\log(1-p_i)]. \tag{4.2}$$

对数用自然底；错误且极度自信的概率会受较大惩罚。若真实类别被赋予零概率，对数损失趋于无穷；软件裁剪概率需说明约定。

模型（同一 8 样本）	正类少组的 p	正类多组的 p	Brier
A	0.1	0.9	0.2100
B	0.25	0.75	0.1875

第一组标签 $[0,0,0,1]$，第二组 $[0,1,1,1]$。阈值 0.5 时，两模型准确率均为 0.75，AUC 也均为 0.75，但概率误差不同。B 的对数损失约 0.562，A 约 0.655；排序、硬标签与概率质量是不同问题。

若同一条件下 $Y \sim \mathrm{Bernoulli}(q)$，则

$$\mathbb{E}[(p-Y)^2] = (p-q)^2 + q(1-q).$$

期望 Brier 在 $p = q$ 处最小；并不要求对每个随机结果都给出 0 或 1。二分类这个定义范围为 $[0,1]$；多分类若对全部类别平方差求和，范围及缩放约定不同。

记住：Brier 反映整体概率误差，不能单独证明校准完美；比较时保持样本、类别定义与缩放口径一致。

4.5 校准、排序与阈值分工

校准（Calibration）问：预测概率相近的一组样本，其实际正类频率是否相近？可靠性图（Reliability Diagram）把组内平均预测概率与组内实际频率作比较。

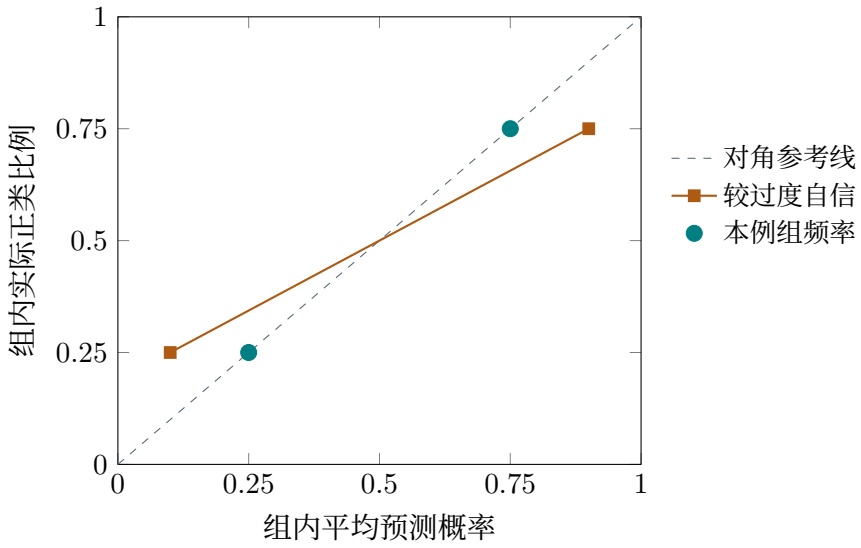


图 4.4: 沿用上页两个各 4 样本的组。有限分组图只用于说明，不证明总体已经校准。

读图： A 将两组概率推向 0 与 1，比本例观察频率更自信。按组频率替换为 B 后，排序与 0.5 阈值标签不变，Brier 下降。实际应用不能用测试标签这样修改预测。

Sigmoid/Platt 或保序回归等校准器，应使用模型拟合之外的校准数据，或合适的交叉拟合流程；模型、校准器、阈值都确定后再测独立测试集。分箱数量和少量样本会影响图形，分布变化后原校准关系也可能失效。

若 p 是适用场景的正类后验概率，正确决策代价为 0，误报代价 C_{FP}、漏报代价 C_{FN}，则预测正类的期望代价为 $C_{FP}(1-p)$，负类为 $C_{FN}p$。因此可按

$$p \geq \frac{C_{FP}}{C_{FP}+C_{FN}}$$

判正（相等时的约定另定）。例如 $C_{FP}=1, C_{FN}=4$ 给阈值 0.2。这个结论依赖概率与代价假设，不可对任意未校准得分照搬，也不等于任何 F1 最优阈值。

4.6 MCC：同时使用四种计数

马修斯相关系数（Matthews Correlation Coefficient, MCC）是二元真实标签与预测标签的相关系数。在四个边际因子均非零时，

$$\mathrm{MCC} = \frac{TP\,TN - FP\,FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}.$$

它在 $[-1,1]$ 内，1 表示完全一致，-1 表示完全反转，0 表示在此二元编码下没有线性相关。MCC 不是准确率，也不是保证公平或校准的综合评分。

100 样本例子	准确率	MCC
$TP=18, FN=12, FP=7, TN=63$	0.81	约 0.529
完全正确，且两类均出现	1	1
完全反转，且两类均出现	0	-1
全部预测为负类	取决于真实负类比例	原公式分母为 0

若真实标签或预测标签恒定，相关系数的普通定义失效。软件可能使用返回 0 等扩展约定，应记录这个约定，不能把 0 自动解释成测得了独立性。多分类 MCC 另有推广公式，不能直接将多分类矩阵四个位置代入本页二分类式。

> **指标服务于问题**
>
> MCC 可补充类别不平衡时的标签评价；仍应看混淆矩阵、各类表现与错误代价。需要概率质量时看概率指标，需要低误报运行点时检查相应阈值表现。

4.7 不确定性：区间也有适用条件

有限测试样本得到的准确率只是估计。在模型已固定、测试结果近似独立且同分布的二元成功/失败设置下，可用二项比例区间描述抽样不确定性。

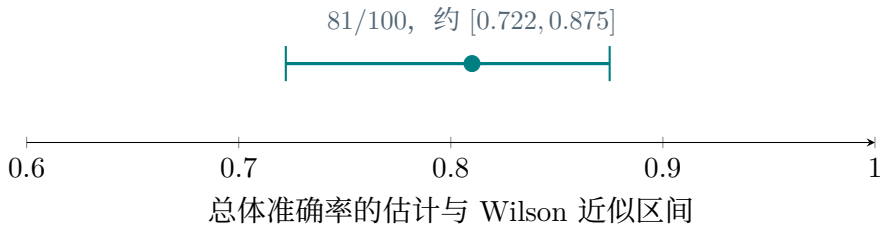


图 4.5： 100 个独立测试结果中 81 个正确，采用 $z = 1.96$ 的 Wilson 近似 95% 区间。

读图： 0.81 不是没有误差的总体常数。区间约为 $[0.722, 0.875]$，这不包含对未来分布变化的保证，也没有自动计入重新训练或调参的不确定性。

令 $\hat{p} = k/n$，Wilson 区间的中心和半宽分别为

$$c = \frac{\hat{p} + z^2/(2n)}{1 + z^2/n}, \qquad r = \frac{z\sqrt{\hat{p}(1-\hat{p})/n + z^2/(4n^2)}}{1 + z^2/n}.$$

区间为 $[c - r, c + r]$；这是近似方法，不对每种有限样本设置保证精确 95% 覆盖。频率学派的 95% 指在相应重复抽样下，该构造方法的长期覆盖率，不是“固定真参数有 95% 概率落在这一次固定区间内”。

> **不能把任何波动除以根号样本数就叫置信区间**
>
> 同一病人的多条记录不是独立试验；交叉验证各折也不相互独立。折间标准差不等于均值的标准误；模型比较还应保留同一测试样本上的成对关系。有组结构时按组设计估计或重采样，明确抽样单位与所覆盖的不确定性。

参考： ISLR 第二版第 5 章；Bergstra 与 Bengio，*Random Search for Hyper-Parameter Optimization*（2012）；scikit-learn Model Selection、Calibration 与 Model Evaluation 文档；Wilson（1927）。全部图与算例独立构造。

第五章　聚类补充：密度与层次

5.1　DBSCAN：通过核心点扩展密度连接

DBSCAN 是基于密度的聚类，不预先指定簇数。给定距离阈值 ε 与最少邻域点数 m，本页约定邻域包含点自身：$N_\varepsilon(x) = \{x_j : d(x, x_j) \le \varepsilon\}$。



图 5.1： 一维例子，$\varepsilon = 0.26, m = 4$。点的类型由邻域计数决定。

读图： 0.3 的邻域为 $\{0.1, 0.2, 0.3, 0.55\}$，因此是核心点；0.55 仅有两个邻域点，是靠近核心点的边界点；1.5 既非核心，也不邻接任何核心，是噪声。

点的类型	判定与扩展
核心点	$\lvert N_\varepsilon(x)\rvert \ge m$，可继续扩展邻域。
边界点	不满足核心条件，但落入某核心点的邻域；可以归簇，不能继续作为扩展桥梁。
噪声点	没有归入任何密度簇的点；“噪声”不自动意味着测量错误。

先连接彼此邻接的核心点，再吸收邻近边界点，可以得到两个簇，1.5 留作噪声。边界点若同时邻接不同簇，归属可能受遍历约定影响；不能通过一串非核心边界点任意合并簇。

尺度和距离仍很关键：ε 过小可能几乎全为噪声，过大可能合为一簇。不同密度的簇未必能用同一阈值识别；高维距离也会变得困难。“形状灵活”不等于对数据没有结构假设。

5.2 层次聚类：链接方式决定合并距离

凝聚式层次聚类（Agglomerative Clustering）从每点一簇开始，每次合并距离最近的两个簇。树状图（Dendrogram）的高度表示合并距离，切割高度可产生不同簇数。

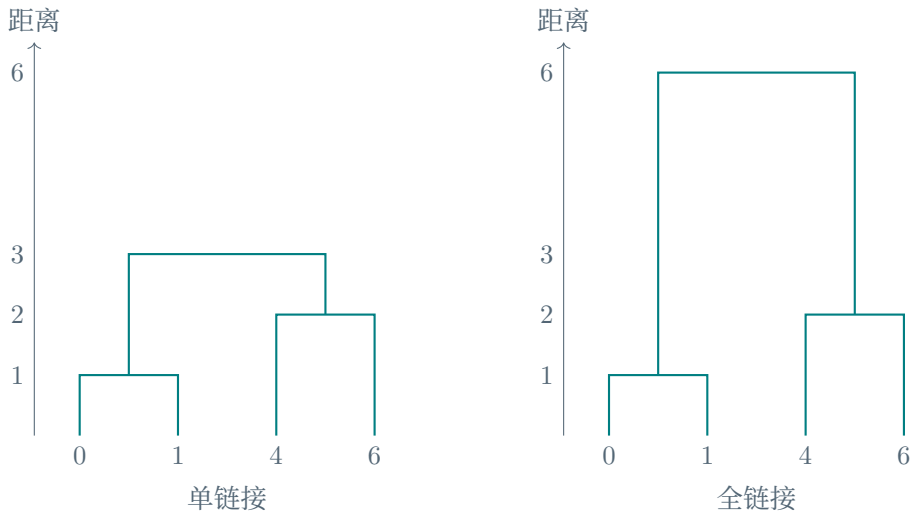


图 5.2: 同样四点 0、1、4、6，链接方式不同，最后合并高度不同。

读图：先在距离 1 处合并 0 与 1，再在距离 2 处合并 4 与 6。随后两簇的单链接距离为 3，全链接距离为 6；平均链接为 4.5。簇内点未移动。

单链接取跨簇点对的最小距离，容易形成链；全链接取最大距离；平均链接取跨簇点对距离的平均。Ward 方法则以组内平方和增加为准则，常用于欧氏设置，不能混同于上述最短/最长距离。

记住：聚类都需要选表示、尺度、距离与规则。比较结果时说明簇数、噪声处理和用途，不能只按图形好看判断。

参考：Ester 等，DBSCAN（1996）；ISLR 第二版第 12 章；scikit-learn Clustering 文档。