机器学习与深度学习：图解速查手册

非线性、稳定计算与迁移

损失、更新与训练边界

第十三批阶段样章

本批逐张核查 15 张原图，补写 XOR、激活变体、稳定损失、权重衰减与梯度裁剪，并独立补迁移学习。所有新图表独立构造；全书仍在修订。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第十章　非线性表示补充 **1**

10.1 XOR：隐藏表示怎样改变可分性 1

第十一章　训练细节：稳定计算与正则化 **2**

11.1 激活变体：看函数，也看导数 2

11.2 从 logits 稳定计算交叉熵 3

11.3 RMSprop、L2 与解耦权重衰减 4

11.4 裁剪梯度：限制范数，不修复全部不稳定 5

11.5 把不同正则化方式放回训练流程 6

第十二章　迁移学习：复用表示，再验证目标任务 **7**

12.1 冻结与微调分别更新什么？ 7

第十章　非线性表示补充

10.1　XOR：隐藏表示怎样改变可分性

异或（XOR）在两个输入不同的时候输出 1，相同时输出 0。四个输入 $(0,0),(1,0),(0,1),(1,1)$ 的目标为 $0,1,1,0$；它们不能由原平面中的一条直线严格分开。

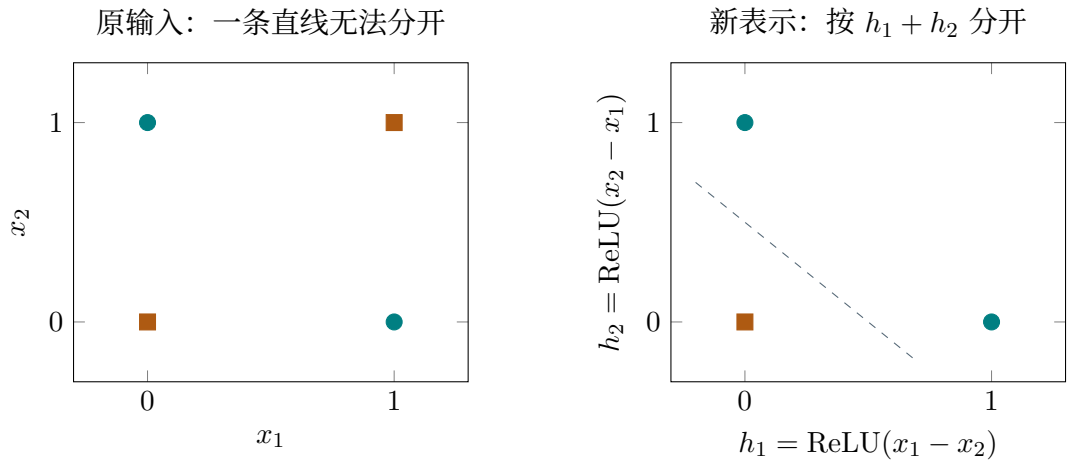


图 10.1：青色圆点为正类，橙色方点为负类；两负类在隐藏表示中重合到原点。

读图：设 $h_1=\mathrm{ReLU}(x_1-x_2)$、$h_2=\mathrm{ReLU}(x_2-x_1)$，则正类映为 $(1,0)$ 或 $(0,1)$，负类均为 $(0,0)$。再按 $h_1+h_2>0.5$ 即可分类。这里显式构造权重，说明表示能力，不等于保证训练自动找到它。

若所有层都只有仿射变换，$W_2(W_1x+b_1)+b_2$ 仍是一个仿射变换；单纯叠层没有引入这里所需的非线性表达。中间的非线性使组合获得不同形状的决策边界。

深度可让某些具有组合结构的函数更高效地表示，并不意味着越深越好。常见通用逼近结论有函数、区域与网络宽度等条件，也不保证优化、样本需求或测试泛化。XOR 只需很小的隐藏表示，不需要很深的网络。

记住：先问结构能否表达，再问优化能否学到，最后问新数据是否有效；三个问题不能相互替代。

第十一章　训练细节：稳定计算与正则化

同一数学公式可以有稳定与不稳定的计算写法；同一个“正则化”名称也可能对应不同更新。本章补充常见激活、logits 损失、按坐标更新、权重衰减和梯度裁剪的边界。

11.1　激活变体：看函数，也看导数

除 Sigmoid 与 ReLU 外，常见激活各有形状和计算特点，不能仅凭“有负值”判断能否解决梯度问题。

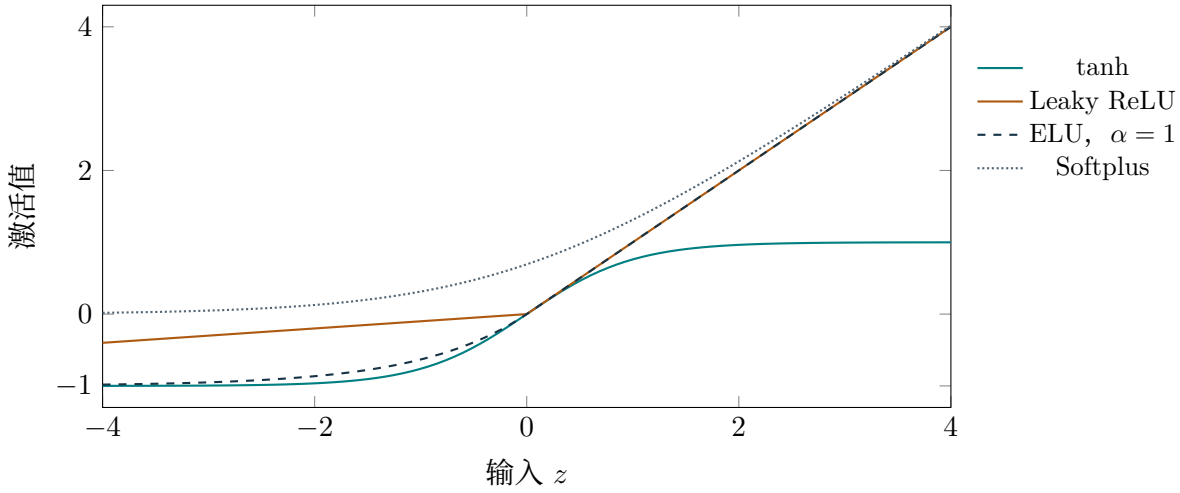


图 11.1: 函数值的独立绘图。Leaky ReLU 示例斜率为 0.1；它不是所有实现的默认值。

读图：tanh 在两端趋于 ± 1；Leaky ReLU 保留负半轴斜率；ELU 负半轴趋于 $-\alpha$；Softplus 平滑接近 ReLU。图示比较函数，不直接代表模型效果排名。

激活	定义或性质	导数与边界
tanh	$\tanh z$，输出在 $(-1, 1)$。	$1 - \tanh^2 z$；两端仍饱和。
Leaky ReLU	$z \geq 0$ 取 z，否则 az，$0 < a < 1$。	两侧导数 1 与 a；原点输出 0 且通常不可微。
ELU	$z \geq 0$ 取 z，否则 $\alpha(e^z - 1)$。	负侧导数 αe^z 仍可很小；$\alpha = 1$ 时原点可微。
Softplus	$\log(1 + e^z)$。	导数为 Sigmoid；负端也会饱和。

ELU 或 tanh 不保证激活均值恰好为 0；Leaky ReLU 也不保证完整网络梯度永远非零。激活、初始化、归一化与优化需一起考虑。

11.2 从 logits 稳定计算交叉熵

对有限 logits $z_1, \dots, z_K$，令 $a = \max_k z_k$，则

$$\mathrm{LSE}(\boldsymbol{z}) = a + \log \sum_k e^{z_k - a}, \qquad \ell_{\mathrm{CE}} = \mathrm{LSE}(\boldsymbol{z}) - z_y.$$

交叉熵需要负号，y 是本例真实类别索引；更一般的目标分布 t_k 用 $-\sum_k t_k \log p_k$。交叉熵与只含预测分布的熵不是同一个概念。

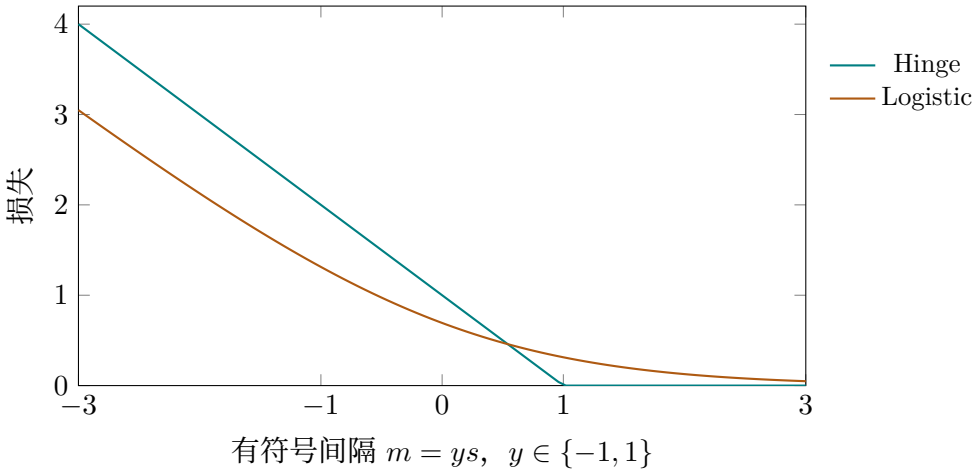


图 11.2: 二分类有符号间隔下的损失比较；Hinge 到达间隔 1 后为 0，Logistic 平滑下降。

读图：对 $\boldsymbol{z} = (1000, 1001, 999)$，若目标为第 1 类，稳定损失为 $1 + \log(1 + e^{-1} + e^{-2}) \approx 1.408$。无需先计算会溢出的 e^{1001}，也无需先生成可能舍入为 0 的目标概率。

二分类用 $y \in \{0, 1\}$、logit s 时，稳定 BCE 可写为

$$\ell = \max(s, 0) - ys + \log(1 + e^{-|s|}).$$

例如 $s = 1000, y = 0$ 时损失约 1000，而不是对舍入到 1 的概率直接求 $\log 0$。合并 logits 损失接口与概率接口要区分，避免重复 Sigmoid/Softmax。

减最大值避免指数上溢，某些很小的指数项仍可能下溢为 0；不能声称完全消除所有浮点问题。Hinge 通常用 $y \in \{-1, 1\}$ 与得分 s，随 ys 增加而不增，不是随 s 增加对两类都下降。

11.3 RMSprop、L2 与解耦权重衰减

一种非中心化 RMSprop 约定为逐坐标计算

$$\boldsymbol{v}_t = \beta \boldsymbol{v}_{t-1} + (1-\beta)\boldsymbol{g}_t^2, \qquad \boldsymbol{w}_t = \boldsymbol{w}_{t-1} - \eta \frac{\boldsymbol{g}_t}{\sqrt{\boldsymbol{v}_t} + \epsilon}.$$

$\boldsymbol{g}_t$ 在 $\boldsymbol{w}_{t-1}$ 处计算。它累积梯度**平方**的指数滑动平均，仍需设置学习率与其他超参数。这里没有 Adam 式的一阶动量和偏差修正；实现可能另有中心化、动量等选项。

标量例子 $v_0 = 0, w_0 = 1, \beta = 0.9, \eta = 0.1$，仅为手算忽略 ϵ，梯度依次为 $2, -1$，得 $v_1 = 0.4, v_2 = 0.46$，$w_1 \approx 0.684, w_2 \approx 0.831$。

L2 惩罚 $\lambda\|\boldsymbol{w}\|_2^2/2$ 增加梯度 $\lambda\boldsymbol{w}$。在无动量的普通 SGD 下，更新可改写为

$$\boldsymbol{w}^+ = (1-\eta\lambda)\boldsymbol{w} - \eta\boldsymbol{g}.$$

但若逐坐标缩放梯度，则加入 L2 梯度与直接衰减参数一般不同。

更新约定	固定缩放矩阵 D 的示意与数值
把 L2 梯度一起缩放	$w^+ = w - \eta D(g + \lambda w) = (0.970, 1.996)$。
解耦衰减	$w^+ = (1-\eta\lambda)w - \eta D g = (0.970, 1.978)$。

本例 $w = (1, 2), g = (0.2, 0.2), D = \mathrm{diag}(1, 0.1), \eta = \lambda = 0.1$。Adam 中加入 L2 梯度还会影响矩估计历史，差异不只这一步；AdamW 采用解耦衰减思想。偏置、归一化参数等是否衰减需明确参数组，不能不看实现就断言全部相同。

11.4 裁剪梯度：限制范数，不修复全部不稳定

给定阈值 $c > 0$，全局 L2 范数裁剪把选定参数的梯度连接成一个向量，当 $\|g\|_2 > c$ 时令 $g' = cg/\|g\|_2$，否则保持不变。

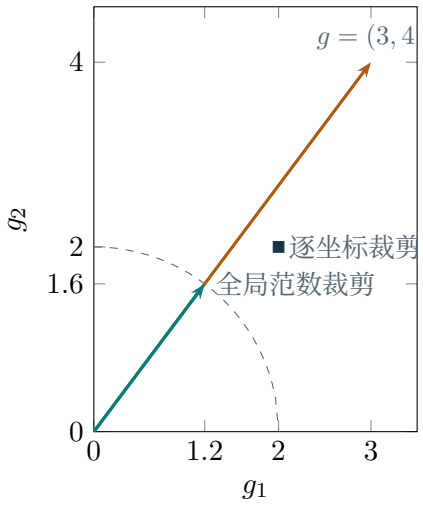


图 11.3: 阈值 2。圆弧表示 L2 范数为 2 的边界；逐坐标裁剪不保持相同方向。

读图： $g = (3, 4)$ 的范数为 5，全局裁剪后为 $(1.2, 1.6)$，范数为 2 且方向不变。逐坐标限制在 $[-2, 2]$ 则得到 $(2, 2)$，范数为 $2\sqrt{2}$，含义不同。

裁剪发生在反向传播之后、优化器更新之前。如果使用梯度累积，应明确对哪一次有效梯度裁剪；使用缩放梯度的混合精度流程时，通常先取消损失缩放，再按真实梯度量级裁剪。

> **梯度有界不等于参数更新一定有界为 ηc**
>
> 对普通 SGD 可直接联系梯度与更新；动量、自适应缩放、权重衰减都会改变最终更新。裁剪不能恢复消失梯度，不能把 NaN 变成有效信息，也不保证损失每步下降。突然出现大梯度时，还应检查数据、损失尺度与实现。

11.5 把不同正则化方式放回训练流程

正则化通过约束、惩罚、随机化或停止规则影响学习，不是给模型增加同一种“防过拟合按钮”。

方法	影响什么	使用时注意
L2/权重衰减	目标梯度或参数更新。	归一化与优化器约定。
Dropout	训练中的随机激活掩码。	推理模式及缩放方式。
数据增强	训练输入与有效样本变化。	标签语义与同源划分。
提前停止	选择保存的训练时刻。	验证规则与恢复状态。
Bagging	重采样后训练多个基模型。	多模型开销与相关性。

Dropout 的不同掩码复用同一组参数；通常不会像 Bagging 那样，为每个子网络单独存一套独立拟合的权重。每步只采样某些掩码，不表示永久只有固定一部分子网络参与训练。

Bagging 的重采样可在给定训练集时独立抽取，但基模型都依赖同一数据来源，它们面对新样本的预测误差通常相关。参数分开存储不等于总体预测统计独立。普通 Dropout 的确定性推理也通常不等于对全部非线性子网络预测的精确平均。

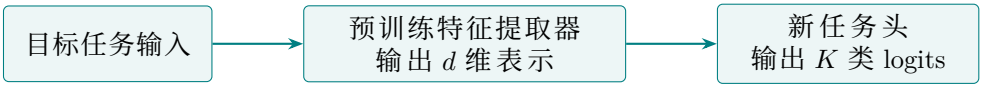
记住： 明确方法改变的是数据、目标、梯度、参数还是选择规则，再设计验证比较；不要把几个方法机械叠加就当作质量保证。

参考： Goodfellow 等《Deep Learning》第 6–8 章; Loshchilov 与 Hutter, *Decoupled Weight Decay Regularization*（2019）；PyTorch 损失、RMSprop、AdamW 与梯度裁剪文档。所有图表与算例独立构造。

第十二章　迁移学习：复用表示，再验证目标任务

迁移学习（Transfer Learning）把已有任务或数据中学到的信息用于目标任务。常见做法是使用预训练特征提取器，接上适合新标签的任务头；不要求源与目标的类别名称相同，但输入与表示需要适配。

12.1　冻结与微调分别更新什么？



冻结：不更新底座参数；微调：更新选定参数。
两种情况都要规定训练/评估模式与预处理。

图 12.1：目标任务有 K 个互斥类别时，线性任务头将 d 维表示映成 K 个 logits。

读图：若 $d = 16, K = 3$，带偏置任务头有 $16 \times 3 + 3 = 51$ 个参数。冻结底座时只训练这些新参数；部分或全部微调时，还更新被选中的底座参数。冻结减少可训练参数，但不消除底座前向计算。

策略	需要比较的因素
冻结表示，仅训练头	可作较省训练计算的起点，表示与目标是否匹配仍需验证。
解冻部分层	控制适应程度、学习率与训练模式；没有通用解冻层数。
全部微调	更大适应空间，也需要数据、计算与过拟合检查。

冻结参数与评估模式是两回事：BatchNorm 运行统计是否更新、Dropout 是否随机，需要另外设定；不能只设置“不求参数梯度”就默认底座输出固定。预处理、词表/分词和输入尺度也需与预训练约定衔接。

> **预训练不保证每个目标任务都有收益**
>
> 源与目标差异、标签质量和数据量会影响结果，可能出现负迁移。应与简单基线比较，按目标对象或时间划分验证，仍要隔离测试集。还需核对预训练数据是否与评估样本重叠，避免把重复内容带来的好分数当作泛化。

参考：《动手学深度学习》微调章节；PyTorch Transfer Learning Tutorial。