数据假设与筛选

缺失、异常与选择边界

第十四批阶段样章

本批从全库存初筛中选出 15 张重点原图作原尺寸复核，补写缺失机制、完整记录分析、异常值、筛选与 Tomek 链接。另两张概念混淆卡并入已有正确公式，不机械重复扩写。

原项目作者：张海飞、郭金珊、任露芹、李慧、朱靖、朱弘毅

2026 年 10 月 28 日

目录

第三章　数据假设与筛选：处理规则为什么需要验证 **1**

3.1　MCAR、MAR 与 MNAR：缺失依赖什么？ 1

3.2　完整记录分析：MAR 下也可能改变总体 2

3.3　异常值：标记、核查，再决定处理 3

3.4　方差筛选：变化大小不是预测价值 4

3.5　卡方关联筛选：频数、期望与局限 5

3.6　向前选择：每一步都是一次模型比较 6

3.7　Tomek 链接与样本量经验的边界 7

第三章　数据假设与筛选：处理规则为什么需要验证

补值、删除、变换与筛选都在改变模型看到的信息。本章把常见处理建议背后的假设拆开，避免把一个统计规则当作无条件的数据清洗标准。

3.1　MCAR、MAR 与 MNAR：缺失依赖什么？

考虑一个可能缺失的变量 X、完整观测的变量 Z，令 $R = 1$ 表示 X 被观测到。下面用这个简化设置理解三类缺失机制，不把“随机”误读成没有任何规律。

机制	条件关系	教学例子
MCAR：完全随机缺失	$P(R = 1 \mid X, Z)$ 为常数。	与记录内容无关的随机传输丢失。
MAR：随机缺失	$P(R = 1 \mid X, Z) = P(R = 1 \mid Z)$。	保留率只由已记录的站点决定。
MNAR：非随机缺失	给定 Z 后，保留率仍依赖未观测的 X。	收入本身越高，越不愿填写收入。

MAR 允许缺失概率依赖已观测信息；它不是 MCAR 的同义词。MNAR 也不等于“缺失不是随机掷硬币”：关键是给定已观测信息后，是否仍依赖缺失部分。一般多变量缺失模式比这里复杂，须针对可用观测和分析目标定义。

> **不能只看观测表就证明 MAR**
>
> 缺失部分的真值通常不可见，不同机制可能产生相同的观测分布。应结合采集流程、领域知识与敏感性分析；“没发现关系”不能证明缺失完全随机。是否采用缺失指示变量、模型填补或专门缺失机制模型，仍需验证。

记住：缺失机制讨论数据怎样被观察；填补方法讨论如何处理已得到的表。两者不能凭名称一一配对。

3.2 完整记录分析：MAR 下也可能改变总体

完整记录分析（Complete-case Analysis）只保留所需变量齐全的记录。是否合适取决于估计目标、缺失机制与模型，不能说“缺失原因在其他特征中体现，就一定可以删”。

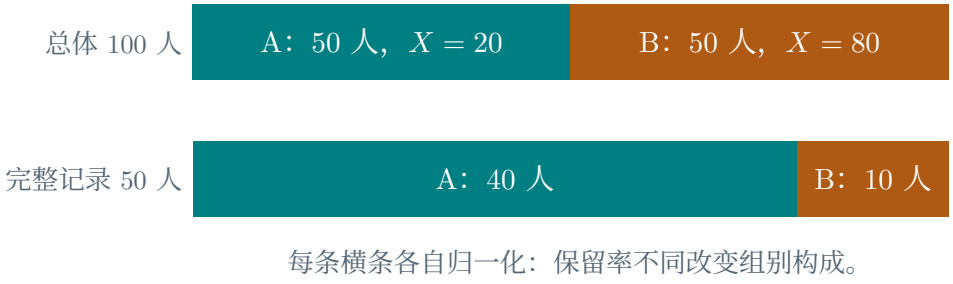


图 3.1： 可见全部真值的教学构造。A 组保留率 0.8，B 组保留率 0.2，只依赖已观测组别 Z。

读图： 总体两组各 50 人，A 的 $X = 20$、B 的 $X = 80$，总体均值为 50。按图中预期保留构成，只看完整记录的均值为 $(40 \times 20 + 10 \times 80)/50 = 32$。即使缺失满足本例 MAR 关系，不加调整的完整记录均值也偏离总体目标。

如果知道目标总体两组各占一半，并且组内观测足以代表组内目标，按目标组比例加权可恢复 $0.5 \times 20 + 0.5 \times 80 = 50$。现实中不能预先看到缺失真值，这种调整也依赖相应假设与足够覆盖。

MCAR 下，完整记录可能仍是对总体的随机子样本，但会损失精度，少量完整记录也不足以可靠训练复杂模型。某些条件模型在更弱机制下仍可有效估计，因此也不能反过来说“只有 MCAR 才允许任何完整记录分析”。

记住： 先写清要估计的是总体均值、条件关系还是预测表现，再论删除与填补；对预测任务也要模拟实际缺失模式。

3.3 异常值：标记、核查，再决定处理

异常值（Outlier）是相对于某种分布、模型或规则显得少见的记录。少见不等于错误；真实故障、罕见疾病或极端交易可能正是目标。

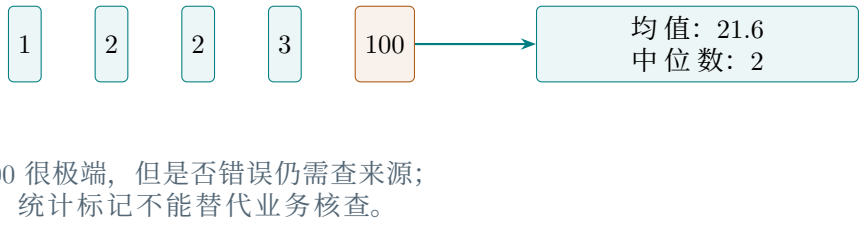


图 3.2: 五个数的例子；方框只列记录，不表示等距数轴。

读图：均值被 100 明显拉动，中位数仍为 2。若把 100 截到 5，均值变为 2.6；这是修改了数据和估计对象，不能仅凭数字更“正常”就宣称处理正确。

按本例线性分位数约定，$Q_1 = 2, Q_3 = 3$，$\mathrm{IQR} = 1$。常见箱线图围栏 $[Q_1 - 1.5\mathrm{IQR}, Q_3 + 1.5\mathrm{IQR}] = [0.5, 4.5]$ 会标记 100；围栏是诊断启发式，不是测量错误的判决。不同分位数定义、分组或时间范围可能改变标记结果。

证据与选择	处理考虑
确认录入或单位错误	按来源修正，无法修正时明确标记或排除理由。
真实但极端	保留目标事件；比较稳健损失、适当变换或分组模型。
暂时不确定	记录标记并做敏感性比较，不默认“标记最安全”或“取对数总有用”。

从数据估计的截断阈值与变换参数仍只在训练部分拟合；不要为了改善测试分数事后删除困难样本。

3.4 方差筛选：变化大小不是预测价值

方差阈值（Variance Threshold）是不使用标签的筛选方法。近乎常数的特征在某些任务中贡献有限，但方差受到量纲影响，低方差也可能保留关键标签信息。

二元变量，取 1 比例 p	分母为 n 的经验方差 $p(1-p)$	含义
$p = 0.5$	0.25	0 与 1 一样常见。
$p = 0.1$	0.09	1 较少见。
$p = 0.01$	0.0099	1 很少见，但可能重要。

如果标签恰为 $y = x$，即使 $p = 0.01$，该特征仍可完美区分正类。仅因它低方差就删除，会丢掉全部检出正类的信息。连续特征乘 100 后，方差乘 10000，含义却未必改变；跨不同单位直接比较原方差不合理。

标准化为单位方差后，再用一个普通方差阈值筛选，也可能失去原来想识别的近常数差别。应先明确筛选目标与处理顺序；二元指示变量、连续量与缺失指示不宜机械套同一阈值。

> **筛选也属于拟合**
>
> 阈值、特征列表、重要性排名或目标关联一旦从数据学习，必须在交叉验证每折的训练部分重新确定，再将同一规则用于该折验证。“这是预处理”不能成为在全部数据上先看标签筛选的理由。

3.5 卡方关联筛选：频数、期望与局限

对类别特征与类别目标，可用列联表比较观测频数与独立假设下的期望频数。设总计 N，则 $E_{rc} = O_{r+}O_{+c}/N$，Pearson 卡方统计量为

$$\chi^2 = \sum_{r,c} \frac{(O_{rc} - E_{rc})^2}{E_{rc}}.$$

这里求和的是表格单元，不是任意把连续取值当频数。

40 条记录	$y=1$	$y=0$	合计
$x=1$	12	8	20
$x=0$	4	16	20
合计	16	24	40

本例期望表为 $\left[\begin{smallmatrix}8 & 12\\ 8 & 12\end{smallmatrix}\right]$，四格差的绝对值均为 4，因此 $\chi^2 = 20/3 \approx 6.667$。使用无连续性校正的 Pearson 统计量；固定 2×2 类别设置下自由度为 1。对稀疏期望频数，渐近近似可能不好，应考虑合适的精确或置换方法。

统计关联不等于因果或独立测试上的预测收益。单变量筛选可漏掉交互：XOR 中每个独立均匀二元输入单独与标签无关联，两者一起却能决定标签。大量特征反复检验还涉及多重选择，不能把筛选后的普通 p 值无条件解读。

记住：某些软件的非负特征卡方筛选有专门数据约定；不可把已标准化的负数直接送入要求非负计数的接口。

3.6 向前选择：每一步都是一次模型比较

向前逐步选择（Forward Selection）从空特征集或预设起点开始，每次分别尝试加入一个尚未选择的特征，按约定的验证指标保留当前最好扩展。

步骤	示例流程，四个候选特征
第一轮	比较 $\{x_1\},\{x_2\},\{x_3\},\{x_4\}$；假设本轮选 x_2。
第二轮	比较 $\{x_2,x_1\},\{x_2,x_3\},\{x_2,x_4\}$。
决定停止	按预定特征数或验证改进规则停止；不能使用最终测试分数控制。

取到两个特征需比较 $4+3=7$ 个候选子集；空集基线另算。若每组候选五折评估，至少涉及 35 次折内模型拟合，预处理与候选搜索也会增加开销。在更多特征中，它比穷举所有子集便宜，但这是贪心搜索，不保证全局最佳子集。

若用同一批数据既选择特征又报告误差，结果会受到选择影响。需要独立测试或合适的外层评估，把整个特征选择流程包在训练部分中。强相关特征可能互换，交互也可能使单独加入时看不出收益。

记住：特征筛选依赖模型和指标。某次没选上不代表该变量没有信息，也不代表它没有科学或因果意义。

3.7 Tomek 链接与样本量经验的边界

Tomek 链接是在给定距离下、互为最近邻且类别不同的一对样本。这里假设没有距离并列；有并列时要说明选择约定。

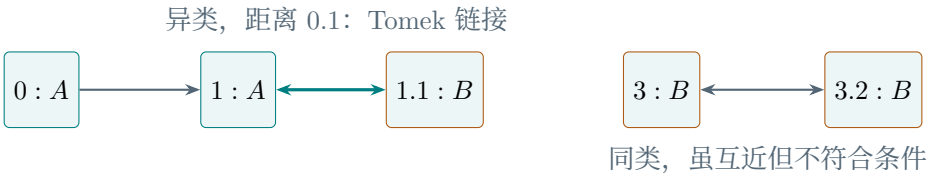


图 3.3: 五个一维数值及类别；箭头指最近邻，横向间距仅作示意，不按数值比例绘制。

读图： 1 与 1.1 异类且互近，构成链接；3 与 3.2 虽互近但同类，因此不构成链接。B 是本例多数类，若采用“只移除链接中多数类样本”规则，会移除 1.1，A/B 从 2/3 变为 2/2。

也有同时移除两端的清理约定，两者改变的数据不同。清理可能去掉噪声或边界重叠，也可能丢失有效边界信息；不保证任何模型的测试表现提高。仍只在训练折内使用，验证与测试应保持目标场景分布。

> **没有通用的每类 5000 条或总量 1000 万条门槛**
>
> 所需样本量取决于任务难度、噪声、分布、表示、模型、迁移与希望达到的误差。不要把某本材料中的经验量级变成训练资格标准或人类水平的保证。用同源边界正确的学习曲线、基线与目标误差检查数据是否仍限制效果。

参考： Little 与 Rubin，*Statistical Analysis with Missing Data*；scikit-learn Feature Selection 文档；imbalanced-learn Tomek Links 文档。图表与数值例子独立构造。