VISUAL REFERENCE HANDBOOK

机器学习与深度学习

图解速查手册

Machine Learning & Deep Learning
A Visual Cheat Sheet Handbook

原项目作者

张海飞，郭金珊，任露芹
李慧，朱靖，朱弘毅

分批修订工作稿 • 2026 年 10 月 28 日

原项目始于 2020 年 9 月；历史贡献记录完整保留于源码。

阅读说明

本书将概念、图解、公式与算例放在一起，帮助初学者建立机器学习知识之间的联系。先理解一个方法要解决的问题，再跟着图中的数据或梯度走一遍，最后回查公式与适用边界。不必先把数学附录背完，也不必一次读完全部模型。

> **当前版本**
>
> 这是持续修订中的工作稿。当前入编章节均已重写或独立补写，正文采用独立矢量图与表格；原项目资产、作者署名和贡献记录完整保留。库存中仍有未详细核查的卡片，全书也仍需后续科学与编辑复审。当前正文已不直接嵌入原插图，不表示已经审完全部原资产。

三条阅读路线

你的当前目标	建议路线
第一次学习建模	第一章建立工作流；第二–五章准备数据、评估与诊断；再挑一个经典模型动手理解。
学习神经网络	先读数据划分与损失；第十一–十三章串起前向、反向、更新与稳定训练；再读 CNN 或序列架构。
遇到具体问题回查	用附录B的主题页码与方法比较找入口，再回到相应图解；形状、概率与梯度见附录A。

每页怎样使用

先读开头的任务与定义；看图中轴、箭头、颜色和形状；对照“读图”复算小例子。随后检查提示框中的前提和常见误解。比较方法时，保持数据划分、评价口径与计算预算可比。图中有些曲线是明确标注的趋势示意，有些来自给出的实际递推或小数据；两者不要混同。

本书偏向可解释的小算例与机制，不提供“某算法总是最好”的选型口诀。不同文献可能采用不同损失缩放、矩阵方向或更新符号；先对照本页定义，再换算。“更低/更高”均需结合指标方向、样本与使用条件理解。

目录

阅读说明 i

第一部分　机器学习与经典模型 1

第一章　学习与泛化：先把问题定义清楚 2

1.1 从经验到规则，再把规则用于新输入 . . . 2
1.2 监督、无监督；分类、回归 . . . 3
1.3 决策边界划分预测区域 . . . 4
1.4 模型容量与泛化能力分别回答什么？ . . . 5
1.5 参数模型与非参数模型 . . . 6
1.6 欠拟合与过拟合：看训练，也看新数据 . . . 7
1.7 偏差与方差：固定输入，改变训练集 . . . 8
1.8 平方误差怎样分成三部分？ . . . 9
1.9 用现象诊断问题，不背固定曲线 . . . 10
1.10 第一类、第二类错误要先声明原假设 . . . 11
1.11 简单模型优先，是有条件的选择原则 . . . 12

第二章　数据准备：从原始记录到可用特征 13

2.1 样本矩阵：行、列与目标 . . . 13
2.2 无序类别与独热编码 . . . 14
2.3 有序编码保留顺序，不保证间距 . . . 15
2.4 缺失值：不知道，不等于零 . . . 16
2.5 近邻填补：用观测部分寻找相似记录 . . . 17
2.6 缩放：参数来自训练集 . . . 18
2.7 特征选择：筛选规则也是模型的一部分 . . . 19
2.8 类别不平衡：调整训练，不改写评估对象 . . . 20
2.9 SMOTE：在少数类邻居之间插值 . . . 21
2.10 把处理步骤放进同一条流水线 . . . 22

第三章　数据假设与筛选：处理规则为什么需要验证 23

3.1 MCAR、MAR 与 MNAR：缺失依赖什么？ . . . 23
3.2 完整记录分析：MAR 下也可能改变总体 . . . 24
3.3 异常值：标记、核查，再决定处理 . . . 25
3.4 方差筛选：变化大小不是预测价值 . . . 26

3.5 卡方关联筛选：频数、期望与局限 . . . 27
3.6 向前选择：每一步都是一次模型比较 . . . 28
3.7 Tomek 链接与样本量经验的边界 . . . 29

第四章 可信评估：从数据划分到指标选择 30
4.1 训练、验证与测试各自负责什么？ . . . 30
4.2 交叉验证：评估整个拟合流程 . . . 31
4.3 混淆矩阵：先声明谁是正类 . . . 32
4.4 准确率、查准率与召回率：分母决定问题 . . . 33
4.5 F1、平均方式与分类阈值 . . . 34
4.6 ROC：让阈值变化起来 . . . 35
4.7 AUC：排序能力与并列得分 . . . 36
4.8 类别比例变化时，Precision 也会变 . . . 37
4.9 回归误差：先看单位与残差 . . . 38
4.10 R^2 与平方和：把适用条件写出来 . . . 39
4.11 一页速查与自测 . . . 40

第五章 选择与诊断：把分数变成可靠判断 41
5.1 参数、超参数与搜索预算 . . . 41
5.2 嵌套交叉验证：评估选择流程 . . . 42
5.3 三种曲线：先读横轴，再谈诊断 . . . 43
5.4 概率预测：Brier 与对数损失 . . . 44
5.5 校准、排序与阈值分工 . . . 45
5.6 MCC：同时使用四种计数 . . . 46
5.7 不确定性：区间也有适用条件 . . . 47

第六章 建模工具：目标、约束与不确定性 48
6.1 假设空间、损失与风险 . . . 48
6.2 常用损失速查 . . . 49
6.3 凸性是相对具体变量而言的 . . . 50
6.4 梯度为零，不保证已经最小 . . . 51
6.5 Bootstrap：从经验分布中有放回重采样 . . . 52
6.6 AIC 与 BIC：在可比似然下权衡拟合与复杂度 . . . 53
6.7 维数灾难：覆盖空间需要多少格子？ . . . 54
6.8 贝叶斯误差：相对给定信息的最佳错误率 . . . 55

第七章 线性模型与近邻：先建立可靠基线 56
7.1 线性回归与最小二乘 . . . 56
7.2 怎样求参数：方程、分解与迭代 . . . 57

7.3 多项式回归：改变表示，不增加样本 . . . 58
7.4 Ridge：连续收缩系数 . . . 59
7.5 Lasso：为什么能够产生零系数? . . . 60
7.6 Elastic Net：同时控制稀疏与收缩 . . . 61
7.7 逻辑回归：线性得分对应分类概率 . . . 62
7.8 多分类：Softmax 与一对其余 . . . 63
7.9 k 近邻：根据局部训练记录预测 . . . 64

第八章 树、概率模型与集成学习 65
8.1 分类树：按规则进入叶子 . . . 65
8.2 回归树：叶子输出常数 . . . 66
8.3 树的复杂度与实现边界 . . . 67
8.4 朴素贝叶斯：给定类别后作独立近似 . . . 68
8.5 概率模型的估计与数值实现 . . . 69
8.6 Bagging 与随机森林：让平均更有价值 . . . 70
8.7 特征重要性：量的是哪种贡献? . . . 71
8.8 梯度提升：逐步拟合修正方向 . . . 72
8.9 AdaBoost：一个完整的二分类权重步骤 . . . 73
8.10 投票、Boosting 与 Stacking 怎样选择? . . . 74

第九章 支持向量机：用间隔约束分类 75
9.1 硬间隔与支持向量 . . . 75
9.2 软间隔：正确分类也可能付出代价 . . . 76
9.3 核函数：在相似性上建立非线性边界 . . . 77

第十章 无监督学习：分组与低维表示 78
10.1 K-means：分配，再更新中心 . . . 78
10.2 选择簇数与轮廓系数 . . . 79
10.3 DBSCAN：通过核心点扩展密度连接 . . . 80
10.4 层次聚类：链接方式决定合并距离 . . . 81
10.5 PCA：寻找单位长度的最大方差方向 . . . 82
10.6 保留多少主成分：方差与任务一起看 . . . 83
10.7 核 PCA 与方法选择的边界 . . . 84

第二部分 深度学习基础 85

第十一章 神经网络：从结构到一次参数更新 86
11.1 把训练过程连起来 . . . 86

11.2 结构、前馈与隐藏层 . . . 87
11.3 神经元与前向计算 . . . 88
11.4 为什么需要非线性激活? . . . 89
11.5 XOR：隐藏表示怎样改变可分性 . . . 90
11.6 Softmax：把一组得分变为分布 . . . 91
11.7 把输出层和损失函数配对 . . . 92
11.8 反向传播：把链式法则组织起来 . . . 93
11.9 手算一次完整的训练更新 . . . 94
11.10 梯度下降与学习率 . . . 95
11.11 一页速查与自测 . . . 96

第十二章 让训练稳定下来：批量、优化与正则化 97
12.1 样本、批量、更新次数与轮次 . . . 97
12.2 小批量 SGD：用部分数据估计梯度 . . . 98
12.3 动量：给更新方向加上记忆 . . . 99
12.4 RMSprop 与 Adam：按坐标调整更新 . . . 100
12.5 手算 Adam 的两步更新 . . . 101
12.6 梯度消失：链条越长，乘积可能越小 . . . 102
12.7 初始化：打破对称，并控制传播量级 . . . 103
12.8 Dropout：训练时加噪声，评估时关掉 . . . 104
12.9 提前停止：保存最优记录，再耐心等待 . . . 105
12.10 把这些组件放回训练流程 . . . 106
12.11 一页速查与自测 . . . 107

第十三章 训练细节：稳定计算与正则化 108
13.1 激活变体：看函数，也看导数 . . . 108
13.2 从 logits 稳定计算交叉熵 . . . 109
13.3 RMSprop、L2 与解耦权重衰减 . . . 110
13.4 裁剪梯度：限制范数，不修复全部不稳定 . . . 111
13.5 把不同正则化方式放回训练流程 . . . 112

第十四章 卷积网络：共享局部计算 113
14.1 张量形状：批量、通道与空间 . . . 113
14.2 一次卷积怎样得到一个数? . . . 114
14.3 通道与参数共享：参数数怎样算? . . . 115
14.4 步幅、填充与输出大小 . . . 116
14.5 池化与理论感受野 . . . 117
14.6 残差连接：为变换加一条直接路径 . . . 118

14.7 归一化层：统计量在哪些轴上计算？ . . . 119
14.8 数据增强：保持任务语义的变化 . . . 120
14.9 一个完整小网络：形状与参数对照 . . . 121

第十五章 文本表示：从符号到模型输入 122
15.1 Tokenization、词干与停用词 . . . 122
15.2 词袋与 TF-IDF：可解释的稀疏基线 . . . 123
15.3 嵌入与 Word2Vec：学习稠密向量 . . . 124

第十六章 序列与注意力：共享状态与动态汇总 125
16.1 RNN：同一组权重逐位置更新状态 . . . 125
16.2 LSTM 与 GRU：门控制信息更新 . . . 126
16.3 注意力：查询键，再汇总值 . . . 127
16.4 因果与填充遮罩：在 Softmax 之前处理 . . . 128
16.5 多头注意力：多组投影再拼接 . . . 129
16.6 Transformer 块：注意力、前馈与残差 . . . 130
16.7 编码器、解码器与下一 Token 目标 . . . 131
16.8 比较架构，同时检查时间与内存 . . . 132

第十七章 迁移学习：复用表示，再验证目标任务 133
17.1 冻结与微调分别更新什么？ . . . 133

附录 A 数学速查：为模型计算服务 134
A.1 向量、矩阵与乘法形状 . . . 134
A.2 内积、范数、秩与行列式 . . . 135
A.3 特征值与奇异值：方向、缩放与降维 . . . 136
A.4 导数、梯度与链式法则 . . . 137
A.5 条件概率与贝叶斯公式 . . . 138
A.6 随机变量、期望、方差与协方差 . . . 139
A.7 常用分布与样本统计量 . . . 140

附录 B 符号、方法比较与主题索引 141
B.1 符号与口径 . . . 141
B.2 监督模型：先做什么基线？ . . . 142
B.3 无监督与神经架构：目标和结构相配 . . . 143
B.4 主题入口：数据、评估与经典方法 . . . 144
B.5 主题入口：神经计算与数学 . . . 145

参考资料与继续阅读 146

第一部分

机器学习与经典模型

第一章　学习与泛化：先把问题定义清楚

机器学习（Machine Learning）利用数据中的经验改善任务表现。开始建模前，至少要说清楚三件事：完成什么任务、有哪些可用经验、怎样判断表现。“会拟合数据”只是其中一环，最终还要看模型面对合适的新数据是否有用。

> **贯穿全书的四个问题**
>
> 要预测什么？预测时能获得什么？希望在哪种新数据上有效？哪些错误代价更大？模型类型、数据处理、训练目标和评估指标，都需要围绕这些问题选择。

1.1　从经验到规则，再把规则用于新输入

例如根据设备运行记录预测下一天是否故障：任务是故障分类，经验是历史记录与后续故障标签，表现可以用漏报率、误报率或相应成本衡量。只报训练准确率不足以说明这个任务已经做好。

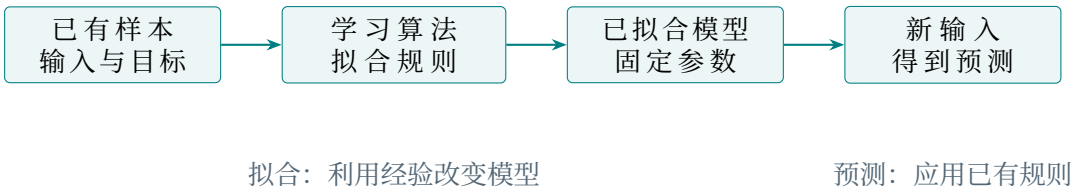


图 1.1：监督学习中的拟合与预测。新输入应满足任务中约定的信息可用性。

读图：学习算法从样本得到一个模型；已拟合模型再把新输入映射为预测。拟合不是逐条记住答案的同义词，预测也不保证每次正确。模型表现是否随更多经验改善，需要用合适的评估流程检验。

1.1.1　预测关系不自动等于因果关系

记录中的某个特征与故障相关，可以帮助预测，但不表示主动改变它一定能减少故障。采集方式、共同原因和选择偏差都可能形成相关性。因果问题需要额外假设或实验设计。

记住：先写下任务、信息与评估规则，再开始选算法。

1.2 监督、无监督；分类、回归

监督学习（Supervised Learning）有用于学习的输入—目标对应关系。无监督学习（Unsupervised Learning）不依赖这种任务标签，常用于寻找结构、压缩或描述分布。

问题	目标形式	例子
分类 Classification	离散类别	是否故障、图像属于哪种动物。
回归 Regression	数值	明日温度、房屋价格。
聚类 Clustering	无给定类别标签，寻找分组	按购买行为探索客户群。
降维 Dimensionality reduction	构造较少的表示坐标	用低维表示压缩或可视化特征。

分类标签即使用数字 0、1、2 表示，仍然是类别。回归值可以是连续测量，也可以是数值计数；关键是预测目标的含义与损失。逻辑回归虽然名为“回归”，常用于分类概率建模。

> **没有标签不代表没有评估**
>
> 聚类结果仍需根据稳定性、结构与实际用途检验，不能只看图上是否分得好看。无监督步骤如果参与后续监督任务，也应服从相应的数据划分与拟合边界。无监督学习并不天然优于或劣于监督学习，两者回答的问题不同。

记住：分类和回归按目标区分；监督和无监督按学习信号区分。

1.3 决策边界划分预测区域

分类器的决策边界（Decision Boundary）是预测类别发生变化的位置。考虑得分 $s = x_1 + x_2 - 4$，采用 $s \geq 0$ 预测 1，否则预测 0；边界是 $x_1 + x_2 = 4$。

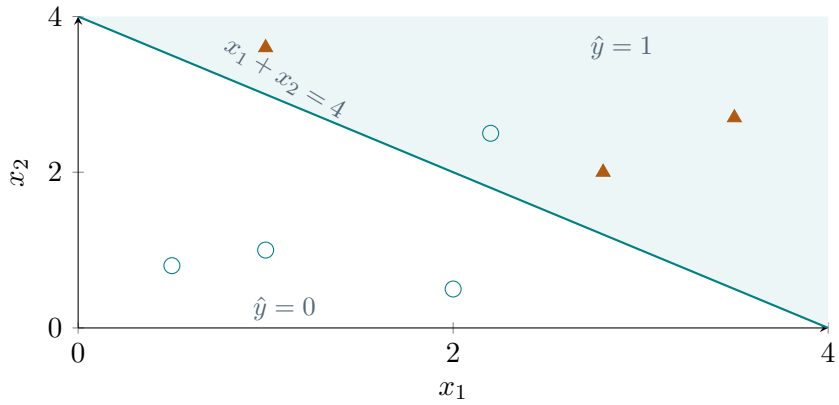


图 1.2: 圆点真实标签为 0，三角真实标签为 1；背景及直线表示模型的预测规则。

读图：直线上方预测 1，下方预测 0。有一个圆点落在上方，因此会被误分。边界说明模型怎样预测，散点说明观测标签，两者不必完全一致。

如果得分先经过 Sigmoid 得到概率 $p = \sigma(s)$，以 $p \geq 0.5$ 分类仍得到同一边界。改变概率阈值会改变边界的位置。非线性特征或模型可以产生弯曲边界，但边界更曲折不直接证明预测更好。

> **类别、得分、概率是不同对象**
>
> 得分可取任意实数；概率应在 $[0, 1]$ 内；类别由决策规则产生。得分经函数变到 $[0, 1]$ 不等于已经证明概率校准良好。

1.4 模型容量与泛化能力分别回答什么？

模型容量（Capacity）描述候选函数集合的表达能力。例如所有常数函数包含在一次多项式中，一次多项式又包含在至多二次多项式中。

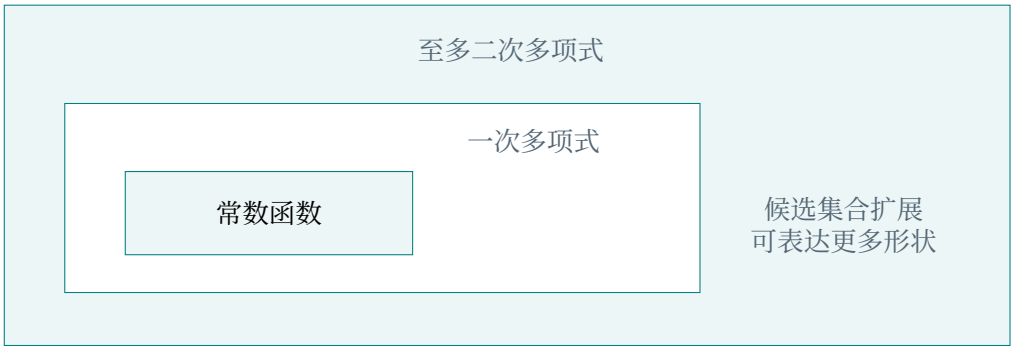


图 1.3: 候选函数集合的包含关系示例。方框面积不表示任何数值容量指标。

读图：外层集合可以表达内层集合的函数，也能表达更多形状。若使用同一训练损失、没有额外限制并找到全局最优，扩大候选集合不会提高最优训练损失。这不保证实际优化一定找到最优，更不保证新数据表现改善。

泛化（Generalization）关注从已见数据学到的规则在目标新数据上的表现。它取决于数据量、任务结构、噪声、模型和训练方式，也受训练与使用分布差异影响。参数多寡可提供一些线索，但不是跨模型通用的容量或泛化度量。

记住：容量问“能够表达什么”；泛化问“学到的规则在目标新数据上表现如何”。

1.5 参数模型与非参数模型

固定输入维度时，参数模型（Parametric Model）用固定有限维参数描述模型族。非参数模型（Nonparametric Model）的复杂度可以随数据量增长；这个名称不表示没有参数。

例子	怎样表示	主要边界
线性回归	d 个系数与一个截距。	固定 d 时，样本增加不会新增系数。
固定结构神经网络	固定数量的权重与偏置。	是参数模型；函数可以高度非线性。
k 近邻预测	保存训练样本并查询邻居。	需要保存的信息通常随训练量增长；k 是超参数。
可增长的树	根据数据形成切分与叶子。	复杂度受深度、叶数等限制；具体约束需声明。

参数是拟合时学习的量，如回归系数；超参数（Hyperparameter）控制模型或训练流程，如近邻数、树深和正则化强度，常通过开发数据内验证选择。

不能从名称推出分布假设

参数模型不等于“数据必须正态”，非参数模型也不等于“没有任何假设”。距离、平滑性、局部结构等仍是重要假设，必须结合具体模型判断。

1.6 欠拟合与过拟合：看训练，也看新数据

欠拟合（Underfitting）指模型或训练流程未充分学到有用结构。过拟合（Overfitting）指对训练样本中的偶然变化适应过多，影响新数据表现。用同一组九条带固定扰动的样本，比较三种最小二乘多项式拟合。

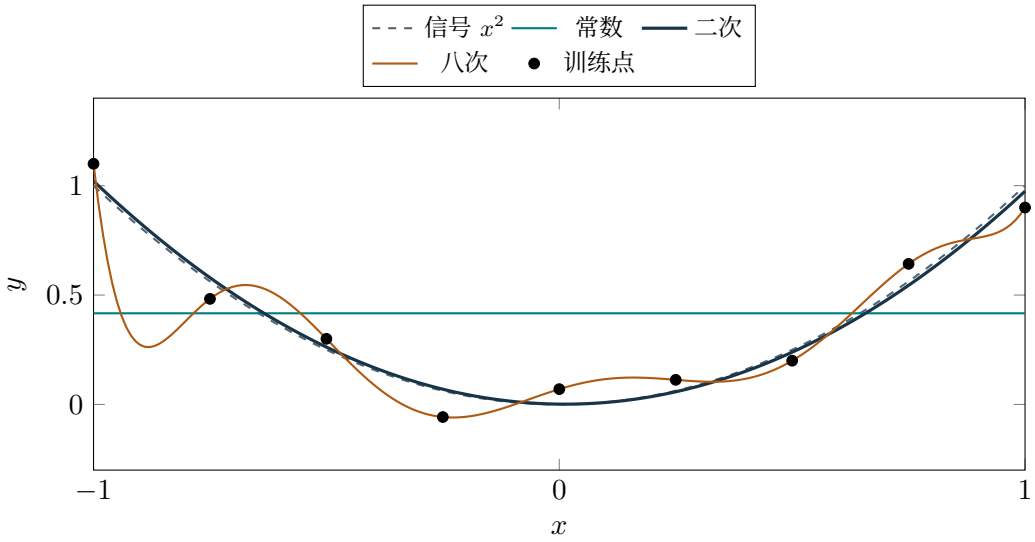


图 1.4: 人工构造的 $y = x^2 + \varepsilon$ 示例。曲线在同一训练集拟合；虚线是已知生成信号。

读图：常数无法描述弯曲趋势；二次函数接近信号；八次函数穿过训练点但产生额外起伏。这些判断在本例有已知信号支撑。真实任务通常不知道信号，需依靠独立验证。

拟合次数	训练 MSE	网格上对真实信号的 MSE
0	0.13933	0.09707
2	0.00639	0.00018
8	$< 10^{-20}$	0.02308

数值保留五位小数；网格误差只比较 201 个等距位置的无噪声信号，不是从真实人群采集的测试分数。

1.7 偏差与方差：固定输入，改变训练集

回归中固定输入 x，令 $f(x) = \mathbb{E}[Y \mid X = x]$。从相同机制重新采集训练集 D 并拟合，得到不同预测 $\hat{f}_D(x)$。期望 $\mathbb{E}_D$ 表示对这些训练集及所考虑的训练随机性取平均。

$$\bar{f}(x) = \mathbb{E}_D[\hat{f}_D(x)], \qquad \mathrm{Bias}(x) = \bar{f}(x) - f(x),$$

$$\mathrm{Var}(x) = \mathbb{E}_D[(\hat{f}_D(x) - \bar{f}(x))^2].$$

偏差描述平均预测偏离条件均值的程度，方差描述不同拟合之间预测的波动。它们都不是单个训练样本的残差。

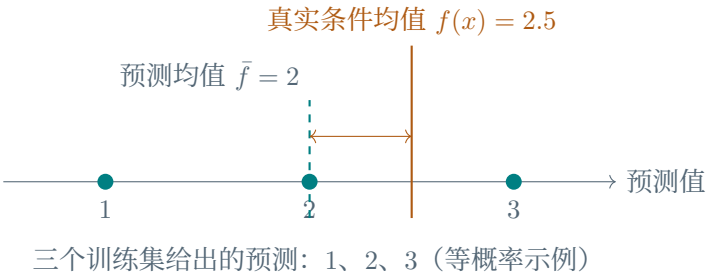


图 1.5: 固定 x 处，三种训练结果等概率出现的离散教学例子。

读图：预测均值为 2,偏差为 $2-2.5 = -0.5$,偏差平方为 0.25。方差为 $[(1-2)^2+0+(3-2)^2]/3 = 2/3$。偏差可以有正负，偏差平方非负。

> **一个数据集的残差不能直接给出这些量**
>
> 真实条件均值通常未知，也没有无限多个独立训练集。重采样实验可以帮助研究稳定性，但不能把其输出自动当作真实偏差和方差。

1.8 平方误差怎样分成三部分?

设新响应 $Y = f(x) + \varepsilon$ 满足 $\mathbb{E}[\varepsilon \mid x] = 0$、$\mathrm{Var}(\varepsilon \mid x) = \sigma^2(x)$，且新响应噪声与训练集独立。固定 x，有

$$\mathbb{E}_{D,Y|x}[(Y - \hat{f}_D(x))^2] = \mathrm{Bias}(x)^2 + \mathrm{Var}(x) + \sigma^2(x).$$

部分	在这个设置下的含义
偏差平方	平均预测与条件均值的差异。
预测方差	不同训练集、训练随机性造成的预测波动。
条件噪声方差	给定现有特征 x，响应仍有的不确定性。

1.8.1 只需看交叉项为什么为零

写成 $Y - \hat{f}_D = \varepsilon + (f - \bar{f}) + (\bar{f} - \hat{f}_D)$。平方展开后，$\mathbb{E}\varepsilon = 0$、$\mathbb{E}_D(\bar{f} - \hat{f}_D) = 0$，以及新噪声与训练集的独立性，使交叉项期望为零；其余三项就是上式。

接着上一页，令新噪声以相同概率取 -0.5 或 0.5，则噪声方差为 0.25。预期平方误差为 $0.25 + 2/3 + 0.25 = 7/6 \approx 1.167$。对三个预测与两个新响应的六种组合直接计算，也得到相同结果。

> **条件与损失不能省略**
>
> 这是固定输入处、独立新响应的平方损失分解，不能原样套到 0–1 错误率。噪声是相对给定特征而言的；增加有效信息可能降低条件不确定性。变量相关本身不等于噪声来源。

1.9 用现象诊断问题，不背固定曲线

经典偏差—方差权衡提供一种解释：放宽模型限制时，偏差可能降低而方差可能增大。但这不是所有算法、数据量和训练方式下的单调定律，验证误差也不保证呈单一 U 形。

观察到的现象	先检查什么
训练与验证都较差	数据/目标是否一致，特征是否有信息，优化是否充分，限制是否过强。
训练好、验证明显差	泄漏与划分是否正确，样本量与代表性，模型约束，选择流程是否过多调试。
训练与验证接近	接近不代表都好；要与简单基线、目标需求比较。
上线表现突然恶化	输入、标签、采集流程或人群是否变化，是否存在时间或群组差异。

正则化、限制树深、早停、更多合适数据等都可能改善泛化。增加复杂度也可能改善欠拟合，但应先排查编码错误、训练未收敛等实现问题。数据量增加并不保证错误标签或分布错位自行消失。

记住：把诊断变成可比较的实验：固定划分、一次改变清楚的因素，再看验证结果。

1.10 第一类、第二类错误要先声明原假设

假设检验中先设原假设 H_0 和备择假设 H_1。第一类错误（Type I Error）是在 H_0 为真时拒绝它；第二类错误（Type II Error）是在 H_0 为假时未拒绝它。

真实情况	拒绝 H_0	未拒绝 H_0
H_0 为真	第一类错误	无此类错误
H_0 为假	无此类错误	第二类错误

若把 H_0 设为“没有故障”，并把拒绝 H_0 作为“检出故障”，第一类错误对应假阳性，第二类错误对应假阴性。这项对应依赖原假设和正类定义，不能跳过声明。第一类错误概率记为 α，第二类错误概率记为 β，检验功效为 $1-\beta$。

> **未拒绝不等于证明为真**
>
> 没有足够证据拒绝 H_0，可能是效应弱或样本不足。p 值也不是“原假设为真的概率”。预测模型的错误率与统计检验的错误概率，需要按各自任务分别定义。

1.11 简单模型优先，是有条件的选择原则

奥卡姆剃刀（Occam's Razor）鼓励在解释能力和证据相近时，避免不必要的复杂性。在实际建模中，可以同时比较验证表现、维护成本、解释要求和运行代价，不能只凭训练集拟合好坏就宣布简单模型总是更优。

1.11.1 没有免费午餐强调假设的重要性

没有免费午餐（No Free Lunch）定理有具体的任务空间、平均方式和损失等条件。在有限输入、所有标签函数等可能的设置下，未观察位置的标签无法仅凭已有标签推断；对所有这些任务平均，并不能获得普遍占优的预测规则。实际任务通常具有结构，模型正是利用这种结构与先验假设工作。

> **两句话可以同时成立**
> 没有一个方法在所有可能任务上普遍最好；某个方法在明确的一类实际任务上可能非常有效。因此应从任务结构提出候选模型，再用适当数据比较，而不是随机选择或放弃比较。

1.11.2 自测与回看

训练误差为零，是否证明泛化良好？**不能**。固定结构神经网络是否一定属于非参数模型？**不是**。偏差是否就是一次预测的残差？**不是**。第二类错误是否是假阳性？**在常见“无病”为原假设的对应中，是假阴性**。

参考：James 等，*An Introduction to Statistical Learning*，第二版，2021，第 2 章；本章数值例子、图和计算文件均为独立构造。

第二章　数据准备：从原始记录到可用特征

模型接收的是经过整理的输入。列代表什么、缺失怎样表达、尺度如何确定，都会改变模型能学到的关系。本章用小表和可复算的数字解释这些步骤。

> **先划分，再学习处理规则**
> 凡是需要从数据中估计的处理规则，都属于拟合流程的一部分。填补值、缩放参数、类别字典和特征选择规则只在训练数据上学习；验证与测试沿用这些规则。交叉验证时，这个边界要在每一折重新建立。

2.1　样本矩阵：行、列与目标

样本矩阵（Design Matrix）$X \in \mathbb{R}^{n \times d}$ 的每行是一条样本，每列是一个输入特征。x_{ij} 表示第 i 个样本的第 j 个特征。单目标监督学习的标签向量为 $y \in \mathbb{R}^n$；分类时其元素也可以是类别标签。



图 2.1：三个样本、三个数值特征与一个目标的结构示例。数字仅用于说明形状。

读图：第三列只有 0 和 1，仍可能是输入特征。是不是目标取决于任务定义，不能仅凭数据类型或列的位置判断。样本顺序改变时，X 与 y 必须同步改变。

2.1.1　先问预测时能否获得这个特征

预测违约时，申请时的收入可能可用，事后产生的催收记录不能提前作为输入。姓名、设备编号、时间戳不应机械地当作普通连续数值：它们可能用于分组划分、构造合理特征，也可能让模型记住身份或未来信息。

记住：特征不是“表中除标签之外的所有列”；每一列都需要含义、单位和可用时间。

2.2 无序类别与独热编码

无序类别（Nominal Category）只有类别差异，没有自然大小顺序。把红、蓝、绿编码为 0、1、2，并不能说明绿比蓝“大”，也不能说明两者距离为 1。独热编码（One-Hot Encoding）为每个类别建立一个指示列。



图 2.2: 三种颜色映射到三个指示列；这里没有定义颜色间的顺序。

读图：一条非缺失、属于已知类别的记录，在完整独热编码中恰有一列为 1。拟合时记录类别字典和列顺序；预测时必须保持同一顺序。

2.2.1 三个常见边界

训练中未出现的新类别需要预先定义处理方法，例如报错、归入“其他”，或按编码器约定输出全零。若全零同时用作基准类别，应理解其语义可能重合。类别很多时，独热矩阵会很宽；可考虑稀疏存储、合理合并或专门的类别模型。有些树模型原生支持类别特征，应遵循实现接口。

> **独热列与截距可能线性相关**
>
> 完整的 K 个独热列逐行之和为 1，和截距列相关。无约束线性模型常删除一个基准类别列，或采用相应约束；是否删除要结合模型与正则化，不能把“所有模型必须删一列”当成规则。

2.3 有序编码保留顺序，不保证间距

有序类别（Ordinal Category）具有自然顺序，例如低、中、高。编码为 0、1、2 可以表达这种顺序，但不保证“中到高”与“低到中”的实际差异相等。

原特征	可用表示	引入的含义
低、中、高	有序编码 0、1、2	保留顺序；在线性模型中还引入等间距效应。
红、蓝、绿	三个独热列	各类别分别具有指示特征，不强加大小关系。
真实温度	有单位的数值	数值差异有物理意义，需保留测量单位。

例如线性预测 $\hat{y} = b + wx$，低、中、高编码 0、1、2 后，相邻等级的预测差都为 w。这是一项模型假设；若不合理，可以用独热编码分别估计各等级效果。树对有序整数作阈值切分可以保留等级顺序，但任意给无序类别编号会限制它可直接表达的分组。

> **编码值不是比例尺度**
>
> 低 =1、中 =2、高 =3，只说明人为选定了三个数字。不能据此说“高的实际程度是低的三倍”。顺序、差值与倍数是不同层次的信息。

记住：编码方式要与变量含义及模型的使用方式一起选择。

2.4 缺失值：不知道，不等于零

缺失值（Missing Value）表示未获得观测。零可能是有效数值，不能默认用零代替所有缺失。先区分未测量、不适用、采集失败等原因，再选择处理策略。

处理方式	适用考虑与代价
训练均值或中位数	数值特征的简单基线；压缩变异，不能恢复真实缺失值。
训练众数或专门类别	用于类别列；专门类别可以显式保留“未知”的语义。
增加缺失指示列	让模型知道该位置原本缺失；需防止采集流程变化破坏关系。
删除行或列	损失信息，并可能改变样本分布；不能只凭缺失比例小就断言无偏。
利用其他特征预测	如近邻填补；依赖相关结构，仍需验证效果。

训练列为 $[10, \text{缺失}, 20, 30]$ 时，中位数为 20。填补后为 $[10, 20, 20, 30]$；缺失指示列为 $[0, 1, 0, 0]$。新样本的缺失仍用训练得到的 20 填补，不在测试列上重新计算中位数。

> **时间顺序也约束填补**
>
> 预测某时刻的结果时，不能利用当时尚未产生的未来记录反向填补。有些模型可以直接处理缺失值，也需要确认实现的支持范围和训练、预测时的语义一致。

记住：填补后的值是建模用的估计，不是已经找回的真实观测。

2.5 近邻填补：用观测部分寻找相似记录

k 近邻填补（k-NN Imputation）根据已观测特征寻找相似的训练记录，再汇总这些邻居在缺失列上的值。下面只用一个已观测特征 A 计算距离。

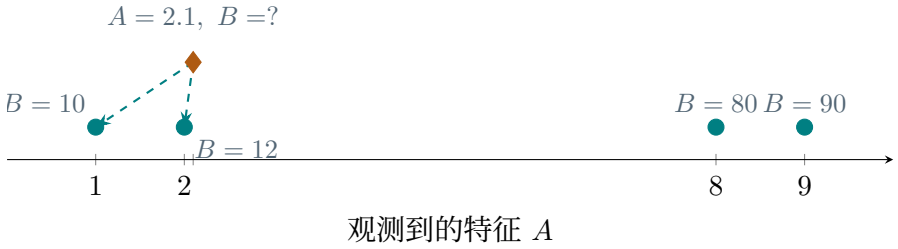


图 2.3: 训练记录为 $(1,10),(2,12),(8,80),(9,90)$；橙色新记录的 B 缺失。

读图：到 $A=2.1$ 的距离分别为 1.1、0.1、5.9、6.9。当 $k=2$ 且等权时，选择前两条记录，填补 $B=(10+12)/2=11$。全部训练 B 的中位数则为 $(12+80)/2=46$；两种规则表达不同假设。

2.5.1 距离怎样定义，决定谁是邻居

缺失的 B 本身不能用于寻找邻居。多维特征可依据共同观测的部分定义距离，但共同观测很少时相似度可能不可靠；具体距离和无可用邻居时的回退规则需明确。量纲也会影响距离，例如以元计价的收入可能淹没以年计的年龄。

> **没有固定最优的邻居数**
>
> k、权重、尺度与距离都应通过训练内验证选择。仅从训练数据保存供填补使用的邻居，不能把验证或测试记录加入邻居库。近邻填补可能保留局部结构，也可能传播异常值，不能预先断言优于简单填补。

2.6 缩放：参数来自训练集

Min–Max 缩放使用训练最小值 a 和最大值 b：

$$x' = \frac{x - a}{b - a} \quad (b > a).$$

标准化（Standardization）使用训练均值 μ 与标准差 s：

$$x' = \frac{x - \mu}{s}, \qquad \mu = \frac{1}{n}\sum_i x_i, \quad s = \sqrt{\frac{1}{n}\sum_i (x_i - \mu)^2}.$$

这里明确使用分母 n，与一些统计教材的样本标准差约定不同。

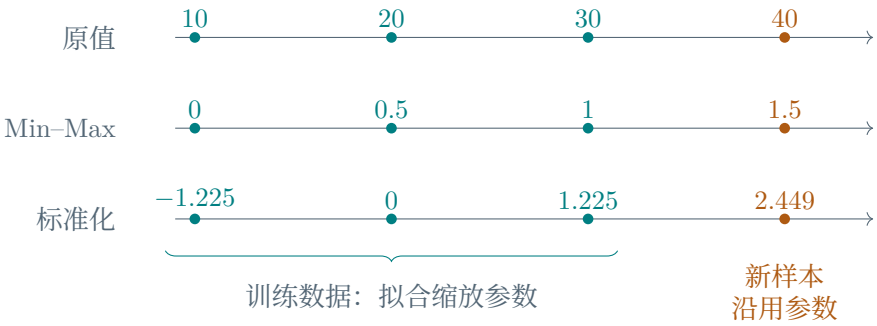


图 2.4: 训练值 10、20、30；新值 40 沿用同一套参数。标准化数字保留三位小数。

读图： 训练均值为 20，标准差为 $\sqrt{200/3} \approx 8.165$。新值 40 经 Min–Max 变为 1.5，经标准化变为约 2.449。训练范围映射到 $[0, 1]$，不意味着所有未来值都在 $[0, 1]$ 内。

> **标准化不会自动变成正态分布**
>
> 减均值、除标准差只改变位置与尺度。它不消除偏态，也不消除异常值。常数列分母为零，需要明确保留、删除或特殊处理规则，不能直接相除。

距离、正则化和梯度更新常受尺度影响；常规按单列阈值切分的树通常不依赖这种缩放。是否缩放仍由模型与特征含义决定。

2.7 特征选择：筛选规则也是模型的一部分

特征选择（Feature Selection）保留原特征的一个子集。它不同于把原特征重新组合成新坐标的特征提取，例如主成分分析。

方法	怎样选择	主要边界
过滤法 Filter	用统计量或单变量分数筛选。	快；单变量分数可能漏掉交互作用。
包装法 Wrapper	对候选子集拟合并验证模型，如前向选择、递归消除。	开销大；反复比较会过拟合验证结果。
嵌入法 Embedded	在训练中形成选择，如 L1 惩罚产生零系数。	依赖模型、尺度及超参数。

先在全部数据上用标签选出“相关性最高”的列，再进行交叉验证，已经泄漏验证标签。每折需要只用子训练集拟合筛选器，再把选定列应用到该折验证集。

2.7.1 不要把经验规则写成定理

高度相关的列可能冗余，也可能各自包含有效信息；低方差的指示特征仍可能识别重要的罕见类别。树的重要性、线性系数大小与预测贡献都受模型和数据影响，不能直接解释为因果作用。

记住：先确定选择流程，再评估整个流程。删列后的泛化表现，比“看起来显著”更接近实际目标。

2.8 类别不平衡：调整训练，不改写评估对象

类别不平衡（Class Imbalance）指类别频率差异较大。多数类、少数类由频率决定，正类、负类由任务定义决定，两组概念不能混用。

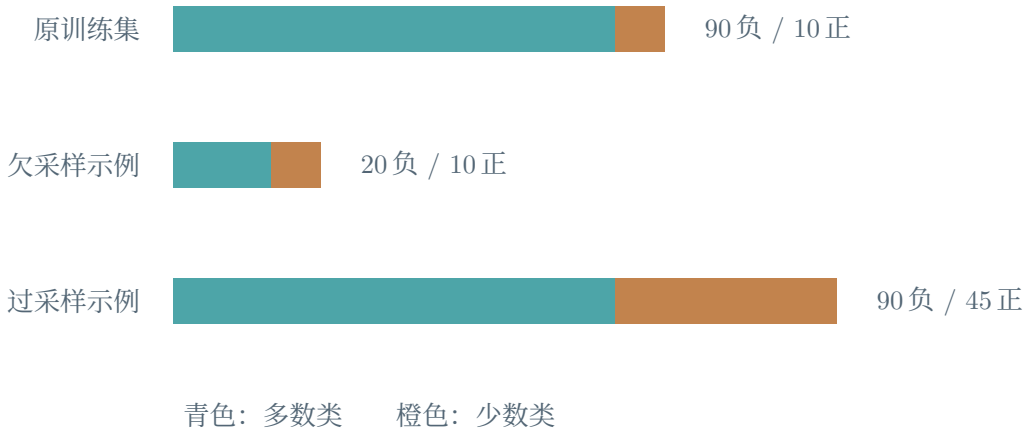


图 2.5： 90 个负类、10 个正类的两个独立采样示例；不要求一定变成 1:1。

读图： 欠采样（Undersampling）从多数类中保留较小子集，会损失部分记录。随机过采样（Random Oversampling）重复抽取少数类，使其在训练中出现更多次；45 条少数类训练记录不代表获得 45 个独立的新对象。

采样只在训练数据内进行；验证与测试保留目标使用场景的分布。交叉验证时也只处理每折子训练集。先重复样本再划分，会使相同对象跨训练与验证。

> **比例变化会影响概率解释**
>
> 采样改变了模型接触的类别先验。输出的概率未必仍是原始人群中的风险概率。阈值选择与概率校准需要在具有目标分布、用途独立的数据上处理。也可以比较类别权重等方案，不必先认定采样一定有益。

2.9 SMOTE：在少数类邻居之间插值

SMOTE 是一种合成过采样方法。基本形式在少数类样本 x_i 与其少数类近邻 x_j 之间生成

$$x_{\text{new}} = x_i + \lambda(x_j - x_i), \qquad 0 \le \lambda \le 1.$$

若 $x_i = (1, 2)$、$x_j = (3, 4)$ 且 $\lambda = 0.25$，则 $x_{\text{new}} = (1.5, 2.5)$。这条新记录位于两点之间，并不证明它在实际世界中一定合理。

需要检查	原因
特征尺度与距离	它们决定选到哪些近邻。
少数类边界与异常值	插值可能穿过多数类区域，或放大噪声。
类别型与离散约束	直接插值可能产生无意义的“半个类别”；需相应方法或表示。
少数类数量	太少时近邻关系不稳，且可能无法满足算法的邻居数要求。
独立验证表现	合成点不是独立采集的额外证据，仍需在目标分布上评估。

记住：随机复制改变记录出现频率；SMOTE 改变训练点的位置。两者都不能替代真实的新数据。

2.10 把处理步骤放进同一条流水线

流水线（Pipeline）把处理步骤按顺序连接，让训练和预测遵循同一套规则。数值列与类别列可以分别处理，再拼接为模型输入。

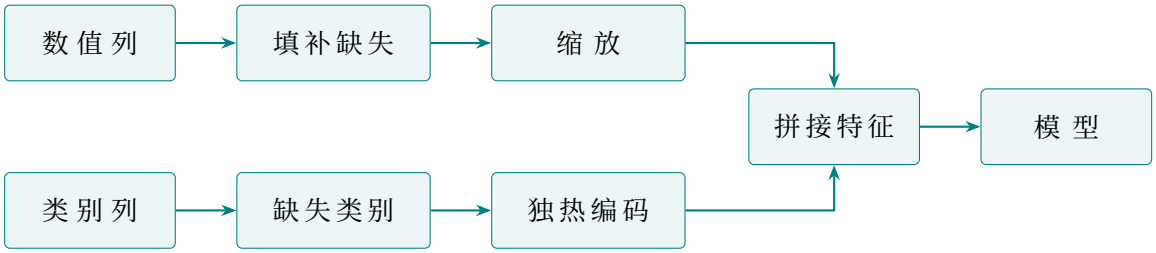


图 2.6: 一个基础表格数据流程；箭头表示数据经过的步骤。可在训练支路添加筛选和采样。

读图：拟合时，在训练集学习各步所需参数并拟合模型。预测时只调用已学规则。数值填补放在缩放之前，是此例的选择；近邻填补等流程还需单独设计距离尺度，不能机械套用。

步骤	训练时学习	验证、测试或上线时使用
填补	中位数、众数或邻居库	固定填补规则
缩放	均值、标准差或极值	固定参数变换
编码	类别字典与列顺序	同一字典及未知类策略
选择	训练内确定的特征子集	同一组列
采样	训练记录的选择、复制或合成	不对待评估记录采样

2.10.1 自测与回看

测试值超出训练最大值，经 Min–Max 得到 1.2，是否一定是程序错误？**不是**。交叉验证前用全部标签筛选列，是否合适？**不合适，筛选应在每折训练内**。复制 10 条少数类到 50 条，是否等于新增 40 个独立对象？**不等于**。

核查依据：scikit-learn 的 Preprocessing、Imputation、Feature selection 与 Common pitfalls 文档，以及 imbalanced-learn 的 Common pitfalls 文档（访问于 2026-10-28）。计算记录见本项目第四批审校文件；图均为本书独立绘制的矢量图。

第三章　数据假设与筛选：处理规则为什么需要验证

补值、删除、变换与筛选都在改变模型看到的信息。本章把常见处理建议背后的假设拆开，避免把一个统计规则当作无条件的数据清洗标准。

3.1　MCAR、MAR 与 MNAR：缺失依赖什么？

考虑一个可能缺失的变量 X、完整观测的变量 Z，令 $R = 1$ 表示 X 被观测到。下面用这个简化设置理解三类缺失机制，不把“随机”误读成没有任何规律。

机制	条件关系	教学例子
MCAR：完全随机缺失	$P(R = 1 \mid X, Z)$ 为常数。	与记录内容无关的随机传输丢失。
MAR：随机缺失	$P(R = 1 \mid X, Z) = P(R = 1 \mid Z)$。	保留率只由已记录的站点决定。
MNAR：非随机缺失	给定 Z 后，保留率仍依赖未观测的 X。	收入本身越高，越不愿填写收入。

MAR 允许缺失概率依赖已观测信息；它不是 MCAR 的同义词。MNAR 也不等于“缺失不是随机掷硬币”：关键是给定已观测信息后，是否仍依赖缺失部分。一般多变量缺失模式比这里复杂，须针对可用观测和分析目标定义。

> **不能只看观测表就证明 MAR**
>
> 缺失部分的真值通常不可见，不同机制可能产生相同的观测分布。应结合采集流程、领域知识与敏感性分析；“没发现关系”不能证明缺失完全随机。是否采用缺失指示变量、模型填补或专门缺失机制模型，仍需验证。

记住：缺失机制讨论数据怎样被观察；填补方法讨论如何处理已得到的表。两者不能凭名称一一配对。

3.2 完整记录分析：MAR 下也可能改变总体

完整记录分析（Complete-case Analysis）只保留所需变量齐全的记录。是否合适取决于估计目标、缺失机制与模型，不能说“缺失原因在其他特征中体现，就一定可以删”。

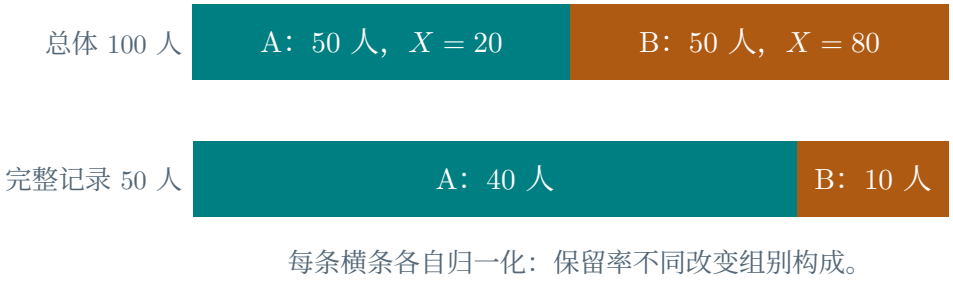


图 3.1： 可见全部真值的教学构造。A 组保留率 0.8，B 组保留率 0.2，只依赖已观测组别 Z。

读图： 总体两组各 50 人，A 的 $X = 20$、B 的 $X = 80$，总体均值为 50。按图中预期保留构成，只看完整记录的均值为 $(40 \times 20 + 10 \times 80)/50 = 32$。即使缺失满足本例 MAR 关系，不加调整的完整记录均值也偏离总体目标。

如果知道目标总体两组各占一半，并且组内观测足以代表组内目标，按目标组比例加权可恢复 $0.5 \times 20 + 0.5 \times 80 = 50$。现实中不能预先看到缺失真值，这种调整也依赖相应假设与足够覆盖。

MCAR 下，完整记录可能仍是对总体的随机子样本，但会损失精度，少量完整记录也不足以可靠训练复杂模型。某些条件模型在更弱机制下仍可有效估计，因此也不能反过来说“只有 MCAR 才允许任何完整记录分析”。

记住： 先写清要估计的是总体均值、条件关系还是预测表现，再论删除与填补；对预测任务也要模拟实际缺失模式。

3.3 异常值：标记、核查，再决定处理

异常值（Outlier）是相对于某种分布、模型或规则显得少见的记录。少见不等于错误；真实故障、罕见疾病或极端交易可能正是目标。

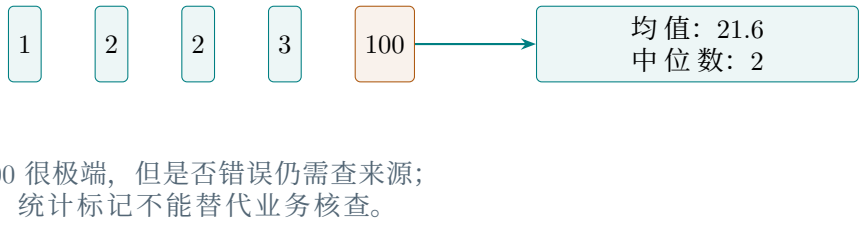


图 3.2: 五个数的例子；方框只列记录，不表示等距数轴。

读图：均值被 100 明显拉动，中位数仍为 2。若把 100 截到 5，均值变为 2.6；这是修改了数据和估计对象，不能仅凭数字更“正常”就宣称处理正确。

按本例线性分位数约定，$Q_1 = 2, Q_3 = 3$，$\mathrm{IQR} = 1$。常见箱线图围栏 $[Q_1 - 1.5\mathrm{IQR}, Q_3 + 1.5\mathrm{IQR}] = [0.5, 4.5]$ 会标记 100；围栏是诊断启发式，不是测量错误的判决。不同分位数定义、分组或时间范围可能改变标记结果。

证据与选择	处理考虑
确认录入或单位错误	按来源修正，无法修正时明确标记或排除理由。
真实但极端	保留目标事件；比较稳健损失、适当变换或分组模型。
暂时不确定	记录标记并做敏感性比较，不默认“标记最安全”或“取对数总有用”。

从数据估计的截断阈值与变换参数仍只在训练部分拟合；不要为了改善测试分数事后删除困难样本。

3.4 方差筛选：变化大小不是预测价值

方差阈值（Variance Threshold）是不使用标签的筛选方法。近乎常数的特征在某些任务中贡献有限，但方差受到量纲影响，低方差也可能保留关键标签信息。

二元变量，取 1 比例 p	分母为 n 的经验方差 $p(1-p)$	含义
$p = 0.5$	0.25	0 与 1 一样常见。
$p = 0.1$	0.09	1 较少见。
$p = 0.01$	0.0099	1 很少见，但可能重要。

如果标签恰为 $y = x$，即使 $p = 0.01$，该特征仍可完美区分正类。仅因它低方差就删除，会丢掉全部检出正类的信息。连续特征乘 100 后，方差乘 10000，含义却未必改变；跨不同单位直接比较原方差不合理。

标准化为单位方差后，再用一个普通方差阈值筛选，也可能失去原来想识别的近常数差别。应先明确筛选目标与处理顺序；二元指示变量、连续量与缺失指示不宜机械套同一阈值。

> **筛选也属于拟合**
>
> 阈值、特征列表、重要性排名或目标关联一旦从数据学习，必须在交叉验证每折的训练部分重新确定，再将同一规则用于该折验证。“这是预处理”不能成为在全部数据上先看标签筛选的理由。

3.5 卡方关联筛选：频数、期望与局限

对类别特征与类别目标，可用列联表比较观测频数与独立假设下的期望频数。设总计 N，则 $E_{rc} = O_{r+}O_{+c}/N$，Pearson 卡方统计量为

$$\chi^2 = \sum_{r,c} \frac{(O_{rc} - E_{rc})^2}{E_{rc}}.$$

这里求和的是表格单元，不是任意把连续取值当频数。

40 条记录	$y=1$	$y=0$	合计
$x=1$	12	8	20
$x=0$	4	16	20
合计	16	24	40

本例期望表为 $\left[\begin{smallmatrix}8 & 12\\ 8 & 12\end{smallmatrix}\right]$，四格差的绝对值均为 4，因此 $\chi^2 = 20/3 \approx 6.667$。使用无连续性校正的 Pearson 统计量；固定 2×2 类别设置下自由度为 1。对稀疏期望频数，渐近近似可能不好，应考虑合适的精确或置换方法。

统计关联不等于因果或独立测试上的预测收益。单变量筛选可漏掉交互：XOR 中每个独立均匀二元输入单独与标签无关联，两者一起却能决定标签。大量特征反复检验还涉及多重选择，不能把筛选后的普通 p 值无条件解读。

记住：某些软件的非负特征卡方筛选有专门数据约定；不可把已标准化的负数直接送入要求非负计数的接口。

3.6 向前选择：每一步都是一次模型比较

向前逐步选择（Forward Selection）从空特征集或预设起点开始，每次分别尝试加入一个尚未选择的特征，按约定的验证指标保留当前最好扩展。

步骤	示例流程，四个候选特征
第一轮	比较 $\{x_1\},\{x_2\},\{x_3\},\{x_4\}$；假设本轮选 x_2。
第二轮	比较 $\{x_2,x_1\},\{x_2,x_3\},\{x_2,x_4\}$。
决定停止	按预定特征数或验证改进规则停止；不能使用最终测试分数控制。

取到两个特征需比较 $4+3=7$ 个候选子集；空集基线另算。若每组候选五折评估，至少涉及 35 次折内模型拟合，预处理与候选搜索也会增加开销。在更多特征中，它比穷举所有子集便宜，但这是贪心搜索，不保证全局最佳子集。

若用同一批数据既选择特征又报告误差，结果会受到选择影响。需要独立测试或合适的外层评估，把整个特征选择流程包在训练部分中。强相关特征可能互换，交互也可能使单独加入时看不出收益。

记住：特征筛选依赖模型和指标。某次没选上不代表该变量没有信息，也不代表它没有科学或因果意义。

3.7 Tomek 链接与样本量经验的边界

Tomek 链接是在给定距离下、互为最近邻且类别不同的一对样本。这里假设没有距离并列；有并列时要说明选择约定。

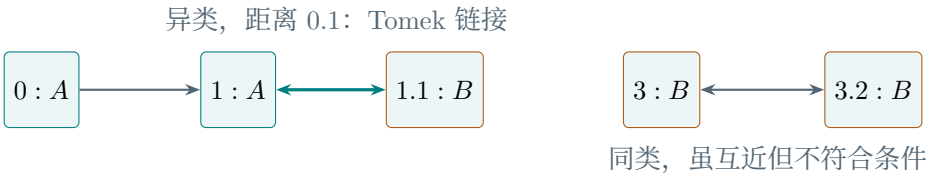


图 3.3: 五个一维数值及类别；箭头指最近邻，横向间距仅作示意，不按数值比例绘制。

读图： 1 与 1.1 异类且互近，构成链接；3 与 3.2 虽互近但同类，因此不构成链接。B 是本例多数类，若采用“只移除链接中多数类样本”规则，会移除 1.1，A/B 从 2/3 变为 2/2。

也有同时移除两端的清理约定，两者改变的数据不同。清理可能去掉噪声或边界重叠，也可能丢失有效边界信息；不保证任何模型的测试表现提高。仍只在训练折内使用，验证与测试应保持目标场景分布。

> **没有通用的每类 5000 条或总量 1000 万条门槛**
>
> 所需样本量取决于任务难度、噪声、分布、表示、模型、迁移与希望达到的误差。不要把某本材料中的经验量级变成训练资格标准或人类水平的保证。用同源边界正确的学习曲线、基线与目标误差检查数据是否仍限制效果。

参考： Little 与 Rubin，*Statistical Analysis with Missing Data*；scikit-learn Feature Selection 文档；imbalanced-learn Tomek Links 文档。图表与数值例子独立构造。

第四章　可信评估：从数据划分到指标选择

评估不是给模型贴上一个分数，而是回答一个具体问题：模型面对怎样的新数据，完成什么任务，哪些错误最值得关注？本章先划清数据用途，再用同一组计数解释分类指标，最后处理回归误差与决定系数。

> **先定规则，再看结果**
> 在比较模型前确定数据划分、主要指标和比较流程。模型、预处理、分类阈值与停止时刻都属于完整方案的一部分。测试集用于评估已确定方案，不能反复参与这些选择。

4.1　训练、验证与测试各自负责什么？

训练集（Training Set）用于拟合参数；验证集（Validation Set）用于比较候选方案；测试集（Test Set）在方案确定后用于最终评估。三者按**数据用途**区分，不是按程序运行时属于“训练阶段”还是“预测阶段”命名。

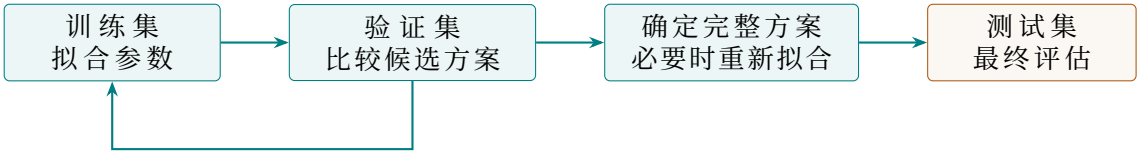


图 4.1：验证形成选择循环，测试不进入这个循环。图中的箭头表示工作流程，不表示将数据混合。

读图：候选模型在训练集上拟合，然后用验证表现调整方案。确定方案后，可以按预定流程使用开发数据重新拟合，再对保留的测试集评估。不能因为测试结果不够好就继续调阈值或换模型，再把同一测试分数作为独立评估。

训练误差在训练集上算，**验证误差**在验证集上算，**测试误差**在测试集上算。分类错误率在相应数据集 D 上定义为

$$\widehat{e}_D = \frac{1}{|D|}\sum_{i\in D}\mathbf{1}[\hat{y}_i \neq y_i].$$

同一公式用于不同数据集时，角色不同。训练错误率低，不等于泛化误差低。

> **独立划分不只是“行号不重叠”**
> 同一设备的多次记录若跨训练与测试，仍可能泄漏设备特征。面向未来预测时，应按时间顺序划分，不能随意打乱未来信息。划分应模拟实际使用条件；随机独立同分布划分只是常见设置之一。

4.2 交叉验证：评估整个拟合流程

K 折交叉验证（K-Fold Cross-Validation）在开发数据内轮流留出一折作验证，其余 $K-1$ 折训练。每折都从头拟合预处理和模型，再汇总各折验证结果。**不从这 K 个模型中简单挑出分数最高的一个作为最终模型。**



图 4.2: 五折示例：每个样本恰作一次折内验证，其余四次用于折内训练。

读图：每一行是一次独立拟合，橙色格仅用于该折验证。把每个候选方案都按相同划分评估，再依据汇总指标选择方案。最后按选定方案用开发数据重新拟合，独立测试集继续留在流程之外。

4.2.1 预处理也必须在折内拟合

标准化的均值与方差、填补缺失值的统计量、特征筛选规则等，都只能从该折的子训练集学习。先在全部数据上做这些步骤，再交叉验证，会让验证信息提前进入训练。把预处理与估计器放在同一拟合流水线中，有助于维持这个边界。

数据情况	常见划分考虑
样本近似独立同分布	普通 K 折或随机留出。
分类且类别不均衡	可分层，让各折类别比例较稳定；少数类数量仍限制折数。
同一对象多次观测	按对象分组，避免同一对象跨训练与验证。
预测未来	按时间向前验证，必要时留间隔防止窗口重叠。

选择折数要权衡样本量和计算开销，不存在“一律 10 折”的规则。重复用同一套交叉验证调参仍可能产生选择偏差；可用独立测试集，或在适当设置下用嵌套交叉验证评估选择流程。

4.3 混淆矩阵：先声明谁是正类

二分类的正类（Positive Class）是需要明确指定的类别，不代表“好”的结果。例如设备故障检测中，可以把“故障”设为正类。混淆矩阵（Confusion Matrix）把真实标签与预测标签交叉计数。

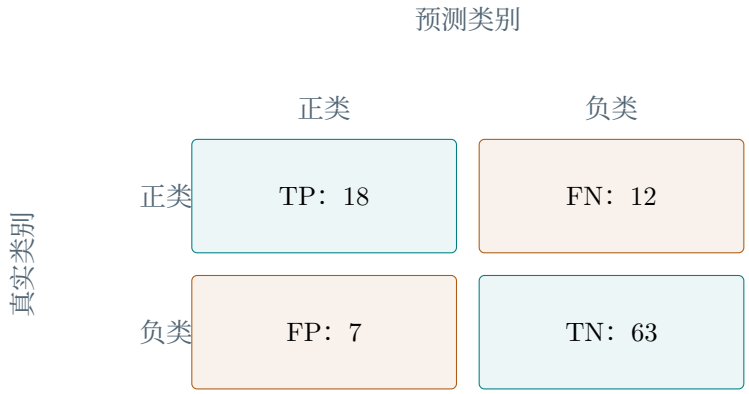


图 4.3： 100 个样本的示例。本书约定行是真实类别、列是预测类别，正类都排在前面。

读图： 30 个真实正类中，18 个被检出，12 个漏检；70 个真实负类中，7 个被误报为正类，63 个正确判为负类。因此预测正类有 25 个，预测负类有 75 个。

计数	英文与中文	本例含义
TP	True Positive，真正例	真实为正，预测也为正：18。
FN	False Negative，假负例	真实为正，预测为负：12。
FP	False Positive，假正例	真实为负，预测为正：7。
TN	True Negative，真负例	真实为负，预测也为负：63。

多分类时可扩展为 $K \times K$ 计数矩阵，主对角线是分类正确的数量。非对角线告诉我们哪些类别互相混淆，比单个准确率提供更多信息。

> **容易混淆**
>
> 不同软件可能按负类在前或其他标签顺序输出矩阵。读取位置之前先核对轴含义和标签顺序。如果只写“左上角是 TP”而没有声明约定，就容易把四种计数认反。

4.4 准确率、查准率与召回率：分母决定问题

准确率（Accuracy）问“全部样本中有多少判对”；查准率（Precision，也称精确率）问“预测为正的样本中有多少真的为正”；召回率（Recall）问“真实正类中有多少被检出”。三者的分母分别是全部样本、预测正类、真实正类。

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \tag{4.1}$$

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}. \tag{4.2}$$

对图 4.3，准确率为 $81/100 = 0.81$，查准率为 $18/25 = 0.72$，召回率为 $18/30 = 0.60$。分类错误率为 $1 - \text{Accuracy} = 0.19$。

4.4.1 把其它常见名称放回同一组计数

在二分类正类口径下，灵敏度（Sensitivity）和真正例率（True Positive Rate, TPR）就是召回率。特异度（Specificity，也称真负例率 TNR）看真实负类中有多少判对；假正例率（False Positive Rate, FPR）看真实负类中有多少被误报：

$$\text{TPR} = \frac{TP}{TP + FN}, \qquad \text{TNR} = \frac{TN}{TN + FP}, \qquad \text{FPR} = \frac{FP}{FP + TN} = 1 - \text{TNR}.$$

本例特异度为 0.90，假正例率为 0.10。**FPR 的分母是真实负类，不是预测正类，因此它不等于** $1 - \text{Precision}$。

> **为什么准确率可能不够？**
> 本例一律预测负类也有 70% 准确率，却检不出任何正类。类别极不均衡时，这种现象更明显。应报告混淆矩阵，并结合漏检和误报的代价选择指标。没有单个指标能在所有任务上替代这项判断。

若某指标公式的分母为 0，其数学定义无法直接使用。软件可能返回 0、缺失值或警告，应记录约定，而不是把这些输出混同于有足够数据支持的测量值。

4.5 F1、平均方式与分类阈值

F1 分数（F1 Score）综合查准率与召回率。在两者定义有效且其和大于 0 时，它是调和平均：

$$F_1 = \frac{2PR}{P+R} = \frac{2TP}{2TP+FP+FN}, \qquad P = \text{Precision},\ R = \text{Recall}.$$

本例为 $36/(36+7+12) = 36/55 \approx 0.655$。这里的 P 不是 Accuracy；本书避免使用含义不清的“精度”替代指标全名。F1 不直接包含 TN，因此也不能代替对真负类表现和错误代价的检查。

4.5.1 多分类汇总必须写明平均方式

可先把每个类别轮流视为正类，求各类 Precision、Recall、F1，再决定怎样汇总。

方式	汇总口径
宏平均（Macro）	各类别的指标等权平均，少数类同样占一份权重。
加权平均（Weighted）	按真实类别样本数加权，各类权重可能差别很大。
微平均（Micro）	先累加各类 TP、FP、FN，再用总计数计算指标。

在覆盖全部类别的**单标签多分类**中，micro-Precision、micro-Recall 和 micro-F1 都等于 Accuracy。宏平均 F1 应当先求各类 F1 再平均，通常不等于把宏平均 Precision 和 Recall 代入 F1 公式。

4.5.2 得分与阈值也是两个对象

若模型输出正类得分 $s(\boldsymbol{x})$，可按 $s \geq \tau$ 判为正类。降低阈值通常会让更多样本判为正类，召回率不会下降，但 Precision 未必单调变化。阈值应在验证流程内选择，然后固定用于测试；不能在测试集上挑最高 F1 再报告为独立测试结果。

> **容易混淆**
>
> F1 对 Precision 和 Recall 给予特定形式的折中，不是通用的业务收益函数。当两种错误的代价差异明显时，应明确代价、约束或使用合适的其它指标，而非仅追求 F1 最大。

4.6 ROC：让阈值变化起来

ROC 曲线（Receiver Operating Characteristic Curve）汇总不同阈值下的分类表现。本书采用常见坐标：**横轴 FPR，纵轴 TPR**，两轴都从 0 到 1。它需要模型输出连续或有序得分，不要求这些得分已是校准概率。

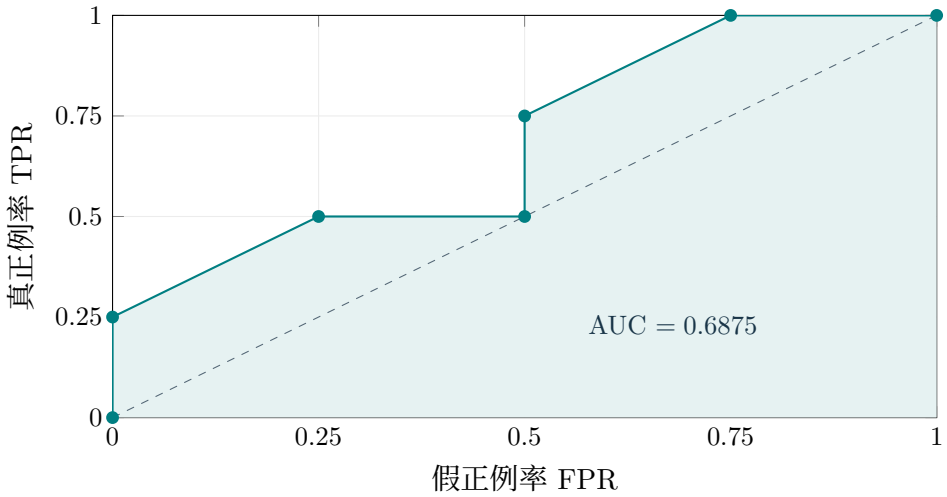


图 4.4: 八个样本的 ROC 示例，得分在下一节给出。并列得分作为一组改变阈值。虚线为对角参考线。

读图：阈值高于全部得分时，没有正类预测，对应 $(0,0)$。逐步降低阈值，会逐组纳入得分相同的样本；阈值低到所有样本都判为正时到达 $(1,1)$。曲线越靠近左上角，表示能在较低假正例率下取得较高真正例率。

每一个曲线点都代表一套阈值选择，不是同一个分类器在固定阈值下同时达到的多种结果。若实际只能接受很低的误报率，应重点看相应区域，而不是只比较整个曲线面积。

> **不要把 Specificity 直接当作本图横坐标**
>
> 有些领域会使用从 1 向 0 排列的特异度横轴，等价展示同一关系。必须同时声明坐标含义和方向，不能把“从 0 到 1 的特异度轴”误画成标准 FPR 轴。计算 ROC 与 AUC 时，评估数据还需包含正、负两类。

4.7 AUC：排序能力与并列得分

ROC 曲线下面积称为 ROC-AUC。对经验二分类得分，一种直观算法是逐对比较正、负样本：

$$\widehat{\mathrm{AUC}} = \frac{\sum_{i\in +}\sum_{j\in -}\left[\mathbf{1}(s_i > s_j) + \frac{1}{2}\mathbf{1}(s_i = s_j)\right]}{n_+ n_-}. \tag{4.3}$$

其中 n_+, n_- 是正、负样本数，s 越大表示越倾向正类。正类得分更高记 1 分，相同记半分，更低记 0 分。

真实类别	模型得分
正类，4 个	0.9, 0.8, 0.5, 0.4
负类，4 个	0.8, 0.6, 0.4, 0.1

四个正类与所有负类逐一比较，分别得到 $4, 3.5, 2, 1.5$ 分，所以 $\widehat{\mathrm{AUC}} = 11/16 = 0.6875$。这也等于图 4.4 按并列分组后作线性连接的梯形面积。若在并列组内部任意排列正负样本再连接，可能得到受排列影响的错误面积。

4.7.1 AUC 告诉了什么，又没告诉什么？

AUC 衡量得分把正类排在负类之前的能力，不直接衡量概率校准，也不指定实际部署阈值。严格递增地变换全部得分不会改变其排序，因而不会改变相应 AUC。一个固定阈值下的准确率却可能改变。

> **核心理解**
>
> AUC 为 0.5 只描述这一排序汇总量，不能断言模型的全部行为与随机猜测相同。AUC 为 1 表示在当前评估样本上正类得分都高于负类，也不是对未来数据的完美保证。报告 AUC 时，应同时说明数据划分与适用任务；多分类还要说明如何组合类别。

4.8 类别比例变化时，Precision 也会变

ROC 使用类内比例 TPR 和 FPR；Precision 还取决于总体中正类有多常见。记正类比例为 π，在类条件表现保持不变的假设下，

$$\text{Precision} = \frac{\pi\,\text{TPR}}{\pi\,\text{TPR} + (1-\pi)\,\text{FPR}}. \tag{4.4}$$

例如保持 TPR $= 0.8$、FPR $= 0.1$：

正类比例	真正例占全部样本比例	Precision
50%	$0.5 \times 0.8 = 0.4$	$0.4/(0.4 + 0.05) \approx 0.889$
1%	$0.01 \times 0.8 = 0.008$	$0.008/(0.008 + 0.099) \approx 0.075$

两种情形的 TPR 与 FPR 相同，预测正类的可靠程度却相差很大。因此，把在均衡抽样数据上得到的 Precision 直接当作实际低发生率场景的 Precision，通常不可靠。若类条件分布也变化，上式中的 TPR 与 FPR 本身还可能改变。

4.8.1 不均衡任务的报告方式

除 Accuracy 外，报告正类支持数、Precision、Recall、阈值和混淆矩阵。Precision–Recall 曲线有助于观察查准与查全的关系；若报告其汇总面积或平均精确率，还要明确计算约定，不能把所有不同定义的“PR 面积”当作同一个数。

> **容易混淆**
>
> “ROC-AUC 对类别比例不敏感”依赖类条件得分分布保持不变，不表示不均衡任务仅看 AUC 就够了，更不表示样本少的正类能得到精确稳定的估计。验证/测试集应代表目标使用情形，并同时考虑统计不确定性。

4.9 回归误差：先看单位与残差

回归任务预测数值。对 n 个样本，记真实目标 y_i、预测 $\hat{y}_i$，残差 $e_i = y_i - \hat{y}_i$。常见指标为

$$\mathrm{MAE} = \frac{1}{n}\sum_i |e_i|, \tag{4.5}$$

$$\mathrm{MSE} = \frac{1}{n}\sum_i e_i^2, \qquad \mathrm{RMSE} = \sqrt{\mathrm{MSE}}. \tag{4.6}$$

MAE 与 RMSE 和目标变量同单位；MSE 的单位是目标单位的平方。平方误差对大残差惩罚更强，但不能因此断言 MAE 完全不受异常值影响。

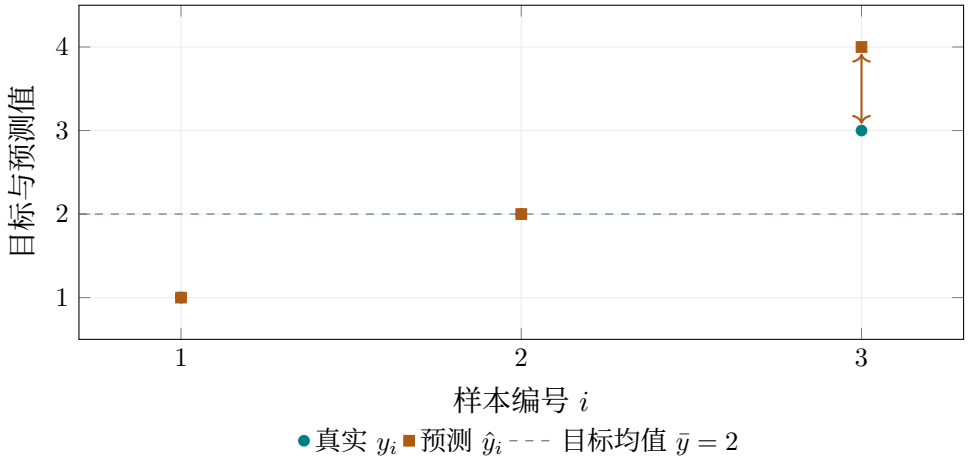


图 4.5: 真实目标为 $(1, 2, 3)$，预测为 $(1, 2, 4)$。箭头标出第 3 个样本的残差大小 1；前两个重合点残差为 0。

读图： 残差向量为 $(0, 0, -1)$，因此 MAE 与 MSE 都为 $1/3$，RMSE 为 $\sqrt{1/3} \approx 0.577$。图中水平线是当前评估目标的均值，不是把模型预测都替换成均值。

> **指标与训练目标可以使用相同公式，但用途不同**
>
> MSE 既可以作为训练目标，也可以作为验证或测试指标。它在测试集上计算时并不会反过来参与训练。比较模型要使用相同数据划分和相同目标尺度；如果训练时变换了目标，需说明评估在哪个尺度上进行。

4.10 R^2 与平方和：把适用条件写出来

决定系数（Coefficient of Determination, R^2）把残差平方和与“始终预测本评估集目标均值”的基准比较。设 $\bar{y} = n^{-1}\sum_i y_i$：

$$\mathrm{TSS} = \sum_i (y_i - \bar{y})^2, \qquad \mathrm{RSS} = \sum_i (y_i - \hat{y}_i)^2, \tag{4.7}$$

$$R^2 = 1 - \frac{\mathrm{RSS}}{\mathrm{TSS}}, \qquad \mathrm{TSS} > 0. \tag{4.8}$$

完美预测的 $R^2 = 1$；与该均值基准同样的平方误差给出 0；比它更差则为负。若评估集目标全相同，TSS 为 0，数学定义的分母失效；软件可能采用约定值，应说明处理方式。当前目标均值只是这个评估统计量的参照，不是允许用测试标签拟合部署模型；实际可部署的均值预测器应从训练数据估计。

目标均为 $(1,2,3)$	预测	RSS	R^2
图中模型	$(1,2,4)$	1	0.5
均值基准	$(2,2,2)$	2	0
较差预测	$(4,4,4)$	14	-6

4.10.1 解释平方和不总等于总平方和减残差平方和

常见定义 $\mathrm{ESS} = \sum_i (\hat{y}_i - \bar{y})^2$。一般展开为

$$\mathrm{TSS} = \mathrm{RSS} + \mathrm{ESS} + 2\sum_i (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}).$$

只有交叉项为 0 时才可直接相加；带截距普通最小二乘的训练集拟合是常见情形。本例预测 $(1,2,4)$ 的 ESS 为 5，交叉项为 -4，所以 $2 = 1 + 5 - 4$，不能把 RSS 和 ESS 无条件相加。

> **容易混淆**
>
> R^2 并非对任意预测都等于相关系数平方。带截距的一元最小二乘训练集拟合、相应方差非 0 时，有 $R^2 = r(x,y)^2$；任意模型或测试集不能照搬。本节图中预测与目标的相关系数平方约为 0.964，实际 R^2 只有 0.5。

4.11 一页速查与自测

要回答的问题	先看什么
模型参数在哪里拟合?	训练集；交叉验证中是每折子训练集。
阈值或超参数在哪里选?	验证流程内；最终测试集保持独立。
预测正类有多少是真的?	Precision：$TP/(TP+FP)$。
真实正类检出了多少?	Recall/TPR：$TP/(TP+FN)$。
真实负类误报了多少?	FPR：$FP/(FP+TN)$。
跨阈值的排序表现怎样?	ROC 与 ROC-AUC；并列正负得分按半对计分。
数值误差有多大?	MAE、RMSE 与残差分布，注意单位。
比目标均值基准好多少?	$R^2 = 1 - \mathrm{RSS}/\mathrm{TSS}$，可能为负。

4.11.1 三个自测问题

1. 若 TP=9、FP=1、FN=6、TN=84，Precision 与 Recall 分别是多少?
2. 两个正类得分为 0.8、0.4，两个负类为 0.8、0.2，AUC 是多少?
3. 若 TSS=10、RSS=15，R^2 是多少? 能否直接认为计算有误?

参考答案：（1）0.9 与 0.6。（2）$(1.5+1)/4 = 0.625$。（3）-0.5；它表示平方误差比该均值基准更大，不必然是计算错误。

4.11.2 进一步查阅

- scikit-learn：数据泄漏与预处理常见问题。
- 指标文档：roc_auc_score、r2_score，核对输入口径与边界约定。

第五章　选择与诊断：把分数变成可靠判断

一个可复用的建模方案包含预处理、模型、超参数、停止规则与决策规则。本章接续可信评估，把搜索、曲线、概率与不确定性放回这个完整流程。

> **分数越好，越需要问清它怎样得到**
> 选择次数、数据用途、指标方向与估计误差共同影响结论。在测试集上反复试出一个好结果，不能替代预先约定的验证流程。

5.1　参数、超参数与搜索预算

参数（Parameter）通常由拟合学习，如回归系数与网络权重；超参数（Hyperparameter）控制模型或学习流程，如正则强度、树深度、学习率。超参数可以由验证搜索自动选择，不能简单理解为“只有人工才设置”。

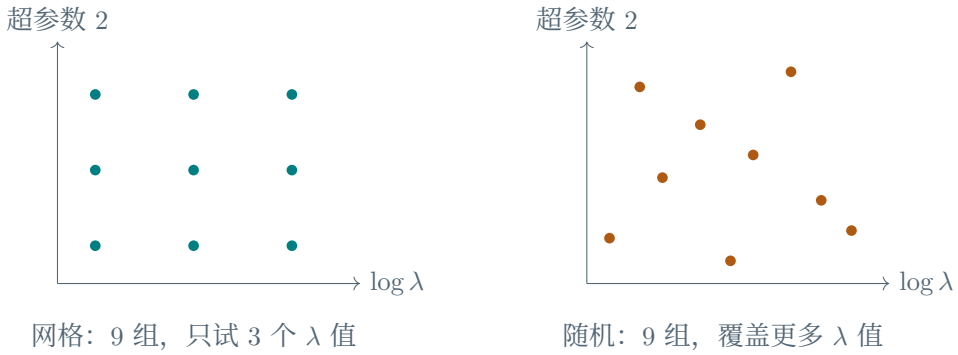


图 5.1：等预算的独立示意。随机搜索能试更多不同坐标值，但不保证每次更优。

读图：网格搜索枚举指定笛卡尔积；3 个正则强度与 4 个树深度共 12 组，五折评估需 60 次折内拟合，最后全开发集重拟合另计一次。不能按训练分数挑选。

随机搜索从预先指定分布抽样；若正值跨多个数量级，可考虑对数尺度，例如 $\log_{10}\lambda \sim U[-4, 0]$，而非默认在线性区间均匀取值。两者给不同尺度的搜索预算，不存在通用最优搜索分布。

记住：先定指标方向、范围、预算、划分与随机种子。候选失败和实际开销也应记录；搜索只在指定范围内比较。

5.2 嵌套交叉验证：评估选择流程

普通交叉验证可用于选择超参数；同一组折上最优候选的分数，已经受到选择影响。若需要估计整套选择流程的泛化表现，可用嵌套交叉验证（Nested CV）。

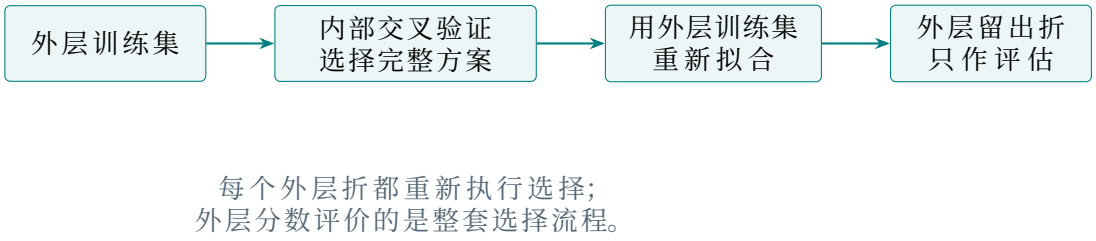


图 5.2: 外层评估、内层选择；预处理始终与模型一起在相应训练部分拟合。

读图：外层留出折不参与内层搜索；在不同外层折上选出的超参数可以不同。汇总外层结果，评价的是“给定新训练样本后执行这套选择流程”的表现。

若外层 5 折、内层 3 折、每次比较 8 组候选，内层拟合共 $5 \times 3 \times 8 = 120$ 次；每个外层选定后重新拟合一次，共 5 次，因此外层评估阶段 125 次。最后在全开发集上再选参并拟合用于部署，属于另外的计算与模型。

> **外层也不能无限反复优化**
>
> 看到外层结果后持续改变特征、候选范围或搜索策略，会再次产生适应性选择。嵌套 CV 不是泄漏或研究者选择的万能修补。独立测试集可作为另一种评估设计；按数据、用途与预算选择，不要求所有项目都同时堆叠两者。

时间序列与分组数据的内外层都需保持相应边界。也不要把五个外层模型中分数最高的一个直接当作“最终最佳模型”。

5.3 三种曲线：先读横轴，再谈诊断

“学习曲线”有时泛指训练过程曲线，阅读时务必先检查横轴。这里区分训练样本量、一个超参数与训练步数三类图。

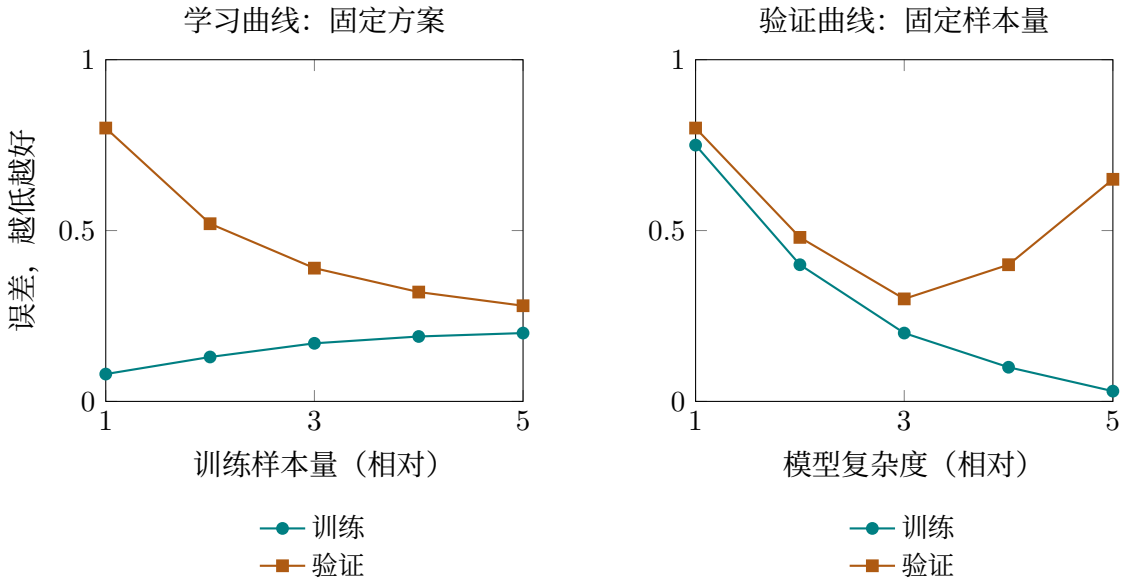


图 5.3: 独立构造的趋势示意，不是实验结果；这类形状并非必然定律。

读图：左图改变训练样本量、固定方案，每个规模重新拟合；右图改变复杂度、固定样本量。纵轴均为误差，越低越好。若换成准确率等得分，方向应对应改变。

横轴	可以帮助判断什么
训练样本量	在固定流程下，增加同分布数据是否仍可能改善验证表现。
超参数	候选范围内的表现与敏感性，不保证所有参数都有简单 U 形关系。
Epoch 或更新步数	优化过程、训练/验证分离和停止时刻；不是样本量变化。

训练与验证都差：先查标签、指标、实现与优化，再考虑容量不足。训练好、验证差：检查泄漏、划分、分布变化、正则与数据量。曲线只提供线索，不能单凭间距唯一诊断原因；验证误差也可能暂时低于训练误差。

5.4 概率预测：Brier 与对数损失

二分类模型给出的 p_i 应对应指定正类，$y_i \in \{0,1\}$。Brier 分数（Brier Score）与二元对数损失都直接评价概率，越小越好：

$$\mathrm{BS} = \frac{1}{n}\sum_i (p_i - y_i)^2, \tag{5.1}$$

$$\mathrm{LogLoss} = -\frac{1}{n}\sum_i [y_i \log p_i + (1-y_i)\log(1-p_i)]. \tag{5.2}$$

对数用自然底；错误且极度自信的概率会受较大惩罚。若真实类别被赋予零概率，对数损失趋于无穷；软件裁剪概率需说明约定。

模型（同一 8 样本）	正类少组的 p	正类多组的 p	Brier
A	0.1	0.9	0.2100
B	0.25	0.75	0.1875

第一组标签 $[0,0,0,1]$，第二组 $[0,1,1,1]$。阈值 0.5 时，两模型准确率均为 0.75，AUC 也均为 0.75，但概率误差不同。B 的对数损失约 0.562，A 约 0.655；排序、硬标签与概率质量是不同问题。

若同一条件下 $Y \sim \mathrm{Bernoulli}(q)$，则

$$\mathbb{E}[(p-Y)^2] = (p-q)^2 + q(1-q).$$

期望 Brier 在 $p = q$ 处最小；并不要求对每个随机结果都给出 0 或 1。二分类这个定义范围为 $[0,1]$；多分类若对全部类别平方差求和，范围及缩放约定不同。

记住：Brier 反映整体概率误差，不能单独证明校准完美；比较时保持样本、类别定义与缩放口径一致。

5.5 校准、排序与阈值分工

校准（Calibration）问：预测概率相近的一组样本，其实际正类频率是否相近？可靠性图（Reliability Diagram）把组内平均预测概率与组内实际频率作比较。

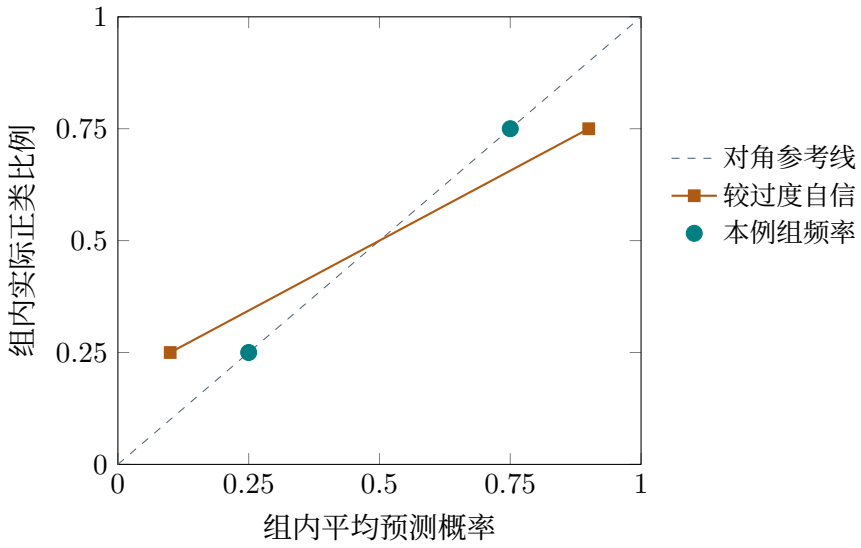


图 5.4: 沿用上页两个各 4 样本的组。有限分组图只用于说明，不证明总体已经校准。

读图： A 将两组概率推向 0 与 1，比本例观察频率更自信。按组频率替换为 B 后，排序与 0.5 阈值标签不变，Brier 下降。实际应用不能用测试标签这样修改预测。

Sigmoid/Platt 或保序回归等校准器，应使用模型拟合之外的校准数据，或合适的交叉拟合流程；模型、校准器、阈值都确定后再测独立测试集。分箱数量和少量样本会影响图形，分布变化后原校准关系也可能失效。

若 p 是适用场景的正类后验概率，正确决策代价为 0，误报代价 C_{FP}、漏报代价 C_{FN}，则预测正类的期望代价为 $C_{FP}(1-p)$，负类为 $C_{FN}p$。因此可按

$$p \geq \frac{C_{FP}}{C_{FP}+C_{FN}}$$

判正（相等时的约定另定）。例如 $C_{FP}=1, C_{FN}=4$ 给阈值 0.2。这个结论依赖概率与代价假设，不可对任意未校准得分照搬，也不等于任何 F1 最优阈值。

5.6 MCC：同时使用四种计数

马修斯相关系数（Matthews Correlation Coefficient, MCC）是二元真实标签与预测标签的相关系数。在四个边际因子均非零时，

$$\mathrm{MCC} = \frac{TP\,TN - FP\,FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}.$$

它在 $[-1,1]$ 内，1 表示完全一致，-1 表示完全反转，0 表示在此二元编码下没有线性相关。MCC 不是准确率，也不是保证公平或校准的综合评分。

100 样本例子	准确率	MCC
$TP=18, FN=12, FP=7, TN=63$	0.81	约 0.529
完全正确，且两类均出现	1	1
完全反转，且两类均出现	0	-1
全部预测为负类	取决于真实负类比例	原公式分母为 0

若真实标签或预测标签恒定，相关系数的普通定义失效。软件可能使用返回 0 等扩展约定，应记录这个约定，不能把 0 自动解释成测得了独立性。多分类 MCC 另有推广公式，不能直接将多分类矩阵四个位置代入本页二分类式。

> **指标服务于问题**
>
> MCC 可补充类别不平衡时的标签评价；仍应看混淆矩阵、各类表现与错误代价。需要概率质量时看概率指标，需要低误报运行点时检查相应阈值表现。

5.7 不确定性：区间也有适用条件

有限测试样本得到的准确率只是估计。在模型已固定、测试结果近似独立且同分布的二元成功/失败设置下，可用二项比例区间描述抽样不确定性。

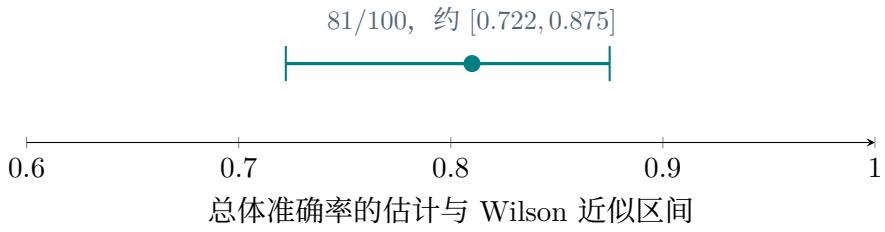


图 5.5： 100 个独立测试结果中 81 个正确，采用 $z = 1.96$ 的 Wilson 近似 95% 区间。

读图： 0.81 不是没有误差的总体常数。区间约为 $[0.722, 0.875]$，这不包含对未来分布变化的保证，也没有自动计入重新训练或调参的不确定性。

令 $\hat{p} = k/n$，Wilson 区间的中心和半宽分别为

$$c = \frac{\hat{p} + z^2/(2n)}{1 + z^2/n}, \qquad r = \frac{z\sqrt{\hat{p}(1-\hat{p})/n + z^2/(4n^2)}}{1 + z^2/n}.$$

区间为 $[c - r, c + r]$；这是近似方法，不对每种有限样本设置保证精确 95% 覆盖。频率学派的 95% 指在相应重复抽样下，该构造方法的长期覆盖率，不是“固定真参数有 95% 概率落在这一次固定区间内”。

> **不能把任何波动除以根号样本数就叫置信区间**
>
> 同一病人的多条记录不是独立试验；交叉验证各折也不相互独立。折间标准差不等于均值的标准误；模型比较还应保留同一测试样本上的成对关系。有组结构时按组设计估计或重采样，明确抽样单位与所覆盖的不确定性。

参考： ISLR 第二版第 5 章；Bergstra 与 Bengio，*Random Search for Hyper-Parameter Optimization*（2012）；scikit-learn Model Selection、Calibration 与 Model Evaluation 文档；Wilson（1927）。全部图与算例独立构造。

第六章　建模工具：目标、约束与不确定性

选定模型后，还需要明确学什么、怎样优化、如何解释不确定性。本章把容易混在一起的概念分开：候选函数集合、训练损失、总体风险、正则化与选择准则。

> **三个层次**
> 假设空间限制可选的函数，目标函数决定拟合时的偏好，优化算法决定如何寻找参数。这三个层次共同影响结果，不能只看某个损失的名称就判断模型是否凸、是否泛化良好。

6.1　假设空间、损失与风险

假设空间（Hypothesis Space）$\mathcal{H}$ 是允许选择的预测函数集合。例如 $\mathcal{H} = \{x \mapsto b + wx : b, w \in \mathbb{R}\}$ 包含所有一元仿射函数。集合中的函数不必都与当前样本拟合良好；训练是在集合内作出选择。

单样本损失 $\ell(\hat{y}, y)$ 衡量一次预测的代价。总体风险和经验风险分别为

$$R(f) = \mathbb{E}_{(X,Y)}[\ell(f(X), Y)], \qquad \widehat{R}_n(f) = \frac{1}{n}\sum_{i=1}^{n} \ell(f(\boldsymbol{x}_i), y_i).$$

前者依赖目标新样本分布，后者在实际数据上求平均。训练集平均较小不保证总体风险较小。

训练目标	含义
经验风险最小化	在 $\mathcal{H}$ 内使 $\widehat{R}_n$ 较小。
带正则化的目标	$J(f) = \widehat{R}_n(f) + \lambda\Omega(f)$，$\lambda \geq 0$。
约束形式	在满足如 $\|w\| \leq c$ 的集合内拟合。

Ω 是对模型的惩罚，不是预测方差的直接测量。λ 控制惩罚强度，需要在开发数据内比较。最终评估指标可以与训练损失不同，例如用交叉熵训练、用召回率评估。

6.2 常用损失速查

以下均先定义单样本损失；对相应数据集取平均，才得到平均损失或错误率。

损失	定义	约定
0–1	$\mathbf{1}[\hat{y} \neq y]$	单标签二类或多类。
平方	$(\hat{y} - y)^2$	对大残差较敏感。
绝对	$\lvert\hat{y} - y\rvert$	在零残差处不可微。
Hinge	$\max(0, 1 - ys)$	$y \in \{-1, 1\}$，s 为实值得分。
二元交叉熵	$-y \log p - (1 - y) \log(1 - p)$	$y \in \{0, 1\}$。
类别交叉熵	$-\log p_y$	p_y 为真实类别概率。

对三个真实值 $[1, 2, 3]$ 和预测 $[1, 1, 5]$，残差为 $[0, -1, 2]$，MAE 为 1，MSE 为 $5/3$。平方与绝对损失表达不同的偏好。交叉熵使用自然对数；正确类别概率从 0.8 降到 0.2 时，损失从约 0.223 升到 1.609。

6.2.1 多标签中的逐位错误与整组错误

有 n 个样本、每样本 K 个二元标签时，汉明损失为

$$L_{\mathrm{H}} = \frac{1}{nK} \sum_{i,k} \mathbf{1}[\hat{y}_{ik} \neq y_{ik}].$$

例如真实标签 $[1, 0, 1]$、预测 $[1, 1, 1]$，汉明损失为 $1/3$，要求整组完全匹配的子集 0–1 损失为 1。

> **零概率的数值处理**
>
> 真实类别概率为 0 时，负对数损失趋于无穷。计算中常直接用 logits 与稳定的 log-sum-exp 实现；不要用错误的代数改写掩盖极端数值。

6.3 凸性是相对具体变量而言的

定义域为凸集，且任意 x, z 及 $\alpha \in [0,1]$ 满足

$$f(\alpha x + (1-\alpha)z) \le \alpha f(x) + (1-\alpha) f(z),$$

则 f 为凸函数（Convex Function）。反向不等式定义凹函数（Concave Function）。不同教材可能使用不同中文旧称，本书统一按上述英文与不等式对应。

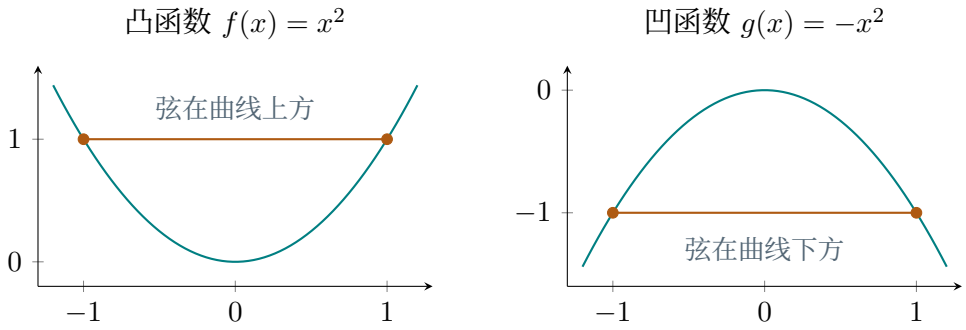


图 6.1: 弦与函数图像的位置关系。线性函数可以同时是凸函数和凹函数。

读图： x^2 的弦不低于曲线；$-x^2$ 的弦不高于曲线。对不同端点和内部权重使用严格不等式，得到严格凸或严格凹。二次可微的一元函数在区间上满足 $f'' \ge 0$ 可判定凸性。

平方损失对预测值 $\hat{y}$ 是凸的，但若 $\hat{y}$ 是参数的非线性函数，训练目标对参数不一定凸。例如 $J(\theta) = (\theta^2 - 1)^2$ 在 $\theta = 0$ 附近非凸。常规线性回归的平方目标对系数凸；一般神经网络的目标则通常非凸。

记住： 判断凸性时，要同时说出函数、变量和定义域。

6.4 梯度为零，不保证已经最小

局部最小值只和附近点比较；全局最小值与整个定义域比较。在内部可微点，局部极小要求梯度为零，但梯度为零只是必要条件之一。

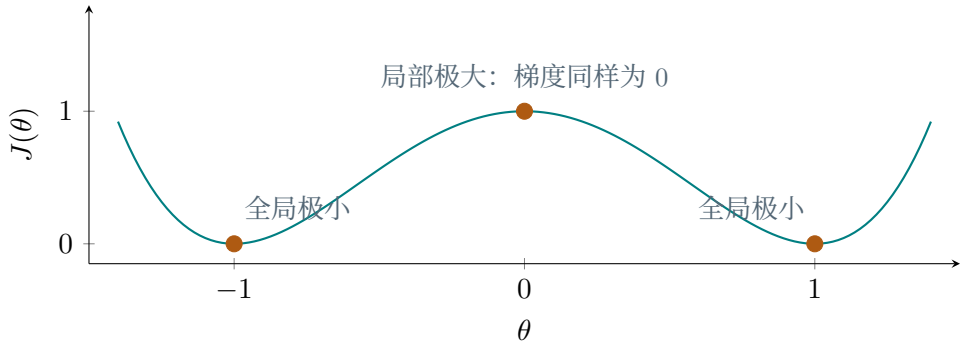


图 6.2： $J(\theta) = (\theta^2 - 1)^2$：导数为 $4\theta(\theta^2 - 1)$。

读图： $\theta = -1, 0, 1$ 处的导数都为 0，但 0 是局部极大值，± 1 是全局极小值。多维非凸函数还可能有鞍点，如 $f(u, v) = u^2 - v^2$ 的原点。

凸函数的任何局部最小值都是全局最小值；严格凸时若最小值存在则唯一。这不表示所有凸函数都能取得最小值，例如 e^x 在实数域内只趋近 0 而不达到。具体算法的收敛还依赖步长、光滑性和其他条件。

> **优化目标与目标分布仍有距离**
>
> 即使找到训练目标的全局最优，也不能单凭这一点证明泛化良好。反之，优化不足也可能造成欠拟合；诊断时应检查数据、模型和优化过程。

6.5 Bootstrap：从经验分布中有放回重采样

自助法（Bootstrap）常从 n 条观测中有放回抽取 n 次，重新计算统计量，用许多次结果近似其抽样变化。重采样的记录可能重复，也可能遗漏。

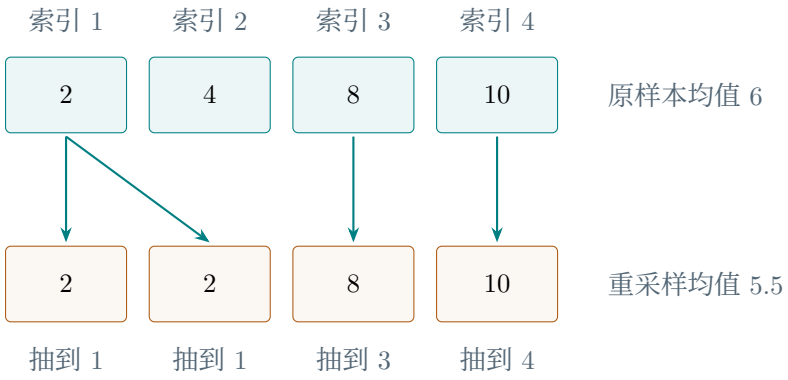


图 6.3： 原样本 $[2, 4, 8, 10]$，一次抽到索引 $[1, 1, 3, 4]$。保持每条记录的所有字段与标签同步。

读图： 这一次均值从 6 变成 5.5；它不是新的独立采集样本。反复重采样可以研究均值等统计量的变动，也可用于 Bagging 训练多个模型。

一条原记录在 n 次抽取中一次都未被抽到的概率为 $(1-1/n)^n$，当 n 很大时趋近 $e^{-1} \approx 0.368$。这解释了袋外记录的来源，不是每次恰好遗漏 36.8% 记录的保证。

> **重采样必须尊重数据结构**
>
> 普通逐行 Bootstrap 依赖近似独立的观测设置。时间序列、同一对象的重复记录等可能需要分块或按组重采样。置信区间方法有不同假设与误差，不能把任意重采样结果自动当成可靠区间。

6.6 AIC 与 BIC：在可比似然下权衡拟合与复杂度

设 $\hat{\ell}$ 为最大化后的**对数似然**，k 为估计参数个数，n 为样本量，常用形式为

$$\mathrm{AIC} = 2k - 2\hat{\ell}, \qquad \mathrm{BIC} = k\log n - 2\hat{\ell}.$$

两者都是在可比候选模型中越小越好。参数个数应按模型完整定义计算；例如高斯回归中，噪声方差若也估计，应计入相应参数数目。

$n = 100$	k	$\hat{\ell}$	AIC	BIC
模型 A	3	-120	246	253.816
模型 B	5	-117	244	257.026

在这个例子中 AIC 选择 B，BIC 选择 A；不同准则有不同目标和推导条件。

6.6.1 比较的前提不能省略

使用同一响应、同一批观测和可比的似然定义。不能直接用不同数据量或任意缩放的损失代替对数似然再比较。AIC 的某些回归专用写法、C_p 或小样本修正形式并非对所有模型通用。

> **不是防止一切过拟合的保证**
>
> BIC 的复杂度项在 $n > e^2$ 时大于 AIC 对应项，但并不自动解决维数灾难、泄漏或分布偏移。这些准则不能代替独立评估，也不是越小的数值就等于越高的分类准确率。

6.7 维数灾难：覆盖空间需要多少格子？

维数灾难（Curse of Dimensionality）描述高维空间中覆盖、距离与统计估计变困难的现象。一个简单例子：每个坐标轴分成 5 份，d 维单位立方体就有 5^d 个小格。

维度 d	1	2	5	10
格子数 5^d	5	25	3125	9765625
1000 样本平均每格	200	40	0.32	0.0001024

即使每格平均一条也不能保证均匀覆盖；这个计数仅帮助理解稀疏性。若希望轴向比例为 r 的邻域覆盖固定概率质量，在独立均匀设置下体积为 r^d，维度增加时会迅速变小。真实数据若集中在低维结构上，实际难度可能不同。

6.7.1 应对方法取决于结构

可以增加有效数据、利用领域约束、做训练内特征选择或降维，并采用合适的正则化。距离方法要特别注意无关列、尺度与表示。支持向量机和树等方法也受数据结构与样本量影响，不能笼统称为“不受维度限制”。

记住：高维不是自动失败；更多特征也不是自动得到更多有效信息。

6.8 贝叶斯误差：相对给定信息的最佳错误率

在 0–1 损失下，知道真实条件概率时，选择概率最大的类别可以最小化条件错误率。二分类记 $\eta(x) = P(Y = 1 \mid X = x)$，则

$$h^*(x) = \mathbf{1}[\eta(x) \geq 0.5], \qquad R^* = \mathbb{E}_X[\min\{\eta(X), 1 - \eta(X)\}].$$

R^* 称为该特征信息与分布下的贝叶斯错误率（Bayes Error Rate）。多分类的条件错误率相应为 $1 - \max_k P(Y = k \mid X = x)$。

输入情形	出现概率	$\eta(x)$	最佳预测	条件错误率
A	0.5	0.9	1	0.1
B	0.5	0.6	1	0.4

总体最佳错误率为 $0.5 \times 0.1 + 0.5 \times 0.4 = 0.25$。这是已知构造分布的计算；真实任务通常不知道精确条件概率，不能直接计算真值。

> **人类表现不是定义中的下界**
>
> 人类可能使用不同特征、不同信息，也可能远未达到最优。人类错误率可以作为有条件的参照，不能自动等同或作为严格估计的贝叶斯误差。增加有效特征可能改变条件分布并降低最佳可达风险。

参考： ISLR 第二版（2021）第 2、5、6 章；Boyd 与 Vandenberghe，*Convex Optimization*（2004），第 3 章。本章例子与图为独立构造，复算见第六批审校记录。

第七章　线性模型与近邻：先建立可靠基线

线性模型把输入特征组合为一个得分；近邻模型根据相似训练记录预测。二者都适合建立可解释的起点，但依赖不同假设。本章使用统一目标约定比较拟合、正则化和分类扩展。

> **把模型与训练目标配对**
> 连续数值可从平方损失线性回归开始；二分类概率可从逻辑回归开始。特征表示决定“线性”能够表达什么，正则化强度与近邻数则需要训练内验证。

7.1　线性回归与最小二乘

线性回归（Linear Regression）预测 $\hat{y} = b + \boldsymbol{w}^{\top}\boldsymbol{x}$。普通最小二乘（Ordinary Least Squares, OLS）最小化残差平方和，也可以等价地最小化其正比例缩放 $J = \frac{1}{2n}\sum_i (\hat{y}_i - y_i)^2$。

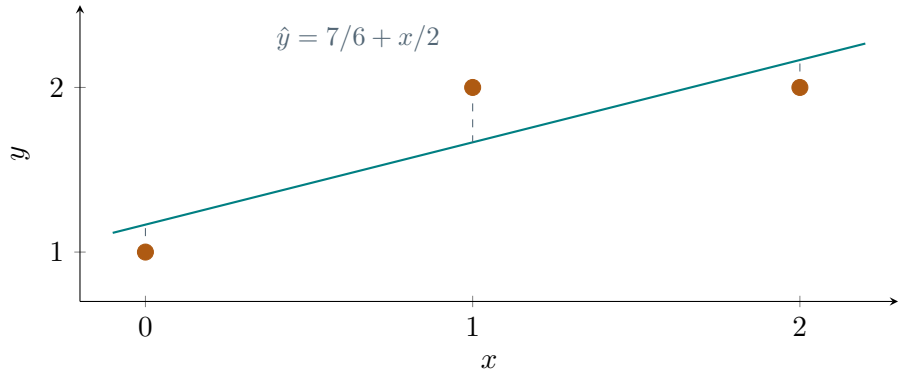


图 7.1： 三个观测 $(0,1),(1,2),(2,2)$ 的最小二乘直线；虚线为竖直残差。

读图： 拟合得到 $w = 1/2$、$b = 7/6$。三个预测为 $7/6, 5/3, 13/6$，按“预测减真实”计的残差为 $1/6, -1/3, 1/6$，平方和为 $1/6$，训练 MSE 为 $1/18$。

7.1.1　线性指的是系数的进入方式

模型可以对 x^2、对数或交互特征作线性组合，仍对系数线性。线性回归本身不要求输入特征服从正态；若要作某些经典置信区间推断，才需额外的误差假设。

记住： 拟合关系不自动具有因果含义；外推到训练范围之外要结合领域结构判断。

7.2 怎样求参数：方程、分解与迭代

将截距作为一列 1 并记增广矩阵为 $\widetilde{X}$，系数为 $\boldsymbol{\theta}$。令平方目标梯度为 0，得到正规方程（Normal Equations）

$$\widetilde{X}^{\top}\widetilde{X}\boldsymbol{\theta} = \widetilde{X}^{\top}\boldsymbol{y}.$$

只有当列满秩时，才能写 $\hat{\theta} = (\widetilde{X}^{\top}\widetilde{X})^{-1}\widetilde{X}^{\top}\boldsymbol{y}$。不满秩时可能有多个最优系数；在样本上的拟合投影仍可确定。

方法	实际考虑
QR 或 SVD 分解	通常比先形成正规方程再显式求逆更适合数值计算；SVD 可处理秩亏。
梯度方法	避免显式矩阵求逆，适合较大或稀疏问题；需考虑尺度、步长和收敛。
闭式表达	有助于理解目标，但不是要求程序照着显式求逆执行。

正规方程不是“大数据时必定首选”或“绝不能用”的二元规则。计算成本与样本数、特征数、稀疏性、条件数及求解器有关。平方目标凸不代表任意步长的梯度下降都能收敛。

> **相关列与数值稳定性**
>
> 重复列或完整独热加截距可能造成秩亏；接近相关的列也可能使系数不稳定。正则化和稳定求解都可以帮助，但用途与假设需要分别理解。

7.3 多项式回归：改变表示，不增加样本

多项式回归（Polynomial Regression）使用 $\phi(x) = (x, x^2, \ldots, x^d)$，预测 $\hat{y} = b + \sum_{j=1}^{d} w_j x^j$。对原输入可非线性，对系数仍线性。

原输入 x	截距列 1	x	x^2
0	1	0	0
1	1	1	1
2	1	2	4

同样三条样本增加了表示列，没有新增独立观测。上一页的目标 $[1, 2, 2]$ 可被 $1 + 1.5x - 0.5x^2$ 精确拟合，但只有三个点不能证明这个二次关系适用于新数据。

7.3.1 次数越高，越要检查数值与泛化

高次幂可能尺度差异很大，并造成病态问题。可结合适当缩放、稳定基函数和正则化。多变量展开还包含交互项，列数可能迅速增加。次数与表示步骤应在训练内选择，不能看完测试结果再决定展开方式。

记住：特征构造扩展了模型可表达的函数；它不是数据增强，也不是免费增加证据。

7.4 Ridge：连续收缩系数

岭回归（Ridge Regression）在本章使用

$$J(\boldsymbol{w}, b) = \frac{1}{2n}\|X\boldsymbol{w} + b\mathbf{1} - \boldsymbol{y}\|_2^2 + \frac{\lambda}{2}\|\boldsymbol{w}\|_2^2, \quad \lambda \geq 0.$$

截距 b 不惩罚。特征已中心化、单独处理截距时，

$$(X^\top X + n\lambda I)\hat{\boldsymbol{w}} = X^\top \boldsymbol{y}.$$

$\lambda > 0$ 时，对全部斜率施加的 L2 惩罚使此系数矩阵正定，即使原矩阵秩亏。

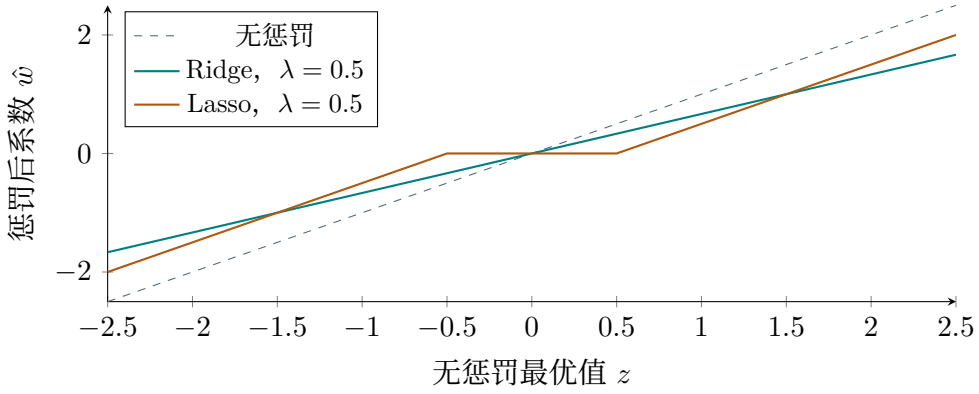


图 7.2: 单系数教学目标 $\frac{1}{2}(w - z)^2$ 上，Ridge 为 $z/(1 + \lambda)$；下页解释 Lasso。

读图： Ridge 通常使系数向 0 收缩，但不能说“绝不等于 0”：当 $z = 0$ 时仍为 0。惩罚强度依赖目标中的 n、$1/2$ 等缩放约定，比较软件参数前需对照完整公式。

尺度会改变同一系数惩罚所代表的限制，数值特征常在训练内标准化。相关特征的单个系数路径可以变化，不能把每个系数都必然单调趋零当作一般定理。

7.5 Lasso：为什么能够产生零系数？

Lasso 使用 $J=\frac{1}{2n}\|X\boldsymbol{w}+b\mathbf{1}-\boldsymbol{y}\|^2+\lambda\|\boldsymbol{w}\|_1$，截距不惩罚。L1 惩罚在 0 处不可微，其几何与次梯度使零系数能够成为最优解。

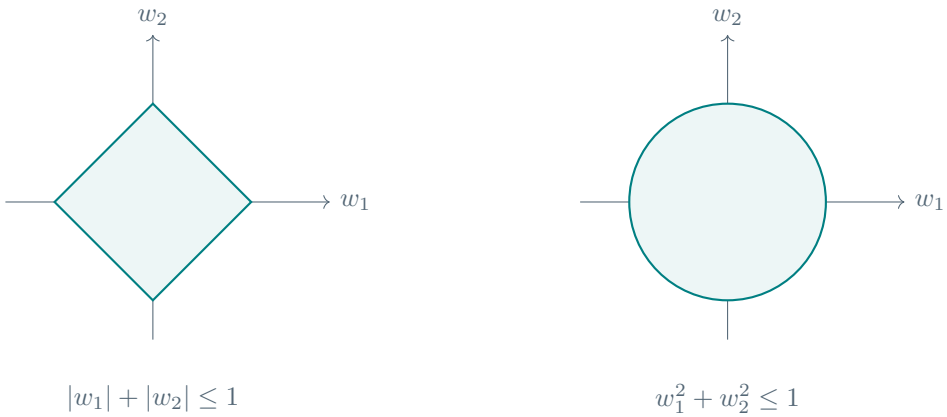


图 7.3: 两个系数的 L1 与平方 L2 约束区域。这里只比较区域形状，未画任意相切等高线。

读图： L1 菱形的角在坐标轴上，一个系数为 0；L2 圆盘边界更平滑。这帮助理解稀疏性，但并不保证每个数据集都选择出真实变量。

对单系数目标 $\frac{1}{2}(w-z)^2+\lambda|w|$，精确解为软阈值

$$\hat{w}=\operatorname{sign}(z)\max(|z|-\lambda,0).$$

当 $z=0.3,\lambda=0.5$，Lasso 系数为 0，Ridge 为 0.2；当 $z=2$ 时，两者分别为 1.5 与 $4/3$。

> **选中不等于因果；未选中不等于永远无用**
> 相关特征可能互相替代，选择结果也可能随样本变化。Lasso 在秩亏等情形下未必有唯一系数解。不能把 L1 也当成保证正规方程可逆的方法。

7.6 Elastic Net：同时控制稀疏与收缩

弹性网络（Elastic Net）结合两种惩罚。本章约定总强度 λ 和混合比例 ρ:

$$J = \frac{1}{2n}\|X\boldsymbol{w} + b\mathbf{1} - \boldsymbol{y}\|^2 + \lambda\rho\|\boldsymbol{w}\|_1 + \frac{\lambda(1-\rho)}{2}\|\boldsymbol{w}\|_2^2, \quad 0 \le \rho \le 1.$$

$\rho = 1$ 得到 Lasso，$\rho = 0$ 得到本章约定的 Ridge。不同软件对 alpha、lambda、l1-ratio 的命名与缩放可能不同，应比较公式。

方法	典型效果	选择时考虑
Ridge	连续收缩，通常保留多数非零系数。	相关列与稳定预测。
Lasso	可以得到零系数。	稀疏表示，选择稳定性。
Elastic Net	结合 L1 与 L2，可同时稀疏与收缩。	相关特征组与两个超参数的权衡。

“特征很多就必须先用 Elastic Net”不是通用规则。应比较基线、特征结构、计算开销和验证表现。若 $\lambda(1-\rho) > 0$，系数目标具有严格的二次惩罚，有助于唯一性；截距仍需按数据与模型定义处理。

记住：正则化表达偏好，不会自动识别哪些特征是真实原因。

7.7 逻辑回归：线性得分对应分类概率

二元逻辑回归（Logistic Regression）令 $p = P(Y = 1 \mid \boldsymbol{x}) = \sigma(s)$，$s = b + \boldsymbol{w}^\top \boldsymbol{x}$，等价于 $\log[p/(1-p)] = s$，即对数几率对特征线性。

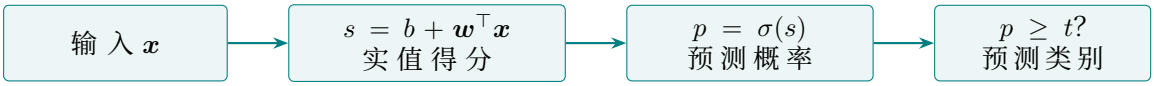


图 7.4: 概率与类别之间还需要决策阈值 t，默认 0.5 只是常见选择。

读图： 若 $s = \log 3$，则几率为 3，概率为 $3/4$。阈值 0.5 时预测 1；阈值 0.8 时预测 0。阈值改变决策，不改变已拟合概率函数。

以二元交叉熵拟合时，对单样本得分有 $\partial \ell / \partial s = p - y$。批量参数梯度为 $X^\top(\boldsymbol{p} - \boldsymbol{y})/n$，再加所选正则项。对线性参数的逻辑损失为凸，但无正则且类别完全可分时，有限最优参数可能不存在。

> **线性得分不表示对输入的概率线性**
>
> Sigmoid 后的概率通常随输入非线性变化。普通线性回归直接输出实数，可能超出 $[0, 1]$；逻辑回归为概率建模提供相应结构。概率是否准确反映频率，还需校准与独立评估。

7.8 多分类：Softmax 与一对其余

多项逻辑回归（Multinomial Logistic Regression）为 K 个互斥类别计算得分 s_k，令 $p_k = \exp(s_k)/\sum_j \exp(s_j)$，用类别交叉熵联合拟合。所有得分加同一常数不会改变概率，因此参数识别通常需基准类或其他约束。

方法	怎样训练	输出如何理解
Softmax	一个联合的多分类目标。	类别概率和为 1，面向互斥类别。
一对其余 OvR	每类训练“此类/其余”的二元模型。	独立二元概率不必和为 1；单标签预测需统一比较规则。
多标签	每个标签独立判断是否存在。	允许多个标签同时为真，不应强行 Softmax 归一化。

得分 $[0, \log 2, \log 3]$ 经 Softmax 变为 $[1/6, 1/3, 1/2]$。三个 OvR 二元模型则可能同时输出 $[0.7, 0.6, 0.2]$，它们并非一组已经归一化的互斥概率。有些实现会另外归一化，但须按实现说明解释，不能与联合 Softmax 混为一谈。

记住：先确定标签能否同时出现，再选择输出结构与损失。

7.9 k 近邻：根据局部训练记录预测

k 近邻（k-Nearest Neighbors, KNN）查询最相似的 k 条训练记录。分类可等权投票，回归可平均目标；也可按距离加权，需明确定义零距离的处理。

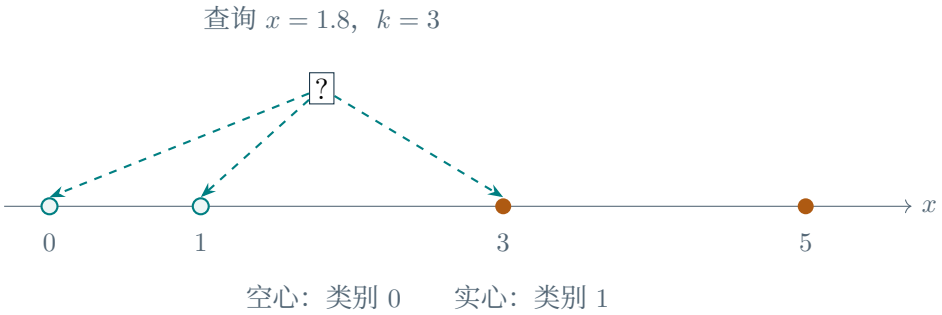


图 7.5: 一维分类例子：训训练位置 0、1 标签为 0，3、5 标签为 1。

读图：查询 1.8 到四点距离为 1.8、0.8、1.2、3.2。三个近邻为 1、3、0，票数 2 比 1，预测 0；若 $k = 1$ 也预测 0，但依据只有最近点。

Minkowski 距离为 $d_p(\boldsymbol{x}, \boldsymbol{z}) = (\sum_j |x_j - z_j|^p)^{1/p}$，$p \geq 1$。$p = 1$ 为曼哈顿，$p = 2$ 为欧氏，$p \to \infty$ 为最大分量差。尺度、相关列和无关特征都会影响“近”的含义，应根据任务设计表示。

> **奇数 k 并不消除所有平票**
>
> 二分类等权投票时奇数可避免两类票数相同；多分类、距离平局或加权规则仍可能平票。KNN 依赖局部相似性假设，也可能受异常点与高维影响。大样本查询成本高，可考虑适合维度与精度需求的索引或近似检索。

参考：ISLR 第二版第 3、4、6 章；scikit-learn Linear Models 与 Nearest Neighbors 文档。本章例子和图独立构造，公式缩放均按正文约定。

第八章　树、概率模型与集成学习

树把输入空间切成若干区域；朴素贝叶斯通过条件分布计算类别后验；集成学习组合多个模型。本章先理解单个预测怎样产生，再解释组合的价值与限制。

> **预测结构决定了检查重点**
>
> 树关注切分与叶子，概率模型关注分布假设和概率方向，集成方法关注模型之间的依赖与组合规则。任何一种训练方法都仍需正确划分、训练内调参和独立评估。

8.1　分类树：按规则进入叶子

决策树（Decision Tree）依次询问特征条件，把输入送到一个叶节点。叶子可给出多数类别或根据训练记录估计的类别比例。下面用八条样本说明一次二元切分。

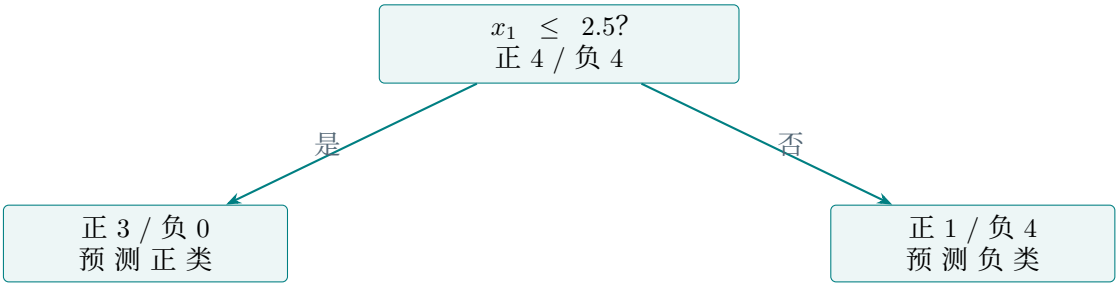


图 8.1： 根节点正负各 4 条；左叶 3 条，右叶 5 条。条件按输入特征判断。

读图： 真实标签为 $[1,1,1,0,0,0,0,1]$、输入 $x_1 = 0,\dots,7$ 时，阈值 2.5 产生图中计数。右叶仍有一个正样本，所以叶子不一定纯，也不一定全部预测正确。

分类节点的 Gini 不纯度为 $G = 1-\sum_k p_k^2$；熵为 $H = -\sum_k p_k \log_2 p_k$，约定 $0\log 0 = 0$。切分后按子节点样本数加权。此例父 Gini 为 0.5，子节点加权 Gini 为 $\frac{3}{8}\times 0+\frac{5}{8}\times[1-(1/5)^2-(4/5)^2] = 0.2$，下降 0.3。

记住： 训练时用标签评价候选切分；预测时沿已确定规则走树，不需要新样本的标签。

8.2 回归树：叶子输出常数

平方损失回归树在区域 R_m 输出训练目标均值 c_m，可写成 $\hat{f}(\boldsymbol{x}) = \sum_m c_m \mathbf{1}[\boldsymbol{x} \in R_m]$。每次尝试特征和阈值，使左右子区域内的残差平方和较小。

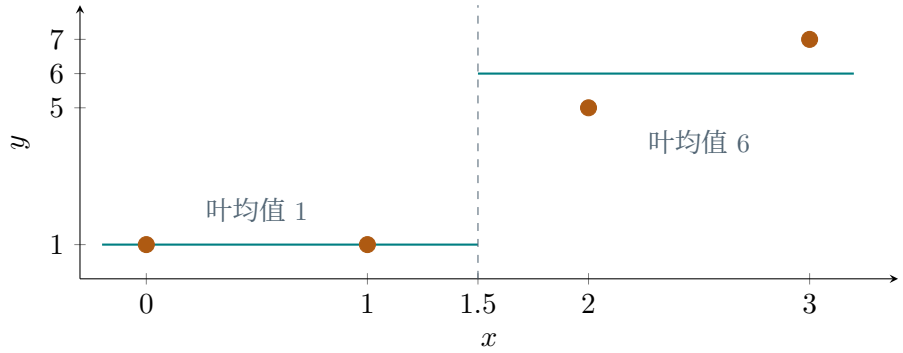


图 8.2: 四条记录 $(0,1),(1,1),(2,5),(3,7)$，在 $x = 1.5$ 切分成两个叶子。

读图：左叶预测 1，右叶预测 6，平方误差和为 0+1+1=2。不切分时输出总体均值 3.5，平方误差和为 27。单次切分降低训练误差，不等于已经证明泛化改善。

叶子均值是在固定区域下平方误差的最优常数；若改为绝对误差，最优常数相应为中位数。常规轴向切分使预测呈分段常数，通常不能像线性趋势那样向训练目标范围之外外推。

> **贪心不等于全局最优树**
>
> 逐节点选择当前最佳切分是局部搜索。它不保证给定深度下找到所有可能树中的最优结构，样本的小变化也可能改变切分。

8.3 树的复杂度与实现边界

树越深、叶子越小，通常越能适应训练样本细节。限制深度、叶子最少样本数、最小增益或作代价复杂度剪枝，都是控制方式。具体参数应在训练内验证，而不是按训练误差一直生长到零。

经典方法	常见选择准则	理解边界
ID3	信息增益	经典形式面向离散分类特征。
C4.5	增益率及相关启发式	用于减轻取值数偏好，非简单任意最大化比值。
CART	分类常用 Gini，回归常用平方误差	二元树；可有不同损失与实现扩展。

原生类别与缺失支持取决于算法和软件版本，不能仅凭“决策树”这个名称假定都支持。常规阈值树一般不需要数值标准化，但无序类别的整数编码仍可能改变可表达的分组。单棵浅树通常容易读；很深的树和大量树的组合则难以完整解释。

记住：树可以表达特征交互；不能笼统说树忽略特征之间的所有关联。

8.4 朴素贝叶斯：给定类别后作独立近似

朴素贝叶斯（Naive Bayes）用类先验 $P(Y=c)$ 及各特征的类条件分布，作近似

$$P(\boldsymbol{x} \mid Y=c) \approx \prod_j P(x_j \mid Y=c), \qquad P(Y=c \mid \boldsymbol{x}) \propto P(Y=c) \prod_j P(x_j \mid Y=c).$$

连续特征应使用相应密度，而非把单点概率写成正数。“朴素”假设是**给定类别后的特征条件独立**，不是要求所有特征无条件独立。

观测 $x_1=1, x_2=0$	类先验	$P(x_1=1 \mid c)$	$P(x_2=0 \mid c)$
类别 1	0.6	0.8	0.5
类别 0	0.4	0.2	0.25

未归一化分数分别为 0.24 与 0.02；归一化得到 $P(Y=1 \mid \boldsymbol{x}) = 12/13 \approx 0.923$。0–1 损失下选择最大后验；错误成本不同则应比较期望成本。

> **不要在后验上再乘一次先验**
>
> 先验已经进入贝叶斯公式。特征强相关时，独立近似可能重复累计证据，分类仍可能有效，但输出概率容易过度自信，需要独立检查。

8.5 概率模型的估计与数值实现

不同朴素贝叶斯版本对输入作不同假设。

版本	常见输入/假设	需要检查
Gaussian NB	类别内数值特征的高斯密度。	方差与分布形态，零方差的稳定处理。
Multinomial NB	词频等非负计数特征。	词典、平滑、非负输入；不是任意有符号数值。
Bernoulli NB	二元是否出现。	出现与未出现都进入相应概率。

对离散计数，平滑可避免训练中未见事件使整项乘积为零。例如有 K 种取值、总计数 N、某取值计数 N_j，加法平滑为 $(N_j+\alpha)/(N+K\alpha)$，$\alpha>0$。实际常用 $\log P(c)+\sum_j \log P(x_j \mid c)$ 计算，再用稳定方式归一化。

8.5.1 MLE、MAP 和后验均值不能混用

MLE 最大化似然，MAP 最大化后验，平方损失下的贝叶斯参数点估计为后验均值。例如硬币 2 次正面、1 次反面，正面概率 θ 的 MLE 为 $2/3$。均匀先验下，后验密度与 $\theta^2(1-\theta)$ 成比例，即 $\mathrm{Beta}(3,2)$ 分布；MAP 为 $2/3$，后验均值为 $3/5$。均匀先验没有让均值也自动等于 MLE。

记住：参数估计的不确定性、模型的预测概率和最终决策规则，是相连但不同的对象。

8.6 Bagging 与随机森林：让平均更有价值

Bagging（Bootstrap Aggregating）在多份有放回重采样数据上拟合模型，再平均或投票。随机森林（Random Forest）进一步在**每个节点的切分**中随机考虑特征子集，常结合 Bootstrap，以减少树之间相似的错误。

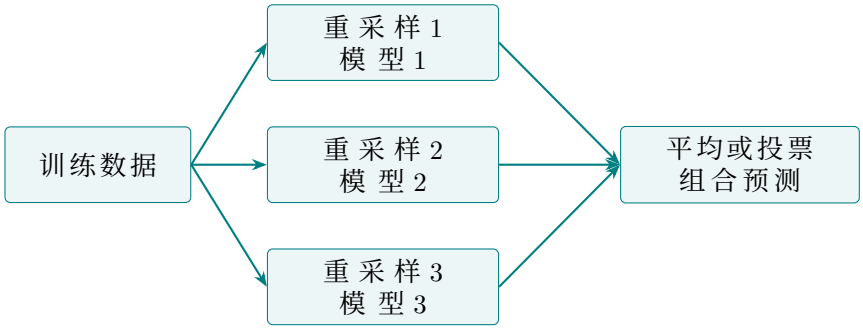


图 8.3: 并列训练与组合示意；仅画三个模型以说明流程。

读图：回归可平均预测。分类可硬投票或平均类别概率后决策，具体要看算法实现。三模型正类概率 0.49、0.49、0.99，硬投票预测 0，但概率均值约 0.657 会预测 1。

若 B 个模型预测方差都为 σ^2、两两相关系数为 ρ，其均值方差为

$$\sigma^2\left[\rho+\frac{1-\rho}{B}\right].$$

$\sigma^2=1,\rho=0.2$ 时，10 模型得 0.28，100 模型得 0.208。这个简化分析说明相关误差不能仅靠无限增加树数消除，不是对所有森林的精确测量公式。

袋外（Out-of-Bag）记录可用于相应评估，但分组、时间约束与数据处理也需保持正确。随机森林能降低单树的高方差风险，仍可能过拟合或遭遇分布变化。

8.7 特征重要性：量的是哪种贡献?

树的不纯度重要性（Mean Decrease in Impurity, MDI）累计某特征参与切分时带来的加权不纯度下降。它反映训练中的使用方式，可能偏向可尝试切分较多的高基数特征。

方法	解释与限制
不纯度重要性	来自训练切分；高基数、相关特征和过拟合可影响排序。
置换重要性	固定已拟合模型，打乱特征后比较评估分数变化；依赖数据、指标与模型。
分组重要性	可把同一原始变量的多个编码列作为一组处理。

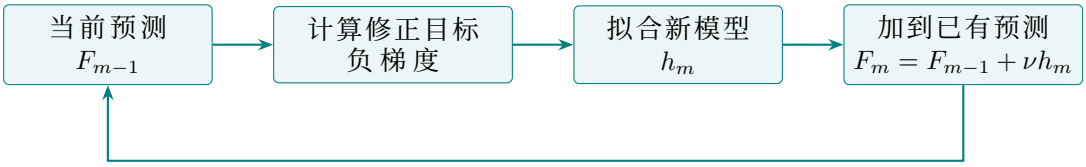
若一个类别变量拆成三个独热列，MDI 分别为 0.10、0.04、0.06，三者求和 0.20 可作为该模型对原变量的汇总，但不自动消除基数偏好。若做分组置换，应对整组使用同一行排列，以保持合法的独热组合；不能随意独立打乱各列。

置换重要性可在开发数据的留出部分计算。若据此反复选择特征或模型，该部分已经参与选择，不能再把其结果当作完全未使用的最终测试。

> **相关特征可能掩盖彼此的重要性**
>
> 一个特征打乱后，另一个仍提供相似信息，分数下降可能很小。这不等于两者都无信息；高重要性也不证明因果作用。

8.8 梯度提升：逐步拟合修正方向

梯度提升（Gradient Boosting）构建加法模型 $F_m = F_{m-1} + \nu h_m$。新模型拟合当前损失对预测值的负梯度方向；ν 是收缩步长。平方损失时，这个方向恰好是残差 $y_i - F_{m-1}(x_i)$。



下一轮依赖当前组合的预测

图 8.4: 每轮依赖当前预测。一般损失的修正目标不一定是普通数值残差。

读图： 目标 $[0, 2, 4]$，初始常数预测为 2。残差 $[-2, 0, 2]$ 若由一个树桩拟合成 $[-2, 1, 1]$，取 $\nu = 0.5$，新预测为 $[1, 2.5, 2.5]$，训练 MSE 从 $8/3$ 下降为 $7/6$。

Boosting 不都通过“给错样本加权”实现；梯度提升也不是只拟合前一棵树的错误，而是针对**当前全部组合**的损失更新。树深、学习率、轮数、采样与正则化共同影响结果。XGBoost、LightGBM 等是相关的树提升实现，细节和默认行为应查具体版本文档。

记住： 训练损失下降是一个过程信号；轮数与停止仍应根据合适的验证表现选择。

8.9 AdaBoost：一个完整的二分类权重步骤

经典离散二分类 AdaBoost 使用 $y_i, h_m(x_i) \in \{-1, 1\}$ 及归一化样本权重 $D_m(i)$。

$$e_m = \sum_i D_m(i)\mathbf{1}[h_m(x_i) \neq y_i], \qquad \alpha_m = \frac{1}{2}\log\frac{1-e_m}{e_m},$$

$$D_{m+1}(i) = \frac{D_m(i)\exp[-\alpha_m y_i h_m(x_i)]}{Z_m}, \qquad H(x) = \operatorname{sign}\left(\sum_m \alpha_m h_m(x)\right).$$

Z_m 使权重和为 1；边界、停止与平票需约定。

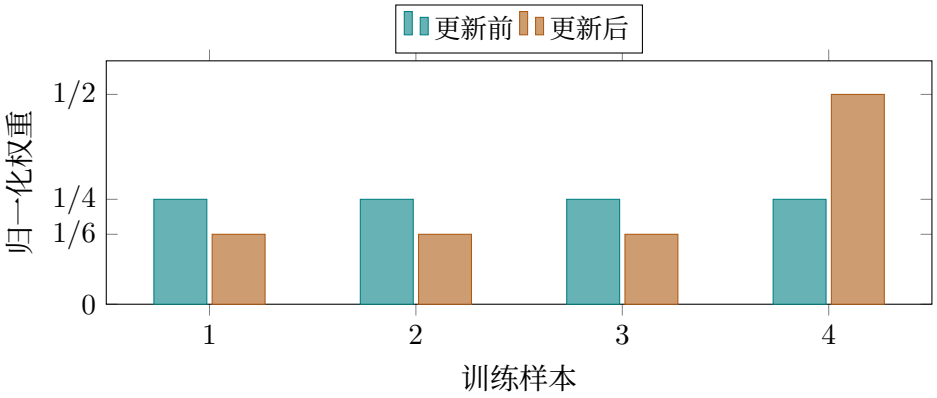


图 8.5: 四个样本初始均为 1/4，仅第 4 个被当前弱模型分错。

读图： $e = 1/4$、$\alpha = \frac{1}{2}\log 3 \approx 0.549$。更新归一化后，错样本权重为 1/2，另外三个各为 1/6；这是相对权重变化，不是重新采集了更多错样本。

若 $e = 0$，应采用相应提前停止/有限数值处理；不能直接除零。若 $e \geq 1/2$，没有上述正权重弱优势，需按算法策略停止或处理，而非机械继续。噪声标签和离群记录可能被反复强调，轮数也需验证。

8.10 投票、Boosting 与 Stacking 怎样选择?

集成不是保证每个模型都正确，而是利用预测之间的差异及组合结构。如果所有模型犯同样的错误，增加数量帮助有限。

方法	模型如何形成	常见检查
Bagging/森林	重采样与随机化后分别拟合。	相关性、叶子限制、袋外/独立验证。
Boosting	根据已有组合逐步添加修正模型。	学习率与轮数、损失、噪声敏感性。
Voting/平均	组合多个已定义的候选模型。	权重、概率与硬标签组合的差别。
Stacking	用基础模型的预测训练一个组合模型。	组合模型需使用折外预测，防止训练预测泄漏。

Stacking 中，基础模型在某样本上的输入给第二层的预测，通常应由未用该样本训练的模型产生。用第一层对自己训练样本的拟合预测直接训练第二层，会让第二层看到过于乐观的输入。最终仍要评估包含预处理、第一层和第二层的完整流程。

8.10.1 自测与回看

森林的树是否必然相互独立? **不是**。梯度提升是否总是修改样本权重? **不是**。贝叶斯后验上是否还要再乘先验? **不需要**。特征重要性是否等于因果作用? **不等于**。

参考： ISLR 第二版第 4、8 章；scikit-learn 的 Decision Trees、Naive Bayes、Ensembles 和 Permutation importance 文档。数字、流程图和权重图均独立构造。

第九章　支持向量机：用间隔约束分类

支持向量机（Support Vector Machine, SVM）在分类得分中同时考虑间隔与违例代价。先理解线性情形，再理解核函数如何改变相似性计算。

> **得分不直接等于概率**
> 线性得分 $s = \boldsymbol{w}^\top \boldsymbol{x} + b$ 的符号给出二分类规则。间隔关注样本离决策边界的程度；若需要概率，应另按适当流程估计或校准。

9.1　硬间隔与支持向量

对可线性分开的数据，硬间隔形式最小化 $\frac{1}{2}\|\boldsymbol{w}\|^2$，约束 $y_i(\boldsymbol{w}^\top \boldsymbol{x}_i + b) \geq 1$，其中 $y_i \in \{-1, 1\}$。在这个规范化下，两条间隔边界为 $s = \pm 1$，总几何宽度为 $2/\|\boldsymbol{w}\|$。

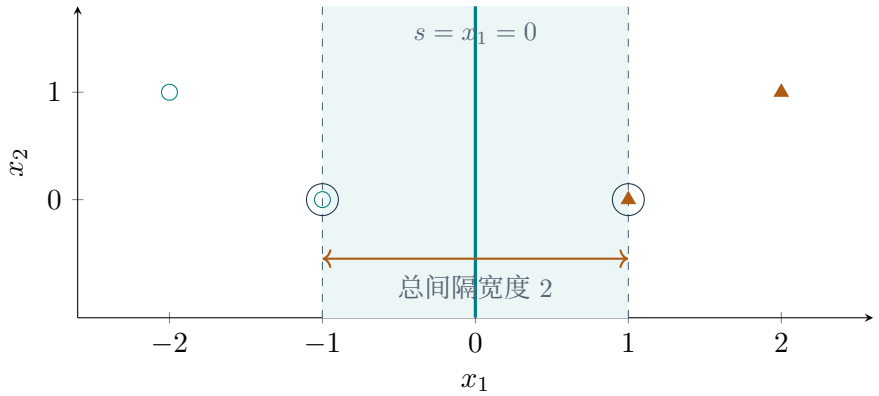


图 9.1： 人工例子 $\boldsymbol{w} = (1, 0)$、$b = 0$，圆形为负类，三角为正类；圈出的点位于间隔边界。

读图： 决策边界 $x_1 = 0$，间隔边界为 $x_1 = \pm 1$，总宽度为 2。在硬间隔解中，贴住间隔约束的点决定边界；对偶中系数 $\alpha_i > 0$ 的训练点称支持向量。

记住： 硬间隔要求可分且对异常记录敏感；不可分时不能机械强制所有约束。

9.2 软间隔：正确分类也可能付出代价

软间隔允许松弛变量 $\xi_i \geq 0$：

$$\min_{\boldsymbol{w},b,\xi} \frac{1}{2}\|\boldsymbol{w}\|^2 + C\sum_i \xi_i, \qquad y_i s_i \geq 1 - \xi_i, \quad C > 0.$$

最小可行松弛为 $\xi_i = \max(0, 1 - y_i s_i)$，即 Hinge 损失。本式使用损失求和，软件或其他章节若改为平均，参数缩放需相应比较。

正类样本得分 s	最小 ξ	解释
1.2	0	正确且在正侧间隔边界之外。
0.4	0.6	正确，但进入间隔内部。
0	1	在决策边界上，类别取决于平票约定。
-0.4	1.4	落到错误一侧。

$\xi = 0$ 不只表示“恰在间隔边界”；$\xi > 0$ 也不都表示误分类。C 越大，单位违例的惩罚越强，模型通常更努力适应训练约束；这不保证泛化更好。支持向量也可能在间隔内部或被误分，不能仅按“离边界最近”一句话定义全部软间隔情形。

> **尺度会改变几何含义**
> 线性间隔和常见核函数都受输入尺度影响。标准化应在训练内拟合；类别不平衡还可能需要类权重与合适评估，而不是只调整 C。

9.3 核函数：在相似性上建立非线性边界

核函数满足 $K(x,z)=\langle\phi(x),\phi(z)\rangle$，允许在不显式构造全部 ϕ 坐标的情况下计算相应内积。核 SVM 得分可写为 $s(x)=\sum_i \alpha_i y_i K(x_i,x)+b$。常见 RBF 核为

$$K(x,z)=\exp[-\gamma\|x-z\|_2^2], \qquad \gamma>0.$$

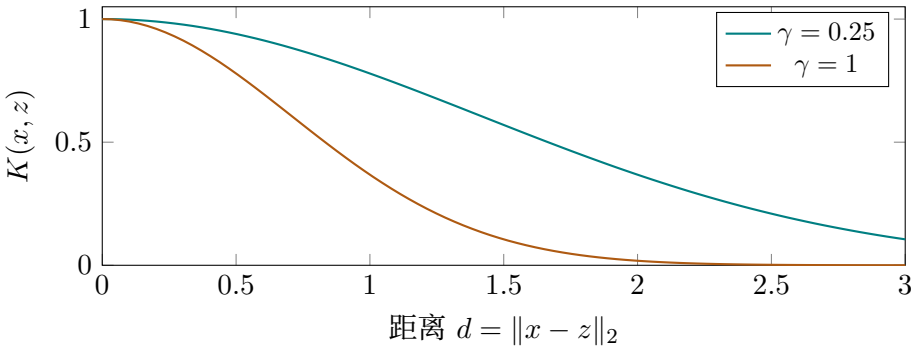


图 9.2: RBF 相似度随距离降低；较大 γ 使影响更局部。

读图：相同点的核值为 1。$x=(0,0)$、$z=(1,1)$、$\gamma=0.5$ 时，核值为 $e^{-1}\approx 0.368$。指数的负号不能省略。核方法也不保证任意数据与标签都能理想泛化。

C 与 γ 通常需要联合验证。核矩阵与求解成本可能随样本数迅速增加，较大任务可比较线性方法、核近似等方案。核相似性、得分和概率各有含义，不能混用。

参考：ISLR 第二版第 9 章；scikit-learn Support Vector Machines 文档。图和数值例子为本书独立构造。

第十章　无监督学习：分组与低维表示

聚类寻找分组，降维寻找较少的表示坐标。没有任务标签时，也要明确距离、结构假设和结果用途。簇编号本身没有类别含义；低维图分得好看也不证明发现了真实类别。

> **先决定什么叫相似，什么值得保留**
> 特征选择和尺度会影响聚类；PCA 保留较大方差方向。这些目标与监督任务的预测准确性不同，需要结合用途评价。

10.1　K-means：分配，再更新中心

K-means 最小化各点到所属中心的平方欧氏距离和：

$$J = \sum_{i} \|\boldsymbol{x}_i - \boldsymbol{\mu}_{c_i}\|_2^2.$$

常用 Lloyd 迭代交替进行最近中心分配与簇内均值更新。

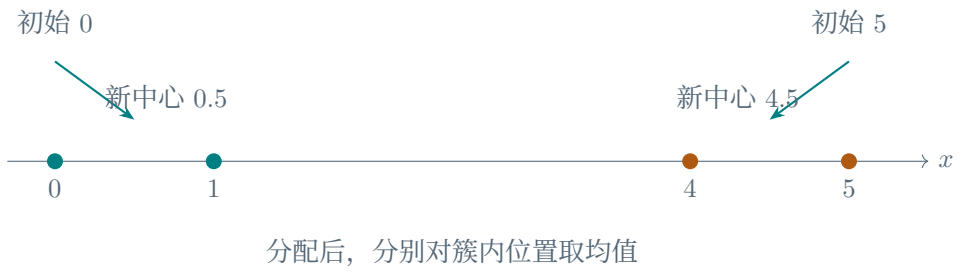


图 10.1：四个一维样本 0、1、4、5，初始中心 0 与 5；一次更新得到 0.5 与 4.5。

读图：初始分组为 $\{0,1\}$、$\{4,5\}$；更新后组内平方和从 2 降到 1。再次分配不变，此例已经稳定。一般迭代不能保证得到全局最优，需考虑初始化和多次运行。

平方距离偏好相应几何中的紧凑分组，异常值可显著移动均值。空簇需要实现约定；混合尺度、非球状结构或密度差异大时，应比较其他方法与表示。K-means++ 改善初始化选择，但不把全局最优变成保证。

10.2 选择簇数与轮廓系数

组内平方和一般随 K 增加而不增，因此不能直接选择其最小值来确定合理簇数。肘部法是观察改进幅度的启发式，未必出现清晰拐点。轮廓系数（Silhouette Coefficient）同时比较簇内和簇间距离。

对样本 i，a_i 是到同簇其他点的平均距离，b_i 是到各其他簇的平均距离的最小值，

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}, \qquad S = \frac{1}{n}\sum_i s_i.$$

常见取值在 $[-1, 1]$，较大表示在该距离定义下更接近本簇、远离最近其他簇。单点簇通常按实现约定取 0；一个簇或每点单独一簇不能按普通定义有效比较。

分组 $\{0,1\},\{4,5\}$	a_i	b_i	s_i
点 0	1	4.5	7/9
点 1	1	3.5	5/7

另外两点对称，总平均为 $47/63 \approx 0.746$。这里用普通一维欧氏距离计算轮廓，不能把 K-means 目标中的平方距离不加说明地代入。

记住：轮廓分数依赖距离和几何，不直接证明分组符合实际用途或真实标签。

10.3 DBSCAN：通过核心点扩展密度连接

DBSCAN 是基于密度的聚类，不预先指定簇数。给定距离阈值 ε 与最少邻域点数 m，本页约定邻域包含点自身：$N_\varepsilon(x) = \{x_j : d(x, x_j) \le \varepsilon\}$。



图 10.2：一维例子，$\varepsilon = 0.26, m = 4$。点的类型由邻域计数决定。

读图：0.3 的邻域为 $\{0.1, 0.2, 0.3, 0.55\}$，因此是核心点；0.55 仅有两个邻域点，是靠近核心点的边界点；1.5 既非核心，也不邻接任何核心，是噪声。

点的类型	判定与扩展
核心点	$\lvert N_\varepsilon(x)\rvert \ge m$，可继续扩展邻域。
边界点	不满足核心条件，但落入某核心点的邻域；可以归簇，不能继续作为扩展桥梁。
噪声点	没有归入任何密度簇的点；“噪声”不自动意味着测量错误。

先连接彼此邻接的核心点，再吸收邻近边界点，可以得到两个簇，1.5 留作噪声。边界点若同时邻接不同簇，归属可能受遍历约定影响；不能通过一串非核心边界点任意合并簇。

尺度和距离仍很关键：ε 过小可能几乎全为噪声，过大可能合为一簇。不同密度的簇未必能用同一阈值识别；高维距离也会变得困难。“形状灵活”不等于对数据没有结构假设。

10.4 层次聚类：链接方式决定合并距离

凝聚式层次聚类（Agglomerative Clustering）从每点一簇开始，每次合并距离最近的两个簇。树状图（Dendrogram）的高度表示合并距离，切割高度可产生不同簇数。

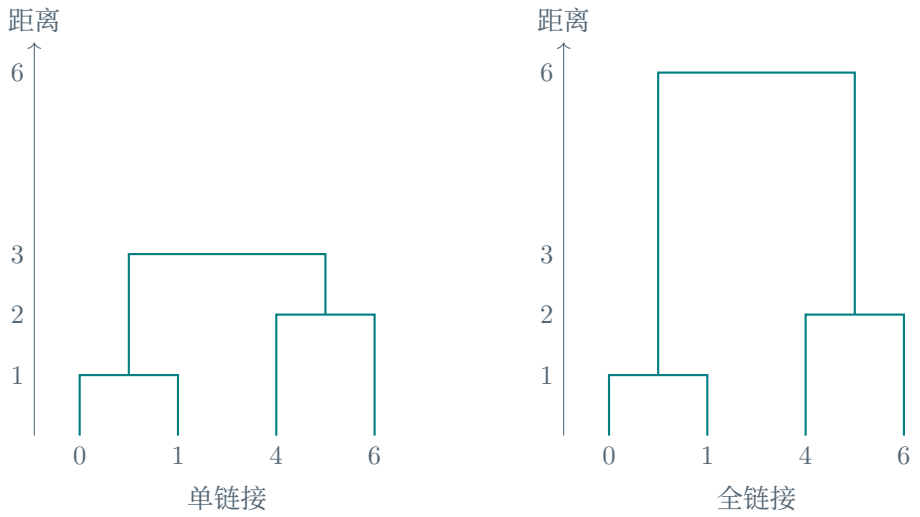


图 10.3: 同样四点 0、1、4、6，链接方式不同，最后合并高度不同。

读图：先在距离 1 处合并 0 与 1，再在距离 2 处合并 4 与 6。随后两簇的单链接距离为 3，全链接距离为 6；平均链接为 4.5。簇内点未移动。

单链接取跨簇点对的最小距离，容易形成链；全链接取最大距离；平均链接取跨簇点对距离的平均。Ward 方法则以组内平方和增加为准则，常用于欧氏设置，不能混同于上述最短/最长距离。

记住：聚类都需要选表示、尺度、距离与规则。比较结果时说明簇数、噪声处理和用途，不能只按图形好看判断。

参考：Ester 等，DBSCAN（1996）；ISLR 第二版第 12 章；scikit-learn Clustering 文档。

10.5 PCA：寻找单位长度的最大方差方向

主成分分析（Principal Component Analysis, PCA）先中心化输入。第一方向最大化投影方差，约束 $\|\boldsymbol{v}\|_2 = 1$；后续方向在与先前方向正交的条件下依次选择。不加长度约束，任意放大系数就能放大方差，问题没有同样意义。

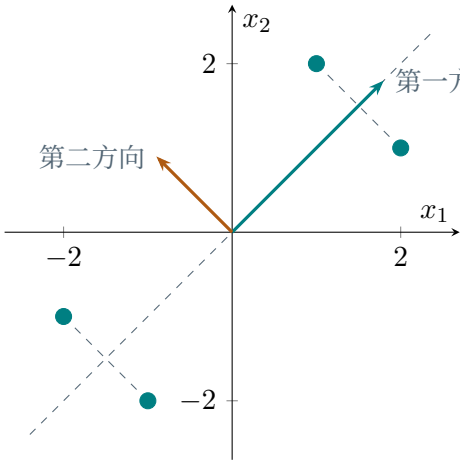


图 10.4: 中心为 0 的四点 $(2,1),(1,2),(-1,-2),(-2,-1)$，第一方向为 $(1,1)/\sqrt{2}$。

读图：沿第一方向投影后，$(2,1)$ 的坐标为 $3/\sqrt{2}$，重建为 $(1.5,1.5)$。虚线表示丢弃第二方向造成的误差，平方距离为 0.5。第一方向描述输入变化，不直接使用类别标签。

投影坐标为 $Z = X_c V_r$，重建为 $\hat{X} = ZV_r^\top + \mathbf{1}\boldsymbol{\mu}^\top$。中心与方向均在训练内拟合。主成分符号正负可以同时翻转，不改变对应子空间。

10.6 保留多少主成分：方差与任务一起看

采用分母 $n-1$ 的样本协方差时，上页四点的矩阵为

$$S = \begin{bmatrix} 10/3 & 8/3 \\ 8/3 & 10/3 \end{bmatrix},$$

特征值为 6 与 $2/3$，解释方差比例为各特征值除以总和。

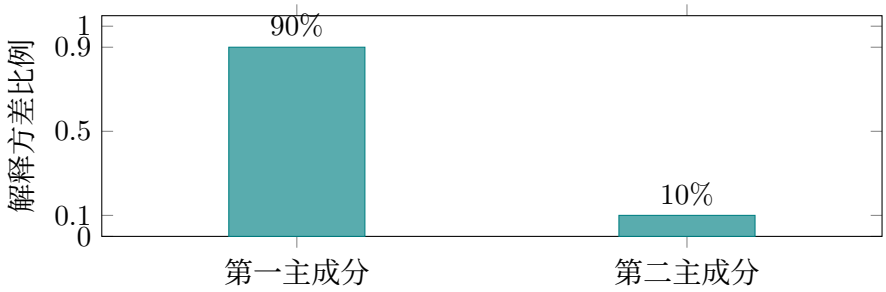


图 10.5: 本例第一方向解释 90% 方差，第二方向解释 10%；保留一维后仍有重建误差。

读图：四条记录各损失 0.5 的平方距离，重建误差平方和为 2。若用“至少 90% 方差”规则，本例保留一维；若要求超过 90%，则需两维。

比例阈值是工程选择，不存在普遍正确的 95% 或 99%。较小方差方向也可能包含重要预测信息；应把 PCA 与后续模型一起在训练内验证。PCA 通常中心化，但是否标准化取决于单位和目标；标准化会改变所优化的方差结构。

记住：解释方差比例描述这个表示对输入变动的保留，不等于保留同比例的“所有有用信息”。

10.7 核 PCA 与方法选择的边界

核 PCA（Kernel PCA）在核所对应的特征空间中进行 PCA，可形成非线性表示。训练核矩阵也要在该特征空间中心化，常写为 $K_c = HKH$，$H = I - \frac{1}{n}\mathbf{1}\mathbf{1}^\top$。

方法	主要目标	不能直接推断
K-means	降低簇内平方距离。	得到的簇自动等于真实类别。
线性 PCA	用正交方向保留较大输入方差。	高解释方差就保留最强标签信号。
核 PCA	在核特征空间中寻找主成分。	降维后一定线性可分或可无损重建。

核与超参数决定表示；核空间的方差不能不加区别地解释为原输入单位下的方差。新点的变换要沿用训练中心化规则；一般核表示的原空间逆映射并不自动存在。对初学者，应先建立线性 PCA 与简单聚类基线，再决定是否需要非线性方法。

10.7.1 自测与回看

$\xi = 0$ 是否只表示在 SVM 间隔边界? **不是**。轮廓系数是否直接使用组内平方和? **不是**。PCA 保留 90% 方差是否保证保留 90% 预测能力? **不能**。核 PCA 是否保证任何标签线性可分? **不能**。

参考： ISLR 第二版第 12 章；MML 第 10 章；scikit-learn Clustering 与 Decomposition 文档。图和数字例子独立构造。

第二部分

深度学习基础

第十一章　神经网络：从结构到一次参数更新

神经网络（Neural Network）把一系列可调的数学变换组合起来，将输入映射为预测。学习的关键，是利用数据调整这些变换中的参数，而不是手工规定每个中间特征。本章围绕一个问题展开：**一次预测出错后，网络怎样知道该调整哪些参数？**

> **本章阅读路线**
>
> 先看网络如何计算预测，再选择输出与损失，最后把损失的梯度传回各层并更新参数。需要的数学只有加权求和、矩阵乘法、导数和链式法则。本章用列向量表示单个样本；n 表示样本数，d 表示输入特征数，K 表示类别数。

11.1　把训练过程连起来

训练一个监督学习网络，需要训练数据、网络结构、损失函数和优化方法。损失函数回答“当前预测错了多少”，反向传播回答“参数改变会怎样影响损失”，优化器根据梯度决定“这一步怎样改参数”。

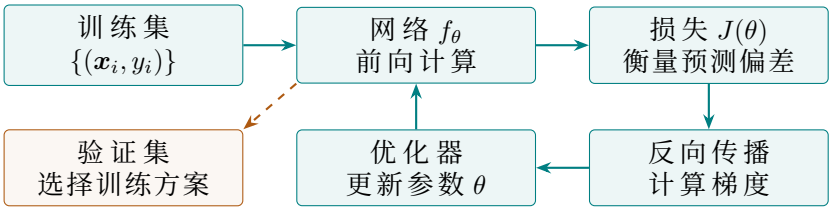


图 11.1：训练循环与验证的分工。虚线表示用验证数据评估方案，不通过该分支拟合参数。

读图：沿实线走一圈，就是一次参数更新。网络先产生预测，损失把预测与标签比较，反向传播计算梯度，优化器据此更新参数，随后才能开始下一次计算。验证集用来选择网络宽度、学习率或停止时刻；测试集留到方案确定后评估。

对于训练集 $\mathcal{D} = \{(\boldsymbol{x}_i, y_i)\}_{i=1}^{n}$，一个常见目标是

$$J(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell\big(f_\theta(\boldsymbol{x}_i), y_i\big) + \lambda \Omega(\theta). \tag{11.1}$$

这里 θ 是网络全部可训练参数，f_θ 是预测模型，ℓ 是单个样本的损失，Ω 是正则化项，$\lambda \geq 0$ 控制正则化强度。本章手算例子令 $\lambda = 0$，便于看清计算过程。

> **容易混淆**
>
> 测试集不参与参数拟合、阈值选择或学习率调整。归一化、缺失值填补等需要从数据估计的步骤，也只能先在训练数据上拟合，再应用于验证集和测试集。训练损失下降，并不保证新数据上的误差下降。

11.2 结构、前馈与隐藏层

前馈神经网络（Feedforward Neural Network）的计算连接不形成有向环。全连接的多层感知机（Multilayer Perceptron, MLP）是其中一种常见形式：相邻层的每个单元与上一层的全部单元相连。卷积网络也可以是前馈网络，所以“前馈网络”和“MLP”不能在所有语境下画等号。

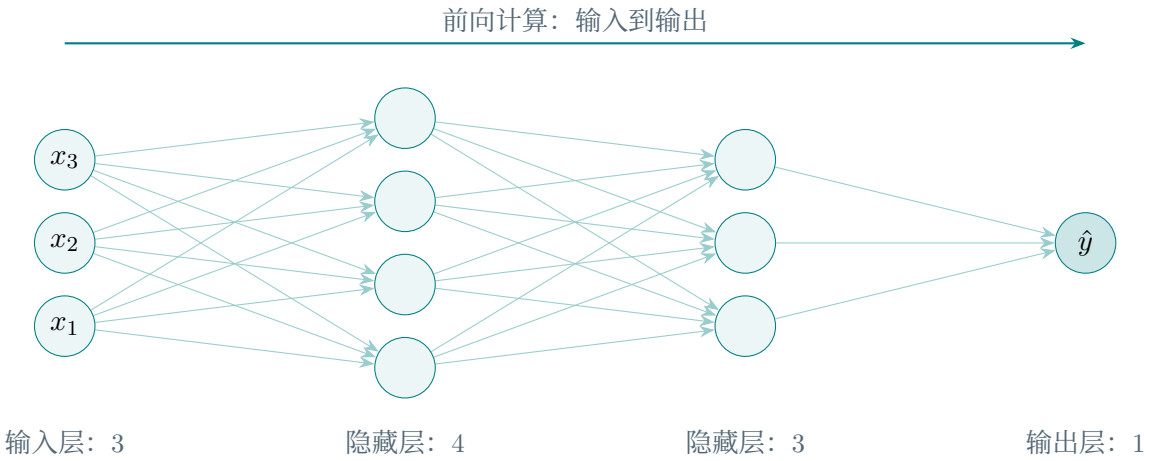


图 11.2： 一个 $3\to4\to3\to1$ 的 MLP。箭头表示计算依赖，偏置未画出。

读图： 最左侧的三个输入单元只是三个特征的入口。中间两列分别有四个和三个隐藏单元，最右侧只有一个输出。每条连接对应一个权重；每个隐藏单元和输出单元通常还有一个偏置。这些偏置不应因为图中省略而在计算时被忘掉。

隐藏层（Hidden Layer）位于输入与输出之间，其激活值是网络根据输入计算出的中间表示。“隐藏”指它们没有直接作为任务所给定的输入或目标，并不表示它们无法观察，也不表示必须另有标签。它们会在后续训练中通过最终损失的梯度间接得到调整。

宽度（Width）描述一层有多少单元；**深度（Depth）**描述计算经过多少层。本书计算参数层数时不计输入层，因此图中的网络有三个参数层、两个隐藏层。其他资料可能采用不同的计数约定，比较结构时应先确认口径。

这个网络的可训练参数总数为

$$(3\times4+4)+(4\times3+3)+(3\times1+1)=35.$$

每个括号中的前一项数连接权重，后一项数偏置。输入层没有要在这里拟合的权重或偏置。

> **结构由什么决定？**
> 输入维度由数据表示决定，输出形式由任务决定；隐藏层的层数、宽度和激活函数是建模选择。可以在验证集上比较候选结构，但不存在对所有数据都最优的网络深度。更多层或更多参数带来表达能力与计算成本的变化，不自动带来更好的泛化。

11.3 神经元与前向计算

人工神经元（Artificial Neuron）可以看成“加权求和，加偏置，再做激活”的小计算模块。权重决定输入各分量怎样组合，偏置决定变换的平移，激活函数改变组合结果的形状。

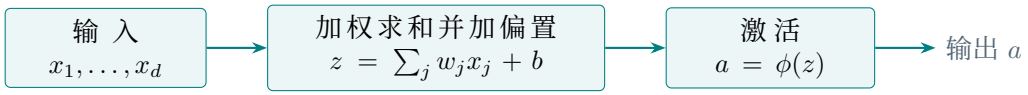


图 11.3: 单个神经元的计算。偏置在激活之前加入。

读图：输入先乘各自权重并相加，得到激活前的数值 z；激活函数 ϕ 将 z 转为输出 a。图中的“求和”并非把输入原样相加，而是进行加权求和。

11.3.1 先算一个单元

设 $\boldsymbol{x} = (2, -1)^\top$、$\boldsymbol{w} = (0.5, 1)^\top$、$b = 0.2$，则

$$z = \boldsymbol{w}^\top \boldsymbol{x} + b = 0.5 \times 2 + 1 \times (-1) + 0.2 = 0.2.$$

若用 ReLU，输出为 $a = 0.2$；若用 Sigmoid，输出约为 $a = 0.550$。相同的加权输入，经过不同的激活函数会产生不同的输出。

11.3.2 一层就是多个单元一起算

记第 l 层有 d_l 个单元，$\boldsymbol{a}^{(0)} = \boldsymbol{x}$。前向传播写为

$$\boldsymbol{z}^{(l)} = W^{(l)} \boldsymbol{a}^{(l-1)} + \boldsymbol{b}^{(l)}, \qquad \boldsymbol{a}^{(l)} = \phi^{(l)}(\boldsymbol{z}^{(l)}). \tag{11.2}$$

对逐元素激活，每个单元只对自己的 z 做变换。Softmax 是向量变换，需把整组输出一起计算。

对象	形状	含义
$\boldsymbol{a}^{(l-1)}$	$d_{l-1} \times 1$	上一层输出
$W^{(l)}$	$d_l \times d_{l-1}$	每一行对应当前层一个单元的权重
$\boldsymbol{b}^{(l)}$	$d_l \times 1$	当前层偏置
$\boldsymbol{z}^{(l)}, \boldsymbol{a}^{(l)}$	$d_l \times 1$	当前层激活前的值与激活值

记住：先检查矩阵形状，再计算数值。隐藏层在计算新的表示；输出层把表示转换成任务所需的预测。

11.4 为什么需要非线性激活?

如果每层都只有仿射变换，堆叠后仍然只是仿射变换。例如

$$W_2(W_1\boldsymbol{x}+\boldsymbol{b}_1)+\boldsymbol{b}_2=(W_2W_1)\boldsymbol{x}+(W_2\boldsymbol{b}_1+\boldsymbol{b}_2).$$

因此，仅增加这样的层数无法获得一般的非线性表达能力。激活函数（Activation Function）让网络能表示更丰富的关系。



图 11.4: Sigmoid 平滑地压缩数值；ReLU 保留正半轴，把负半轴置零。

读图：左图过 $(0,0.5)$ 且单调递增，两端逐渐变平；右图在原点折转，负半轴为水平线，正半轴斜率为 1。曲线的斜率就是反向传播会用到的局部导数。

$$\sigma(z)=\frac{1}{1+e^{-z}},\qquad \sigma'(z)=\sigma(z)(1-\sigma(z)), \tag{11.3}$$

$$\mathrm{ReLU}(z)=\max(0,z),\qquad \mathrm{ReLU}'(z)=\begin{cases}0, & z<0,\\ 1, & z>0.\end{cases} \tag{11.4}$$

Sigmoid：有限实数输入的输出严格位于 $(0,1)$，适合表示单个二元事件的概率估计。其导数不超过 $1/4$；当 $|z|$ 很大时导数趋近于 0，但在有限实数处不等于 0。多层连乘小导数可能使梯度变小，因而 Sigmoid 通常不是深层隐藏层的默认选择。

修正线性单元（Rectified Linear Unit, ReLU）：计算简单，正半轴的导数为 1，是隐藏层常见的起点。$z=0$ 处经典导数不存在，实际自动求导通常约定取 0。如果一个单元对训练输入长期都输出 0，其输入侧参数可能难以再更新，这称为“死亡 ReLU”。

> **容易混淆**
>
> ReLU 不能保证整个深层网络不会出现梯度消失。梯度还受到权重、网络深度、输入分布等因素影响。Sigmoid 输出的数值也不会仅因位于 $(0,1)$ 就自动成为校准良好的概率。

11.5 XOR：隐藏表示怎样改变可分性

异或（XOR）在两个输入不同的时候输出 1，相同时输出 0。四个输入 $(0,0),(1,0),(0,1),(1,1)$ 的目标为 $0,1,1,0$；它们不能由原平面中的一条直线严格分开。

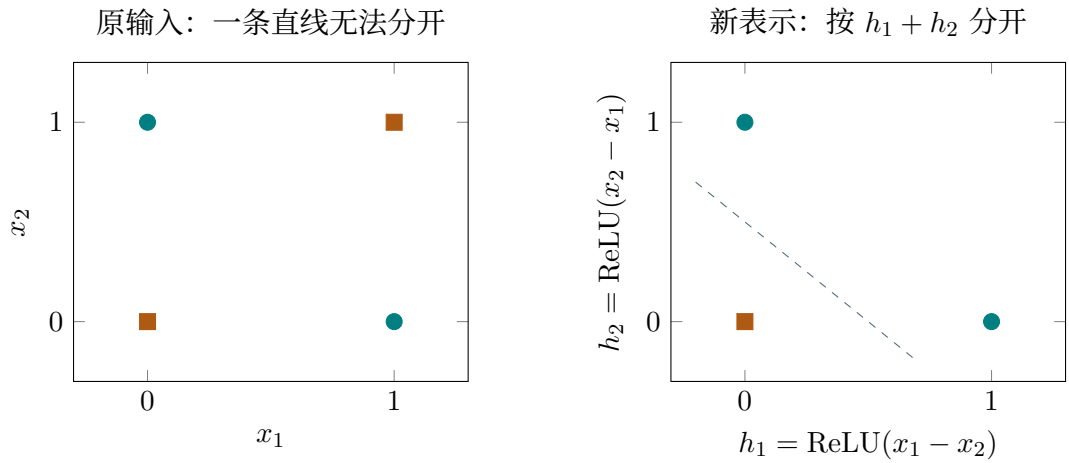


图 11.5: 青色圆点为正类，橙色方点为负类；两负类在隐藏表示中重合到原点。

读图： 设 $h_1=\mathrm{ReLU}(x_1-x_2)$、$h_2=\mathrm{ReLU}(x_2-x_1)$，则正类映为 $(1,0)$ 或 $(0,1)$，负类均为 $(0,0)$。再按 $h_1+h_2>0.5$ 即可分类。这里显式构造权重，说明表示能力，不等于保证训练自动找到它。

若所有层都只有仿射变换，$W_2(W_1x+b_1)+b_2$ 仍是一个仿射变换；单纯叠层没有引入这里所需的非线性表达。中间的非线性使组合获得不同形状的决策边界。

深度可让某些具有组合结构的函数更高效地表示，并不意味着越深越好。常见通用逼近结论有函数、区域与网络宽度等条件，也不保证优化、样本需求或测试泛化。XOR 只需很小的隐藏表示，不需要很深的网络。

记住： 先问结构能否表达，再问优化能否学到，最后问新数据是否有效；三个问题不能相互替代。

11.6 Softmax：把一组得分变为分布

当一个样本必须属于 K 个互斥类别中的某一个时，网络通常先输出 K 个实数得分，称为 logits。Softmax 将这组得分转换为和为 1 的概率分布估计：

$$p_k = \mathrm{softmax}(\boldsymbol{z})_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}, \qquad k = 1, \dots, K. \tag{11.5}$$

对有限 logits，所有 $p_k > 0$ 且 $\sum_k p_k = 1$。分母遍历同一个样本的全部类别，而不是遍历不同样本。

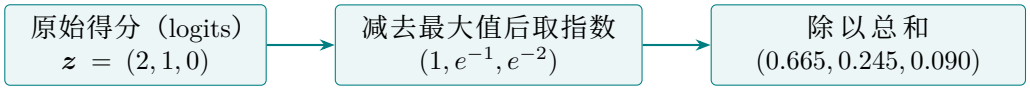


图 11.6: 三分类的数值例子。显示值经过四舍五入。

读图：得分最大的第一类获得最高概率，但其概率约为 0.665，并不接近 1。第二、三类仍保有概率质量。若取概率最大的类别作为最终标签，这一步才是离散的分类决策。

11.6.1 数值稳定性来自平移不变性

若给每个得分同时减去常数 c，分子分母会约去相同的因子 e^{-c}，所以结果不变。通常取 $c = \max_j z_j$：

$$p_k = \frac{e^{z_k - c}}{\sum_j e^{z_j - c}}. \tag{11.6}$$

这样所有指数的输入都不大于 0，避免直接计算过大的指数。图中的 $(2, 1, 0)$ 与 $(1002, 1001, 1000)$ 应当得到相同的分布。极小分量仍可能在有限精度下下溢；需要对数概率时，应直接使用稳定的 log-softmax 计算。

> **Softmax 会不会总选出一个接近 1 的概率？**
> 不会。若所有得分相等，每类概率都是 $1/K$；差距越大，分布才可能越集中。Softmax 保持得分的大小顺序，**它不是取最大值运算，也不是概率校准的保证**。例如把 $\boldsymbol{z}$ 乘以一个较大的正数，会改变概率集中程度，却不改变最高分的类别。

记住：Sigmoid 逐个处理二元事件；Softmax 联合处理互斥类别。判断任务能否同时有多个真标签，再选择输出。

11.7 把输出层和损失函数配对

输出层的形式由预测目标决定，不能只根据“分类”两个字选择。例如，一张图片的主类别若必须从猫、狗、鸟中选一个，是互斥多分类；若同时判断“有动物”“在室外”“有车辆”，则是多标签分类（Multilabel Classification）。

任务	输出维度	预测时常见变换	常见损失
无约束实值回归	目标数	恒等映射（线性输出）	均方误差
二分类	1	Sigmoid	二元交叉熵
互斥多分类	K	Softmax	类别交叉熵
多标签分类	标签数 K	每个分量分别用 Sigmoid	逐标签二元交叉熵

读表：维度是每个样本输出的数值个数。多标签任务的概率不必加起来等于 1；无约束实值回归才通常采用线性输出。正值目标、计数或其他带约束的目标，需要结合其统计模型选择输出和损失。二分类也能采用两个 logits 的 Softmax，这里列出的是更紧凑的一输出形式。

11.7.1 二元交叉熵（Binary Cross-Entropy, BCE）

对于 $y \in \{0, 1\}$，$p = \sigma(s)$ 是正类概率估计：

$$\ell_{\mathrm{BCE}}(s, y) = -y \log p - (1 - y) \log(1 - p). \tag{11.7}$$

这是**一个样本**的损失；数据集平均需另除以样本数 n，不会因为有两个类别而除以 2。本章的 log 均指自然对数。例如真实标签 $y = 1$ 时，$p = 0.9$ 的损失约为 0.105，$p = 0.1$ 的损失约为 2.303。

11.7.2 类别交叉熵（Categorical Cross-Entropy）

若真实类别索引为 y，则

$$\ell_{\mathrm{CE}}(\boldsymbol{z}, y) = -\log p_y = -\sum_{k=1}^{K} t_k \log p_k, \tag{11.8}$$

其中 $\boldsymbol{t}$ 是真实标签的独热向量。k 遍历类别，i 才用来遍历样本。例如图 11.6 若真实类别为第一类，损失约为 $-\log 0.665 = 0.408$。

> **公式里的概率与程序接口里的输入**
>
> 写概率形式便于理解；实际训练常把原始 logits 直接交给合并激活与交叉熵的稳定实现。例如 `BCEWithLogitsLoss` 接收 Sigmoid 前的得分，`CrossEntropyLoss` 接收 Softmax 前的得分。使用这类接口时，再手动做一次激活会改变计算。不同接口要求不同，应检查文档。

11.8 反向传播：把链式法则组织起来

反向传播（Backpropagation）高效地计算损失对参数的梯度。它沿前向计算的依赖关系反向工作，把已经算出的上游梯度与当前运算的局部导数组合，避免对共享的中间计算反复求导。

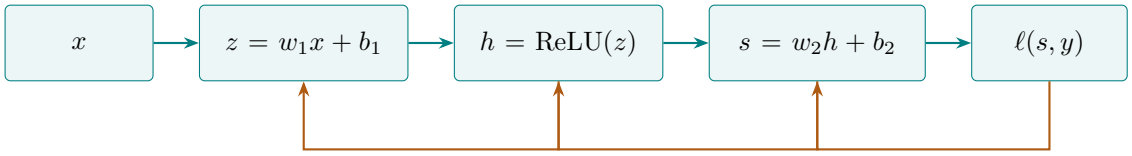


图 11.7：一个标量小网络的计算图。青色向前计算数值，橙色反向传递导数。

读图：输入 x 先经过第一层和 ReLU 得到 h，再经过第二层得到得分 s，最后计算损失。反向时从 $\partial \ell/\partial s$ 开始，经第二层传到 h，再经 ReLU 传到 z。参数梯度从对应运算处分支得到。

对这一标量例子，链式法则给出

$$\frac{\partial \ell}{\partial w_1} = \frac{\partial \ell}{\partial s}\frac{\partial s}{\partial h}\frac{\partial h}{\partial z}\frac{\partial z}{\partial w_1}.$$

如果一个变量影响损失的路径不止一条，应将各路径的贡献相加。反向传播本身**不负责更新参数**；更新要由梯度下降、Adam 等优化器执行。

11.8.1 推广到全连接层

记 $\boldsymbol{\delta}^{(l)} = \partial \ell/\partial \boldsymbol{z}^{(l)}$，即损失对第 l 层激活前数值的梯度。对逐元素隐藏层激活，有

$$\boldsymbol{\delta}^{(l)} = \left((W^{(l+1)})^{\top}\boldsymbol{\delta}^{(l+1)}\right) \odot \phi'(\boldsymbol{z}^{(l)}), \tag{11.9}$$

$$\frac{\partial \ell}{\partial W^{(l)}} = \boldsymbol{\delta}^{(l)}(\boldsymbol{a}^{(l-1)})^{\top}, \qquad \frac{\partial \ell}{\partial \boldsymbol{b}^{(l)}} = \boldsymbol{\delta}^{(l)}. \tag{11.10}$$

其中 $\odot$ 表示逐元素乘法。外积得到的权重梯度形状为 $d_l \times d_{l-1}$，与 $W^{(l)}$ 相同。这些式子针对单个样本、未加正则化的损失；小批量平均损失的梯度也需取平均。

> **两个常见输出梯度**
>
> Sigmoid 配二元交叉熵时，$\partial \ell/\partial s = p - y$。Softmax 配类别交叉熵时，$\partial \ell/\partial \boldsymbol{z} = \boldsymbol{p} - \boldsymbol{t}$。这是“激活与相应损失组合”的结果，不能换一个损失后仍照抄。

11.9 手算一次完整的训练更新

现在用图 11.7 的网络做一次二分类训练。只用一个样本 $x = 2, y = 1$，初始参数为

$$w_1 = 0.5, \quad b_1 = 0, \quad w_2 = 1, \quad b_2 = 0.$$

隐藏层用 ReLU，输出得分经 Sigmoid 得到概率，损失为二元交叉熵。

11.9.1 第一步：前向计算

$$z = w_1 x + b_1 = 1, \qquad h = \mathrm{ReLU}(1) = 1,$$
$$s = w_2 h + b_2 = 1, \qquad p = \sigma(1) \approx 0.731059,$$
$$\ell = -\log p \approx 0.313262.$$

真实标签为 1，预测的正类概率还不够高，因此损失大于 0。

11.9.2 第二步：反向计算梯度

因为 $\partial \ell / \partial s = p - y \approx -0.268941$ 且 $z > 0$，所以 ReLU 的局部导数为 1：

$$\frac{\partial \ell}{\partial w_2} = (p - y)h \approx -0.268941, \qquad \frac{\partial \ell}{\partial b_2} = p - y \approx -0.268941,$$
$$\frac{\partial \ell}{\partial w_1} = (p - y)w_2 \times 1 \times x \approx -0.537883, \qquad \frac{\partial \ell}{\partial b_1} = (p - y)w_2 \times 1 \approx -0.268941.$$

这四个梯度全部用**更新前的同一组参数**计算。例如计算第一层梯度时，使用的是旧的 $w_2 = 1$。

11.9.3 第三步：统一更新，再重新计算

取学习率 $\eta = 0.1$，每个参数减去学习率乘对应梯度：

$$(w_1', b_1', w_2', b_2') \approx (0.553788, 0.026894, 1.026894, 0.026894).$$

更新后重新前向计算，得到 $p' \approx 0.767$、$\ell' \approx 0.265$。这一步提高了正类概率，也降低了该训练样本的损失。这是本例的数值结果，并不是所有网络、所有学习率下每步都会下降的保证。

> **不要把反向传播拆成“边求梯度边更新”**
> 若先更新 w_2，再用新 w_2 求 w_1 的梯度，就不再是对同一个参数点计算整个梯度。通常应完成当前损失的反向计算，再让优化器统一更新。

11.10 梯度下降与学习率

梯度 $\nabla J(\theta)$ 指向目标函数局部增长最快的方向（采用欧氏距离衡量单位步长）。梯度下降（Gradient Descent）沿负梯度方向尝试降低目标：

$$\boxed{\theta_{t+1} = \theta_t - \eta_t \nabla J(\theta_t)}, \qquad \eta_t > 0. \tag{11.11}$$

t 为更新次数，η_t 为学习率（Learning Rate），控制梯度对参数更新的影响。实际步长为 $\eta_t \|\nabla J(\theta_t)\|$，不只由学习率决定。反向传播计算右侧的梯度，优化器执行这条或其他更新规则。

11.10.1 用一个二次函数看清学习率

令 $J(\theta) = \theta^2/2$，则 $J'(\theta) = \theta$，固定学习率下有 $\theta_{t+1} = (1-\eta)\theta_t$。取 $\theta_0 = 2$，得到下面三组**实际递推数值**。

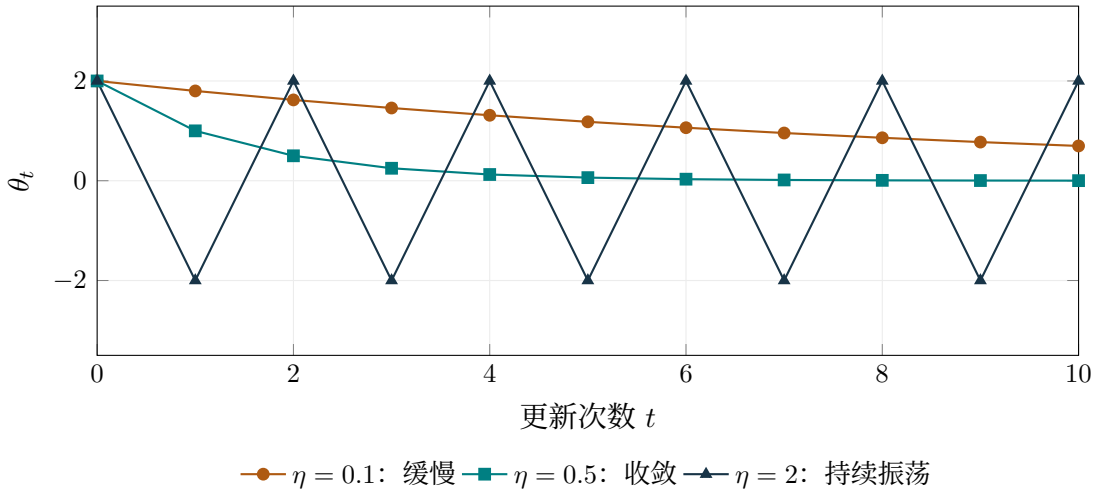


图 11.8: 纵轴是参数值，横轴是更新次数；最优参数为 $\theta = 0$。

读图：橙线每次只缩小一点；青线较快接近 0；深色线不断在 2 与 -2 之间跳动，损失并未减小。这个例子中 $0 < \eta < 2$ 才收敛，$\eta > 2$ 则参数绝对值不断增大。

一般可微目标在足够小的步长下，负梯度方向具有局部下降意义。但神经网络目标通常非凸；不能据此保证到达全局最优。即使目标凸，也需要最小值存在、步长等条件，才能讨论具体算法的收敛。梯度为 0 只说明处于驻点，可能对应极小值、极大值或鞍点，损失也不必为 0。

> **从全批量到小批量**
>
> 全批量梯度下降每步使用全部训练样本。小批量随机梯度下降（Minibatch SGD）用一小批样本平均梯度近似整体梯度，计算更便宜，但训练损失可能上下波动。调学习率和停止时刻应参考训练与验证表现，不用测试集反复试验。

11.11 一页速查与自测

问题	快速定位
网络怎样计算?	仿射变换与激活逐层组合；见11.3节。
为什么需要激活?	仿射变换堆叠仍是仿射变换；见11.4节。
Sigmoid 输出什么?	单个二元事件的概率估计，$\sigma(z) = 1/(1 + e^{-z})$。
Softmax 输出什么?	互斥类别的一组概率，分母遍历该样本的全部类别。
多标签怎么做?	常见起点是每个标签一个 Sigmoid，配逐标签 BCE。
反向传播做什么?	由损失计算梯度；每个梯度形状与对应参数一致。
优化器做什么?	按更新规则调整参数；普通梯度下降减去 $\eta\nabla J$。
训练损失越低越好?	还要检查验证表现；测试集用于最终评估。

11.11.1 三个自测问题

1. 一个 $5 \to 4 \to 2$ 的全连接网络，每个参数层都有偏置，共有多少参数?
2. 三个类别的 logits 都是 0，Softmax 输出是什么?
3. 若 $J(\theta) = \theta^2/2$，$\theta = 2$，$\eta = 0.1$，下一步参数是多少?

参考答案：（1）$(5 \times 4 + 4) + (4 \times 2 + 2) = 34$。（2）$(1/3, 1/3, 1/3)$。（3）$2 - 0.1 \times 2 = 1.8$。

11.11.2 进一步查阅

以下资料用于核对本章的计算机制与接口约定；本章图表和数值例子独立编写。

- 《动手学深度学习》：前向传播、反向传播与计算图。
- PyTorch 文档：BCEWithLogitsLoss 与 CrossEntropyLoss，核对 logits 输入及损失定义。

第十二章　让训练稳定下来：批量、优化与正则化

知道怎样计算一次梯度，还不足以完成可靠训练。训练时要决定每步使用多少数据、怎样利用梯度、参数从哪里开始，以及何时停止。本章接着前向与反向传播的基础，把这些选择放回同一条训练流程。

先分清三类问题

训练算不动：检查数据、梯度、初始化和学习率。**训练算得慢**：检查批量与优化器。**训练很好，验证不好**：检查数据划分与泄漏，再考虑正则化和停止时刻。不同问题可以同时出现，一个技巧不能替代整套诊断。

12.1　样本、批量、更新次数与轮次

批量大小（Batch Size）是一次计算所用的样本数；一次优化器更新称为一步（Step）。训练轮次（Epoch）通常表示将整个训练集遍历一次。**一个 epoch 通常包含很多步，不能把两者混为同一个计数。**

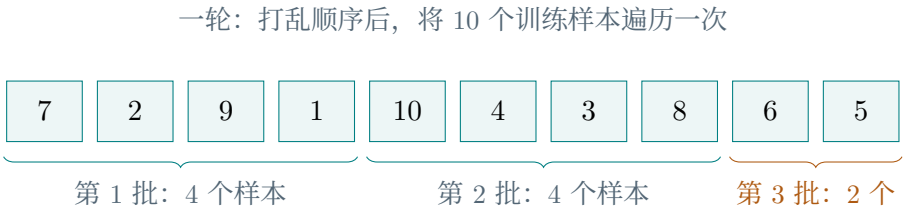


图 12.1：训练集有 10 个样本，批量大小为 4，不丢弃最后一批时，一轮包含 3 个批量。数字是样本编号。

读图：本轮先打乱样本顺序，再依次取出 4、4、2 个样本。若每个批量更新一次参数，完整一轮就更新 3 次。下一轮可重新打乱顺序，避免固定顺序持续影响更新。

设训练样本数为 n，批量大小为 B，在**单份数据遍历、每批更新一次、保留末批**的设置下，每轮更新次数为

$$S = \left\lceil \frac{n}{B} \right\rceil .$$

本例训练 5 轮共更新 $5 \times 3 = 15$ 次，而不是 5 次。若丢弃最后不足一批的数据，则每轮批数变成 $\lfloor n/B \rfloor$，也不再保证每个样本都被遍历。

这条计数公式有适用范围

梯度累积、分布式采样、重复抽样和无限数据流会改变“批量—更新—轮次”的关系。例如先累积两个批量的梯度再更新一次，就不能再把批数直接当作更新次数。批量大小也没有通用的最佳值，应结合显存、吞吐量和验证效果选择。

12.2 小批量 SGD：用部分数据估计梯度

记单样本损失为 $\ell_i(\theta)$，未加正则化的训练目标为 $J(\theta)=n^{-1}\sum_i \ell_i(\theta)$。全批量梯度下降每步使用所有样本；小批量随机梯度下降（Minibatch Stochastic Gradient Descent, Minibatch SGD）改用一小批样本：

$$\boldsymbol{g}_t=\frac{1}{|\mathcal{B}_t|}\sum_{i\in\mathcal{B}_t}\nabla\ell_i(\theta_t),\qquad \theta_{t+1}=\theta_t-\eta_t\boldsymbol{g}_t. \tag{12.1}$$

$\mathcal{B}_t$ 是当前批次的样本索引集合，$|\mathcal{B}_t|$ 是本批实际大小，$\eta_t>0$ 为学习率。最后不足一批时，也应按其实际大小求平均。严格说，单样本 SGD 取 $B=1$；实践中“SGD”也常泛指小批量版本。

12.2.1 一个能手算的梯度估计

设只有一个参数 θ，三个目标值为 $y_1=0,y_2=2,y_3=4$，单样本损失 $\ell_i(\theta)=\frac{1}{2}(\theta-y_i)^2$。固定 $\theta=0$，可得：

样本目标	单样本梯度 $\theta-y_i$	学习率 0.1 时的下一步参数
0	0	0
2	-2	0.2
4	-4	0.4

全体平均梯度为 -2，全批量一步会得到 $\theta'=0.2$。若均匀选取一个样本，三个候选梯度的平均同样是 -2；若均匀选两个不同样本，三种候选批量的平均梯度分别是 $-1,-2,-3$，其平均仍是 -2。本例后者的梯度估计方差更小，但一次计算也更贵。

> **平均方向有用，不代表每一步都下降**
>
> 对固定参数均匀抽样，批量平均梯度的期望等于整体梯度。具体一次抽到的梯度可能偏离整体方向，因此小批量损失或整体训练损失都可能短暂上升。每轮不放回随机重排与每步独立抽样的随机过程不同，不能不加条件地套用相同的独立性假设。

记住：比较批量大小时，要同时关注更新次数、处理的样本数与实际耗时，不能只比较 epoch 数。

12.3 动量：给更新方向加上记忆

普通 SGD 只看当前梯度；动量法（Momentum）还保留过去的方向。本书采用以下一种常见约定，初始 $\boldsymbol{v}_0 = 0$：

$$\boldsymbol{v}_t = \beta \boldsymbol{v}_{t-1} + \boldsymbol{g}_t, \qquad \theta_t = \theta_{t-1} - \eta \boldsymbol{v}_t, \quad 0 \le \beta < 1. \tag{12.2}$$

这里 $\boldsymbol{g}_t$ 在更新前的 θ_{t-1} 计算。持续同向的梯度会累积；相互抵消的梯度对历史方向的贡献较弱。另一些资料把当前梯度乘上 $1-\beta$，对应的学习率解释也会变化，比较公式时须先核对约定。

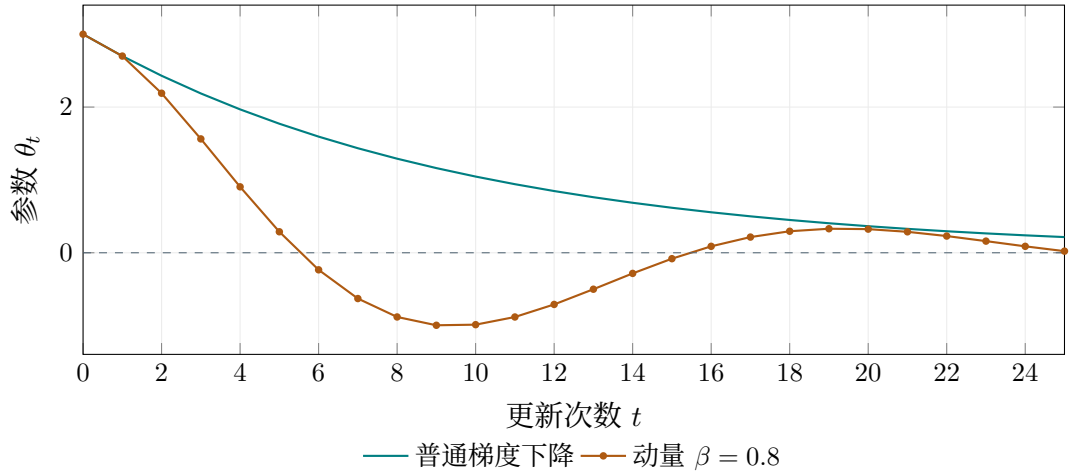


图 12.2： 对 $J(\theta) = \theta^2/2$ 的真实递推轨迹：$\theta_0 = 3$、学习率 0.1、动量初值 0。

读图： 两种方法第一步都到 2.7。第二步，普通梯度下降到 2.43；动量累积值为 $0.8 \times 3 + 2.7 = 5.1$，参数到 2.19。橙线更早接近 0，也越过 0 并振荡；动量可以加快某些方向上的移动，但也可能造成过冲。

> **容易混淆**
>
> 不能把“带动量”理解为一定跳出局部极小值，或一定比普通 SGD 更快。效果取决于目标形状、学习率和动量系数。学习率过大时，带动量的更新仍可能不稳定。图中的比较仅针对给定二次函数与参数设置。

记住： 先明确动量的定义，再调整学习率与 β。梯度历史本身也是优化器状态，不属于网络权重。

12.4 RMSprop 与 Adam：按坐标调整更新

不同参数坐标的梯度量级可能差别很大。RMSprop 用梯度平方的指数滑动平均估计近期量级，再按坐标缩放更新。Adam（Adaptive Moment Estimation，自适应矩估计）同时平滑有符号梯度和梯度平方。

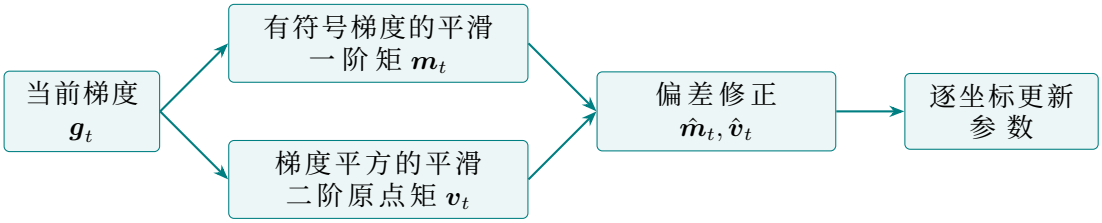


图 12.3： Adam 的两条统计分支。平方和开方均为逐元素运算，二阶原点矩不是中心方差。

读图： 上方分支保留方向信息，下方分支反映梯度的平方量级。两者先修正零初始化带来的早期缩小效应，再组合成参数更新。分母通常使近期梯度平方较大的坐标相对少走一些。

对无权重衰减的基本 Adam，令 $\boldsymbol{m}_0 = \boldsymbol{v}_0 = 0$，$t = 1, 2, \ldots$：

$$\boldsymbol{m}_t = \beta_1 \boldsymbol{m}_{t-1} + (1-\beta_1)\boldsymbol{g}_t, \tag{12.3}$$

$$\boldsymbol{v}_t = \beta_2 \boldsymbol{v}_{t-1} + (1-\beta_2)(\boldsymbol{g}_t \odot \boldsymbol{g}_t), \tag{12.4}$$

$$\hat{\boldsymbol{m}}_t = \frac{\boldsymbol{m}_t}{1-\beta_1^t}, \qquad \hat{\boldsymbol{v}}_t = \frac{\boldsymbol{v}_t}{1-\beta_2^t}, \tag{12.5}$$

$$\theta_t = \theta_{t-1} - \eta \, \frac{\hat{\boldsymbol{m}}_t}{\sqrt{\hat{\boldsymbol{v}}_t} + \epsilon}. \tag{12.6}$$

其中 $\beta_1, \beta_2 \in [0, 1)$ 是平滑系数，$\epsilon > 0$ 用于数值稳定；最后一式的除法也逐元素进行。偏差修正补偿指数平均的初始权重和，不表示对任意非平稳梯度过程都获得无偏估计。

> **优化器选择的边界**
>
> SGD、带动量 SGD、RMSprop 与 Adam 都需要选择学习率。Adam 的“自适应”不代表不需要调参，也不保证泛化优于 SGD。AdamW 还改变了权重衰减的处理方式，不能只凭名字把它与基本 Adam 完全等同。

12.5 手算 Adam 的两步更新

用一个参数看清偏差修正与历史记忆。设 $\theta_0 = 1, m_0 = v_0 = 0, \eta = 0.1, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$。为单独检验更新规则，**人为给定**两次输入梯度为 $g_1 = 2$、$g_2 = -1$；不把这组输入当作某项真实实验的测量结果。

12.5.1 第一步：先平均，再修正

$$
\begin{aligned}
m_1 &= 0.1 \times 2 = 0.2, & v_1 &= 0.001 \times 2^2 = 0.004,\\
\hat{m}_1 &= 0.2/(1-0.9) = 2, & \hat{v}_1 &= 0.004/(1-0.999) = 4,\\
\theta_1 &= 1 - 0.1\frac{2}{\sqrt{4}+10^{-8}} \approx 0.900000.
\end{aligned}
$$

若只看未修正的 m_1 和 v_1，数值大小受到零初始化的明显影响。修正后的第一步基本相当于按梯度符号走一个学习率长度，前提是梯度非零且 ϵ 可忽略。

12.5.2 第二步：新梯度已经反向，历史仍然存在

$$
\begin{aligned}
m_2 &= 0.9 \times 0.2 + 0.1 \times (-1) = 0.08,\\
v_2 &= 0.999 \times 0.004 + 0.001 \times (-1)^2 = 0.004996,\\
\hat{m}_2 &= 0.08/(1-0.9^2) \approx 0.421053,\\
\hat{v}_2 &= 0.004996/(1-0.999^2) \approx 2.499250,\\
\theta_2 &= \theta_1 - 0.1\frac{\hat{m}_2}{\sqrt{\hat{v}_2}+10^{-8}} \approx 0.873366.
\end{aligned}
$$

当前梯度 g_2 虽为负，历史平均 m_2 仍为正，因此参数这一步继续减小。Adam 不是每一步都沿当前负梯度方向更新，这也解释了为什么不能仅由当前梯度符号判断实际移动方向。

> **续训时只恢复权重够不够?**
>
> 若要接着同一次优化过程继续训练，通常还需恢复优化器的一阶矩、二阶矩、步数，以及学习率调度等相关状态。只恢复网络权重后重新创建 Adam，会改变后续更新轨迹。若只是做最终预测，则不需要这些优化器状态。

12.6 梯度消失：链条越长，乘积可能越小

反向传播连续应用链式法则。若一条标量计算链上每个局部导数都是 q，长度为 L 时，总导数是 q^L。这给出了梯度消失（Vanishing Gradient）的一个最简单例子。

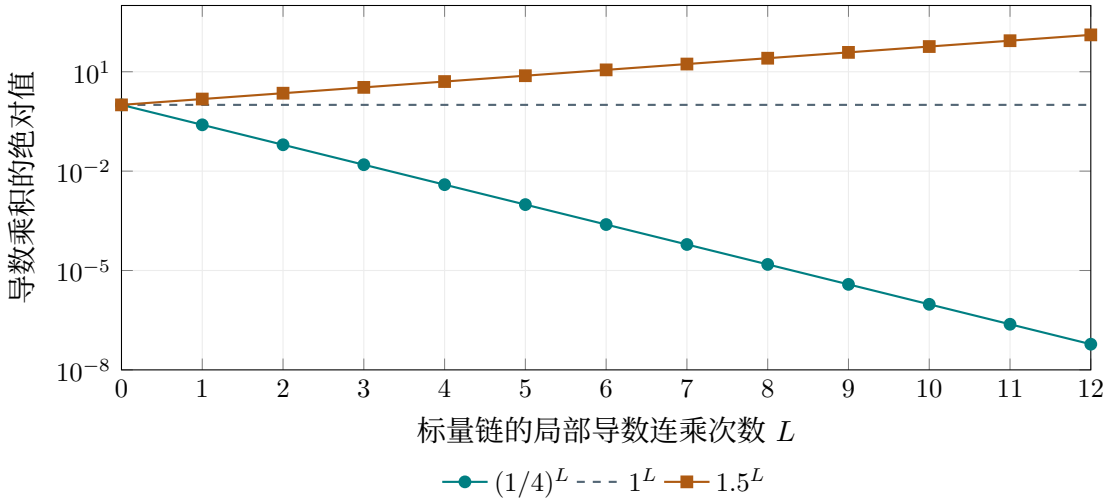


图 12.4: 标量链的导数连乘示例。纵轴为对数刻度；该图不代表任意实际网络的梯度曲线。

读图：当每一项只有 1/4 时，乘 10 次约为 9.54×10^{-7}；乘积很快变小。每项为 1 时量级不变；每项为 1.5 时则越来越大，提示梯度爆炸的另一种可能。纵轴每下降一个十进数量级，数值就缩小 10 倍。

真实网络的反传还包含**权重矩阵、激活导数、不同路径的求和**，不是只把激活导数相乘。图中保留的是链式法则的直觉，不能从 Sigmoid 导数不超过 1/4 直接推出所有深层网络的参数梯度都按 $(1/4)^L$ 衰减。

12.6.1 怎样判断与缓解

早期层的梯度长期极小、参数几乎不变，可能提示梯度消失；但学习率过小、错误的梯度连接或数据问题也会造成训练停滞。应先核对计算与数据，再观察各层梯度量级。合适的激活、初始化和网络连接设计有助于稳定传播；后续架构中的残差连接也与此有关。

> **两个常见误解**
>
> ReLU 正半轴的局部导数为 1，并不保证整个网络梯度稳定；权重连乘仍会影响量级。梯度裁剪通常用来限制过大的梯度，不能把已经消失的梯度恢复出来。

记住：训练不动时，同时检查梯度是否存在、数值是否有限、量级是否合理，以及优化器是否实际执行更新。

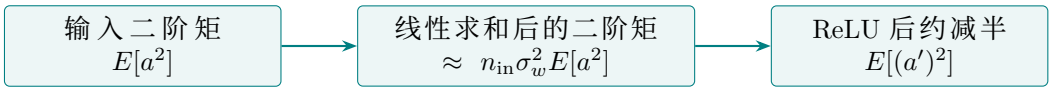
12.7 初始化：打破对称，并控制传播量级

初始化（Initialization）是选择训练的起点，不是预先找到损失的最小值。若一个隐藏层中对称位置的单元采用完全相同的权重，且其它条件保持对称，它们可能得到相同输出和梯度，一直学习重复的特征。因此权重通常随机初始化；偏置常可从 0 开始。

12.7.1 先分清输入数、输出数与分布参数

对 $W \in \mathbb{R}^{n_{\text{out}} \times n_{\text{in}}}$，$n_{\text{in}}$ 是每个单元接收的输入数（fan-in），n_{out} 是本层输出单元数（fan-out），两者都不是网络的层数。下面列出两种常见设置：

方法	单个权重的分布	主要考虑
Xavier 均匀	$U(-a, a),\ a = \sqrt{6/(n_{\text{in}} + n_{\text{out}})}$	增益为 1 时，折中前向与反向量级
He 正态	$N(0, \sigma_w^2),\ \sigma_w^2 = 2/n_{\text{in}}$	用于 ReLU 的常见 fan-in 设置



He 初始化：令 $n_{\text{in}}\sigma_w^2/2 \approx 1$，保持二阶矩的量级

图 12.5: He 初始化的量级直觉：在独立、零均值权重等近似条件下，补偿 ReLU 对二阶矩的缩减。

读图： 若 $z = \sum_j w_j a_j$，在相应独立性和均值假设下，$E[z^2] \approx n_{\text{in}}\sigma_w^2 E[a^2]$。若 z 的分布关于 0 对称，ReLU 把二阶矩约减半，于是令 $\sigma_w^2 = 2/n_{\text{in}}$ 可使经过一层后的二阶矩大致保持量级。ReLU 输出均值一般不为 0，所以这里使用二阶矩，而不把它无条件称作中心方差。

例如 $n_{\text{in}} = 100$、$n_{\text{out}} = 50$ 时，Xavier 均匀的界限为 $a = 0.2$；He 正态的**方差**为 0.02，**标准差**约为 0.141421。不能把方差直接当作正态采样接口要求的标准差。

> **容易混淆**
>
> Xavier 可与不同激活的增益配合；He 也有 fan-out 等变体。表中仅列明示条件下的常见形式，不是所有结构的唯一规则。初始化控制起始量级，不能保证整段训练始终稳定。

12.8 Dropout：训练时加噪声，评估时关掉

随机失活（Dropout）是一种正则化方法：训练时随机屏蔽一部分激活，减少网络对特定单元组合的依赖。本节采用常见的反向缩放 Dropout（Inverted Dropout）。记丢弃概率为 $p \in [0,1)$、保留概率为 $q = 1 - p$，则

$$\tilde{\boldsymbol{a}} = \frac{\boldsymbol{m} \odot \boldsymbol{a}}{q}, \qquad m_j \sim \text{Bernoulli}(q). \tag{12.7}$$

普通逐元素 Dropout 对各位置独立采样掩码。屏蔽改变当前计算，不会永久删除参数或改变层的宽度。

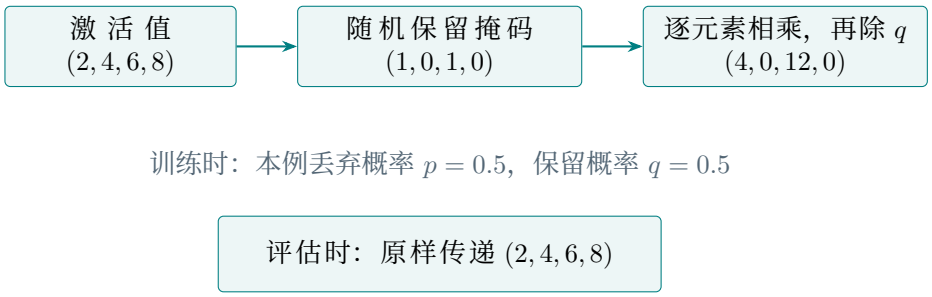


图 12.6: 一个具体掩码的效果。训练时保留值放大 $1/q$ 倍；标准评估时使用恒等映射。

读图：本例保留第 1、3 个激活，屏蔽第 2、4 个，保留值乘 2。这是一次随机采样，不表示每次一定恰好保留一半。评估时不再随机屏蔽，也不再重复做训练时的 $1/q$ 缩放。

对固定输入激活，$E[m_j] = q$，因此

$$E[\tilde{a}_j \mid a_j] = a_j, \qquad \text{Var}(\tilde{a}_j \mid a_j) = \frac{p}{q} a_j^2.$$

缩放保持的是**该激活的条件期望**，不是保证整个非线性网络的输出等于所有随机子网络输出的精确平均。“训练许多共享参数的子网络”是一种理解方式，并非逐个独立训练或枚举所有子网络。

> **容易混淆**
>
> 丢弃概率过高可能导致欠拟合或优化困难；Dropout 也不保证验证效果改善。训练和验证时必须使用正确模式。若验证仍在随机丢弃，指标会额外波动；若在训练时提前关闭，则没有执行预期的正则化。

12.9 提前停止：保存最优记录，再耐心等待

提前停止（Early Stopping）根据验证表现选择训练时长。验证指标可能波动，所以通常不会仅因某一轮上升就立刻停止。应事先规定监控指标、改进阈值、耐心轮数和最大轮数，并保存最佳检查点。

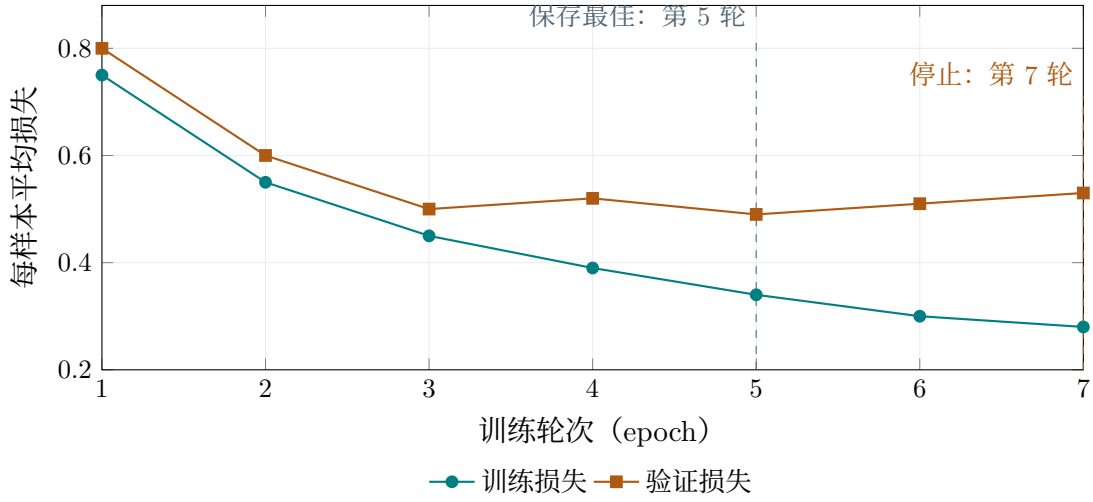


图 12.7: 人为设定的损失序列，用于说明规则：监控验证损失，阈值为 0，patience 为 2。不是实验测量结果。

读图：第 4 轮验证损失从 0.50 升到 0.52，暂记一次未改进；第 5 轮降到 0.49，刷新最佳记录并把等待计数归零。第 6、7 轮连续未改进，到第 7 轮停止，最后恢复第 5 轮的权重。

本例明确采用：验证损失 $V_t < V_{\text{best}} - \delta$ 才算改进；否则计数加 1。连续未改进次数达到 P 就停止。δ 是最小改进量（min-delta），P 是耐心轮数（patience），本例分别为 0 和 2。

轮次	验证损失	最佳轮次	连续未改进数
3	0.50	3	0
4	0.52	3	1
5	0.49	5	0
6	0.51	5	1
7	0.53	5	2：停止

提前停止本身也是模型选择

最佳轮次不是总体泛化风险的已知最优点，而是当前验证规则选出的检查点。patience、阈值和监控指标仍需选择，反复尝试也可能过拟合验证集。最终测试集留到方案确定后评估，不用它决定停止时刻。

12.10 把这些组件放回训练流程

训练和评估不是只差“是否计算梯度”。有些层在不同模式下具有不同计算行为，Dropout 就是本章的例子。因此，**切换评估模式**与**关闭梯度记录**应分开理解。

环节	训练阶段	标准验证/预测阶段
使用哪些数据	训练集各小批量	验证集或最终测试集
Dropout	随机掩码与 $1/q$ 缩放	恒等传递
梯度与更新	对训练目标反传，执行优化器更新	通常关闭梯度记录，不更新参数
记录什么	每样本平均训练损失等	固定评估口径下的损失和指标
影响哪些选择	拟合模型参数	验证选方案；测试做最终评估

12.10.1 一轮可执行的检查顺序

1. 开始训练前，只用训练数据拟合预处理，并初始化网络与优化器状态。
2. 每轮打乱训练样本；对每批先清理上一批梯度，再前向、求损失、反传、更新。
3. 一轮结束后，切到评估模式，关闭不需要的梯度记录，遍历验证集。
4. 按**样本数**汇总损失，应用提前停止规则，必要时保存最佳权重。
5. 继续下一轮前切回训练模式；结束后恢复所选检查点，再做最终测试。

若三批分别有 4、4、2 个样本，批内平均损失分别为 0.2、0.4、0.8，全体每样本平均损失应为

$$\frac{4\times 0.2+4\times 0.4+2\times 0.8}{10}=0.4,$$

不能直接把三个批平均再等权平均，得到约 0.467。

> **训练曲线与验证曲线要有可比口径**
>
> 启用 Dropout 等噪声或数据增强时，训练阶段的预测本来就更难；正则化项也可能只计入训练目标。因此“验证损失低于训练损失”不必然是错误，二者的差也不能直接全部归因于过拟合。诊断时可在统一评估模式、相同损失定义下额外比较。

12.11 一页速查与自测

遇到的问题	先检查什么
epoch 与 step 对不上	是否保留末批、累积梯度或重复采样。
小批量损失上下波动	抽样噪声、批量大小、学习率；单次上升不等于训练失败。
动量移动过头	学习率与动量系数，不把惯性当作收敛保证。
Adam 续训轨迹变了	是否同时恢复矩估计、步数和调度状态。
早期层几乎不更新	梯度连接、梯度量级、初始化、激活与学习率。
Dropout 评估不稳定	是否关掉标准评估时的随机丢弃。
停止后效果反而差	是否恢复最佳轮次，而不是保留最后一轮。
批量汇总指标不准确	是否按样本数加权，尤其是最后一个小批量。

12.11.1 三个自测问题

1. 有 103 个样本，批量 32，保留末批且每批更新一次。5 轮共更新多少次?
2. Inverted Dropout 的丢弃概率为 0.25。某个激活值 3 被保留时，输出是多少?
3. 验证损失依次为 0.8、0.6、0.61、0.59、0.60、0.62，按本章规则 $\delta = 0, P = 2$，何时停止并恢复哪一轮?

参考答案：（1）$5\lceil 103/32 \rceil = 20$ 次。（2）$3/(1 - 0.25) = 4$。（3）第 6 轮停止，恢复第 4 轮。

12.11.2 进一步查阅

- PyTorch 文档：Adam、初始化、Dropout，用于核对常见公式和模式约定。
- Keras 文档：EarlyStopping，用于核对监控、耐心轮数与恢复最佳权重的配置含义。

第十三章　训练细节：稳定计算与正则化

同一数学公式可以有稳定与不稳定的计算写法；同一个“正则化”名称也可能对应不同更新。本章补充常见激活、logits 损失、按坐标更新、权重衰减和梯度裁剪的边界。

13.1　激活变体：看函数，也看导数

除 Sigmoid 与 ReLU 外，常见激活各有形状和计算特点，不能仅凭“有负值”判断能否解决梯度问题。

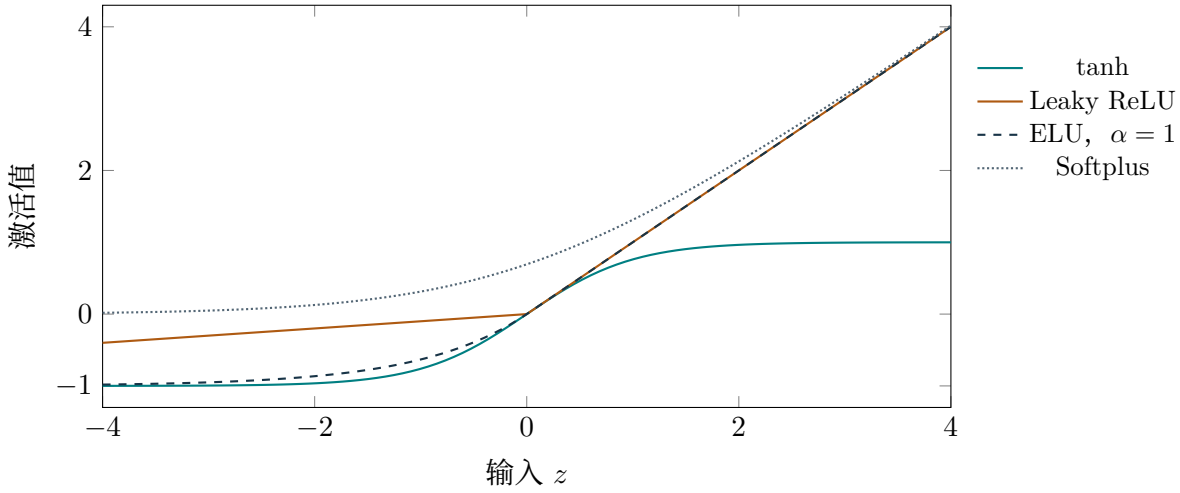


图 13.1：函数值的独立绘图。Leaky ReLU 示例斜率为 0.1；它不是所有实现的默认值。

读图：tanh 在两端趋于 ± 1；Leaky ReLU 保留负半轴斜率；ELU 负半轴趋于 $-\alpha$；Softplus 平滑接近 ReLU。图示比较函数，不直接代表模型效果排名。

激活	定义或性质	导数与边界
tanh	$\tanh z$，输出在 $(-1, 1)$。	$1 - \tanh^2 z$；两端仍饱和。
Leaky ReLU	$z \geq 0$ 取 z，否则 az，$0 < a < 1$。	两侧导数 1 与 a；原点输出 0 且通常不可微。
ELU	$z \geq 0$ 取 z，否则 $\alpha(e^z - 1)$。	负侧导数 αe^z 仍可很小；$\alpha = 1$ 时原点可微。
Softplus	$\log(1 + e^z)$。	导数为 Sigmoid；负端也会饱和。

ELU 或 tanh 不保证激活均值恰好为 0；Leaky ReLU 也不保证完整网络梯度永远非零。激活、初始化、归一化与优化需一起考虑。

13.2 从 logits 稳定计算交叉熵

对有限 logits $z_1, \dots, z_K$，令 $a = \max_k z_k$，则

$$\mathrm{LSE}(\boldsymbol{z}) = a + \log \sum_k e^{z_k - a}, \qquad \ell_{\mathrm{CE}} = \mathrm{LSE}(\boldsymbol{z}) - z_y.$$

交叉熵需要负号，y 是本例真实类别索引；更一般的目标分布 t_k 用 $-\sum_k t_k \log p_k$。交叉熵与只含预测分布的熵不是同一个概念。

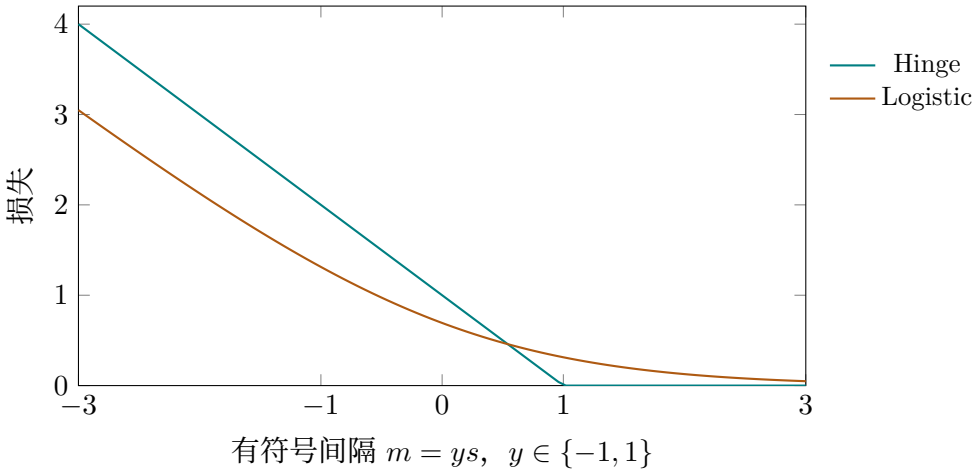


图 13.2: 二分类有符号间隔下的损失比较；Hinge 到达间隔 1 后为 0，Logistic 平滑下降。

读图： 对 $\boldsymbol{z} = (1000, 1001, 999)$，若目标为第 1 类，稳定损失为 $1 + \log(1 + e^{-1} + e^{-2}) \approx 1.408$。无需先计算会溢出的 e^{1001}，也无需先生成可能舍入为 0 的目标概率。

二分类用 $y \in \{0, 1\}$、logit s 时，稳定 BCE 可写为

$$\ell = \max(s, 0) - ys + \log(1 + e^{-|s|}).$$

例如 $s = 1000, y = 0$ 时损失约 1000，而不是对舍入到 1 的概率直接求 $\log 0$。合并 logits 损失接口与概率接口要区分，避免重复 Sigmoid/Softmax。

减最大值避免指数上溢，某些很小的指数项仍可能下溢为 0；不能声称完全消除所有浮点问题。Hinge 通常用 $y \in \{-1, 1\}$ 与得分 s，随 ys 增加而不增，不是随 s 增加对两类都下降。

13.3 RMSprop、L2 与解耦权重衰减

一种非中心化 RMSprop 约定为逐坐标计算

$$\boldsymbol{v}_t = \beta \boldsymbol{v}_{t-1} + (1-\beta)\boldsymbol{g}_t^2, \qquad \boldsymbol{w}_t = \boldsymbol{w}_{t-1} - \eta \frac{\boldsymbol{g}_t}{\sqrt{\boldsymbol{v}_t} + \epsilon}.$$

$\boldsymbol{g}_t$ 在 $\boldsymbol{w}_{t-1}$ 处计算。它累积梯度**平方**的指数滑动平均，仍需设置学习率与其他超参数。这里没有 Adam 式的一阶动量和偏差修正；实现可能另有中心化、动量等选项。

标量例子 $v_0 = 0, w_0 = 1, \beta = 0.9, \eta = 0.1$，仅为手算忽略 ϵ，梯度依次为 $2, -1$，得 $v_1 = 0.4, v_2 = 0.46$，$w_1 \approx 0.684, w_2 \approx 0.831$。

L2 惩罚 $\lambda\|\boldsymbol{w}\|_2^2/2$ 增加梯度 $\lambda\boldsymbol{w}$。在无动量的普通 SGD 下，更新可改写为

$$\boldsymbol{w}^+ = (1-\eta\lambda)\boldsymbol{w} - \eta\boldsymbol{g}.$$

但若逐坐标缩放梯度，则加入 L2 梯度与直接衰减参数一般不同。

更新约定	固定缩放矩阵 D 的示意与数值
把 L2 梯度一起缩放	$w^+ = w - \eta D(g + \lambda w) = (0.970, 1.996)$。
解耦衰减	$w^+ = (1-\eta\lambda)w - \eta D g = (0.970, 1.978)$。

本例 $w = (1, 2), g = (0.2, 0.2), D = \mathrm{diag}(1, 0.1), \eta = \lambda = 0.1$。Adam 中加入 L2 梯度还会影响矩估计历史，差异不只这一步；AdamW 采用解耦衰减思想。偏置、归一化参数等是否衰减需明确参数组，不能不看实现就断言全部相同。

13.4 裁剪梯度：限制范数，不修复全部不稳定

给定阈值 $c > 0$，全局 L2 范数裁剪把选定参数的梯度连接成一个向量，当 $\|g\|_2 > c$ 时令 $g' = cg/\|g\|_2$，否则保持不变。

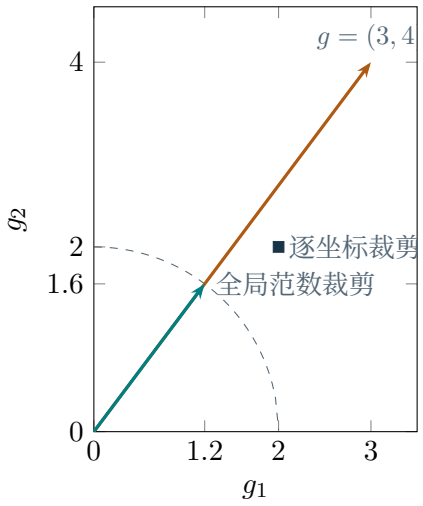


图 13.3: 阈值 2。圆弧表示 L2 范数为 2 的边界；逐坐标裁剪不保持相同方向。

读图： $g = (3, 4)$ 的范数为 5，全局裁剪后为 $(1.2, 1.6)$，范数为 2 且方向不变。逐坐标限制在 $[-2, 2]$ 则得到 $(2, 2)$，范数为 $2\sqrt{2}$，含义不同。

裁剪发生在反向传播之后、优化器更新之前。如果使用梯度累积，应明确对哪一次有效梯度裁剪；使用缩放梯度的混合精度流程时，通常先取消损失缩放，再按真实梯度量级裁剪。

> **梯度有界不等于参数更新一定有界为 ηc**
>
> 对普通 SGD 可直接联系梯度与更新；动量、自适应缩放、权重衰减都会改变最终更新。裁剪不能恢复消失梯度，不能把 NaN 变成有效信息，也不保证损失每步下降。突然出现大梯度时，还应检查数据、损失尺度与实现。

13.5 把不同正则化方式放回训练流程

正则化通过约束、惩罚、随机化或停止规则影响学习，不是给模型增加同一种“防过拟合按钮”。

方法	影响什么	使用时注意
L2/权重衰减	目标梯度或参数更新。	归一化与优化器约定。
Dropout	训练中的随机激活掩码。	推理模式及缩放方式。
数据增强	训练输入与有效样本变化。	标签语义与同源划分。
提前停止	选择保存的训练时刻。	验证规则与恢复状态。
Bagging	重采样后训练多个基模型。	多模型开销与相关性。

Dropout 的不同掩码复用同一组参数；通常不会像 Bagging 那样，为每个子网络单独存一套独立拟合的权重。每步只采样某些掩码，不表示永久只有固定一部分子网络参与训练。

Bagging 的重采样可在给定训练集时独立抽取，但基模型都依赖同一数据来源，它们面对新样本的预测误差通常相关。参数分开存储不等于总体预测统计独立。普通 Dropout 的确定性推理也通常不等于对全部非线性子网络预测的精确平均。

记住： 明确方法改变的是数据、目标、梯度、参数还是选择规则，再设计验证比较；不要把几个方法机械叠加就当作质量保证。

参考： Goodfellow 等《Deep Learning》第 6–8 章; Loshchilov 与 Hutter, *Decoupled Weight Decay Regularization*（2019）；PyTorch 损失、RMSprop、AdamW 与梯度裁剪文档。所有图表与算例独立构造。

第十四章　卷积网络：共享局部计算

卷积神经网络（Convolutional Neural Network, CNN）把局部连接与参数共享结合起来，适合处理具有网格结构的输入。理解 CNN 时，先跟踪形状、一次局部计算和参数数量，再理解多层组合怎样形成表示。

> **同一个核，在多个位置重复使用**
> 一个卷积核在不同空间位置使用同一组权重。这能减少参数，并表达对局部模式重复出现的偏好；它不保证对所有位置变化完全不敏感。

14.1　张量形状：批量、通道与空间

深度学习程序中的张量（Tensor）通常指多维数组。图像批量常用 NCHW 或 NHWC 布局；字母顺序决定轴的含义，不能只看数组有几维。本章统一用 B, C, H, W 表示批量、通道、高、宽。



NCHW 布局示例：$X \in \mathbb{R}^{8\times3\times32\times32}$

图 14.1: 8 张 32×32 的 RGB 图像，按通道在前布局存储。每个通道不是一条独立样本。

读图：共有 $8 \times 3 \times 32 \times 32 = 24576$ 个数值。卷积通常在每张图像上独立进行，跨输入通道加权求和，不把批量轴当空间轴滑动。

标量、向量、矩阵分别可以作为 0 阶、1 阶、2 阶数组；这里的“阶/轴数”不要与矩阵秩或特征数混用。改变轴顺序需要相应置换，单纯 reshape 通常不能代替布局转换。

记住：每层都记录输入、输出的轴顺序与形状，比仅画一个三维方块更容易检查实现。

14.2 一次卷积怎样得到一个数?

常见深度学习库称为“卷积”的操作实际按不翻转核的互相关（Cross-correlation）实现。单通道、步幅 1、无填充时，$Y_{ij} = b + \sum_{u,v} K_{uv} X_{i+u,j+v}$。数学上的离散卷积常还包含核翻转，读公式时需声明约定。

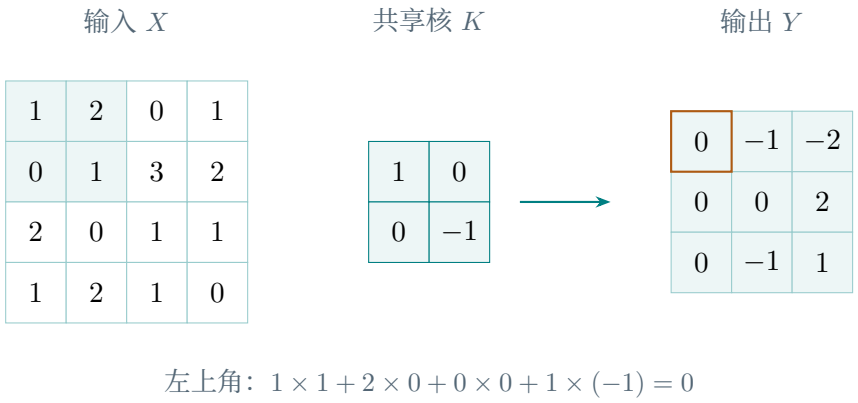


图 14.2: 4×4 输入、2×2 核，偏置 0；每次移动一格，得到 3×3 输出。

读图：核左上位置乘 1、右下位置乘 −1，其余乘 0。在输入左上 2×2 块计算得 0；向右一格得到 $2 - 3 = -1$。输出每个位置都复用同一组四个权重。

核权重通常由损失与反向传播学习，不能一概说每个核固定是边缘检测器。叠加非线性使多层网络能表达更复杂关系；若只叠加线性或仿射层而没有非线性，整体仍是线性或仿射映射。

> **特征图不是原图的复制**
> 输出位置表示某个局部加权计算的结果。空间大小、通道数与原输入可能不同，数值也不必在原像素范围内。

14.3 通道与参数共享：参数数怎样算?

普通非分组二维卷积中，每个输出通道都有覆盖所有输入通道的核:

$$Y_{o,i,j} = b_o + \sum_{c=1}^{C_{\text{in}}} \sum_{u,v} K_{o,c,u,v} X_{c,i+u,j+v}.$$

$k_h \times k_w$ 核、每输出通道一个偏置时，参数数为

$$C_{\text{out}}(C_{\text{in}} k_h k_w + 1).$$

若不使用偏置，去掉最后的 C_{out}；分组卷积要按分组方式另算。

相同 3×3 输出的教学比较	参数数	连接方式
4×4 单通道输入，2×2 卷积	$4 + 1 = 5$	9 个位置共享一个核与偏置。
同样局部窗口，但各位置不共享	$9(4 + 1) = 45$	每位置单独学习。
完全连接到 9 个输出单元	$9(16 + 1) = 153$	每单元连接全部 16 输入。

较大的例子：3 输入通道、16 输出通道、3×3 核，共 $16(27 + 1) = 448$ 个参数。同一层参数数不随批量或图像宽高增加而增加，但计算量和激活内存会增加。

记住：通道汇总、空间滑动和批量独立，是三种不同的轴操作。

14.4 步幅、填充与输出大小

对某一空间轴，输入长度 L、两侧各填充 p、核大小 k、步幅 s、膨胀率 d，常用输出长度为

$$L_{\text{out}} = \left\lfloor \frac{L + 2p - d(k-1) - 1}{s} \right\rfloor + 1.$$

有效核跨度为 $d(k-1)+1$。公式假定参数有效、使用通常的向下取整规则，某些自动 padding 或池化的 ceil 模式需要另按接口约定。

例子	L	k	p	s	d	输出
无填充小例子	4	2	0	1	1	3
保持 32 长度	32	3	1	1	1	32
步幅 2 降采样	7	3	1	2	1	4
膨胀核示例	7	3	0	1	2	3

Padding 在边缘提供约定的额外数值，例如 0；它不是自动补回真实图像信息。Stride 跳过部分位置，Dilation 拉开核采样点间隔；二者对输出大小与感受野的作用不同。

> **“same”不总等于宽高完全不变**
> 一些接口在步幅 1 下维持大小，在步幅大于 1 时按特定规则产生约 L/s 的输出。使用文字模式时，应查接口的填充与非对称边界约定。

14.5 池化与理论感受野

池化（Pooling）按局部窗口汇总数值，常见最大池化和平均池化通常没有可学习权重。它们可减少空间大小，但也可能丢失位置或细节信息。

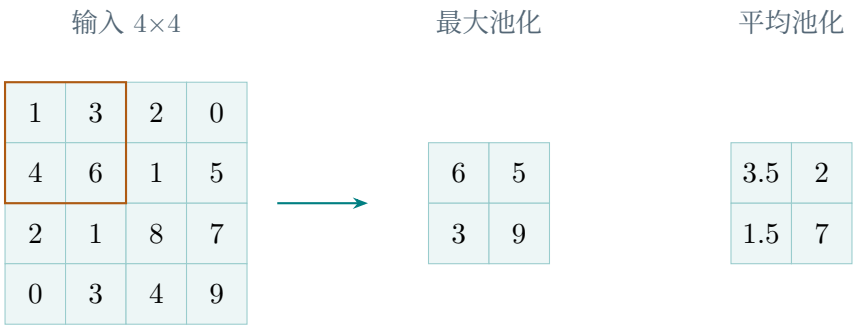


图 14.3: 两个独立的 2×2 池化例子；最大与平均不是要依次串联的两步。

读图： 左上块 $[1,3;4,6]$ 最大值为 6，均值为 3.5。最大池化的反向梯度流向取得最大值的位置；出现相等最大值时需按实现约定处理。

一个输出所能依赖的输入区域称感受野（Receptive Field）。令初始跨度 $r_0 = 1$、相邻位置间距 $j_0 = 1$，则

$$r_l = r_{l-1} + [d_l(k_l - 1)]j_{l-1}, \qquad j_l = j_{l-1}s_l.$$

3 核步幅 1 卷积后，$r = 3, j = 1$；2 核步幅 2 池化后，$r = 4, j = 2$；再接 3 核步幅 1 卷积，$r = 8, j = 2$。这是理论依赖跨度，不表示该区域内每个像素影响完全相同。

记住： 共享卷积常带来平移等变倾向；步幅、填充和边界会影响它，池化也不保证任意平移不变。

14.6 残差连接：为变换加一条直接路径

残差块（Residual Block）把一个变换 $F(x)$ 与输入相加：$y = x + F(x)$。当 $F(x) = 0$ 时，可以直接实现恒等映射；这为深层网络的信息与梯度提供另一条路径。

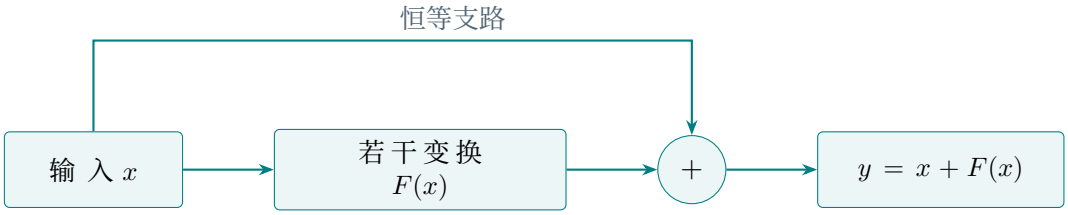


图 14.4: 最简残差结构示意，未规定卷积、归一化和激活的具体顺序。

读图：两条支路的输出形状必须能逐元素相加。若通道数或空间大小变化，可用相应投影/下采样支路 $P(x)$，成为 $y = P(x) + F(x)$。

在形状一致、可微设置中，局部 Jacobian 为 $I + \partial F/\partial x$。这说明直接路径的存在，但不意味着梯度永不消失或训练必定成功。不同 ResNet 变体的归一化与激活位置不同，应按具体结构计算。

> **相加与拼接不同**
>
> 相加要求对应位置具有兼容形状，输出通道数通常不增加。拼接（Concatenation）沿指定轴保留两组特征，会改变该轴长度。不要因为图中都是两条箭头汇合，就把两种操作视作同一个运算。

14.7 归一化层：统计量在哪些轴上计算?

Batch Normalization（BN）训练时按约定轴计算均值与方差，再进行可学习的缩放与平移：

$$\hat{x} = \frac{x - \mu}{\sqrt{v + \epsilon}}, \qquad y = \gamma\hat{x} + \beta.$$

CNN 中常为每个通道在批量和空间位置上汇总。$\epsilon > 0$ 用于数值稳定，γ, β 为可学习参数，统计量不是同一种参数。

层/阶段	常见统计范围	预测时的考虑
BN 训练	同通道的批量与空间位置。	训练批量影响统计，常维护滑动估计。
BN 推理	通常使用保存的滑动统计。	需切换到适当模式，不能默认仍用当前批量。
Layer Normalization	单条记录约定的特征轴。	通常训练/推理都按该条输入计算，无批量滑动统计。

简单两值 $x = [1, 3]$，$\mu = 2, v = 1$，$\gamma = 1, \beta = 0$ 时，输出为 $[-1, 1]/\sqrt{1 + \epsilon}$。方差估计和滑动更新的细节取决于框架，不能把所有实现的分母约定混为一谈。

记住：训练/推理模式与是否记录梯度是不同开关；归一化也不会自动把分布变成正态。

14.8 数据增强：保持任务语义的变化

数据增强（Data Augmentation）在训练中构造合理变换，让模型学习任务所允许的变化。它是建模假设，不是“加入任意噪声都能大幅改善表现”。

操作	必须同时考虑
裁剪、翻转、旋转	是否改变标签？方向识别、数字或医学左右侧任务可能不适合某些变换。
亮度或颜色扰动	是否仍处于真实采集的合理范围？颜色本身可能是目标信号。
检测与分割变换	框、掩码与图像使用同一几何变换。
训练数据派生记录	先按原对象/时间划分，再在训练内增强，避免同源副本跨验证测试。

增强样本通常与原记录相关，不能当作独立新增的真实对象来估计有效样本量。验证与测试使用约定的确定性处理；测试时增强若使用，应作为完整评估方案明确报告。

> **共享权重不保证识别所有位置**
>
> 参数共享使相同局部计算在多处可用；识别完整对象仍依赖训练分布、上下文与后续层。CNN 对旋转、尺度和任意位置变化的鲁棒性不是自动得到的保证。

14.9 一个完整小网络：形状与参数对照

下面是用于说明计算的小型 10 类图像分类器，不代表对任何任务的最佳架构。卷积采用 3 核、步幅 1、填充 1，池化采用 2 核、步幅 2。

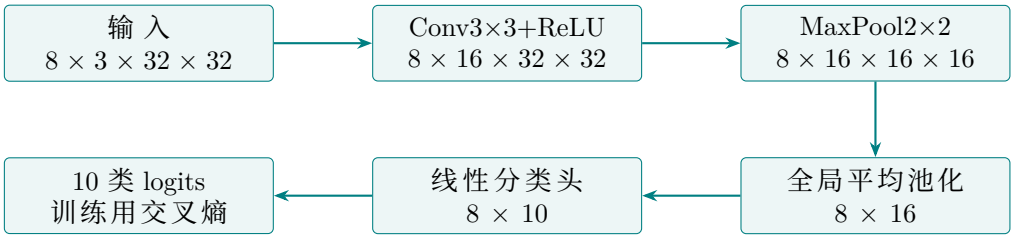


图 14.5: 蛇形箭头按顺序连接，批量轴 8 始终保留；最后输出尚未归一化的 logits。

读图：卷积有 448 个参数；线性头 16 输入、10 输出，含偏置共 170 个参数。ReLU、池化和全局平均池化无可学习参数，本例总计 618 个参数。

全局平均池化（Global Average Pooling）对每通道的空间位置取平均，把 $8 \times 16 \times 16 \times 16$ 变为 8×16，不对批量或通道轴求平均。训练时常把 logits 直接交给包含稳定对数运算的交叉熵接口，避免重复 Softmax。

14.9.1 自测与回看

图像宽高翻倍，卷积参数会自动翻四倍吗？**共享核参数不变，计算与激活内存会增大**。张量 4 轴是否代表四维特征空间的四个特征？**不是，必须看每轴含义**。残差相加是否与通道拼接相同？**不同**。

参考：Goodfellow 等，*Deep Learning*（2016）第 9 章；He 等，*Deep Residual Learning for Image Recognition*（2016）；PyTorch Conv2d、Pooling 与 Normalization 文档。图和例子为独立构造。

第十五章　文本表示：从符号到模型输入

文本要先转成模型能处理的表示。词袋、TF-IDF 与嵌入向量保留的信息不同，并非一个必然比另一个更高级。先用简单基线理解任务，再决定是否需要序列与上下文模型。

> **符号编号没有大小距离含义**
>
> Token ID 是查表索引，不表示语义的高低远近。词典、分词规则与模型输入必须一致；需要从当前数据学习的词典和文档频率，应在训练内拟合。

15.1　Tokenization、词干与停用词

Tokenization 把文本切成处理单元（Token），可以是词、子词、字符等。中文不必按空格切分，词干提取也不是所有语言和模型都需要的步骤。

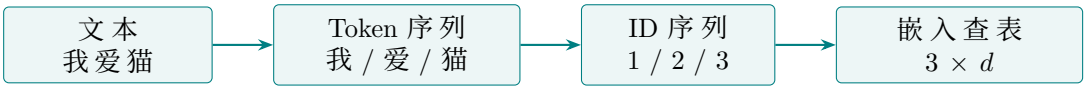


图 15.1： 一个人工分词与词典例子，词典含 PAD=0、我 =1、爱 =2、猫 =3。实际系统可采用不同切分。

读图： 三项 ID 查三行嵌入，得到三条向量。ID 为 3 不表示“猫”是“我”的三倍。验证与上线必须沿用同一词典及未知 Token 处理规则。

处理	作用与限制
词干提取 Stemming	按规则缩减词形，输出未必是语言学词根或完整单词。
词形还原 Lemmatization	试图还原词元，可能依赖词性或语言资源。
停用词 Stop words	某些任务过滤高频功能词；否定、语气等也可能是关键信息，不能默认全删。

记住：“不喜欢”中的“不”可能决定情感标签；文本清洗必须与任务语义一致。

15.2 词袋与 TF-IDF：可解释的稀疏基线

词袋（Bag of Words）把文档表示为词典上的计数或出现指示向量。它忽略词序：“猫追狗”与“狗追猫”在相同分词下可以具有相同词袋，但含义不同。指示值 0/1 不是一个“二元分类器”，只是特征数值。

文档/词典	猫	狗	看	跑
D1：猫看猫	2	0	1	0
D2：狗看	0	1	1	0
D3：猫跑	1	0	0	1
文档频率 df	2	1	2	1

TF-IDF 组合词频与逆文档频率。本例使用原始计数 tf、自然对数和平滑式

$$idf(t) = \log \frac{1+N}{1+df(t)} + 1, \qquad v_{d,t} = tf(t,d)\, idf(t),$$

其中 $N = 3$, df 按出现该词的**文档数**计, 不是总次数。“猫”和“看”的 $idf = 1+\log(4/3) \approx 1.288$, 另外两项为 $1 + \log 2 \approx 1.693$。若再作 L2 归一化，D1 变为 $[2/\sqrt{5}, 0, 1/\sqrt{5}, 0]$。

不同实现有不同 TF、平滑与归一化约定，应报告完整设置。常见词权重降低不代表它没有语义价值，稀有词权重高也不证明它具有预测或因果作用。

记住：词典与 IDF 从训练数据学习，随后固定用于验证、测试和新文档。

15.3 嵌入与 Word2Vec：学习稠密向量

嵌入（Embedding）用矩阵 $E \in \mathbb{R}^{V \times d}$ 为 V 个 Token 存储 d 维向量。长度 T 的 ID 序列查表得到 $T \times d$ 矩阵，批量后常为 $B \times T \times d$。仅嵌入矩阵就有 Vd 个参数；PAD、未知词和是否冻结按实现设计。

Word2Vec 通过局部上下文预测等目标学习词向量，典型形式包括 CBOW 与 Skip-gram。上下文相似可能产生向量相近，但相似性和类比关系是数据与训练的结果，不是对任意词都成立的语义定理。词向量还可能保留语料中的偏差。

表示	同一 Token 在不同句子中	常见考虑
词袋/TF-IDF	对应固定词典列。	简单、稀疏；通常忽略顺序。
静态词嵌入	查同一行向量。	稠密；多义词共享初始表示。
上下文表示	经序列/注意力层后可随上下文变化。	需要位置、遮罩及更复杂训练。

预训练嵌入可冻结后作为特征，也可以随任务微调。预处理应与预训练模型约定一致，不能任意删词、改变 Token 划分后仍假定原模型语义不变。

参考： Manning 等，*Introduction to Information Retrieval*（2008）第 6 章；Mikolov 等（2013）的 Word2Vec 工作；scikit-learn Text feature extraction 文档。本章表格与流程图独立设计。

第十六章　序列与注意力：共享状态与动态汇总

序列模型需要处理位置之间的依赖。RNN 按顺序更新状态，注意力根据当前表示计算位置之间的权重。本章沿着输入形状、计算路径与可见信息，建立 RNN、门控结构和 Transformer 的基本联系。

> **能看到什么，是模型定义的一部分**
> 离线阅读整段文本与根据历史预测未来，允许的信息不同。双向处理、填充遮罩与因果遮罩必须围绕任务设定，不能仅把它们当作程序选项。

16.1　RNN：同一组权重逐位置更新状态

基本循环神经网络（Recurrent Neural Network, RNN）可写为

$$\boldsymbol{h}_t = \tanh(W_x \boldsymbol{x}_t + W_h \boldsymbol{h}_{t-1} + \boldsymbol{b}).$$

若输入维度 d、状态维度 h，则 $W_x \in \mathbb{R}^{h\times d}$、$W_h \in \mathbb{R}^{h\times h}$。同一组参数在所有位置复用，序列加长不自动增加这组参数数量。

三个位置使用同一组权重，不是三个独立模型

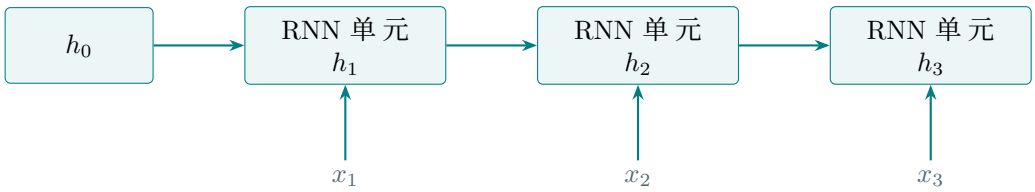


图 16.1： 展开三个位置只是展示计算依赖，横向箭头传递状态。

读图： 标量例子 $h_t = \tanh(x_t + 0.5h_{t-1})$，$h_0 = 0$、输入 $[1, 0, -1]$，得到约 $[0.762, 0.363, -0.674]$。同一个输入值出现在不同历史后，可以产生不同状态。

反向传播通过时间（Backpropagation Through Time, BPTT）沿展开图计算，共享参数在各位置的贡献需要相加。长路径上的 Jacobian 连乘可能导致梯度消失或爆炸；截断 BPTT 限制回传长度，裁剪可帮助控制爆炸，但两者都不是保证学到所有长期依赖。

记住： 双向 RNN 可以利用前后文，因而不能直接用于当时不可获得未来输入的实时预测。

16.2 LSTM 与 GRU：门控制信息更新

长短期记忆网络（Long Short-Term Memory, LSTM）的经典形式用 Sigmoid 门与候选状态控制更新：

$$\boldsymbol{c}_t = \boldsymbol{f}_t \odot \boldsymbol{c}_{t-1} + \boldsymbol{i}_t \odot \widetilde{\boldsymbol{c}}_t, \qquad \boldsymbol{h}_t = \boldsymbol{o}_t \odot \tanh(\boldsymbol{c}_t).$$

遗忘门 f、输入门 i、输出门 o 分别由当前输入和前一状态的仿射变换经 Sigmoid 得到；候选 $\tilde{c}$ 常用 tanh。c 为记忆单元，h 为输出状态，$\odot$ 表示逐元素乘法。

结构	主要区别
基本 RNN	直接由输入与旧状态生成新状态，路径反复经过同类非线性。
LSTM	有 c 与 h 两种状态，门控制旧记忆保留、候选写入与输出。
GRU	通常只有一个状态，用更新门与重置门组合旧状态和候选。

一种 GRU 约定为 $h_t = z_t \odot h_{t-1} + (1 - z_t) \odot \widetilde{h}_t$，候选依赖输入与 $r_t \odot h_{t-1}$。不同文献可对 z 采用互补命名，读实现时要对照公式。LSTM 的 i 与 f 一般独立，不要求两者之和为 1。

标量 LSTM 例子 $c_{t-1} = 2, f = 0.9, i = 0.2, \widetilde{c} = -0.5, o = 0.8$,则 $c_t = 1.7, h_t = 0.8 \tanh 1.7 \approx 0.748$。门控提供更适合保留状态的路径，但并不保证永远记住所有历史。

16.3 注意力：查询键，再汇总值

缩放点积注意力（Scaled Dot-Product Attention）为

$$\mathrm{Attn}(Q,K,V)=\mathrm{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}+M\right)V.$$

Softmax 逐行作用。Q 是查询（Query），K 是键（Key），V 是值（Value），M 指定允许关注的位置；键与值的行数必须对应。

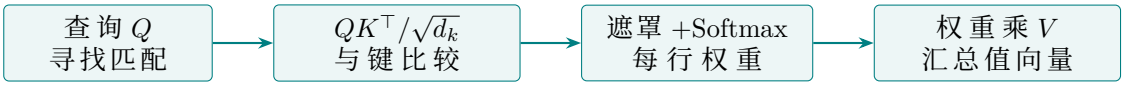


图 16.2: 键参与计算匹配分数，值提供被加权汇总的内容；两者职责不同。

读图：一个查询 $q=\log 3$、$d_k=1$，两个键为 $[0,1]$，得分为 $[0,\log 3]$。权重为 $[1/4,3/4]$；若值为 $(2,0)$ 和 $(0,4)$，输出为 $(0.5,3)$。

若 $Q\in\mathbb{R}^{T_q\times d_k}$、$K\in\mathbb{R}^{T_k\times d_k}$、$V\in\mathbb{R}^{T_k\times d_v}$，权重形状是 $T_q\times T_k$，输出为 $T_q\times d_v$。自注意力（Self-attention）的 Q/K/V 来自同一序列的不同投影，不要求三个矩阵数值相同。交叉注意力可让查询与键/值来自不同序列。

记住：权重随输入变化，是一种计算关系；不能直接把权重大小当作因果解释。

16.4 因果与填充遮罩：在 Softmax 之前处理

因果自注意力只允许位置 i 关注 $j \le i$。常令 $M_{ij}=0$ 表示允许，$M_{ij}=-\infty$ 表示屏蔽，再计算 Softmax。这使被屏蔽位置的权重为 0，而允许位置重新归一化。

	键 1	键 2	键 3
查询 1	1	0	0
查询 2	1/2	1/2	0
查询 3	1/3	1/3	1/3

右上三角被遮罩；每行允许的权重和为 1

图 16.3: 三个位置的未遮罩得分全为 0 时，加入因果遮罩后得到的注意力权重。

读图：第一行只能看第 1 位置，第二行平均看前两个，第三行平均看三个。先做 Softmax 再简单把未来位置设 0 而不重新归一化，会得到另一种运算。

填充遮罩（Padding Mask）用于排除 PAD 等无效位置，和因果遮罩解决不同问题。损失或序列池化也要排除相应填充位置；不要只屏蔽键就默认所有输出均有效。避免整行都被屏蔽，使 Softmax 没有可用位置；实际布尔遮罩的 True 含义还需对照接口。

> **训练可并行，不表示能偷看未来**
>
> 训练时可以同时计算所有位置，但因果遮罩仍限制每个位置的可见信息。逐步生成则按已有前缀扩展，两种计算方式可以实现同一个信息约束。

16.5 多头注意力：多组投影再拼接

多头注意力（Multi-Head Attention, MHA）并行计算多个注意力头：

$$\text{head}_i = \text{Attn}(XW_i^Q, XW_i^K, XW_i^V).$$

再拼接并乘输出投影 W_O。头之间通常有不同的可学习投影。

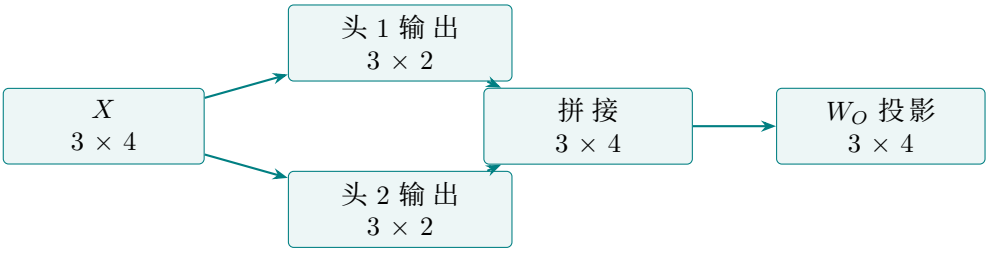


图 16.4: 省略批量轴，长度 3、表示维度 4、两个等宽头的形状例子。

读图：每头的键和值维度为 2，输出各为 3×2，拼接恢复 3×4。拼接不是取平均；W_O 进一步混合不同头的输出。

在常见等宽设置中，d_{model} 能被头数整除。若 Q、K、V 和输出均从 d 维映到 d 维，忽略偏置，四组投影参数共 $4d^2$；这不是整个 Transformer 的参数数，还未包括前馈层、归一化和嵌入。

> **每个头不保证学到一种固定语言功能**
>
> 可以观察到不同注意模式，但不能预先指定“某头一定负责语法、某头一定负责语义”。头的作用依赖任务、数据和训练结果。

16.6 Transformer 块：注意力、前馈与残差

Transformer 把注意力、逐位置前馈层、残差和归一化组合起来。下面选择一种 Pre-LN 示意：$Z = X + \mathrm{MHA}(\mathrm{LN}(X))$，$Y = Z + \mathrm{FFN}(\mathrm{LN}(Z))$。

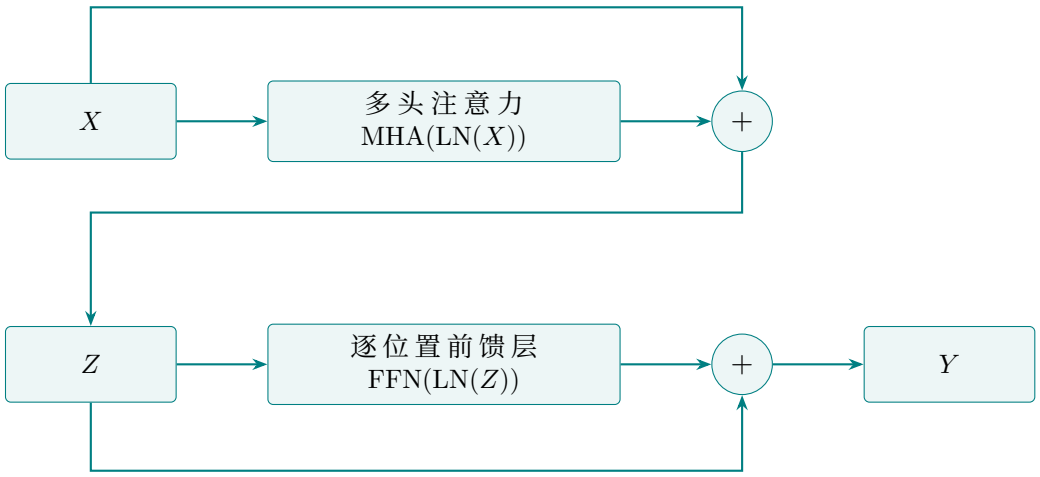


图 16.5: 省略 Dropout 与部分实现细节的 Pre-LN 块；不是所有 Transformer 变体的唯一顺序。

读图：注意力在位置间汇总；FFN 对每个位置分别应用同一组权重，典型为 $d \to d_{\mathrm{ff}} \to d$ 的两次仿射变换与中间非线性。残差支路保持对应形状，LayerNorm 常按每个位置的特征轴计算。

普通自注意力若没有位置或其他次序结构，对位置排列具有等变性。序列模型通常加入位置表示，如可学习位置向量、正弦编码或相对位置机制。它们提供次序信息，不能用“不同 Token 的编号大小”代替。

记住：Transformer 不是只有一个 Softmax：表示、位置、遮罩、注意力、前馈与训练目标共同决定行为。

16.7 编码器、解码器与下一 Token 目标

编码器常对完整输入作双向表示；自回归解码器按前缀预测下一 Token；编码器—解码器结构还用交叉注意力读取源表示。

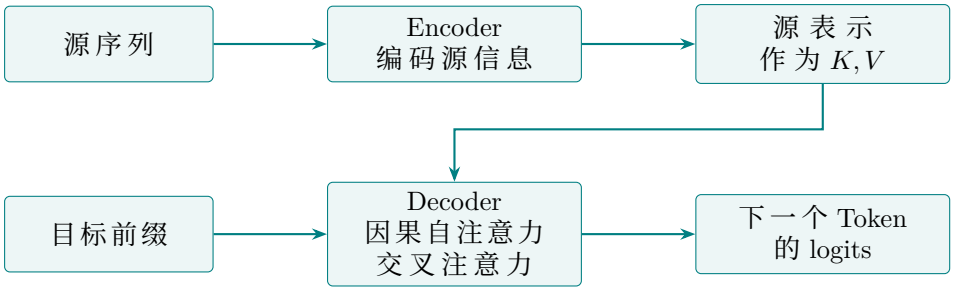


图 16.6: 条件生成示意：目标查询读取源序列的键和值，同时屏蔽目标未来位置。

读图：交叉注意力中的键/值来自编码器源表示，查询来自解码器目标状态。源长度与目标长度可以不同，不能按逐位置一一配对理解。

自回归训练通常将输入和目标错开一个位置：

位置	1	2	3
输入	BOS	我	爱
监督目标	我	爱	猫

位置 3 在训练时只看到 BOS、我、爱，预测猫；不能把猫同时放在该位置输入中让模型直接复制。教师强制（Teacher Forcing）使用真实历史目标作为训练前缀，生成时则使用已生成前缀。

> **预训练目标不同，使用方式也不同**
>
> 掩码 Token 恢复与因果下一 Token 预测有不同可见信息和输出目标。不能仅凭名称把任何编码器模型当作已经训练好的自回归生成器。

16.8 比较架构，同时检查时间与内存

没有架构在所有任务上都最好。局部结构、序列长度、可用数据与部署需求会影响选择。

架构	信息交互	常见考虑
CNN	共享局部窗口，叠层扩大依赖范围。	网格与局部模式；步幅、边界和尺度。
RNN、LSTM、GRU	按顺序更新共享状态。	有序计算与长路径；可逐步维护状态。
Transformer	根据输入计算注意力交互。	位置、遮罩、长序列开销与任务目标。

显式注意力权重的元素数为 $B\,h\,T_q\,T_k$。$B=2, h=4, T_q=T_k=128$ 时，共 131072 个元素；float32 仅这部分占 0.5MiB。长度都变为 256 时，该部分变为 2MiB，即 4 倍。这不是总训练显存；优化实现可能避免完整保存权重矩阵，其他激活和参数仍需计入。

16.8.1 自测与回看

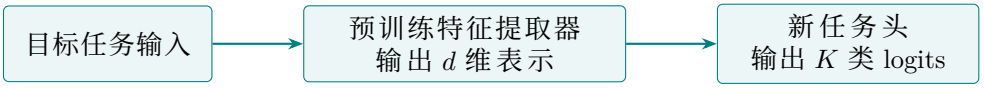
共享参数是否意味着每个位置输出相同？**不意味着**。LSTM 输入门与遗忘门是否必须互补？**不必**。多头输出是否简单取平均？**通常是拼接再投影**。训练并行是否允许看到未来标签？**不允许**。

参考： Goodfellow 等《Deep Learning》第 10 章；Hochreiter 与 Schmidhuber（1997）的 LSTM；Cho 等（2014）的门控结构；Vaswani 等，*Attention Is All You Need*（2017）。图、形状与数值例子独立构造。

第十七章　迁移学习：复用表示，再验证目标任务

迁移学习（Transfer Learning）把已有任务或数据中学到的信息用于目标任务。常见做法是使用预训练特征提取器，接上适合新标签的任务头；不要求源与目标的类别名称相同，但输入与表示需要适配。

17.1　冻结与微调分别更新什么？



冻结：不更新底座参数；微调：更新选定参数。
两种情况都要规定训练/评估模式与预处理。

图 17.1：目标任务有 K 个互斥类别时，线性任务头将 d 维表示映成 K 个 logits。

读图：若 $d = 16, K = 3$，带偏置任务头有 $16 \times 3 + 3 = 51$ 个参数。冻结底座时只训练这些新参数；部分或全部微调时，还更新被选中的底座参数。冻结减少可训练参数，但不消除底座前向计算。

策略	需要比较的因素
冻结表示，仅训练头	可作较省训练计算的起点，表示与目标是否匹配仍需验证。
解冻部分层	控制适应程度、学习率与训练模式；没有通用解冻层数。
全部微调	更大适应空间，也需要数据、计算与过拟合检查。

冻结参数与评估模式是两回事：BatchNorm 运行统计是否更新、Dropout 是否随机，需要另外设定；不能只设置“不求参数梯度”就默认底座输出固定。预处理、词表/分词和输入尺度也需与预训练约定衔接。

> **预训练不保证每个目标任务都有收益**
>
> 源与目标差异、标签质量和数据量会影响结果，可能出现负迁移。应与简单基线比较，按目标对象或时间划分验证，仍要隔离测试集。还需核对预训练数据是否与评估样本重叠，避免把重复内容带来的好分数当作泛化。

参考：《动手学深度学习》微调章节；PyTorch Transfer Learning Tutorial。

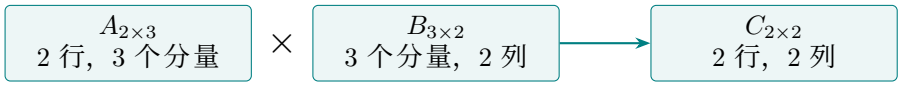
附录 A　数学速查：为模型计算服务

本附录保留理解本书公式最常用的数学工具：形状、内积、矩阵运算、导数、概率与统计量。每个公式都应先确认变量含义与适用条件。无需在开始学习机器学习之前逐页背诵。

> **先检查形状，再检查数值**
> 矩阵相乘看内部维度，梯度应与参数具有相同形状，概率应满足非负与归一化。这三类检查能较早发现许多实现错误。

A.1　向量、矩阵与乘法形状

列向量 $\boldsymbol{x} \in \mathbb{R}^d$ 有 d 个分量；矩阵 $A \in \mathbb{R}^{m\times n}$ 有 m 行 n 列，元素记为 a_{ij}，转置满足 $(A^\top)_{ji} = a_{ij}$。矩阵积 $C = AB$ 的元素为 $c_{ij} = \sum_{k=1}^{n} a_{ik} b_{kj}$。



内部维度相同才能相乘；结果保留外部维度

图 A.1: 例子 $A \in \mathbb{R}^{2\times 3}$、$B \in \mathbb{R}^{3\times 2}$，相乘后为 2×2。

读图：结果每个位置都是左矩阵一行与右矩阵一列的内积。一般 $AB \neq BA$，甚至可能只有一个方向的积有定义。维度合适时，乘法满足结合律。

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 1 & 3 \end{bmatrix}, \quad B = \begin{bmatrix} 2 & 1 \\ 1 & 2 \\ 3 & 0 \end{bmatrix}, \quad AB = \begin{bmatrix} 4 & 5 \\ 10 & 2 \end{bmatrix}.$$

例如 $(AB)_{12} = 1\times 1 + 2\times 2 + 0\times 0 = 5$。逐元素乘法 $A \odot B$ 要求相应形状匹配，不是上述矩阵乘法。

记住：批量线性预测常写作 $X\boldsymbol{w} + b\mathbf{1}$：$X$ 为 $n \times d$，$\boldsymbol{w}$ 为 $d \times 1$，结果为 $n \times 1$。

A.2 内积、范数、秩与行列式

内积 $\boldsymbol{x}^\top \boldsymbol{z} = \sum_j x_j z_j$ 衡量方向上的关系。常用范数为

$$\|\boldsymbol{x}\|_1 = \sum_j |x_j|, \quad \|\boldsymbol{x}\|_2 = \sqrt{\sum_j x_j^2}, \quad \|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2}.$$

例如 $(3,-4)$ 的 L1 范数为 7，L2 范数为 5；范数总是非负。矩阵的秩（Rank）是独立列或独立行的最大数目，不等于行数、列数的简单乘积。

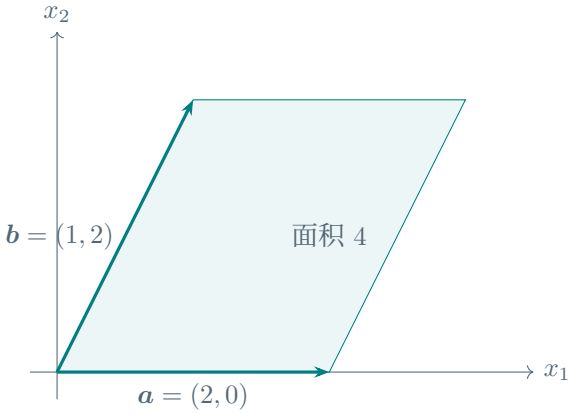


图 A.2: 二维列向量构成的平行四边形，面积为行列式绝对值。

读图： $A = [\boldsymbol{a}\ \boldsymbol{b}] = \left[\begin{smallmatrix} 2 & 1 \\ 0 & 2 \end{smallmatrix}\right]$，$\det A = 2\times 2 - 1\times 0 = 4$，面积为 4。行列式本身有符号，交换两列会变号。

$n \times n$ 方阵的行列式是 n 个特征值的乘积，**不是所有元素的乘积**。$\det A \neq 0$ 等价于方阵可逆。非方阵没有此处定义的行列式。实际求解线性方程常采用稳定分解方法，不必先显式计算 A^{-1}。

A.3 特征值与奇异值：方向、缩放与降维

若非零向量 $\boldsymbol{v}$ 满足 $A\boldsymbol{v} = \lambda\boldsymbol{v}$, 则 λ 是特征值, $\boldsymbol{v}$ 是特征向量。实对称矩阵可写成 $A = Q\Lambda Q^\top$, Q 的列为正交单位向量。

工具	用途与条件
正半定	对称矩阵满足 $\boldsymbol{z}^\top A\boldsymbol{z} \geq 0$；等价于特征值非负。
奇异值分解 SVD	任意实 $m \times n$ 矩阵可写成 $A = U\Sigma V^\top$，奇异值非负。
低秩近似	只保留最大的若干奇异值和相应方向，以压缩矩阵。
PCA 的线性代数	对中心化的数据矩阵作 SVD，或对相应协方差矩阵求特征方向。

例如 $A = \mathrm{diag}(3, 1)$ 把两个坐标方向分别缩放为 3 倍、1 倍，奇异值为 3、1。保留第一方向得到 $A_1 = \mathrm{diag}(3, 0)$，误差 $\|A - A_1\|_F = 1$。

> **方向不是自动“有用”的标签信息**
>
> PCA 寻找较大方差方向，不直接使用目标标签，也不保证保留最强预测信号。用于监督流程时，中心化和降维都应在训练内拟合。一般矩阵不一定有实数特征值；SVD 与特征分解不是同一概念。

A.4 导数、梯度与链式法则

一元导数 $f'(x)$ 描述局部变化率；多元标量函数的梯度由各偏导组成：

$$\nabla_{\boldsymbol{w}} J = (\partial J/\partial w_1, \dots, \partial J/\partial w_d)^\top.$$

在可微条件下，$J(\boldsymbol{w}+\Delta) \approx J(\boldsymbol{w}) + \nabla J(\boldsymbol{w})^\top \Delta$。

函数	导数或梯度
x^p	$p x^{p-1}$（在有定义且可微处）
e^x	e^x
$\log x$	$1/x$，$x>0$
$\sigma(x)=1/(1+e^{-x})$	$\sigma(x)(1-\sigma(x))$
$\frac{1}{2}\lVert\boldsymbol{w}\rVert_2^2$	$\boldsymbol{w}$
$\frac{1}{2n}\lVert X\boldsymbol{w}-\boldsymbol{y}\rVert_2^2$	$\frac{1}{n}X^\top(X\boldsymbol{w}-\boldsymbol{y})$

复合函数 $z=f(g(x))$ 的导数为 $f'(g(x))g'(x)$。多条路径依赖同一变量时，各路径贡献相加，这正是计算图中反向传播的基础。

A.4.1 一个形状与数值检查

$X=\left[\begin{smallmatrix}1&2\\3&4\end{smallmatrix}\right]$、$\boldsymbol{w}=(0.5,-0.25)^\top$、$\boldsymbol{y}=(1,0)^\top$，则残差为 $(-1,0.5)^\top$，$J=0.3125$、$\nabla J=(0.25,0)^\top$。梯度与 $\boldsymbol{w}$ 均为两维列向量。

> **不可微与零梯度**
>
> $|x|$ 在 0 处不可微，可以使用次梯度；ReLU 在 0 处也需实现约定。梯度为 0 不一定是极小值。神经网络反向传播要先正确设置损失与计算依赖。

A.5 条件概率与贝叶斯公式

对事件 A, B，$P(A \cup B) = P(A) + P(B) - P(A \cap B)$。当 $P(B) > 0$ 时，$P(A \mid B) = P(A \cap B)/P(B)$。独立要求 $P(A \cap B) = P(A)P(B)$；互斥事件并不因此独立。

设 $B_1, \ldots, B_K$ 构成互斥且完备的划分，$P(B_k) > 0$，则

$$P(A) = \sum_k P(A \mid B_k)P(B_k), \qquad P(B_j \mid A) = \frac{P(A \mid B_j)P(B_j)}{P(A)}.$$

后一式还要求 $P(A) > 0$。先验 $P(B_j)$、似然 $P(A \mid B_j)$ 与后验 $P(B_j \mid A)$ 的方向不同。

某检测的已知概率	数值
患病先验	$P(D) = 0.01$
患病者检出率	$P(+ \mid D) = 0.90$
未患病者假阳性率	$P(+ \mid \bar{D}) = 0.05$

$$P(D \mid +) = \frac{0.90 \times 0.01}{0.90 \times 0.01 + 0.05 \times 0.99} = \frac{2}{13} \approx 0.154.$$

检出率 90% 并不意味着阳性者有 90% 患病；先验与假阳性共同影响后验。

记住：遇到条件概率，先读清楚竖线两侧，再决定能否交换方向。

A.6 随机变量、期望、方差与协方差

随机变量（Random Variable）把试验结果映射到数值。例如两次抛硬币的正面个数，把四种等可能结果映射到 0、1、2。

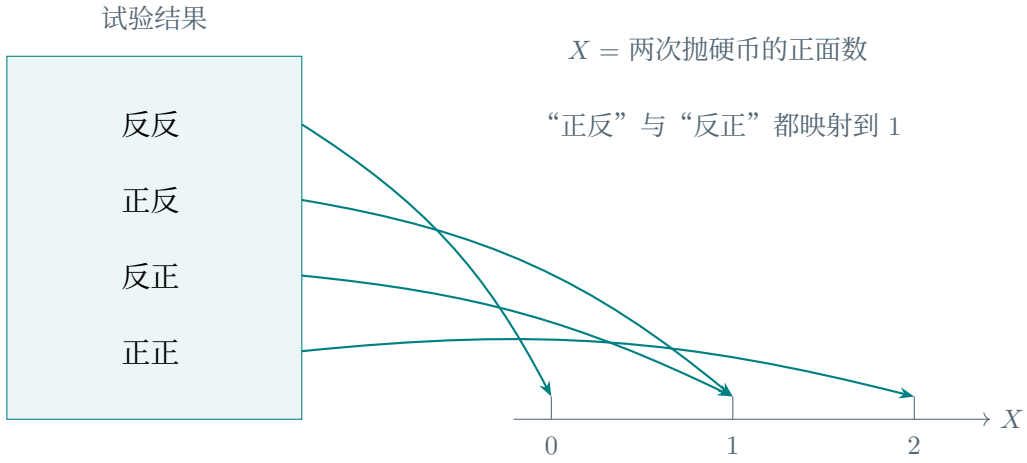


图 A.3: 四种试验结果映射到三个计数值；不同结果可以映射到相同数值。

读图：公平且独立的两次抛掷中，$P(X=0)=1/4$、$P(X=1)=1/2$、$P(X=2)=1/4$，所以 $\mathbb{E}X=1$、$\mathrm{Var}(X)=1/2$。

离散随机变量有 $\mathbb{E}[g(X)]=\sum_x g(x)P(X=x)$；连续情形用密度积分。若相应二阶矩存在，

$$\mathrm{Var}(X)=\mathbb{E}[(X-\mathbb{E}X)^2]=\mathbb{E}[X^2]-(\mathbb{E}X)^2,$$

$$\mathrm{Cov}(X,Y)=\mathbb{E}[(X-\mathbb{E}X)(Y-\mathbb{E}Y)].$$

期望满足线性性，不要求独立；独立且二阶矩有限时协方差为 0，逆命题一般不成立。

> **零相关仍可能有确定依赖**
>
> 令 X 等可能取 $-1,0,1$，$Y=X^2$，则协方差为 0，但 Y 完全由 X 决定。相关系数只反映相应的线性关系，且两变量方差应非零。

A.7 常用分布与样本统计量

概率质量函数直接给离散取值的概率；概率密度需要在区间上积分。密度可以大于 1，例如 $U(0, 0.5)$ 的密度为 2，整个区间概率仍为 1。

分布	质量函数或密度	均值与方差
Bernoulli(p)	$p^x(1-p)^{1-x}$，$x \in \{0,1\}$	p；$p(1-p)$
Binomial(n,p)	$\binom{n}{x}p^x(1-p)^{n-x}$，$x=0,\dots,n$	np；$np(1-p)$
Uniform(a,b)	$1/(b-a)$ 在 $[a,b]$ 内，区间外 0	$(a+b)/2$；$(b-a)^2/12$
Normal(μ,s^2)	$\exp[-(x-\mu)^2/(2s^2)]/(s\sqrt{2\pi})$	μ；s^2

$0 \le p \le 1$，二项 n 为非负整数，均匀分布 $a < b$，正态 $s > 0$。固定 n 次独立同分布 Bernoulli 试验的和才具有上述二项分布。

A.7.1 总体矩与样本估计要区分

对独立同分布观测 $x_1, \dots, x_n$，样本均值为 $\bar{x} = \sum_i x_i/n$。$n > 1$ 时，$s^2 = \sum_i (x_i - \bar{x})^2/(n-1)$ 是总体方差的无偏估计（有限二阶矩）。描述手头数据或某些标准化实现则使用分母 n，应明确约定。对 $[1,2,3]$，均值为 2，分母 n 的方差为 $2/3$，分母 $n-1$ 为 1。

> **大样本结论仍有条件**
>
> 在独立同分布等适当条件下，大数定律说明均值趋近总体期望，中心极限定理描述标准化均值的近似分布。它们不表示任意原始数据都会随着样本增多变成正态。

参考： Deisenroth、Faisal 与 Ong，*Mathematics for Machine Learning*（2020），第 2、4、5、6 章。本附录图与数字例子独立设计；更多计算细节见本项目复核脚本。

附录 B　符号、方法比较与主题索引

本附录是阅读入口。速查表只保留定位与关键判断；算法前提、公式约定和例子仍以相应正文为准。

B.1　符号与口径

记号	本书常见含义
n, d, K	样本数、特征维度、类别/簇数；K 也可在 K 折验证中表示折数，按局部定义。
$X \in \mathbb{R}^{n\times d}$	表格数据按行放样本、按列放特征；单个样本常写列向量 $\boldsymbol{x}$。
$\boldsymbol{w}, b, \theta$	权重、偏置与一般参数；$\hat{y}$ 表示预测，帽子也可表示估计量。
ℓ, J, η, λ	单样本损失、目标、学习率、正则强度；各目标是否按样本平均需看公式。
$\nabla, \partial, \odot$	梯度、偏导、逐元素乘法；矩阵相乘用并置或显式乘号，不用 $\odot$。
$\|\cdot\|_2$	向量欧氏范数；平方惩罚为范数平方，不能漏看平方或 $1/2$ 系数。
B, T, C, H, W	神经网络中常指批量、长度、通道、高、宽；轴次序必须说明。
Q, K, V, d_k	注意力查询、键、值与键维度；这里 K 是矩阵而不是类别数。
$\mathbb{E}, \mathrm{Var}$	期望、方差；条件概率竖线右侧是已知条件。
$\log, \exp$	若无另注，log 是自然对数，$\exp z = e^z$。

> **先确认三个口径**
>
> **标签：**二元交叉熵常用 $0/1$，Hinge 常用 $-1/+1$。**矩阵：**表格样本按行，神经元推导可按单样本列向量；转置由形状决定。**数据：**训练用来拟合，验证用来选择，测试用来评价已确定流程。

同一字母在不同领域可有不同局部含义，例如 λ 也可表示特征值，h 可表示隐藏维度或头数。本书尽量在公式附近给出定义，不把符号表当作省略局部解释的理由。

B.2 监督模型：先做什么基线?

模型与入口	核心做法	需要验证的地方
线性/多项式回归	以选定特征的线性组合预测数值。	残差、外推、特征尺度与复杂度；线性系数不自动是因果效应。
Ridge、Lasso	用 L2/L1 限制系数；Elastic Net 结合两者。	损失缩放、标准化、正则强度与变量相关性。
逻辑回归	线性 logit 经 Sigmoid 给二分类概率。	线性边界、正则、校准与阈值；名字含“回归”但常用于分类。
K 近邻	按距离找邻居后投票或平均。	尺度、距离、维度、存储与查询开销。
朴素贝叶斯	按类组合特征似然与先验。	条件独立假设、似然形式、平滑与概率校准。
决策树	递归分割特征空间。	深度、叶节点样本量与稳定性；贪心切分不保证全局最优树。
SVM	结合间隔、惩罚与可选核形成边界。	C、核参数、尺度及数据规模；得分不是自动的校准概率。
随机森林/Bagging	重采样、特征随机性与多模型汇总。	模型相关、计算预算、重要性偏差与目标指标。
梯度提升	顺序增加拟合当前损失方向的弱模型。	学习率、树复杂度、轮数与验证；不要与所有提升算法的权重机制混称。

记住：表格数据可先比较简单线性基线与树模型，文本可先比较稀疏词袋基线；这只是可解释的起点，不是性能排序。

B.3 无监督与神经架构：目标和结构相配

方法与入口	提供什么结构	关键边界
K-means	固定簇数，以平方距离和聚组。	紧凑几何、尺度、初始化与异常值。
DBSCAN	连接高密度核心并吸收边界点，可留噪声。	距离、密度阈值、密度差异与高维。
层次聚类	通过合并构造多层分组。	链接、距离、截断高度与计算规模。
PCA	保留较大方差的正交线性方向。	中心化、尺度、重建与预测用途不同。
MLP	仿射与非线性组合的可学习表示。	容量、数据、优化与过拟合；需完整评估流程。
CNN	局部连接和参数共享。	输入轴、边界、感受野、下采样与任务对齐。
RNN、LSTM、GRU	顺序更新共享状态；门控调节信息保留。	状态、长路径、梯度与在线可见信息。
Transformer	注意力、前馈、残差与位置结构组合。	遮罩、长度开销、训练目标和表示维度。
迁移学习	复用已有表示并适应目标任务。	来源匹配、冻结/模式、评估重叠与负迁移。

复杂方法需要与任务合适的简单基线比较。聚类编号不等于已知类别，解释方差不是预测能力，能拟合不是能泛化，预训练也不是数据泄漏与分布变化的豁免。

B.4 主题入口：数据、评估与经典方法

以下页码可点击，指向当前整书版本。英文缩写与中文术语并列，便于不同资料间对照。

要查的概念	具体入口	页
容量、过拟合 Capacity/Overfitting	容量与泛化	5
偏差—方差 Bias–Variance	期望误差分解及前提	9
缺失、填补 Imputation	缺失值与训练内填补	16
编码 One-hot/Ordinal	独热与类别编码	14
缺失机制、完整记录	MCAR/MAR/MNAR 与分析目标	23
异常与特征筛选	核查、方差与卡方关联	25
缩放 Scaling	标准化与 MinMax	18
不平衡、SMOTE	采样的用途与边界	20
泄漏 Data Leakage	完整拟合流水线	22
交叉验证 Cross-validation	折内拟合整个流程	31
Precision/Recall/Specificity	分母与正类口径	33
F1、Macro/Micro	F1 与多分类汇总	34
ROC/AUC	排序、并列得分与面积	36
MAE/MSE/RMSE、R^2	回归误差、决定系数	38
调参、Nested CV	搜索预算与内外层验证	41
学习/验证曲线	横轴不同，问题不同	43
Brier、LogLoss	概率质量	44
校准、阈值 Calibration	可靠性图与代价	45
MCC、置信区间	标签相关、抽样不确定性	46
Bootstrap、AIC/BIC	重采样、信息准则	52
Ridge/Lasso/Elastic Net	惩罚与系数收缩	59
NB、Bagging、Boosting	概率、树与集成	65
SVM、核 Kernel	间隔与核相似度	77
聚类、PCA	分组与低维表示	78

B.5 主题入口：神经计算与数学

要查的概念	具体入口	页
神经元、前向 Forward	形状与加权计算	88
ReLU/Sigmoid、XOR	非线性激活、隐藏表示	89
Softmax 与输出/损失	得分、概率与配对	91
反向传播 Backprop	链式法则和共享贡献	93
Batch/Epoch/Step、SGD	数据遍历与更新	97
Momentum/Adam	历史梯度与更新	99
初始化、梯度消失	激活与尺度	103
Dropout、提前停止	随机掩码、停止规则	104
tanh/ELU/Softplus	激活形状与导数	108
LogSumExp、稳定 CE	直接使用 logits	109
RMSprop、AdamW	自适应更新与权重衰减	110
梯度裁剪 Clipping	范数、方向与边界	111
卷积、池化、感受野	局部窗口与共享参数	114
残差、BN/LN	相加支路、统计轴	118
TF-IDF、嵌入 Embedding	从符号到表示	122
RNN、LSTM、GRU	状态与门控	125
Q/K/V、Attention	查询与加权汇总	127
Causal/Padding Mask	可见信息约束	128
Transformer、Teacher Forcing	块结构与训练目标	130
冻结、微调 Fine-tuning	参数更新与运行模式	133
矩阵、SVD、梯度	形状与运算	134
贝叶斯、期望、分布	概率方向与统计量	138

记住：缩写相同不代表定义相同；遇到接口差异，检查标签编码、轴次序、归约、平滑与默认模式。

参考资料与继续阅读

本书以小例子解释机制，公式与算法的系统推导可从以下教材继续学习。文档中的接口默认值可能随版本变化，实际复现实验时应记录软件版本。章节末尾给出相应主题的阅读入口；这里汇总主要来源，不把独立新图当作原书或原卡片的复制品。

教材与公开教学材料

1. James, Witten, Hastie, Tibshirani. *An Introduction to Statistical Learning*, 2nd ed., 2021. 教材网站。经典模型、模型评估与无监督方法。

2. Goodfellow, Bengio, Courville. *Deep Learning*, 2016. 公开教材。前馈网络、正则化、优化、卷积与序列模型。

3. Deisenroth, Faisal, Ong. *Mathematics for Machine Learning*, 2020. 公开教材。线性代数、概率、优化与 PCA。

4. Zhang, Lipton, Li, Smola. *Dive into Deep Learning*（《动手学深度学习》）. 英文在线版, 中文在线版。计算图、架构与微调。

5. Manning, Raghavan, Schütze. *Introduction to Information Retrieval*, 2008. 公开教材。文本表示与 TF-IDF。

6. Little, Rubin. *Statistical Analysis with Missing Data*, 3rd ed., 2019. 缺失机制与分析条件。

实现约定与接口

1. scikit-learn User Guide：预处理、流水线、模型选择、指标、校准、聚类与分解。

2. imbalanced-learn Documentation：训练内重采样、Tomek 链接与验证边界。

3. PyTorch Documentation：张量、损失、卷积、归一化、优化器与梯度裁剪。

4. PyTorch Transfer Learning Tutorial：冻结、微调与训练模式。

代表性原始论文

下列论文用于沿着正文中的方法继续查阅；研究论文通常比本书要求更高的数学或实现背景。

1. Hochreiter, Schmidhuber. *Long Short-Term Memory.* Neural Computation, 1997. DOI。
2. Cho 等. *Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation*, 2014. 论文。
3. Mikolov 等. *Efficient Estimation of Word Representations in Vector Space*, 2013. 论文。
4. Srivastava 等. *Dropout: A Simple Way to Prevent Neural Networks from Overfitting.* JMLR, 2014. 论文。
5. Kingma, Ba. *Adam: A Method for Stochastic Optimization.* ICLR, 2015. 预印本（2014）。
6. He 等. *Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification.* ICCV, 2015. 论文。
7. He 等. *Deep Residual Learning for Image Recognition.* CVPR, 2016. 论文。
8. Vaswani 等. *Attention Is All You Need.* NeurIPS, 2017. 论文。
9. Loshchilov, Hutter. *Decoupled Weight Decay Regularization.* ICLR, 2019. 预印本。
10. Bergstra, Bengio. *Random Search for Hyper-Parameter Optimization.* JMLR, 2012. 论文。
11. Ester 等. *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise.* KDD, 1996. 论文。
12. Wilson. *Probable Inference, the Law of Succession, and Statistical Inference.* JASA, 1927. Wilson 比例区间的原始工作；本书给出的区间为近似推断。